MATERIAL DE APOIO · CURSO DE 2 HORAS

IA nas Engenharias

Uma introdução prática com Python e Google Colab: Civil, Produção, Elétrica, Mecânica e Química



Dra. Patricia Pedroso Estevam Ribeiro

Minicurso para graduação em Engenharia

Sumário

1. Apresentação do curso 3
2. Python e Colab em 5 minutos 4
3. Conceitos fundamentais 7
4. Algoritmos e avaliação 12
5. Bloco 1 · Engenharia Civil: resistência do concreto 34
6. Bloco 2 · Engenharia de Produção: qualidade na linha 42
7. Bloco 3 · Engenharia Elétrica: motores, perfis e anomalias 49
8. Bloco 4 · Engenharia Mecânica: diagnóstico de rolamentos 61
9. Bloco 5 · Engenharia Química: concentração por espectros 67
10. Quadro-resumo: a técnica certa para cada pergunta 73
11. Cuidados na prática 74
12. Guia da prática no Colab 75
13. Bônus A · Imagens: folhas e Teachable Machine 77
14. Bônus B · Do modelo à ação: n8n e outras ferramentas 81
15. Glossário 83
16. Perguntas de revisão 85
17. Referências e materiais 87
18. Bônus C · Redes neurais e Deep Learning (extra) 88

1. Apresentação do curso

Este material acompanha o curso **IA nas Engenharias**, com duração de duas horas: conceitos e prática no Google Colab, em cinco blocos, um para cada engenharia (Civil, Produção, Elétrica, Mecânica e Química). Ele reúne a explicação dos temas, o guia do notebook e atividades de revisão, para que você possa estudar no seu ritmo depois da aula.

A ideia central é simples: **toda engenharia gera dados** (ensaios, sensores, processos) e a inteligência artificial ajuda a transformar esses dados em decisão. O dado muda de uma engenharia para outra, mas o método se repete: definir a pergunta, preparar os dados, separar treino e teste, treinar, medir e decidir com responsabilidade.

Objetivos de aprendizagem

1. Diferenciar aprendizado supervisionado (regressão e classificação) de não supervisionado (agrupamento e detecção de anomalias).
2. Executar o fluxo básico de um projeto: dados, visualização, separação treino/teste, métrica e decisão.
3. Escolher métricas adequadas (MAE, R^2; acurácia, precisão, sensibilidade, especificidade, matriz de confusão e curva ROC) e reconhecer overfitting e desbalanceamento de classes.
4. Usar o PCA para visualizar e reduzir dimensionalidade, e comparar classificadores (regressão logística, árvore, Random Forest e SVM).
5. Reconhecer onde implementar IA em Engenharia Civil, de Produção, Elétrica, Mecânica e Química.
6. Visualizar os dados antes de modelar (histograma, boxplot, dispersão, mapa de calor, série temporal e PCA).
7. Extras opcionais: classificar imagens de folhas (Bônus A) e conectar um modelo a um fluxo de automação, o n8n (Bônus B).

Como o material está organizado

Parte	O que é	Slides	Colab	Nesta apostila
Exemplos 1 a 5	Os conceitos em motores elétricos: fronteira, árvore e Random Forest, regressão, SVM, overfitting	33 a 44	Parte A	cap. 3 e 4
Bloco 1 a 5	Uma engenharia por bloco (Civil, Produção, Elétrica, Mecânica, Química), com exercícios numerados 1.1, 1.2, …	51 a 60	Blocos 1 a 5	cap. 5 a 9
Bônus A, B e C	Extras: imagens de folhas (Teachable Machine), alerta no n8n e rede neural (Deep Learning, opcional)	27 a 32 (A)	Bônus A, B e C	cap. 13, 14 e 18

Em cada exemplo e exercício, a faixa laranja **NO COLAB** repete o mesmo título que aparece no notebook, com os slides correspondentes.

Pré-requisitos

- Noções de Python (variáveis, listas, funções) e de estatística descritiva (média, desvio padrão, correlação).
- Uma conta Google para abrir o Colab. Nada precisa ser instalado no computador, e todos os dados são simulados dentro do notebook.

2. Python e Colab em 5 minutos

Este capítulo é para quem **nunca programou**. Você não precisa escrever código no curso: precisa **executar** as células, **ler os comentários** e **interpretar os resultados**. Ele corresponde à **seção 0** do notebook.

2.1 Como o Colab funciona

- O notebook é feito de **células**. As de **texto** explicam; as de **código** (com o botão ▶) executam.
- Para executar uma célula, clique nela e aperte **Shift+Enter**. O resultado aparece **logo abaixo**.
- O código roda em um computador do Google, na nuvem: nada é instalado no seu computador.
- Tudo que começa com `#` é **comentário**: o Python ignora, é explicação para você.
- Execute as células **de cima para baixo**. Se aparecer `name '...' is not defined`, execute as células anteriores (*Ambiente de execução › Executar tudo*).

2.2 As cinco ideias de Python que aparecem no curso

Ideia	Exemplo	Para que serve
Variável	`idade = 28`	guardar um valor com um nome
Lista / vetor	`idades = [3, 7, 28]`	guardar vários valores
Função	`np.mean(idades)`	uma "máquina" que recebe dados e devolve um resultado
Tabela (DataFrame)	`pd.DataFrame(...)`	dados em linhas (amostras) e colunas (variáveis)
Gráfico	`plt.plot(...)`, `plt.show()`	desenhar os dados

Exemplo mínimo do notebook (seção 0.1). Execute e veja o resultado; ainda não é machine learning:

```
# Exemplo mínimo: execute e veja o resultado. Nada aqui é "machine learning" ainda.
import numpy as np                # numpy: contas com vetores e números
import pandas as pd               # pandas: tabelas de dados
import matplotlib.pyplot as plt   # matplotlib: gráficos

idades = [3, 7, 28]               # 1) uma lista com as idades do concreto (dias)
resistencia = [14.0, 22.5, 32.5]  # 2) uma lista com a resistência medida (MPa)

media = np.mean(resistencia)      # 3) função do numpy: calcula a média da lista
print("Resistência média: %.1f MPa" % media)   # 4) print escreve o resultado na tela

# 5) monta uma tabela
tabela = pd.DataFrame({"idade_dias": idades, "resistencia_MPa": resistencia})
print(tabela)                     # cada linha é uma amostra; cada coluna é uma variável

# 6) gráfico: x = idade, y = resistência
plt.plot(tabela["idade_dias"], tabela["resistencia_MPa"], "o-")
plt.xlabel("idade (dias)"); plt.ylabel("resistência (MPa)")       # nomes dos eixos
plt.title("Quanto mais velho, mais resistente"); plt.show()       # título e exibição
```

Saída

```
Resistência média: 23.0 MPa
   idade_dias  resistencia_MPa
0           3             14.0
1           7             22.5
2          28             32.5
```

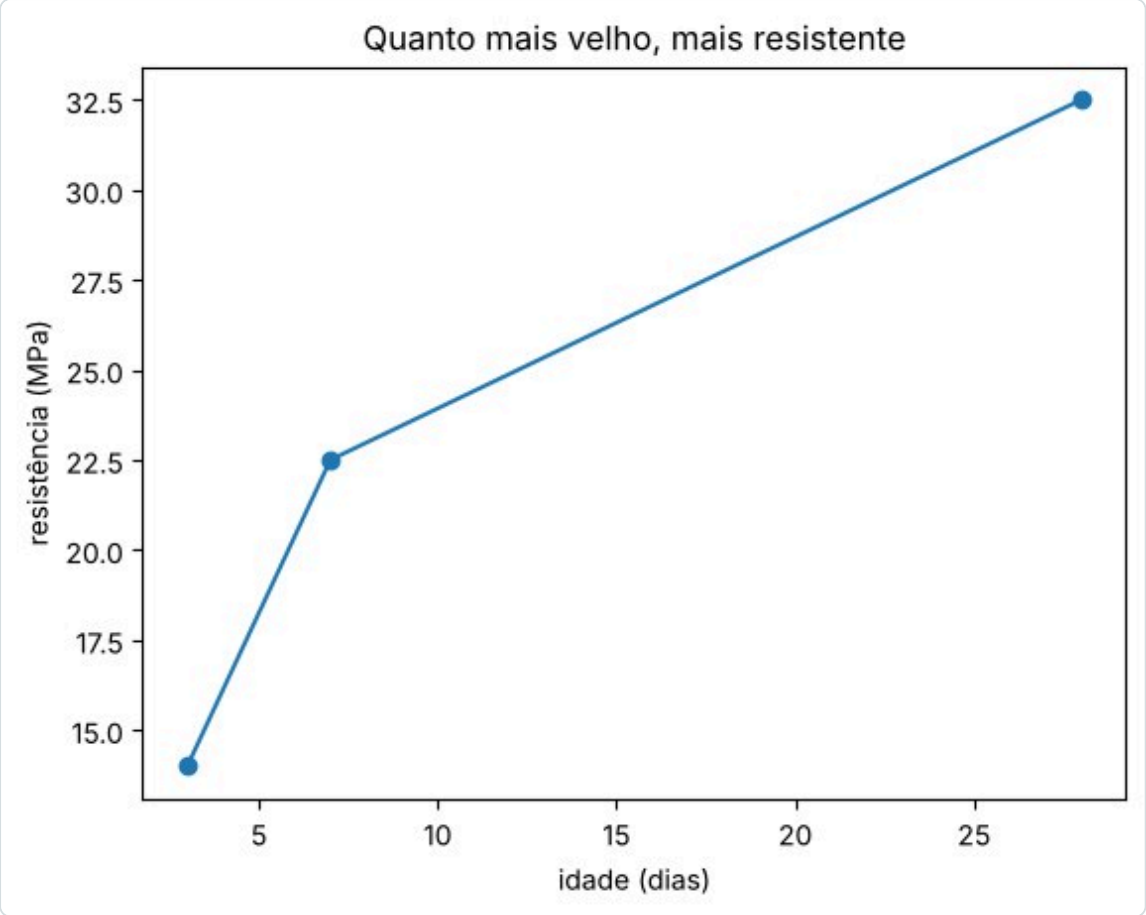


Gráfico gerado pela célula acima no Colab

2.3 A receita que se repete em todo exercício

1 Dados	2 Treino e teste	3 Modelo	4 Treinar	5 Prever	6 Medir
X (entradas) e, se houver, y (o que prever).	`train_test_split`	por exemplo `LinearRegression()`	`modelo.fit(X_treino, y_treino)`	`modelo.predict(X_teste)`	MAE, acurácia, sensibilidade...

2.4 Bibliotecas e instalação

Uma **biblioteca** é um conjunto de funções prontas. Usamos **numpy** (números e sorteios), **pandas** (tabelas), **matplotlib** e **seaborn** (gráficos), **scikit-learn** (os modelos e as métricas) e **scipy** (o dendrograma). **No Colab nada precisa ser instalado**: elas já vêm prontas. A célula 0.2 do notebook é opcional e só serve para quem roda fora do Colab (Jupyter ou VS Code no próprio computador).

A célula 0.3 carrega as bibliotecas e define as cores e duas funções de apoio. Cada linha tem comentário:

```
# ---------- Bibliotecas básicas ----------
import numpy as np                      # contas e números aleatórios
import pandas as pd                     # tabelas (DataFrame)
import matplotlib.pyplot as plt         # gráficos
import seaborn as sns                   # gráficos estatísticos mais bonitos

# ---------- Ferramentas do scikit-learn (os "modelos") ----------
# separar treino/teste e validação cruzada
from sklearn.model_selection import train_test_split, cross_val_score, StratifiedKFold
# padronizar variáveis; criar termos polinomiais
from sklearn.preprocessing import StandardScaler, PolynomialFeatures
```

```
# encadear etapas (ex.: padronizar e depois modelar)
from sklearn.pipeline import make_pipeline
from sklearn.linear_model import LinearRegression, LogisticRegression   # modelos lineares
# florestas de árvores
from sklearn.ensemble import RandomForestRegressor, RandomForestClassifier, IsolationForest
# árvore de decisão
from sklearn.tree import DecisionTreeClassifier, export_text, plot_tree
# SVM (máquina de vetores de suporte)
from sklearn.svm import SVC
from sklearn.cluster import KMeans                                      # agrupamento k-means
# análise de componentes principais
from sklearn.decomposition import PCA
from sklearn.metrics import (mean_absolute_error, r2_score, accuracy_score, recall_score,
                             precision_score, f1_score, confusion_matrix, ConfusionMatrixDisplay,
                             # métricas
                             adjusted_rand_score, silhouette_score, roc_curve, roc_auc_score)
from scipy.cluster.hierarchy import linkage, dendrogram                 # agrupamento hierárquico

# ---------- Configurações ----------
# "semente" do sorteio: com ela fixa, todos obtêm os mesmos resultados
SEED = 42
np.random.seed(SEED)
sns.set_theme(style="whitegrid", context="notebook")    # estilo dos gráficos
plt.rcParams["figure.dpi"] = 100                        # resolução dos gráficos
TEAL, ORANGE, NAVY, RED = "#1F8A8A", "#F2A93B", "#0F2B3D", "#E4572E"   # cores usadas nos gráficos

# ---------- Funções de apoio (definidas aqui para usar várias vezes) ----------
def limpa(ax):
    """Remove as bordas de cima e da direita de um gráfico (visual mais limpo)."""
    for s in ("top", "right"):
        ax.spines[s].set_visible(False)

def matriz(y_real, y_prev, ax, rotulos, nomes=None, cmap="Blues", titulo=None):
    """Desenha a matriz de confusão (linhas = real, colunas = previsto)."""
    ConfusionMatrixDisplay.from_predictions(y_real, y_prev, labels=rotulos, display_labels=nomes or
rotulos,
                                            cmap=cmap, colorbar=False, ax=ax)
    ax.set_xlabel("previsto"); ax.set_ylabel("real"); ax.grid(False)
    if titulo:
        ax.set_title(titulo)

print("Ambiente pronto!")
```

3. Conceitos fundamentais

3.1 IA, Machine Learning e Deep Learning

Os termos não são sinônimos. **Inteligência Artificial** é o campo amplo: sistemas que simulam capacidades humanas como raciocinar, aprender e decidir. **Machine Learning** (aprendizado de máquina) é o subconjunto em que o modelo **aprende com exemplos** em vez de seguir regras escritas à mão. **Deep Learning** usa redes neurais com muitas camadas e domina imagens, áudio e texto. Neste curso o foco é o ML clássico, implementado com a biblioteca scikit-learn, que funciona bem com dados tabulares de sensores e ensaios e roda em um computador comum. Uma introdução opcional às redes neurais está no **Bônus C**, no final desta apostila (capítulo 18).

3.2 Tipos de aprendizado

Tipo	Característica	Exemplos nas engenharias
Supervisionado	Aprende com exemplos que têm a resposta (rótulo ou valor). **Regressão** prevê um número; **classificação** prevê uma categoria.	Resistência do concreto (Civil); peça boa ou defeituosa (Produção); condição do rolamento (Mecânica)
Não supervisionado	Não há resposta pronta. O algoritmo procura estrutura: grupos (agrupamento), padrões e observações atípicas (anomalias).	Regimes de operação e anomalias em motores (Elétrica)
Por reforço	Um agente aprende por tentativa e recompensa ao interagir com um ambiente.	Controle de robôs e de processos (fora do escopo do curso)

3.3 O fluxo de um projeto de ML

1 Problema
Que decisão queremos apoiar? Qual o custo de errar?

2 Dados
Sensores, ensaios e históricos disponíveis.

3 Exploração
Gráficos, faltantes, outliers e correlações.

4 Modelo
Escolher e treinar um algoritmo.

5 Avaliação
Medir em dados nunca vistos.

6 Ação
Implantar, monitorar e retreinar.

A maior parte do tempo costuma ir para as etapas 2 e 3. Um algoritmo sofisticado não compensa dados ruins.

3.4 Os dados: variáveis de entrada e alvo

Cada linha da tabela é uma observação (uma amostra de concreto, uma peça, uma leitura de motor). As colunas de entrada são as **variáveis explicativas** ou *features* (**X**); a coluna que queremos prever é o **alvo** ou *target* (**y**). Na regressão o alvo é um número; na classificação, uma categoria; no aprendizado não supervisionado, não há alvo.

3.5 Aprendizado supervisionado em três etapas

A palestra mostra a ideia com **imagens de folhas**: (1) o computador recebe **muitos exemplos rotulados** (“esta folha tem sinais de greening”, “esta pertence a outra classe”), como estudar questões com o gabarito; (2) o algoritmo procura **padrões**, que em imagens envolvem textura, distribuição de cores, formato e manchas (ele não “entende” a folha como uma pessoa, aprende relações estatísticas); (3) uma **nova imagem** (teste) é comparada com o que foi aprendido e o modelo devolve uma estimativa, que é uma **pista para investigar** e não substitui a confirmação especializada.

O mesmo raciocínio vale para sensores. No exemplo dos motores da figura abaixo, cada ponto é um motor com vibração e temperatura já classificado como normal ou com falha; o modelo aprende uma fronteira e, com ela, atribui uma probabilidade de falha a uma **máquina nova** (aqui, cerca de 64%).

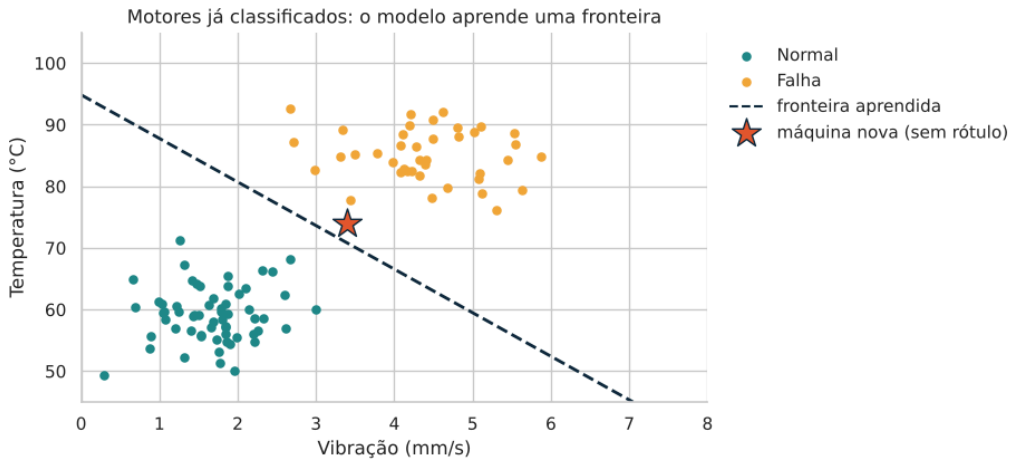


Figura 1. Motores já classificados: o modelo aprende uma fronteira e usa essa fronteira para uma máquina nova, sem rótulo.

NO COLAB · EXEMPLO 1 · APRENDIZADO SUPERVISIONADO: APRENDER UMA FRONTEIRA	
Problema	Classificar um motor como **normal** ou **com falha** a partir de vibração e temperatura, e dizer a probabilidade de falha de uma **máquina nova**.
Dados	100 motores simulados já classificados (60 normais e 40 com falha), com vibração (mm/s) e temperatura (°C).
Modelo / técnica	**Regressão logística** (estima a probabilidade de falha com uma curva em S; a fronteira é uma reta).
Como medimos	Probabilidade de falha da máquina nova (0 a 100%).
O que observar	A linha tracejada é a fronteira aprendida. A estrela fica perto dela: o modelo não tem certeza (cerca de 64% de falha).
Nos slides	33 e 34

```
# --- 1) Criar os dados (simulados) ---
# gerador de números aleatórios (semente 7)
rng = np.random.default_rng(7)
# vibração: 60 normais (média 1,8) + 40 com falha (média 4,5)
vib = np.r_[rng.normal(1.8, 0.6, 60), rng.normal(4.5, 0.9, 40)]
# temperatura: normais ~60 °C, com falha ~85 °C
temp = np.r_[rng.normal(60, 5, 60), rng.normal(85, 5, 40)]
rotulo = np.r_[np.zeros(60), np.ones(40)]                          # rótulo: 0 = normal, 1 = falha

# --- 2) Treinar o modelo ---
# junta as duas variáveis em uma tabela X
X = np.c_[vib, temp]
# padroniza as variáveis e aplica a regressão logística
modelo = make_pipeline(StandardScaler(), LogisticRegression())
# TREINAR: o modelo aprende a fronteira com os exemplos
modelo.fit(X, rotulo)

# --- 3) Usar o modelo em uma máquina nova (sem rótulo) ---
# vibração 3,4 mm/s e temperatura 74 °C
nova = np.array([[3.4, 74.0]])
# probabilidade de ser da classe 1 (falha)
p_falha = modelo.predict_proba(nova)[0, 1]
print("Probabilidade de falha da máquina nova: %.0f%%" % (100 * p_falha))

# --- 2b) Olhar o que o modelo aprendeu: α (intercepto) e β (pesos) da regressão logística ---
# o passo final do pipeline: a regressão logística
lr = modelo[-1]
print("\nlog-odds de falha = α + β1·vibração + β2·temperatura   (variáveis padronizadas)")
```

```
print("α = %.2f | β (vibração) = %.2f | β (temperatura) = %.2f" % (lr.intercept_[0], lr.coef_[0][0],
lr.coef_[0][1]))
print("β > 0: quanto maior a variável, maior a chance de falha.")
# desvio-padrão de cada variável (a padronização divide por ele)
dp = modelo[0].scale_
b = lr.coef_[0]                                                  # os dois pesos β
print("\nComo ler os pesos (β):")
print("  Vibração:    +1 desvio-padrão (%.1f mm/s) aumenta o log-odds de falha em %.2f  -> chances (odds)
x %.1f" % (dp[0], b[0], np.exp(b[0])))
print("  Temperatura: +1 desvio-padrão (%.1f °C) aumenta o log-odds de falha em %.2f  -> chances (odds) x
%.1f" % (dp[1], b[1], np.exp(b[1])))
print("  A variável de maior peso é a %s (%.2f contra %.2f): ela puxa mais a decisão do modelo." % (
      "temperatura" if b[1] > b[0] else "vibração", max(b), min(b)))
print("  α = %.2f é o log-odds de uma máquina na média das duas variáveis (probabilidade %.0f%%)." %
(lr.intercept_[0], 100 / (1 + np.exp(-lr.intercept_[0]))))

# --- 2c) Avaliar com dados que o modelo não viu: separa 70% treino e 30% teste só para MEDIR ---
X_a, X_b, y_a, y_b = train_test_split(X, rotulo, test_size=0.3, stratify=rotulo, random_state=SEED)
m_av = make_pipeline(StandardScaler(), LogisticRegression()).fit(X_a, y_a)
# classe prevista (0 = normal, 1 = falha) no teste
pred_b = m_av.predict(X_b)
vn_, fp_, fn_, vp_ = confusion_matrix(y_b, pred_b).ravel()
print("\nNo teste (%d motores): acurácia = %.2f | precisão = %.2f | sensibilidade = %.2f | F1 = %.2f" % (
      len(y_b), accuracy_score(y_b, pred_b), precision_score(y_b, pred_b), recall_score(y_b, pred_b),
f1_score(y_b, pred_b)))
print("Matriz de confusão: VN = %d (normal certo) | FP = %d | FN = %d | VP = %d (falha certa)" % (vn_,
fp_, fn_, vp_))

# --- 4) Desenhar: pontos, fronteira e a máquina nova ---
# grade de pontos para colorir o plano
xx, yy = np.meshgrid(np.linspace(0, 8, 300), np.linspace(45, 105, 300))
# probabilidade em cada ponto da grade
zz = modelo.predict_proba(np.c_[xx.ravel(), yy.ravel()])[:, 1].reshape(xx.shape)
fig, ax = plt.subplots(figsize=(9.4, 4.4))
# motores normais
ax.scatter(vib[rotulo == 0], temp[rotulo == 0], color=TEAL, s=26, label="Normal")
# motores com falha
ax.scatter(vib[rotulo == 1], temp[rotulo == 1], color=ORANGE, s=26, label="Falha")
# fronteira: onde a probabilidade é 50%
ax.contour(xx, yy, zz, levels=[0.5], colors=NAVY, linestyles="--", linewidths=2)
# entrada da legenda
ax.plot([], [], "--", color=NAVY, label="fronteira aprendida")
ax.scatter(*nova[0], marker="*", s=380, color=RED, edgecolor=NAVY, zorder=5, label="máquina nova (sem
rótulo)")
# legenda fora do gráfico
ax.set_xlabel("Vibração (mm/s)"); ax.set_ylabel("Temperatura (°C)"); ax.legend(frameon=False, loc="upper
left", bbox_to_anchor=(1.01, 1)); limpa(ax)
ax.set_title("Motores já classificados: o modelo aprende uma fronteira"); plt.tight_layout(); plt.show()
```

Saída

```
Probabilidade de falha da máquina nova: 64%

log-odds de falha = α + β1·vibração + β2·temperatura   (variáveis padronizadas)
α = -1.01 | β (vibração) = 1.83 | β (temperatura) = 2.35
β > 0: quanto maior a variável, maior a chance de falha.

Como ler os pesos (β):
  Vibração:    +1 desvio-padrão (1.5 mm/s) aumenta o log-odds de falha em 1.83  -> chances (odds)
x 6.2
  Temperatura: +1 desvio-padrão (13.4 °C) aumenta o log-odds de falha em 2.35  -> chances (odds)
x 10.5
  A variável de maior peso é a temperatura (2.35 contra 1.83): ela puxa mais a decisão do modelo.
  α = -1.01 é o log-odds de uma máquina na média das duas variáveis (probabilidade 27%).

No teste (30 motores): acurácia = 1.00 | precisão = 1.00 | sensibilidade = 1.00 | F1 = 1.00
Matriz de confusão: VN = 18 (normal certo) | FP = 0 | FN = 0 | VP = 12 (falha certa)
```

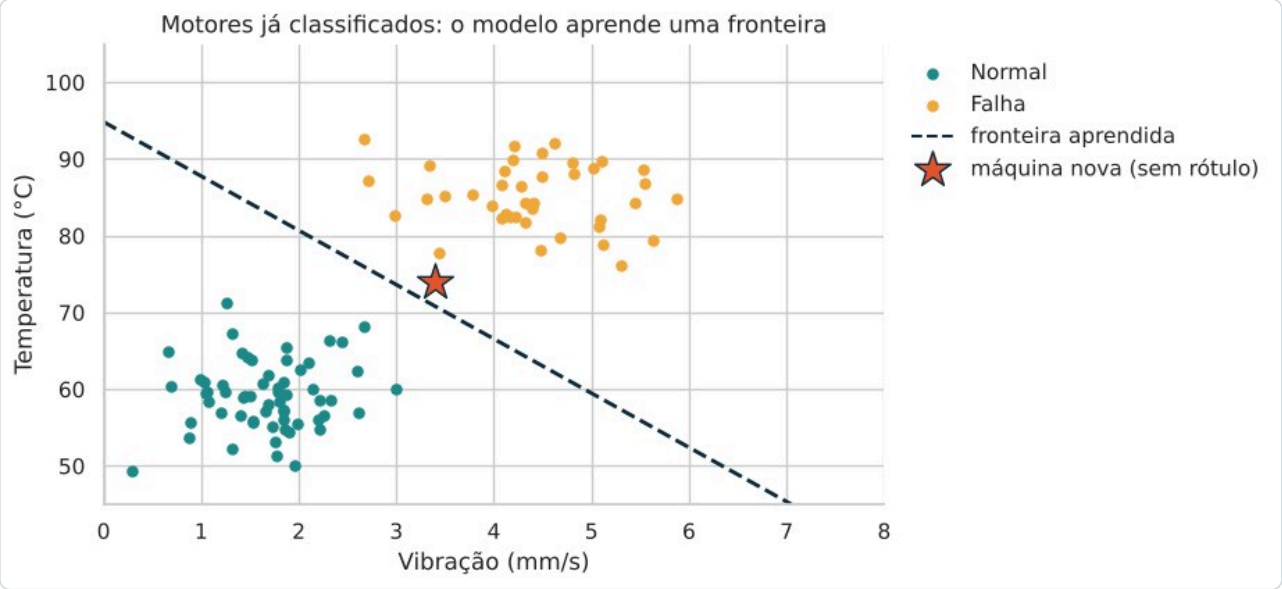


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(leia antes das perguntas)

- **O que cada ponto é:** um motor já inspecionado. **Eixo horizontal:** vibração (mm/s). **Eixo vertical:** temperatura (°C). **Verde:** motor normal. **Laranja:** motor que falhou.
- **O que os pontos mostram:** os motores com falha têm vibração **e** temperatura mais altas, no canto superior direito. Os normais ficam no canto inferior esquerdo. Quando a vibração sobe, a temperatura também sobe, o que faz sentido para um motor com defeito.
- **O que a reta tracejada é:** a **fronteira de decisão**, não uma tendência dos dados. Ela precisa passar entre os dois grupos e, como eles estão em diagonal, a fronteira cai de cima à esquerda para baixo à direita. Essa inclinação negativa vem só da posição dos grupos: **a reta não diz que mais temperatura significa menos vibração**.
- **Como ler:** tudo acima e à direita da reta é classificado como **Falha**, e tudo abaixo e à esquerda como **Normal**. A **estrela** (máquina nova, vibração ≈ 3,4 e temperatura ≈ 74 °C) cai um pouco acima da reta, então o modelo diz Falha, mas com pouca folga. Isso bate com a probabilidade de cerca de 64% impressa acima.
- **Os pesos β (impressos acima):** com as variáveis padronizadas, um aumento de **1 desvio-padrão** na vibração soma **1,83** ao log-odds de falha, e na temperatura soma **2,35**. Os dois são positivos (mais vibração ou mais temperatura, mais chance de falha) e a **temperatura pesa mais**. Em chances (odds), isso multiplica a chance de falha por cerca de **6** (vibração) e **10** (temperatura).
- **Na engenharia:** o modelo transforma duas leituras de sensor em um número (a probabilidade de falha) que ajuda a decidir se a máquina deve ser inspecionada.

PERGUNTAS

1. Onde está a "aprendizagem"? (os rótulos vieram de especialistas: o modelo só generaliza o que já foi classificado)
2. A máquina nova fica perto da fronteira. O que significa uma probabilidade de falha de cerca de 64%? Você manda inspecionar?

RESPOSTAS COMENTADAS

1. A aprendizagem está em **ajustar α e os β** (pesos) aos exemplos já rotulados, até a fronteira separar bem normais e falhas. O modelo não "entende" o motor: só generaliza o padrão dos rótulos que especialistas deram. **Sem rótulos confiáveis não há aprendizado supervisionado.**

2. Cerca de 64% de falha quer dizer que, entre motores com esses valores, aproximadamente 2 em cada 3 falhariam. É uma zona de **incerteza** (perto da fronteira), não de certeza. Se uma falha inesperada custa muito mais do que uma

inspeção, vale **inspecionar**. O modelo informa o risco; **quem decide é a pessoa**, pelo custo de cada erro.

Sobre a métrica: no teste, as classes aqui são bem separadas, por isso acurácia, precisão e sensibilidade chegam a 1,00. Em dados reais isso quase nunca acontece.

Teachable Machine: o mesmo fluxo sem programar

O **Teachable Machine** (https://teachablemachine.withgoogle.com/) é uma ferramenta educacional do Google que cria e testa modelos direto no navegador, com imagens, sons ou poses. Você cria classes, envia exemplos, clica em treinar e testa com uma nova imagem: são exatamente as três etapas acima. A atividade completa está no **Bônus A**.

4. Algoritmos e avaliação

4.1 Regressão

O que é. Regressão é uma técnica de **aprendizado supervisionado** usada para **prever um valor numérico contínuo**: a resistência de um concreto (MPa), a temperatura de um motor (°C), a concentração de uma substância (%). "Supervisionado" quer dizer que o modelo aprende a partir de um **histórico em que a resposta correta já é conhecida**. Existem vários tipos de regressão (linear, polinomial, árvores, Random Forest, redes neurais), todos com o mesmo objetivo: transformar as variáveis de entrada (**X**) em uma previsão numérica (**y**).

Como o modelo sabe se está acertando. Para cada exemplo do histórico, a máquina calcula a diferença entre o valor que ela previu e o valor real. Essa diferença é o **erro** (ou **resíduo**). O grande objetivo do algoritmo é **ajustar seus parâmetros matemáticos** para que o erro total seja o menor possível. Esse ajuste é o **treino**.

Exemplo básico: a regressão linear

A regressão linear traça a **melhor reta** que passa entre os pontos. Com uma variável ela tem a forma **y = α + β · x**. No Exemplo 3 do curso, queremos prever a **temperatura do motor** (y) a partir da **corrente** (x), e o treino encontrou:

$$\text{temperatura} = 38{,}68 + 4{,}66 \times \text{corrente}$$

O **α** (38,68 °C) é onde a reta cruza o eixo vertical, o ponto de partida da conta. O **β** (4,66 °C por ampère) é a **inclinação**: cada 1 A a mais de corrente soma, em média, 4,66 °C à temperatura. Para uma corrente de 10 A, a previsão é 38,68 + 4,66 × 10 = **85,3 °C**; se o motor realmente estivesse a 88 °C, o erro (resíduo) seria de 2,7 °C. Treinar é escolher o α e o β que deixam a soma de todos esses erros a menor possível.

Com várias variáveis, temos a **regressão linear múltipla**, com um β para cada uma, como no concreto: **resistência = α + β1·cimento + β2·água + β3·aditivo + β4·idade**. Cada β diz quanto a resistência muda quando aquela variável sobe 1 unidade e as outras ficam fixas. Isso torna o modelo **fácil de interpretar**, mas ele só sabe desenhar **retas**.

Outro tipo: Random Forest para regressão

Uma **árvore de decisão** faz perguntas de sim ou não ("a corrente é maior que 12 A?") e termina em um valor. O **Random Forest** (floresta aleatória) treina centenas de árvores, cada uma com uma amostra diferente dos dados, e a previsão final é a **média** das previsões das árvores. Ele acompanha **curvas e degraus**, mas não extrapola além do que viu e é mais difícil de explicar que a reta.

Como medir o erro: MAE, RMSE e R^2

Para entender as três métricas, veja um exemplo de três peças de concreto. A resistência real foi **40, 50 e 60 MPa** e o modelo previu **42, 47 e 66 MPa**; os erros foram **+2, −3 e +6**.

Métrica	O que calcula	No exemplo das três peças	Como interpretar
MAE (erro médio absoluto)	Média dos erros, ignorando o sinal: média de | real − previsto |	(2 + 3 + 6) ÷ 3 = **3,67 MPa**	Erro típico, na mesma unidade do alvo. Menor é melhor.
RMSE (raiz do erro quadrático médio)	Eleva cada erro ao quadrado, tira a média e a raiz	√((4 + 9 + 36) ÷ 3) = **4,04 MPa**	Parecido com o MAE, mas **castiga mais os erros grandes** (o erro de 6 pesou mais). Se for bem maior que o MAE, há erros grandes isolados.
R^2 (coeficiente de determinação)	1 − (erro do modelo ÷ erro de prever sempre a média)	A média real é 50: erro da média = 200, erro do modelo = 49, logo R^2 = 1 − 49 ÷ 200 = **0,76**	Fração da variação dos dados que o modelo explica. 1 = perfeito; 0 = não é melhor que prever sempre a média; negativo = pior que a média.

Linear x Random Forest em um exemplo simples

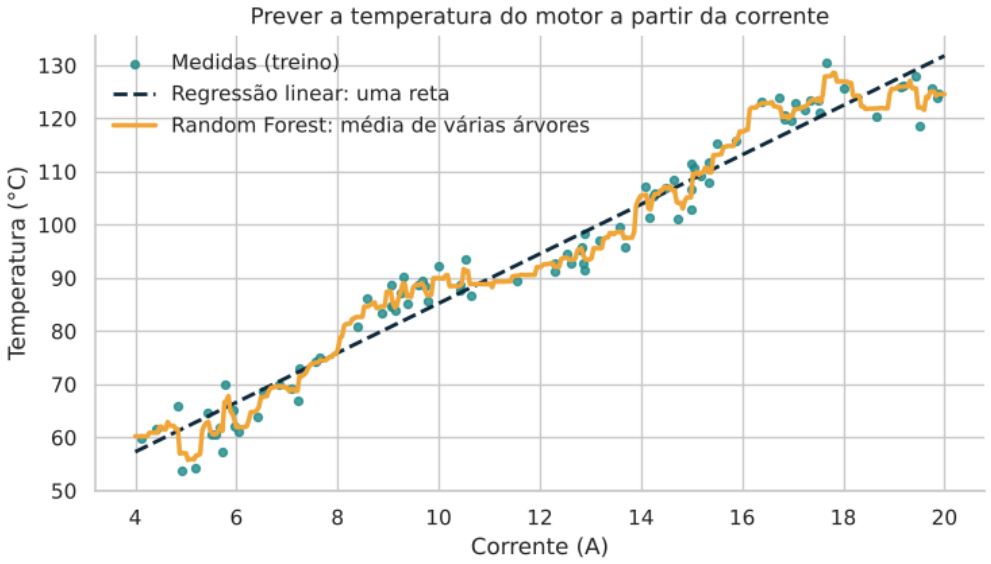


Figura 2. Prever a temperatura do motor a partir da corrente: a reta é simples; a floresta acompanha curvas e degraus (erro médio no teste de 2,96 °C para a reta contra 2,34 °C para a floresta; α = 38,68 °C e β = 4,66 °C por ampère).

NO COLAB · EXEMPLO 3 · REGRESSÃO: PREVER UM NÚMERO	
Problema	Prever a **temperatura do motor** a partir da **corrente** elétrica.
Dados	150 motores simulados (corrente de 4 a 20 A); a temperatura cresce com a corrente, com pequenas curvas e ruído.
Modelo / técnica	**Regressão linear** (uma reta) x **Random Forest** (média de árvores, acompanha curvas e degraus).
Como medimos	MAE: erro médio em °C no teste (quanto menor, melhor).
O que observar	A reta é simples e fácil de explicar; a floresta erra menos (cerca de 3,0 contra 2,3 °C).
Nos slides	39

```
# --- 1) Criar os dados ---
rng = np.random.default_rng(67)
n = 150
# corrente (A)
corrente = rng.uniform(4, 20, n)
# temperatura = tendência + curva + ruído (°C)
temp_motor = 40 + 4.6 * corrente + 4 * np.sin(corrente / 1.2) + rng.normal(0, 3, n)
# X precisa ser uma tabela (1 coluna)
Xr = corrente[:, None]

# --- 2) Separar treino e teste ---
Xr_tr, Xr_te, yr_tr, yr_te = train_test_split(Xr, temp_motor, test_size=0.4, random_state=67)

# --- 3) Treinar os dois modelos ---
lin_r = LinearRegression().fit(Xr_tr, yr_tr)                                  # uma reta
rf_r = RandomForestRegressor(n_estimators=100, random_state=67).fit(Xr_tr, yr_tr)   # 100 árvores
print("Reta ajustada: temperatura = α + β × corrente  →  α = %.2f °C | β = %.2f °C por ampère" %
(lin_r.intercept_, lin_r.coef_[0]))
print("(β: cada 1 A a mais de corrente aumenta a temperatura em %.2f °C, em média)\n" % lin_r.coef_[0])

linhas_r = []
for nome_m, mod_m in [("Regressão linear", lin_r), ("Random Forest", rf_r)]:
    pr = mod_m.predict(Xr_te)                                                 # previsões no teste
    linhas_r.append({"Modelo": nome_m,
                     "MAE (°C)": mean_absolute_error(yr_te, pr),              # erro médio absoluto
                     # raiz do erro quadrático médio (pune erros grandes)
                     "RMSE (°C)": np.sqrt(np.mean((yr_te - pr) ** 2)),
                     # fração da variação explicada (1 = perfeito)
                     "R²": r2_score(yr_te, pr)})
display(pd.DataFrame(linhas_r).set_index("Modelo").round(3))

# --- 4) Desenhar ---
# pontos para traçar as curvas dos modelos
g = np.linspace(4, 20, 400)[:, None]
fig, ax = plt.subplots(figsize=(8.5, 4.4))
ax.scatter(Xr_tr, yr_tr, color=TEAL, s=18, alpha=0.8, label="Medidas (treino)")
ax.plot(g, lin_r.predict(g), "--", color=NAVY, lw=2, label="Regressão linear: uma reta")
ax.plot(g, rf_r.predict(g), color=ORANGE, lw=2.5, label="Random Forest: média de várias árvores")
ax.set_xlabel("Corrente (A)"); ax.set_ylabel("Temperatura (°C)"); ax.legend(frameon=False); limpa(ax)
ax.set_title("Prever a temperatura do motor a partir da corrente"); plt.show()
```

Saída

```
Reta ajustada: temperatura = α + β × corrente  →  α = 38.68 °C | β = 4.66 °C por ampère
(β: cada 1 A a mais de corrente aumenta a temperatura em 4.66 °C, em média)


                  MAE (°C)  RMSE (°C)     R²
Modelo
Regressão linear     2.962      3.567  0.977
Random Forest        2.335      3.193  0.982
```

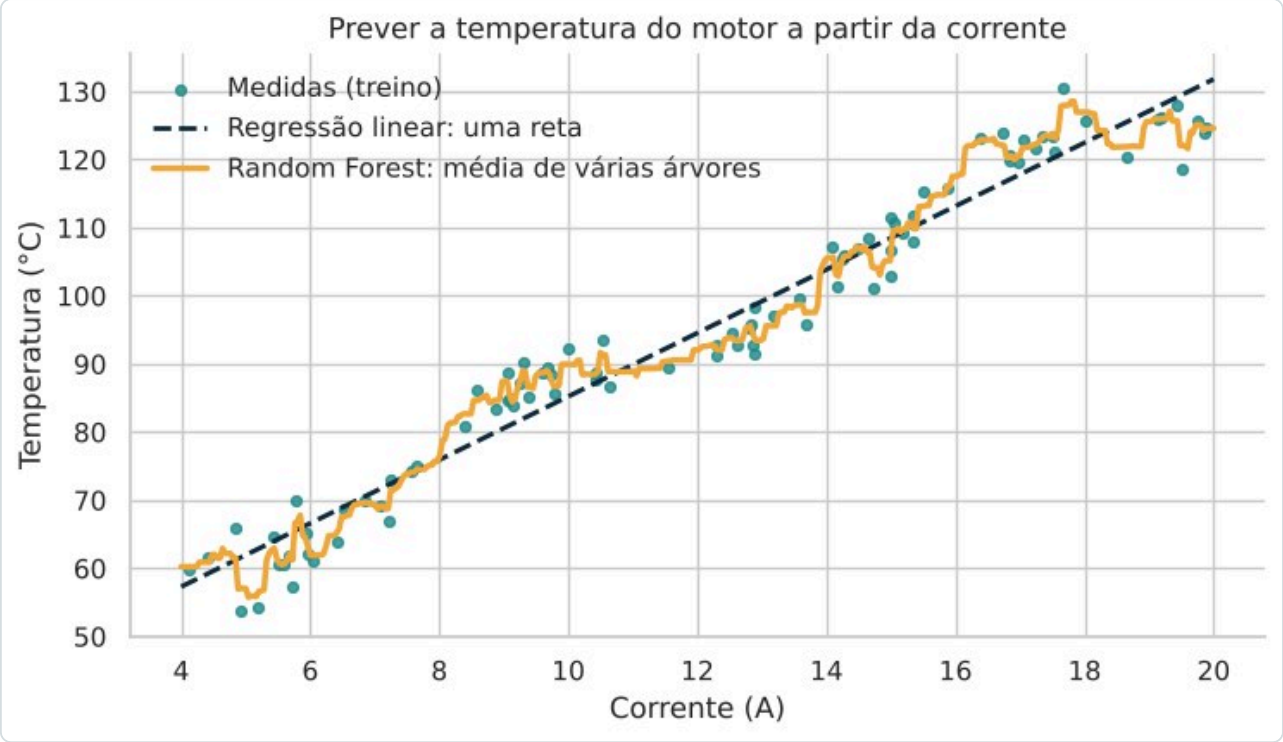


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

- **Eixos:** corrente elétrica do motor (A) na horizontal e temperatura (°C) na vertical. O **alvo** que queremos prever é a **temperatura**; a **entrada** é a **corrente**.
- **Pontos verde-azulados:** as 150 medidas usadas no treino. A nuvem sobe com a corrente, com uma leve curvatura e ruído.
- **Reta tracejada (regressão linear):** a melhor reta. Pela equação, **α = 38,68 °C** (temperatura extrapolada para corrente zero) e **β = 4,66 °C por ampère**. Ela acompanha a tendência geral, mas passa **abaixo** dos pontos entre 8 e 10 A e **acima** deles perto de 20 A, porque a relação não é perfeitamente reta.
- **Linha laranja (Random Forest):** média de várias árvores; acompanha as curvas e os "degraus" dos dados. Nos extremos (4 e 20 A) ela fica **plana**, pois não extrapola além do que viu.
- **Números do teste:** erro médio (MAE) de **2,96 °C** para a reta e **2,34 °C** para a floresta; R^2 de **0,977** contra **0,982**. Os dois são bons; a reta é mais simples de explicar, e a floresta erra um pouco menos.
- **Na engenharia:** estima a temperatura de operação sem precisar de um sensor térmico em cada motor.

PERGUNTAS

1. O que significam o **α** e o **β** da reta? Para que serve o R^2?
2. A floresta teve MAE menor (2,3 contra 3,0 °C), mas o R^2 da reta também é alto (0,98). A reta é ruim?

RESPOSTAS COMENTADAS

1. α (intercepto) é a temperatura prevista quando a corrente é zero (≈ 38,7 °C; serve para posicionar a reta, não precisa ser fisicamente realista). **β** é a **inclinação**: cada 1 A a mais de corrente aumenta a temperatura em ≈ 4,66 °C. O **R^2** diz que fração da variação da temperatura o modelo explica: 0 = o mesmo que prever sempre a média; 1 = perfeito.

2. Não. O R^2 alto mostra que a tendência geral é quase linear, e a reta é **simples e fácil de explicar** (um α e um β). A floresta ganha por seguir as pequenas curvas (MAE e RMSE menores), mas não dá um β para interpretar. Escolher entre elas é equilibrar **erro** e **interpretabilidade**.

Separar treino e teste

Antes de qualquer ajuste, separamos os dados: o **treino** ajusta o modelo e o **teste** o avalia em dados que ele nunca viu. Nos notebooks usamos 25% ou 30% para teste e uma semente fixa (`random_state=42`), para que todos obtenham os mesmos resultados.

4.2 Classificação

O que é. Classificação também é aprendizado supervisionado, mas o alvo é uma **categoria**: peça boa ou defeituosa, motor normal ou com falha, rolamento saudável, com falha na pista externa ou na interna. A partir de exemplos já classificados, o modelo aprende a **fronteira** que separa as classes e depois usa essa fronteira para classificar um caso novo. Muitos classificadores devolvem uma **probabilidade** (por exemplo, 64% de chance de falha); o **limiar de decisão** (em geral 50%) é a probabilidade a partir da qual o alerta dispara. Quatro algoritmos aparecem no curso:

Algoritmo	O que é e como aprende	Exemplo no curso	Pontos fortes e cuidados
Regressão logística	Apesar do nome, **classifica**. Faz uma soma ponderada das variáveis (como a regressão linear) e transforma o resultado em uma **probabilidade entre 0% e 100%** com uma curva em S. A fronteira entre as classes é uma **reta**.	Exemplo 1: motor normal ou com falha pela vibração e temperatura (64% de falha para a máquina nova).	Rápida e fácil de explicar (os β mostram o peso de cada variável). Não separa fronteiras curvas.
Árvore de decisão	Uma sequência de perguntas de sim ou não (“a vibração é maior que 4 mm/s?”, “a temperatura passa de 80 °C?”) que termina em uma classe. Aprende escolhendo, a cada passo, a pergunta que melhor separa as classes.	Exemplo 2 e exercício 2.3: regras que levam a uma peça defeituosa.	Fácil de explicar a um gestor, porque vira regras “se… então…”. Sozinha **decora** o treino e muda muito com pequenas variações dos dados.
Random Forest	Centenas de árvores, cada uma treinada com uma **amostra diferente** dos dados, que **votam**: vale a classe mais votada.	Exemplo 2, exercício 2.2 (peças) e Bônus A (folhas).	Bom desempenho com pouco ajuste e mostra a importância das variáveis. É mais difícil de explicar que uma só árvore.
SVM (máquina de vetores de suporte)	Procura a reta (ou curva) que separa as classes com a **maior folga** possível, a **margem**. Só os pontos mais próximos da fronteira, os **vetores de suporte**, a definem. Com o **kernel RBF**, a fronteira pode ser curva.	Exemplo 4 e exercício 4.3: normal ou com falha; peça boa ou defeituosa; condição do rolamento.	Bom com poucas variáveis e fronteiras curvas. Exige variáveis padronizadas.

Uma árvore sozinha tende a **decorar** o treino. A floresta treina muitas árvores, cada uma com uma **amostra diferente** dos dados, e elas votam. Cada árvore erra de um jeito, mas a média dos votos dá uma fronteira mais estável: no exemplo da figura, a árvore acerta cerca de 82% no teste e o Random Forest cerca de 86%.

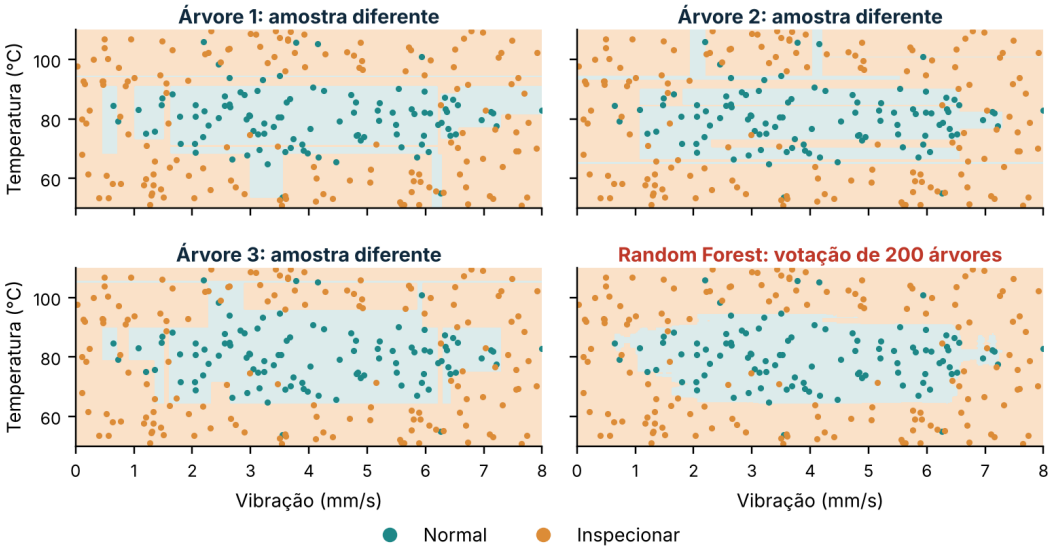


Figura 3. Três árvores treinadas em amostras diferentes (fronteiras recortadas) e a votação de 200 árvores (fronteira mais estável).

NO COLAB · EXEMPLO 2 · ÁRVORE DE DECISÃO E RANDOM FOREST	
Problema	Separar a região de operação **normal** da que precisa de **inspeção**, usando vibração e temperatura.
Dados	400 pontos simulados; a região normal é uma faixa (vibração 1 a 6,5 e temperatura 65 a 92), com 8% de rótulos trocados (ruído).
Modelo / técnica	**Árvore de decisão** (perguntas do tipo "vibração > 6?") x **Random Forest** (200 árvores, cada uma com uma amostra diferente, que votam).
Como medimos	Acurácia no teste (fração de acertos em dados novos).
O que observar	Cada árvore tem fronteiras recortadas e diferentes. A votação da floresta é mais estável e acerta mais (cerca de 82% contra 86%).
Nos slides	35 a 38

```
# --- 1) Criar os dados ---
rng = np.random.default_rng(11)
n = 400                                                    # número de pontos
v = rng.uniform(0, 8, n)                                   # vibração sorteada entre 0 e 8 mm/s
# temperatura sorteada entre 50 e 110 °C
t = rng.uniform(50, 110, n)
# True se o motor está na faixa normal de operação
faixa_ok = (v > 1) & (v < 6.5) & (t > 65) & (t < 92)
# 8% dos rótulos serão trocados (ruído real)
erro_rotulo = rng.random(n) < 0.08
y_c = np.where(faixa_ok ^ erro_rotulo, 0, 1)               # 0 = normal, 1 = inspecionar
# tabela de entrada (vibração, temperatura)
X_c = np.c_[v, t]

# --- 2) Separar treino (60%) e teste (40%) ---
Xa, Xb, ya, yb = train_test_split(X_c, y_c, test_size=0.4, random_state=11)

# --- 3) Treinar e comparar os dois modelos ---
# uma única árvore
arvore_c = DecisionTreeClassifier(random_state=11).fit(Xa, ya)
# 200 árvores que votam
floresta_c = RandomForestClassifier(n_estimators=200, random_state=11).fit(Xa, ya)
met = []
for nome_m, mod_m in [("Árvore de decisão", arvore_c), ("Random Forest", floresta_c)]:
    # classe prevista no teste
    pr = mod_m.predict(Xb)
    met.append({"Modelo": nome_m, "Acurácia": accuracy_score(yb, pr), "Precisão": precision_score(yb,
pr),
                # 4 métricas de classificação
```

```
                "Sensibilidade": recall_score(yb, pr), "F1": f1_score(yb, pr)})
display(pd.DataFrame(met).set_index("Modelo").round(3))
print("Acurácia no teste | árvore: %.1f%% | Random Forest: %.1f%%" % (
      # .score = acurácia
      100 * arvore_c.score(Xb, yb), 100 * floresta_c.score(Xb, yb)))

# --- 4) Desenhar 3 árvores (amostras diferentes) e a floresta ---
xx, yy = np.meshgrid(np.linspace(0, 8, 250), np.linspace(50, 110, 250))
# todos os pontos do plano, para pintar as regiões
grade = np.c_[xx.ravel(), yy.ravel()]
fig, axes = plt.subplots(2, 2, figsize=(12, 7), sharex=True, sharey=True)
rs = np.random.default_rng(0)
for k, ax in enumerate(axes.ravel()):                          # percorre os 4 quadros
    if k < 3:                                                  # quadros 1 a 3: árvores individuais
        # amostra com reposição (cada árvore vê dados diferentes)
        idx = rs.choice(len(Xa), len(Xa), replace=True)
        m = DecisionTreeClassifier(random_state=k).fit(Xa[idx], ya[idx]); titulo = "Árvore %d: amostra
diferente" % (k + 1)
    else:                                                      # quadro 4: a floresta
        m = floresta_c; titulo = "Random Forest: votação de 200 árvores"
    # pinta as regiões
    ax.contourf(xx, yy, m.predict(grade).reshape(xx.shape), levels=[-.5, .5, 1.5], colors=["#DDEFEF",
"#FBE3CC"])
    ax.scatter(Xa[ya == 0, 0], Xa[ya == 0, 1], color=TEAL, s=8)       # pontos normais do treino
    # pontos "inspecionar" do treino
    ax.scatter(Xa[ya == 1, 0], Xa[ya == 1, 1], color=ORANGE, s=8)
    ax.set_title(titulo, color=RED if k == 3 else NAVY, fontweight="bold"); limpa(ax)
for ax in axes[1]: ax.set_xlabel("Vibração (mm/s)")
for ax in axes[:, 0]: ax.set_ylabel("Temperatura (°C)")
plt.tight_layout(); plt.show()
```

Saída

```
                   Acurácia  Precisão  Sensibilidade    F1
Modelo
Árvore de decisão     0.825     0.855          0.887  0.87
Random Forest         0.862     0.868          0.934  0.90
Acurácia no teste | árvore: 82.5% | Random Forest: 86.2%
```

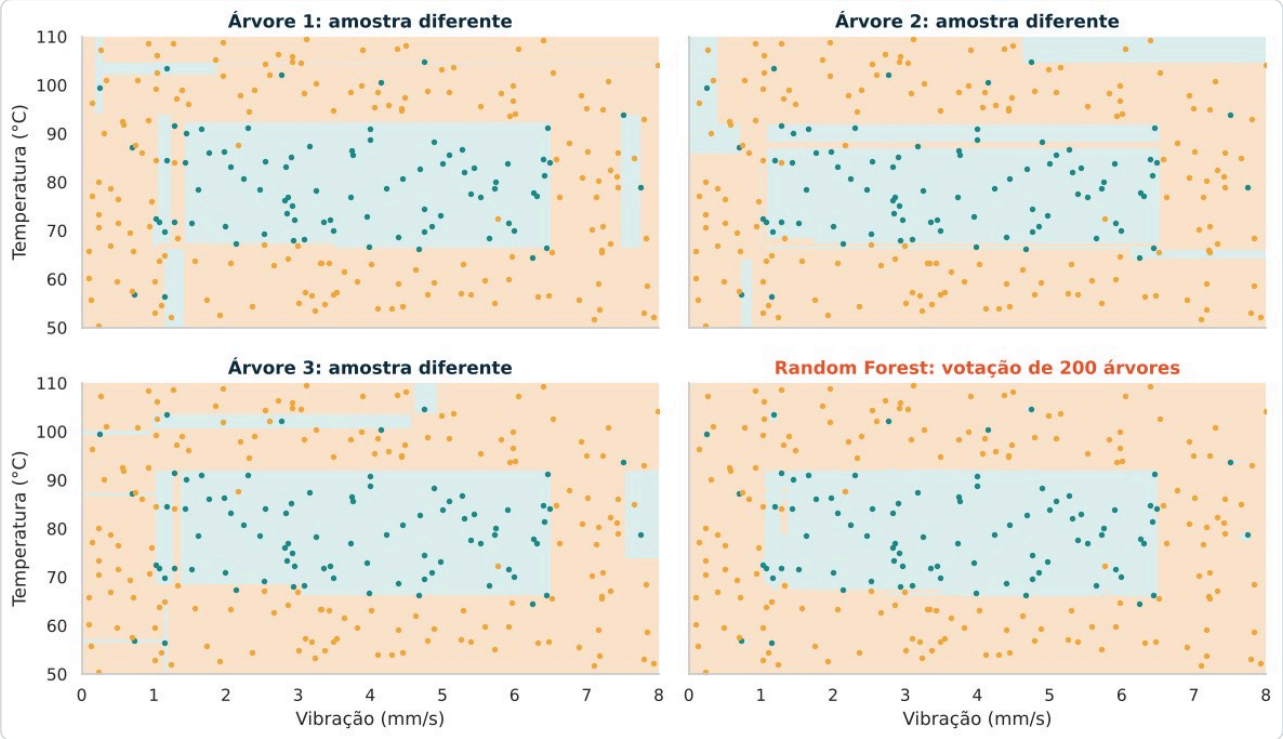


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(os quatro painéis usam os mesmos 400 pontos)

- **Eixos e pontos:** vibração (mm/s) na horizontal, temperatura (°C) na vertical. Cada ponto é uma leitura de motor: **verde** = operação normal, **laranja** = precisa de inspeção. Cerca de 8% dos pontos têm o rótulo trocado de propósito (ruído, como erros de apontamento na vida real).
- **A cor do fundo** é o que o modelo decide para aquela região: **azul-claro** = "normal" e **laranja-claro** = "inspecionar". A região normal verdadeira é um retângulo (vibração de 1 a 6,5 mm/s e temperatura de 65 a 92 °C).
- **Painéis "Árvore 1, 2 e 3":** cada árvore foi treinada com uma amostra diferente e desenha o retângulo de um jeito. Veja as "ilhas" e faixas estranhas: elas aparecem quando a árvore tenta acertar até os pontos com rótulo trocado, ou seja, **decora o ruído** (cada árvore sozinha é instável).
- **Painel "Random Forest":** a votação das 200 árvores apaga as ilhas e deixa só o retângulo limpo, muito perto da região verdadeira. Por isso a acurácia no teste sobe de **82,5%** (uma árvore) para **86,2%** (floresta).
- **Na engenharia:** isso é o mapeamento da **janela de operação segura** de uma máquina a partir de dados históricos. Uma só árvore é frágil; a média de várias é mais estável.

PERGUNTAS

cada árvore erra de um jeito (fronteiras "recortadas"). Por que a **média dos votos** tem uma fronteira mais suave e acerta mais no teste? (a floresta reduz o *overfitting* de uma árvore isolada)

RESPOSTAS COMENTADAS

Cada árvore treina com uma **amostra diferente** e, por isso, **decora o ruído de um jeito diferente** (fronteiras recortadas). Na votação, esses erros individuais não coincidem e se **cancelam em parte**: a fronteira fica mais estável (menor variância) e o desempenho no teste sobe (acurácia de ~82,5% para ~86,2%; sensibilidade de 0,89 para 0,93). O custo é perder a leitura simples "se... então..." de uma única árvore.

O **SVM** procura a fronteira que mais afasta as classes (a **maior margem**); só os pontos mais próximos, os **vetores de suporte** (circulados), definem a fronteira. Quando as classes não se separam por uma reta, o **kernel RBF** cria uma fronteira curva.

Exemplos de engenharia (Exemplo 4): (1) separar **motores normais de motores com falha** a partir da vibração e da temperatura, o caso em que uma reta basta; (2) separar **peças boas de peças defeituosas** a partir da temperatura do molde e da pressão, quando o defeito aparece nos **dois extremos** (muito quente ou muito frio, pressão muito alta ou muito baixa). Aqui a classe boa fica no centro e a defeituosa em volta, e **nenhuma reta** separa as duas: o kernel RBF resolve.

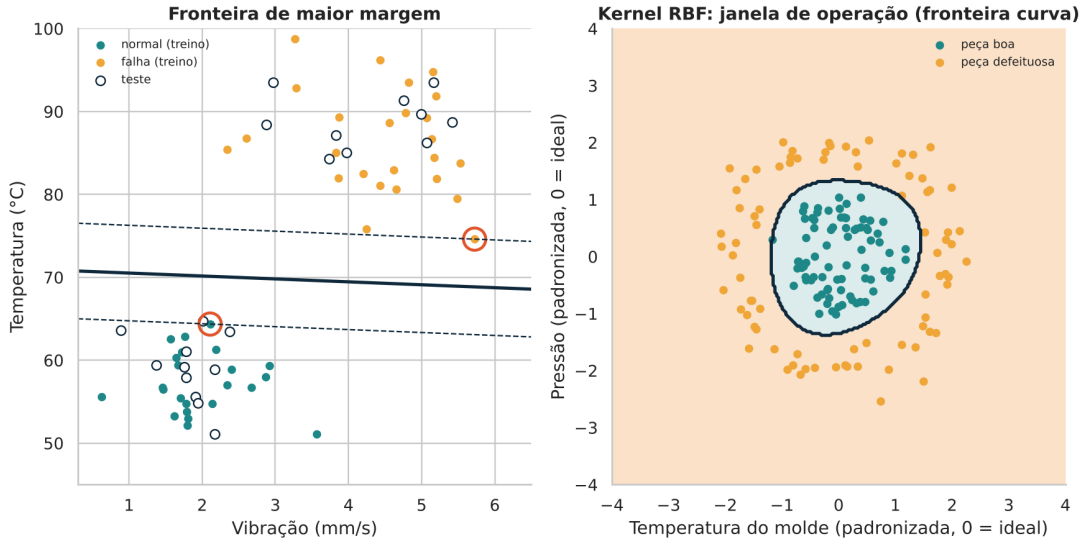


Figura 4. Esquerda: motores normais e com falha separados por uma reta de maior margem (círculos vermelhos = vetores de suporte). Direita: peças boas (centro) e defeituosas (em volta) separadas por uma fronteira curva, com o kernel RBF.

NO COLAB · EXEMPLO 4 · SVM: FRONTEIRA DE MAIOR MARGEM	
Problema	Separar **motores normais de motores com falha** (vibração e temperatura) e **peças boas de peças defeituosas** (temperatura do molde e pressão), usando a fronteira que deixa a **maior folga** entre as classes.
Dados	Esquerda: 70 motores simulados (35 normais e 35 com falha), com vibração (mm/s) e temperatura (°C). Direita: 160 peças simuladas, com temperatura do molde e pressão padronizadas: as boas ficam no centro e as defeituosas em volta (defeito quando qualquer variável sai da faixa, para cima ou para baixo).
Modelo / técnica	**SVM** com kernel **linear** (reta) e com kernel **RBF** (fronteira curva).
Como medimos	Acurácia, precisão e sensibilidade no teste; quantos pontos são vetores de suporte; e quanto a reta e o kernel RBF acertam nas peças.
O que observar	Só os pontos mais próximos da fronteira (vetores de suporte) a definem. O kernel RBF cria uma fronteira curva.
Nos slides	40 e 41

```
# gerador de dados em forma de círculos
from sklearn.datasets import make_circles

# --- 1) Dados do painel esquerdo: duas classes separáveis por uma reta ---
rng = np.random.default_rng(3)
va = np.r_[rng.normal(1.9, 0.5, 35), rng.normal(4.6, 0.8, 35)]  # vibração
ta = np.r_[rng.normal(58, 4, 35), rng.normal(86, 5, 35)]        # temperatura
ya_s = np.r_[np.zeros(35), np.ones(35)]                         # 0 = normal, 1 = falha
Xs = np.c_[va, ta]
# 70% treino, 30% teste
Xs_tr, Xs_te, ys_tr, ys_te = train_test_split(Xs, ya_s, test_size=0.3, stratify=ya_s, random_state=SEED)
# SVM com fronteira reta (treinado só com o treino)
svm_lin = SVC(kernel="linear", C=1).fit(Xs_tr, ys_tr)

# --- 2) O que o SVM aprendeu e como foi no teste ---
# classe prevista para os motores de teste
pred_s = svm_lin.predict(Xs_te)
# a reta: w1·vibração + w2·temperatura + b = 0
w, b = svm_lin.coef_[0], svm_lin.intercept_[0]
print("Fronteira: %.2f·vibração + %.2f·temperatura + %.2f = 0" % (w[0], w[1], b))
print("Vetores de suporte: %d de %d pontos de treino (só eles definem a fronteira)" %
(len(svm_lin.support_), len(Xs_tr)))
vn_, fp_, fn_, vp_ = confusion_matrix(ys_te, pred_s, labels=[0, 1]).ravel()
print("Teste (%d motores): acurácia = %.2f | precisão = %.2f | sensibilidade = %.2f" % (
      len(ys_te), accuracy_score(ys_te, pred_s), precision_score(ys_te, pred_s), recall_score(ys_te,
pred_s)))
```

```
print("O que classificou: VN = %d normais certos | VP = %d falhas certas | FP = %d | FN = %d" % (vn_,
vp_, fp_, fn_))

fig, axes = plt.subplots(1, 2, figsize=(13, 4.8))
ax = axes[0]
# pontos de treino
ax.scatter(Xs_tr[ys_tr == 0, 0], Xs_tr[ys_tr == 0, 1], color=TEAL, s=22, label="normal (treino)")
ax.scatter(Xs_tr[ys_tr == 1, 0], Xs_tr[ys_tr == 1, 1], color=ORANGE, s=22, label="falha (treino)")
# pontos de teste (círculo branco)
ax.scatter(Xs_te[:, 0], Xs_te[:, 1], facecolors="white", edgecolors=NAVY, s=40, label="teste")
xx, yy = np.meshgrid(np.linspace(0.3, 6.5, 200), np.linspace(45, 100, 200))
# distância de cada ponto à fronteira
dec = svm_lin.decision_function(np.c_[xx.ravel(), yy.ravel()]).reshape(xx.shape)
# fronteira e margens
ax.contour(xx, yy, dec, levels=[-1, 0, 1], colors=NAVY, linestyles=["--", "-", "--"], linewidths=[1, 2.2,
1])
# circula os vetores de suporte
ax.scatter(*svm_lin.support_vectors_.T, s=230, facecolors="none", edgecolors=RED, linewidths=2)
ax.set_xlabel("Vibração (mm/s)"); ax.set_ylabel("Temperatura (°C)"); ax.set_title("Fronteira de maior
margem", fontweight="bold"); ax.legend(frameon=False, fontsize=8); limpa(ax)

# --- 3) Dados do painel direito: uma classe cercada pela outra (reta não resolve) ---
Xcir, ycir = make_circles(n_samples=160, factor=0.35, noise=0.12, random_state=3)
Xcir = Xcir * 2.0
Xc_tr, Xc_te, yc_tr, yc_te = train_test_split(Xcir, ycir, test_size=0.3, stratify=ycir,
random_state=SEED)
svm_lin2 = SVC(kernel="linear", C=1).fit(Xc_tr, yc_tr)              # SVM com reta (vai falhar)
# SVM com kernel RBF: fronteira curva
svm_rbf = SVC(kernel="rbf", gamma="scale", C=5).fit(Xc_tr, yc_tr)
print("\nPeças boas x defeituosas (teste): acurácia com reta = %.2f | acurácia com kernel RBF = %.2f" % (
      accuracy_score(yc_te, svm_lin2.predict(Xc_te)), accuracy_score(yc_te, svm_rbf.predict(Xc_te))))
ax = axes[1]
xx, yy = np.meshgrid(np.linspace(-4, 4, 250), np.linspace(-4, 4, 250))
# classe prevista em cada ponto
zz = svm_rbf.predict(np.c_[xx.ravel(), yy.ravel()]).reshape(xx.shape)
# pinta as duas regiões
ax.contourf(xx, yy, zz, levels=[-.5, .5, 1.5], colors=["#FBE3CC", "#DDEFEF"])
ax.contour(xx, yy, zz, levels=[0.5], colors=NAVY, linewidths=2.2)                    # fronteira
# miolo: peças boas
ax.scatter(Xcir[ycir == 1, 0], Xcir[ycir == 1, 1], color=TEAL, s=22, label="peça boa")
# anel: defeitos nos dois extremos
ax.scatter(Xcir[ycir == 0, 0], Xcir[ycir == 0, 1], color=ORANGE, s=22, label="peça defeituosa")
ax.set_xlabel("Temperatura do molde (padronizada, 0 = ideal)"); ax.set_ylabel("Pressão (padronizada, 0 =
ideal)")
ax.set_title("Kernel RBF: janela de operação (fronteira curva)", fontweight="bold");
ax.legend(frameon=False, fontsize=8, loc="upper right"); limpa(ax)
plt.tight_layout(); plt.show()
```

Saída

```
Fronteira: 0.06·vibração + 0.17·temperatura + -12.30 = 0
Vetores de suporte: 2 de 49 pontos de treino (só eles definem a fronteira)
Teste (21 motores): acurácia = 1.00 | precisão = 1.00 | sensibilidade = 1.00
O que classificou: VN = 11 normais certos | VP = 10 falhas certas | FP = 0 | FN = 0

Peças boas x defeituosas (teste): acurácia com reta = 0.56 | acurácia com kernel RBF = 1.00
```

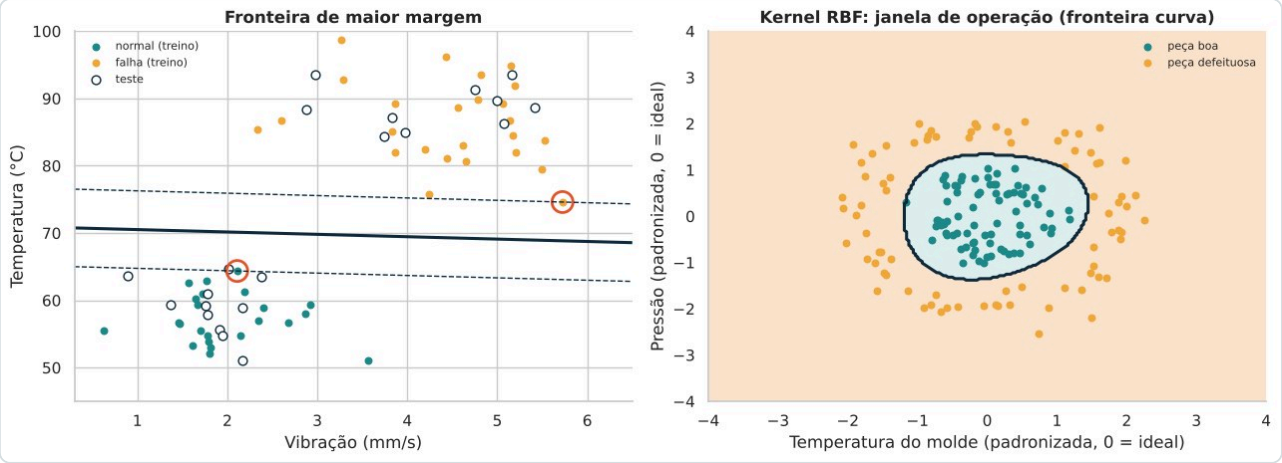


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

- **O problema prático:** o SVM **separa duas classes** com a fronteira mais folgada possível. Aqui, as classes são **motor normal** e **motor com falha**, e as entradas são leituras de sensor.
- **Painel da esquerda (reta):** horizontal = vibração (mm/s), vertical = temperatura (°C). Pontos **verdes** = normais (treino), **laranja** = falha (treino), **círculos brancos** = motores de teste (que o modelo não viu). A **linha cheia** é a fronteira e as **tracejadas** são as margens (a "folga"). Os pontos **circulados em vermelho** são os **vetores de suporte**: são os únicos **2 de 49** pontos de treino que definem a fronteira. A reta ficou quase horizontal porque a **temperatura sozinha já separa** bem as duas classes (normais por volta de 58 °C, falhas por volta de 86 °C).
- **O que o modelo classificou (teste, 21 motores):** acertou **11 normais** e **10 falhas**, nenhum erro: acurácia 1,00. Atenção: com dados simulados e bem separados isso é fácil. Com dados reais haveria erros.
- **Painel da direita (curva):** exemplo de **peças de uma linha de produção**. Horizontal = temperatura do molde e vertical = pressão, ambas **padronizadas** (0 = valor ideal, ±2 = muito longe do ideal). Pontos **verdes** = peças boas, no centro; **laranja** = peças defeituosas, que aparecem quando temperatura **ou** pressão saem da faixa, para qualquer lado. Nenhuma reta separa o miolo do anel: a reta acerta só **56%**. O kernel **RBF** desenha uma fronteira **curva** (a linha escura em volta do grupo verde) e acerta **100%** no teste.
- **Regra prática:** use o kernel linear quando uma reta basta (rápido, fácil de explicar) e o RBF quando o problema tem **janela de operação** (bom no meio, ruim nos dois extremos).

PERGUNTAS

1. Por que a acurácia do SVM com reta ficou em 0,56 nos círculos e 1,00 com o kernel RBF?
2. Só 2 de 49 pontos são vetores de suporte. O que isso quer dizer? Qual foi a acurácia nos motores?

RESPOSTAS COMENTADAS

1. Com uma classe **cercada** pela outra, nenhuma **reta** separa os grupos: o SVM linear acerta pouco mais que um palpite (0,56). O **kernel RBF** permite uma fronteira **curva** em volta do grupo central e acerta tudo no teste (1,00).

2. Só os **pontos mais próximos da fronteira** (os vetores de suporte, circulados em vermelho) a definem: se os outros 47 mudassem de posição sem cruzar a margem, a fronteira seria a mesma. No teste (21 motores), o SVM com reta classificou **todos** corretamente: 11 normais e 10 falhas (VN = 11, VP = 10, FP = 0, FN = 0), ou seja, acurácia 1,00. As duas classes estão bem separadas; em dados reais, o resultado costuma ser menor.

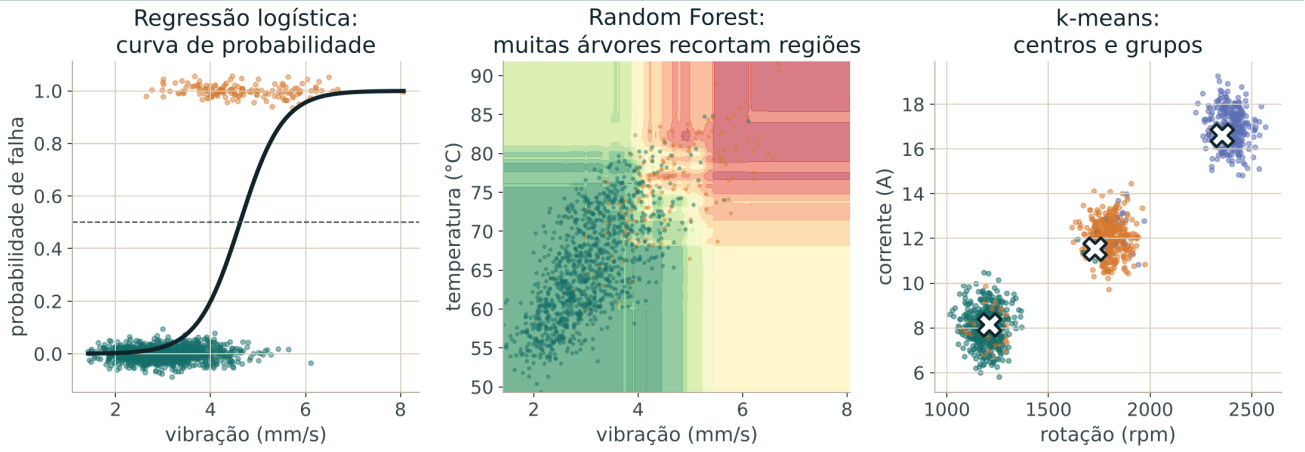


Figura 5. Três algoritmos nos mesmos dados de motores: a regressão logística estima probabilidades, a floresta recorta regiões e o k-means encontra centros.

Matriz de confusão e métricas de classificação

Depois de treinar, comparamos as previsões com a resposta real em dados de **teste**. Como os erros têm custos diferentes (deixar passar uma peça defeituosa x reprovar uma peça boa), não basta contar acertos: usamos a matriz de confusão e várias métricas.

A matriz de confusão cruza o que o modelo previu com o que realmente aconteceu: verdadeiros positivos (VP, defeito achado), falsos positivos (FP, alarme falso), verdadeiros negativos (VN, peça boa liberada) e falsos negativos (FN, defeito que passou).



Figura 6. Matriz de confusão do Random Forest no bloco de Produção: 625 peças de teste, 72 defeituosas (VN = 534, FP = 19, FN = 19, VP = 53).

Métrica	Fórmula	Pergunta que responde	No exemplo
Acurácia	(VP + VN) ÷ total	Quanto acertamos em geral? Engana quando uma classe é rara.	93,9%
Precisão	VP ÷ (VP + FP)	Dos alertas emitidos, quantos eram casos reais? Alta precisão = menos falsos alarmes.	73,6%
Sensibilidade (recall)	VP ÷ (VP + FN)	Dos casos reais, quantos foram detectados? Baixa = falsos negativos, casos que passam.	73,6%
Especificidade	VN ÷ (VN + FP)	Dos casos normais, quantos foram liberados corretamente? Baixa = falsos positivos.	96,6%
F1	2·P·R ÷ (P + R)	Média harmônica de precisão e recall: um número único de equilíbrio.	0,736

Curva ROC e AUC

Cada ponto da curva ROC corresponde a um **limiar de decisão**. O eixo vertical é a sensibilidade e o horizontal é a taxa de falsos positivos (1 − especificidade); quanto mais perto do canto superior esquerdo, melhor. A **AUC**, área sob a curva, vale 0,5 no acaso e 1,0 no modelo perfeito (aqui, 0,96). Com limiar 0,2 o modelo acha 90% dos defeitos, com cerca de 9% de falsos alarmes; com 0,5, acha 74%, com cerca de 3,4%.

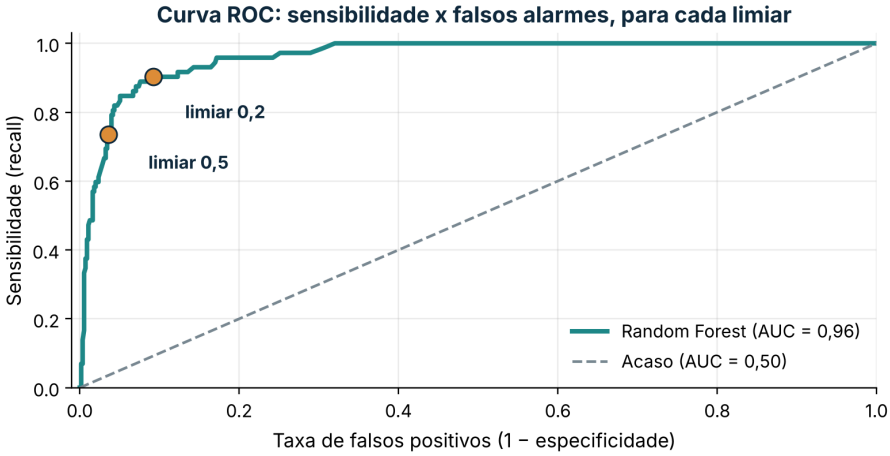


Figura 7. Curva ROC do Random Forest (mesmo modelo e dados da matriz de confusão), com dois limiares destacados.

NO COLAB · EXERCÍCIO 2.4 · MÉTRICAS: COMO SABER SE A CLASSIFICAÇÃO FUNCIONA?	
Problema	Ler a **matriz de confusão** do Random Forest (peça boa x defeituosa) e calcular as métricas à mão.
Dados	As 625 peças de teste (72 defeituosas).
Modelo / técnica	Random Forest (já treinado em 2.2).
Como medimos	**Acurácia**, **precisão**, **sensibilidade** e **especificidade**.
O que observar	VN = 534, FP = 19, FN = 19, VP = 53. Sensibilidade: dos defeitos reais, quantos achamos. Especificidade: das peças boas, quantas liberamos.
Nos slides	42 e 54

```
rf_p = modelos_prod["Random Forest"]                    # o modelo que vamos avaliar
pred_rf = rf_p.predict(Xp_te)                           # previsões no teste
# os 4 números da matriz
vn, fp, fn, vp = confusion_matrix(yp_te, pred_rf, labels=[0, 1]).ravel()
print("VN = %d | FP = %d | FN = %d | VP = %d | total = %d peças (%d defeituosas)" % (vn, fp, fn, vp,
len(yp_te), yp_te.sum()))
print("Acurácia       = (VP+VN)/total   = %.1f%%" % (100 * (vp + vn) / len(yp_te)))
print("Precisão       = VP/(VP+FP)      = %.1f%%" % (100 * vp / (vp + fp)))
print("Sensibilidade  = VP/(VP+FN)      = %.1f%%   (defeitos que o modelo achou)" % (100 * vp / (vp +
fn)))
print("Especificidade = VN/(VN+FP)      = %.1f%%   (peças boas liberadas)" % (100 * vn / (vn + fp)))

fig, ax = plt.subplots(figsize=(5.6, 4.6))
matriz(yp_te, pred_rf, ax, [0, 1], ["boa", "defeito"], titulo="Random Forest (teste)")
for (i, j), nome in zip([(0, 0), (0, 1), (1, 0), (1, 1)], ["VN", "FP", "FN", "VP"]):
    # escreve VN, FP, FN, VP em cada quadrado
    ax.text(j, i + 0.30, nome, ha="center", color=RED, fontweight="bold")
plt.tight_layout(); plt.show()
```

Saída

```
VN = 534 | FP = 19 | FN = 19 | VP = 53 | total = 625 peças (72 defeituosas)
Acurácia       = (VP+VN)/total   = 93.9%
Precisão       = VP/(VP+FP)      = 73.6%
Sensibilidade  = VP/(VP+FN)      = 73.6%   (defeitos que o modelo achou)
Especificidade = VN/(VN+FP)      = 96.6%   (peças boas liberadas)
```

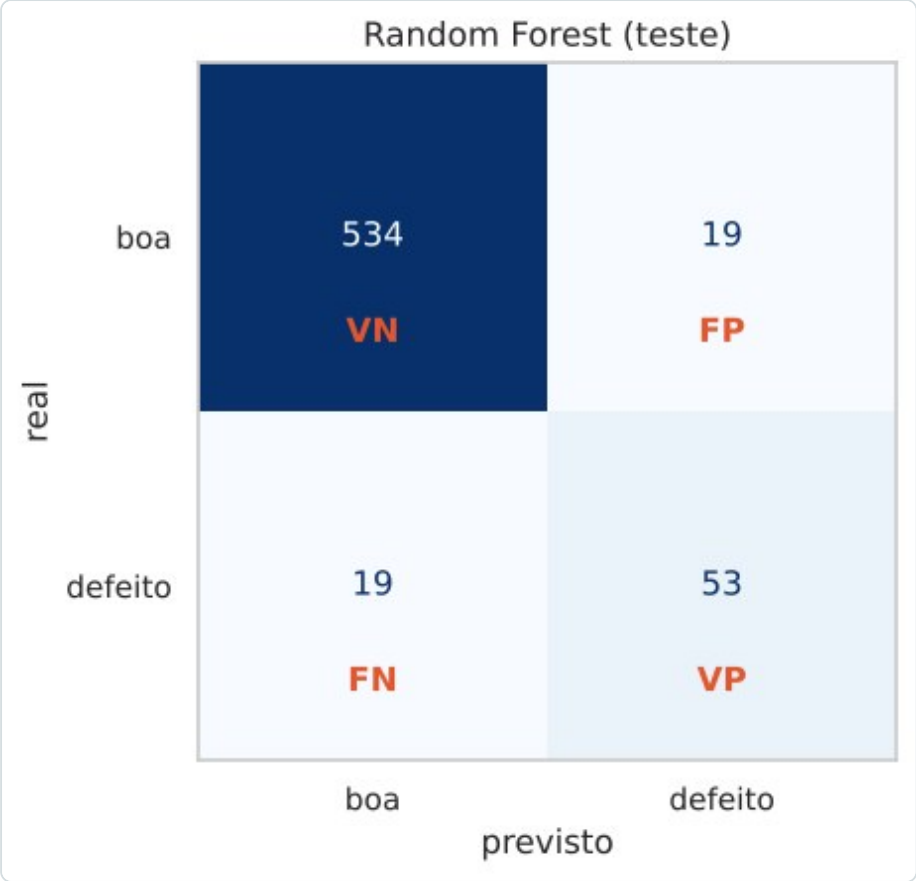


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(matriz de confusão do Random Forest, 625 peças de teste)

- **Os quatro quadrantes: VN = 534** (peça boa, prevista boa: liberada corretamente); **FP = 19** (peça boa, prevista defeito: **falso alarme**, vai para retrabalho sem precisar); **FN = 19** (peça com defeito prevista boa: **defeito que escapou**, o erro mais caro); **VP = 53** (defeito corretamente achado).
- **Como cada métrica sai da matriz: acurácia** = (53 + 534)/625 = **93,9%** (acertos no total); **precisão** = 53/(53 + 19) = **73,6%** (dos alertas, quantos eram defeito); **sensibilidade** = 53/(53 + 19) = **73,6%** (dos defeitos reais, quantos achamos); **especificidade** = 534/(534 + 19) = **96,6%** (das peças boas, quantas liberamos).
- **Na engenharia:** a acurácia de 93,9% parece ótima, mas ainda deixamos escapar 19 de 72 defeitos (26%). Quem decide se isso é aceitável é o **custo do erro** (peça defeituosa chegando ao cliente x retrabalho de peça boa).

PERGUNTAS

1. Qual a diferença entre **sensibilidade** e **especificidade** neste exemplo?
2. A acurácia é 93,9%, a precisão e a sensibilidade são 73,6%. O modelo está "bom"?

RESPOSTAS COMENTADAS

1. Sensibilidade (73,6%): dos 72 defeitos reais, achamos 53 (VP); 19 passaram (FN). **Especificidade (96,6%)**: das 553 peças boas, liberamos 534 (VN); 19 foram alarmes falsos (FP). A primeira mede o risco de **deixar defeito passar**; a segunda, o de **refugar peça boa**.

2. Depende do uso. A acurácia (93,9%) parece alta, mas é puxada pelas 553 peças boas (classe majoritária). Para peça de segurança, 26% de defeitos sem alerta (sensibilidade 73,6%) é muito; por isso usamos a curva ROC e baixamos o limiar. O "bom" só existe **em relação ao custo dos erros**.

NO COLAB · EXERCÍCIO 2.5 · CURVA ROC: O EFEITO DO LIMIAR DE DECISÃO

Problema	Ver, em um só gráfico, o que acontece com a **sensibilidade** (defeitos achados) e os **falsos alarmes** (peças boas reprovadas) quando mudamos o limiar.
Dados	As probabilidades do Random Forest nas 625 peças de teste.
Modelo / técnica	Curva **ROC** e **AUC** (área sob a curva).
Como medimos	AUC: 0,5 é o acaso; 1,0 é perfeito.
O que observar	AUC ≈ 0,96. Limiar 0,2: acha ~90% dos defeitos com ~9% de falsos alarmes. Limiar 0,5: ~74% e ~4%.
Nos slides	43 e 54

```
prob_rf = rf_p.predict_proba(Xp_te)[:, 1]                # probabilidade de defeito de cada peça
# taxa de falsos positivos e sensibilidade para cada limiar
fpr, tpr, lims = roc_curve(yp_te, prob_rf)
auc = roc_auc_score(yp_te, prob_rf)                      # área sob a curva

def ponto(lim):
    """Sensibilidade e taxa de falsos positivos para um limiar escolhido."""
    pred = (prob_rf > lim).astype(int)
    return recall_score(yp_te, pred), 1 - recall_score(yp_te, pred, pos_label=0)

fig, ax = plt.subplots(figsize=(6.2, 4.8))
ax.plot(fpr, tpr, color=TEAL, lw=2.5, label="Random Forest (AUC = %.2f)" % auc)     # a curva ROC
# modelo que chuta
ax.plot([0, 1], [0, 1], "--", color="gray", label="acaso (AUC = 0,50)")
# destaca dois limiares
for lim, cor_p in [(0.2, ORANGE), (0.5, RED)]:
    s_, f_ = ponto(lim)
    ax.scatter(f_, s_, s=90, color=cor_p, zorder=5,
               label="limiar %.1f: sens. %.0f%%, falsos alarmes %.1f%%" % (lim, 100 * s_, 100 * f_))
ax.set_xlabel("Falsos positivos (1 − especificidade)"); ax.set_ylabel("Sensibilidade (recall)")
ax.legend(frameon=False, loc="lower right", fontsize=9); limpa(ax); ax.set_title("Curva ROC"); plt.show()
```

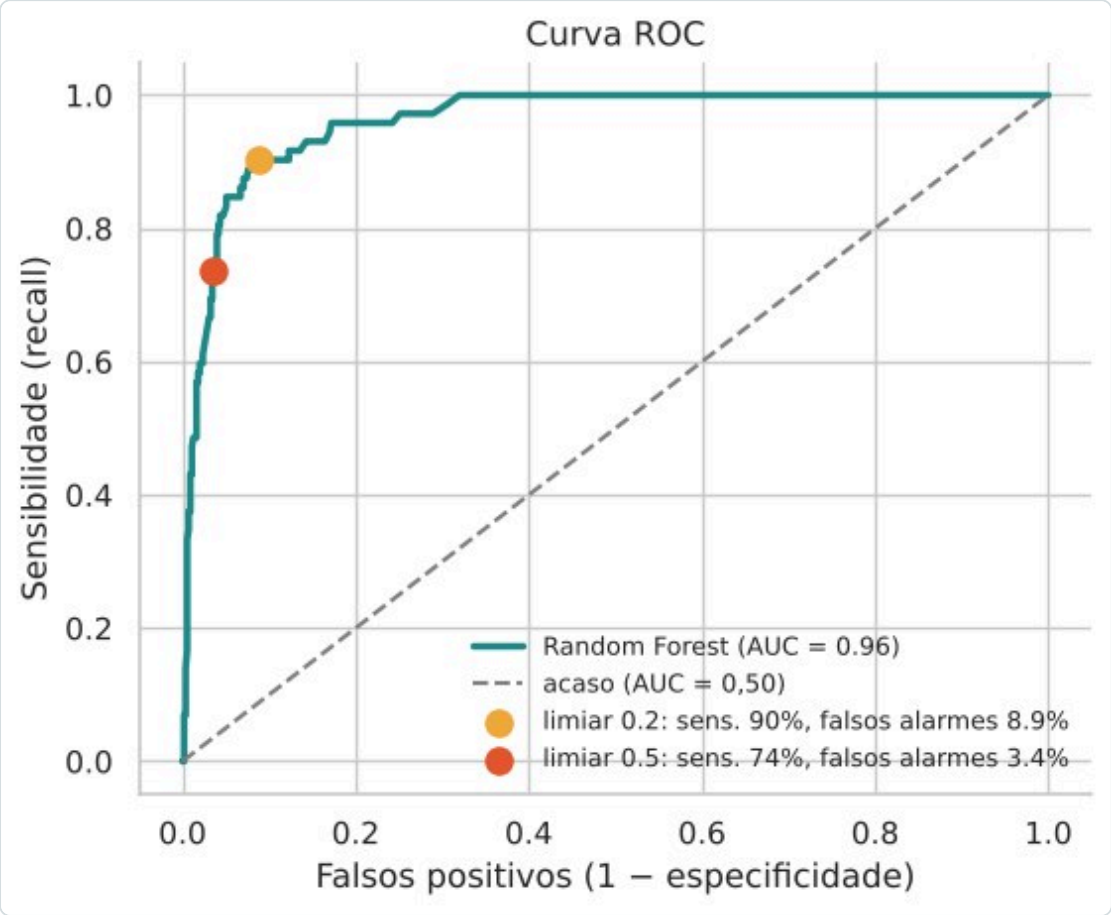


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

- **Eixos:** horizontal = **falsos positivos** (fração das peças **boas** que o modelo reprova, 1 − especificidade); vertical = **sensibilidade** (fração dos defeitos que ele acha). Cada ponto da curva verde é um **limiar de decisão** diferente (a partir de que probabilidade emitimos o alerta).
- **Linha cinza tracejada:** um modelo que chuta (AUC = 0,50). Quanto mais a curva se afasta dela para o canto superior esquerdo, melhor.
- **Curva verde (Random Forest):** AUC = **0,96** (1,0 seria perfeito). A curva sobe quase vertical e depois se achata.
- **Ponto vermelho (limiar 0,5):** acha **74%** dos defeitos com **3,4%** de falsos alarmes. **Ponto laranja (limiar 0,2):** acha **90%** dos defeitos, mas com **8,9%** de falsos alarmes.
- **Na engenharia:** baixar o limiar acha mais defeitos e reprova mais peças boas. Se um defeito que escapa custa muito mais que um retrabalho, escolha o ponto laranja; se o retrabalho é caro, o vermelho.

PERGUNTAS

em peça de segurança, você escolhe o limiar 0,2 ou 0,5? O que se ganha e o que se paga? (mais defeitos achados, mais alarmes falsos)

RESPOSTAS COMENTADAS

Em **peça de segurança**, escolha o limiar **0,2**: a curva mostra sensibilidade ≈ 90% com ≈ 9% de falsos alarmes (das 553 peças boas, ≈ 51 sinalizadas à toa). **Ganha-se** defeitos achados (de 53 para ≈ 65 dos 72); **paga-se** mais inspeção e refugo desnecessários. Com o limiar **0,5**, a sensibilidade cai para ≈ 74%, com ≈ 3,4% de falsos alarmes. Para peças simples, 0,5 costuma bastar. A **AUC** (0,96) diz que o modelo separa bem as classes **em geral**; o **limiar** é a escolha de negócio.

Qual métrica priorizar?

Depende do custo do erro. Em uma peça de segurança, um falso negativo (defeito que passa) custa muito mais do que um falso positivo (peça boa refugada): priorize o **recall**. Em um produto de baixo custo, pode valer mais a **precisão**.

Classes desbalanceadas: quando a acurácia engana

Se apenas 11% das peças têm defeito, um "modelo" que diz sempre *peça boa* acerta 88,5% e não encontra nenhum defeito. Por isso olhamos sensibilidade (recall), precisão, especificidade e a curva ROC, além do F1, e usamos `class_weight="balanced"` para dar mais peso à classe rara.

4.3 Overfitting e validação cruzada

Um modelo pode acertar quase tudo no treino e falhar em dados novos porque **decorou** particularidades e ruído: é o *overfitting*. O contrário, um modelo simples demais, é o *underfitting*.

Exemplo de engenharia (Exemplo 5): queremos **prever a temperatura de um motor a partir da corrente**, mas só temos 36 medidas. Um polinômio muito complexo passa por todos os pontos de treino, mas oscila entre eles e prevê temperaturas absurdas para correntes que não mediu. Ele **decorou o ruído** das medidas em vez de aprender a relação física, parece perfeito na bancada e **falha no motor novo**. Por isso avaliamos sempre com dados de teste separados.

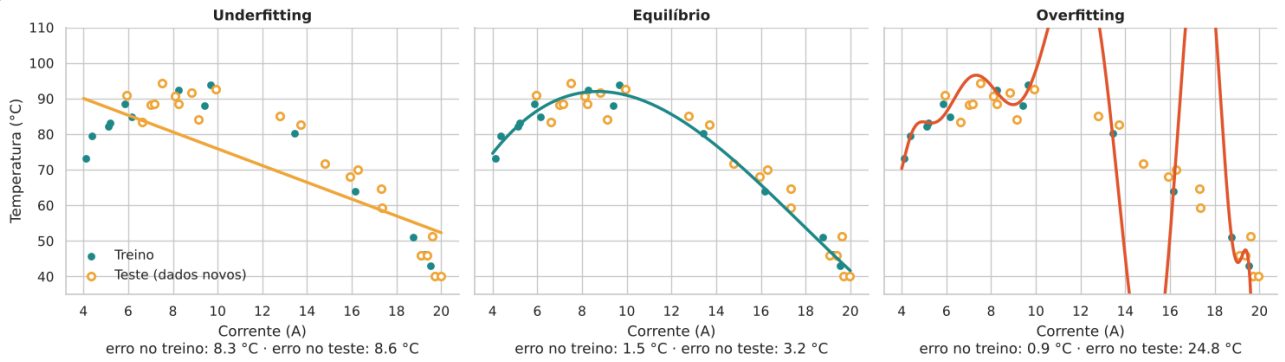


Figura 8. Polinômios de grau 1, 3 e 13 nos mesmos pontos. Underfitting: erra no treino e no teste. Equilíbrio: erra pouco nos dois. Overfitting: erro de treino quase zero e erro de teste que explode (valores do exemplo: 0,9 °C no treino e 24,8 °C no teste no grau 13).

NO COLAB · EXEMPLO 5 · OVERFITTING: DECORAR NÃO É APRENDER

Problema	Prever a **temperatura do motor** a partir da **corrente** (como no Exemplo 3), mas com **poucas medidas**, e mostrar que um modelo **complexo demais** erra pouco no treino e muito em dados novos.
Dados	36 medidas simuladas de corrente (A) e temperatura (°C): 14 para treino e 22 para teste.
Modelo / técnica	**Regressão polinomial** de grau 1 (simples demais), 3 (equilíbrio) e 13 (complexo demais).
Como medimos	MAE no treino e no teste, em °C.
O que observar	Grau 1 (*underfitting*): erra nos dois. Grau 3: erra pouco nos dois. Grau 13 (*overfitting*): erro de treino quase zero e erro de teste enorme.
Nos slides	44

```
# --- 1) Criar os dados: temperatura sobe e depois desce com a corrente (forma de morro) ---
rng = np.random.default_rng(199)
n = 36
cor = rng.uniform(4, 20, n)                                                    # corrente (A)
# temperatura (°C) = morro + ruído
tem = np.clip(88 - 0.405 * (cor - 9) ** 2 + rng.normal(0, 3.5, n), 40, None)
# treino e teste
c_tr, c_te, t_tr, t_te = train_test_split(cor, tem, test_size=0.6, random_state=199)

# --- 2) Ajustar polinômios de graus 1, 3 e 13 e desenhar ---
g = np.linspace(4, 20, 300)
tabela_ov = []                                      # vai guardar as métricas de cada grau
fig, axes = plt.subplots(1, 3, figsize=(15, 4.4), sharey=True)
for ax, (grau, titulo, cor_l) in zip(axes, [(1, "Underfitting", ORANGE), (3, "Equilíbrio", TEAL), (13,
"Overfitting", RED)]):
    # polinômio do grau escolhido
    m = make_pipeline(StandardScaler(), PolynomialFeatures(grau), LinearRegression()).fit(c_tr[:, None],
t_tr)
    e_tr = mean_absolute_error(t_tr, m.predict(c_tr[:, None]))      # erro no treino
    e_te = mean_absolute_error(t_te, m.predict(c_te[:, None]))      # erro no teste (dados novos)
    tabela_ov.append({"Grau": grau, "MAE treino": e_tr, "MAE teste": e_te,
                      "RMSE teste": np.sqrt(np.mean((t_te - m.predict(c_te[:, None])) ** 2)),
                      "R² treino": r2_score(t_tr, m.predict(c_tr[:, None])), "R² teste": r2_score(t_te,
m.predict(c_te[:, None]))})
    ax.scatter(c_tr, t_tr, color=TEAL, s=28, label="Treino")
    ax.scatter(c_te, t_te, facecolors="white", edgecolors=ORANGE, linewidths=2, s=36, label="Teste (dados
novos)")
    ax.plot(g, m.predict(g[:, None]), color=cor_l, lw=2.5); ax.set_ylim(35, 110)
    ax.set_title(titulo, fontweight="bold")
    ax.set_xlabel("Corrente (A)\nerro no treino: %.1f °C · erro no teste: %.1f °C" % (e_tr, e_te));
limpa(ax)
axes[0].set_ylabel("Temperatura (°C)"); axes[0].legend(frameon=False, loc="lower left")
plt.tight_layout(); plt.show()
# tabela: o R² de teste do grau 13 fica negativo (pior que prever a média)
display(pd.DataFrame(tabela_ov).set_index("Grau").round(2))
```

Saída

Grau	MAE treino	MAE teste	RMSE teste	R^2 treino	R^2 teste
1	8.31	8.56	9.71	0.65	0.72
3	1.54	3.18	3.88	0.99	0.96
13	0.85	24.77	44.97	0.99	-4.99

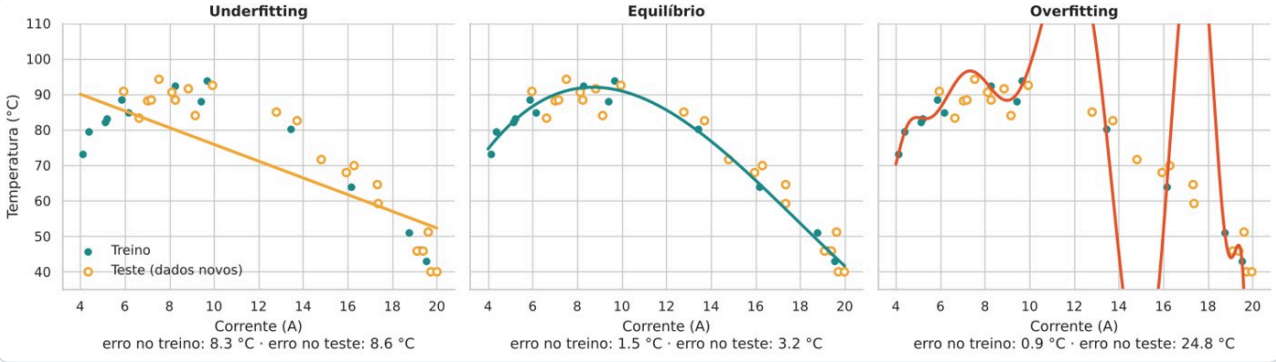


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(mesmo problema do Exemplo 3: prever a **temperatura do motor** a partir da **corrente**, agora com poucas medidas)

- **Eixos e pontos:** corrente (A) na horizontal, temperatura (°C) na vertical. **Pontos verdes** = 14 medidas de **treino** (o modelo vê). **Círculos laranja vazados** = 22 medidas de **teste** (dados novos, que o modelo não viu). Abaixo de cada painel está o erro médio no treino e no teste.
- **Painel "Underfitting" (grau 1, uma reta):** simples demais. Erra **8,3 °C no treino e 8,6 °C no teste**: erra parecido nos dois, mas erra muito, porque a temperatura **sobe e depois desce** com a corrente e uma reta não faz curva (R^2 de teste 0,72).
- **Painel "Equilíbrio" (grau 3):** a curva acompanha o formato real. Erra **1,5 °C no treino e 3,2 °C no teste** (R^2 de teste 0,96). Um pouco pior no teste é o esperado e saudável.
- **Painel "Overfitting" (grau 13):** a curva passa por quase todos os pontos de treino (erro **0,9 °C**), mas entre eles **oscila loucamente**, chegando a prever temperaturas absurdas, como valores muito acima de 110 °C ou abaixo de 40 °C, para correntes que não mediu. No teste o erro vai a **24,8 °C** e o R^2 fica **negativo (−4,99)**, pior que simplesmente chutar a média.
- **O que o overfitting representa:** o modelo **decorou o ruído** das 14 medidas em vez de aprender a relação física corrente → temperatura. Na prática, ele parece perfeito na bancada e **falha no motor novo**, e é por isso que sempre se avalia com dados de teste separados.

PERGUNTAS

1. Qual grau você escolheria? Por quê?
2. O que significa o R^2 de teste **negativo** (−4,99) no grau 13?

RESPOSTAS COMENTADAS

1. O **grau 3**: erro de treino e de teste parecidos e baixos (MAE 1,5 e 3,2 °C; R^2 de teste 0,96). O grau 1 erra muito nos dois (*underfitting*); o grau 13 erra quase nada no treino (0,85 °C) mas 24,8 °C no teste (*overfitting*).

2. R^2 negativo quer dizer que o modelo é **pior do que simplesmente prever a média** dos dados de teste. O grau 13 "decorou" o treino e inventa curvas absurdas fora dele. **Sempre avalie no teste**, nunca só no treino.

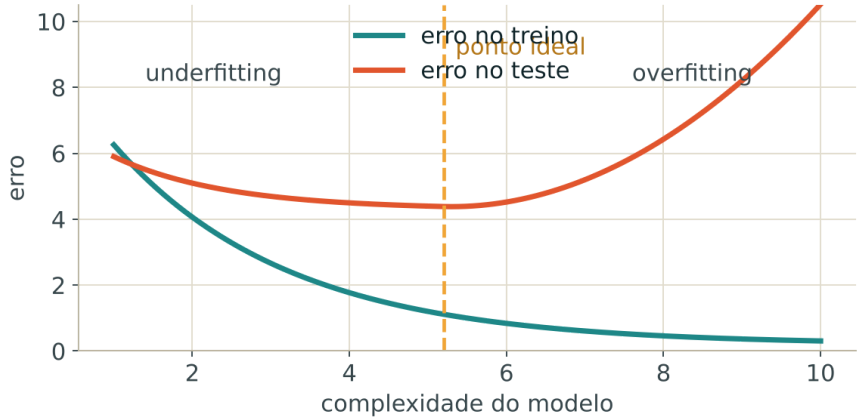


Figura 9. Com a complexidade crescente, o erro de treino sempre cai; o erro de teste cai e depois sobe. O ponto ideal está no mínimo do erro de teste.

Um único corte treino/teste pode dar sorte ou azar. Na **validação cruzada** (5 partes, por exemplo) o conjunto é dividido em cinco; cada parte serve uma vez como teste e as outras quatro como treino. Reportamos a **média** e o **desvio padrão**: um desvio grande indica resultado instável.

4.4 Aprendizado não supervisionado

No aprendizado não supervisionado **não há resposta pronta** (não existe a coluna "alvo"). O algoritmo procura sozinho estrutura nos dados. Três ferramentas aparecem no curso, todas com leituras de motores:

- **k-means (agrupamento).** *O que é:* divide os dados em **k grupos** de pontos parecidos. *Como funciona:* (1) sorteia k centros; (2) cada ponto vai para o centro mais próximo; (3) cada centro se move para a média do seu grupo; os passos 2 e 3 se repetem até estabilizar. *Exemplo:* descobrir que o motor trabalha em **3 regimes de carga** (baixa, média e alta) olhando rotação, corrente, vibração e temperatura. O valor de k é escolhido com o **método do cotovelo** (inércia) e a **silhueta**, sempre com o conhecimento do domínio.
- **Agrupamento hierárquico.** *O que é:* uma "árvore genealógica" dos dados. *Como funciona:* no começo cada motor é um grupo; a cada passo, os dois grupos mais parecidos se unem, até sobrar um só. O resultado é o **dendrograma**, e cortar a árvore em uma altura define o número de grupos. *Vantagem:* não é preciso fixar k antes.
- **Isolation Forest (detecção de anomalias).** *O que é:* encontra leituras **raras**, sem exemplos de falha. *Como funciona:* faz cortes aleatórios nos dados; um ponto estranho fica sozinho com **poucos cortes**, enquanto um ponto comum, no meio da multidão, exige muitos. Quanto menos cortes, mais atípico. *Exemplo:* picos de vibração em um motor. O parâmetro `contamination` define a fração esperada de anomalias e controla o equilíbrio entre achar tudo e gerar alarmes falsos.

Um grupo encontrado pelo algoritmo não é automaticamente um diagnóstico nem uma causa: precisa ser interpretado.

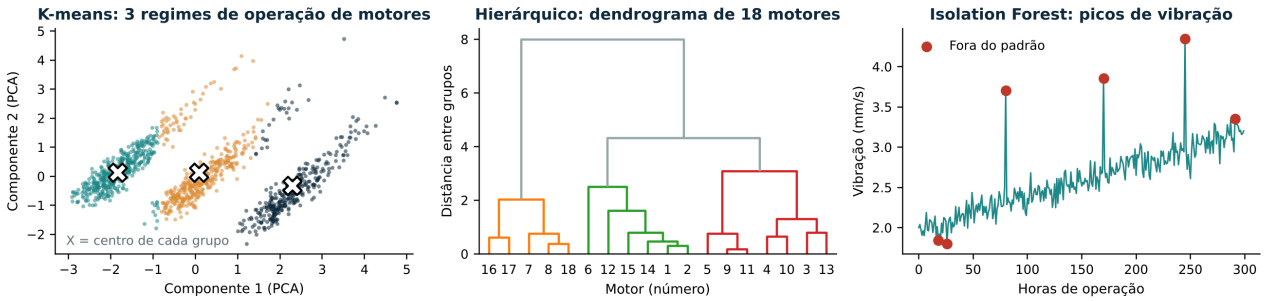


Figura 10. Três métodos não supervisionados em dados de motores: k-means (X marca o centro de cada grupo), dendrograma de 18 motores e Isolation Forest sinalizando picos de vibração.

4.5 PCA: resumir muitas variáveis em poucas dimensões

Analogia: a sombra de um objeto na parede é uma versão em 2D de algo que tem 3D; ela perde informação, mas, se escolhermos bem o ângulo da luz, ainda mostra a forma. O PCA faz isso com os dados: escolhe o "ângulo" que preserva mais informação. **Exemplo:** cada rolamento tem 6 medidas de vibração, impossíveis de desenhar de uma vez; o PCA as resume em 2 eixos e deixa ver as três condições (saudável, falha externa e interna).

O PCA (análise de componentes principais) combina as variáveis originais em **eixos novos** (componentes), ordenados pela variância que preservam. Serve para **visualizar** dados de muitas dimensões em 2D, **comprimir** variáveis correlacionadas e **reduzir ruído** antes de outro modelo. Duas regras: padronize as variáveis antes e ajuste o PCA **só com os dados de treino**; dentro de um *pipeline* isso é automático. O PCA não é um classificador nem um algoritmo de agrupamento.

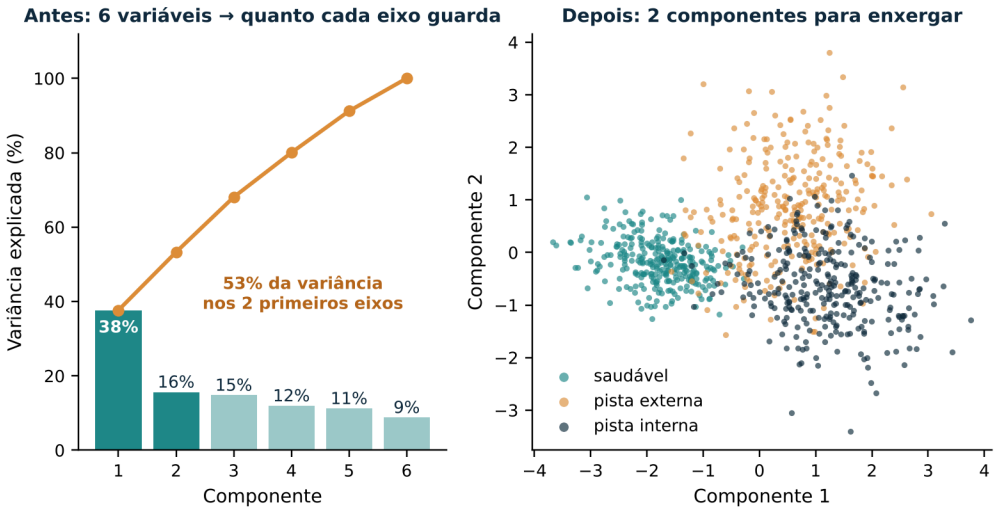


Figura 11. Antes: seis variáveis e quanto cada eixo guarda da variância. Depois: dois componentes para enxergar as três condições do rolamento.

4.6 Visualizar antes de modelar

Olhar os dados é o primeiro passo. Cada gráfico responde a uma pergunta:

Gráfico	Pergunta que responde
Histograma	Como a variável se distribui? Há assimetria, grupos ou valores extremos?
Boxplot	Como os grupos se comparam (por exemplo, peças boas e defeituosas)?
Dispersão	Duas variáveis se relacionam? Os grupos se separam?
Mapa de calor	Quais variáveis andam juntas (correlação)?
Série temporal	Há tendência, desgaste ou picos ao longo do tempo?
PCA 2D	Muitas variáveis juntas formam padrões ou grupos?

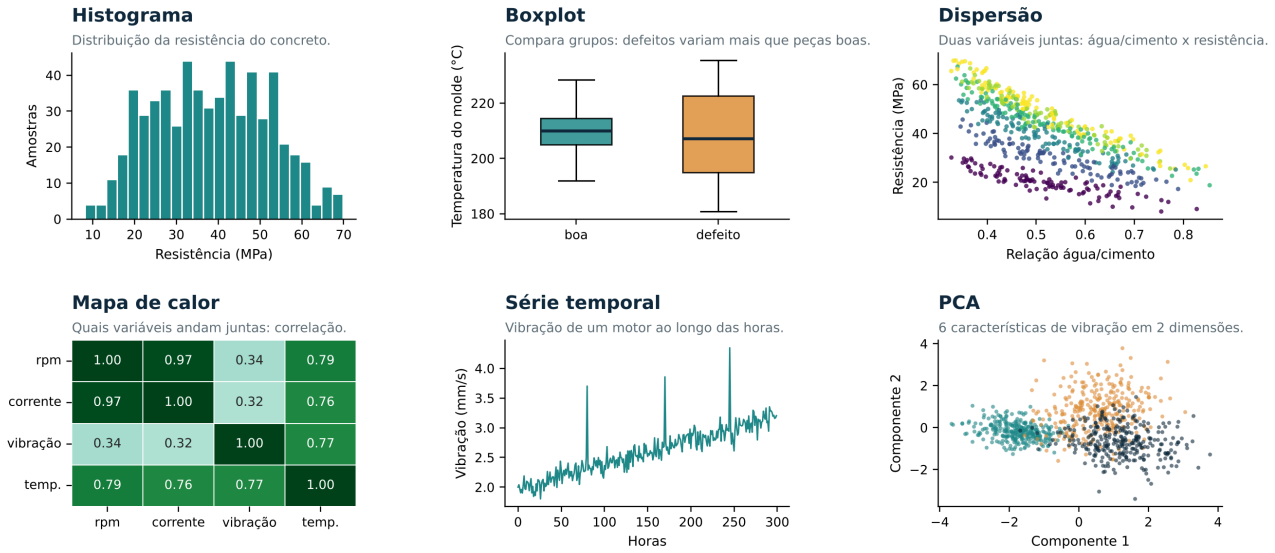


Figura 12. Os seis gráficos com dados do curso: histograma da resistência do concreto, boxplot da temperatura do molde (peças boas e defeituosas), dispersão água/cimento x resistência, mapa de calor das variáveis do motor, série temporal da vibração e PCA dos rolamentos.

5. Bloco 1 · Engenharia Civil: resistência do concreto

Onde implementar

Na usina de concreto e no canteiro de obras. O ensaio de compressão aos 28 dias demora quase um mês, e o traço só é validado depois. Um modelo que estima a resistência a partir do traço e da idade ajuda a **ajustar o traço antes**, a decidir a **desforma** e a **reduzir ensaios**.

Pergunta	Dados	Técnica	Ganho
Qual a resistência (MPa)?	cimento, água, aditivo, idade	Regressão + visualização	decisão mais cedo e menos ensaios

Os dados (simulados)

600 amostras geradas a partir da **Lei de Abrams**: quanto maior a relação água/cimento, menor a resistência; a resistência cresce com a idade e satura. Há ruído de ensaio de 2 MPa.

NO COLAB · EXERCÍCIO 1.1 · CRIAR OS DADOS (SIMULADOS)

Problema	Prever a **resistência do concreto (MPa)** a partir do traço e da idade, sem esperar o ensaio.
Dados	600 amostras simuladas com a **Lei de Abrams**: quanto maior a relação água/cimento, menor a resistência; a resistência cresce (e satura) com a idade. Colunas: cimento, água, aditivo, idade e resistência.
Modelo / técnica	Ainda não há modelo: só construímos a tabela.
Como medimos	—
O que observar	O formato da tabela: cada linha é uma amostra de concreto; cada coluna, uma variável.
Nos slides	51 e 52

```
# gerador aleatório (mesma semente = mesmos dados para todos)
rng = np.random.default_rng(SEED)
n = 600                                          # número de amostras de concreto
# consumo de cimento, kg/m3 (sorteado entre 250 e 480)
cimento = rng.uniform(250, 480, n)
agua = rng.uniform(150, 215, n)                  # água, L/m3
aditivo = rng.uniform(0, 2.0, n)                 # aditivo, % sobre o peso do cimento
idade = rng.choice([3, 7, 14, 28, 56, 90], n)    # idade do ensaio, em dias (um dos seis valores)

# relação água/cimento (a variável mais importante)
ac = agua / cimento
# Lei de Abrams: resistência aos 28 dias (MPa)
f28 = 115 * np.exp(-2.0 * ac) * (1 + 0.06 * aditivo)
# como a resistência evolui com a idade
fator_idade = (idade / (4 + 0.85 * idade)) / (28 / (4 + 0.85 * 28))
# resistência final + erro de ensaio de 2 MPa
resistencia = f28 * fator_idade + rng.normal(0, 2.0, n)

civil = pd.DataFrame({"cimento": cimento, "agua": agua, "aditivo": aditivo,
                      "idade": idade, "resistencia_MPa": resistencia})   # monta a tabela
# guarda também a relação água/cimento
civil["rel_agua_cimento"] = civil["agua"] / civil["cimento"]
print(civil.shape)                               # (linhas, colunas)
display(civil.head())                            # as 5 primeiras linhas
# resumo estatístico: média, desvio, mínimo e máximo
display(civil.describe().T.round(2))
```

Saída

```
(600, 6)

      cimento        agua   aditivo  idade  resistencia_MPa  rel_agua_cimento
0  428.009891  181.037882  1.132841     14        46.809727          0.422976
1  350.942041  199.493117  1.101818     28        40.498557          0.568450
2  447.477522  208.716312  1.657094      3        21.634441          0.466429
3  410.394647  196.845237  1.421066     28        44.200247          0.479649
4  271.660790  212.608730  0.053156     90        25.563679          0.782626
                   count    mean     std     min     25%     50%     75%     max
cimento            600.0  364.08   66.06  251.25  304.45  364.95  422.57  479.79
agua               600.0  182.77   19.18  150.03  165.93  182.07  199.71  214.96
aditivo            600.0    1.01    0.58    0.00    0.49    0.99    1.55    2.00
idade              600.0   32.02   30.60    3.00    7.00   14.00   56.00   90.00
resistencia_MPa    600.0   38.37   13.62    8.09   27.31   38.28   48.83   69.89
rel_agua_cimento   600.0    0.52    0.11    0.33    0.43    0.50    0.60    0.85
```

Regressão: linear x Random Forest

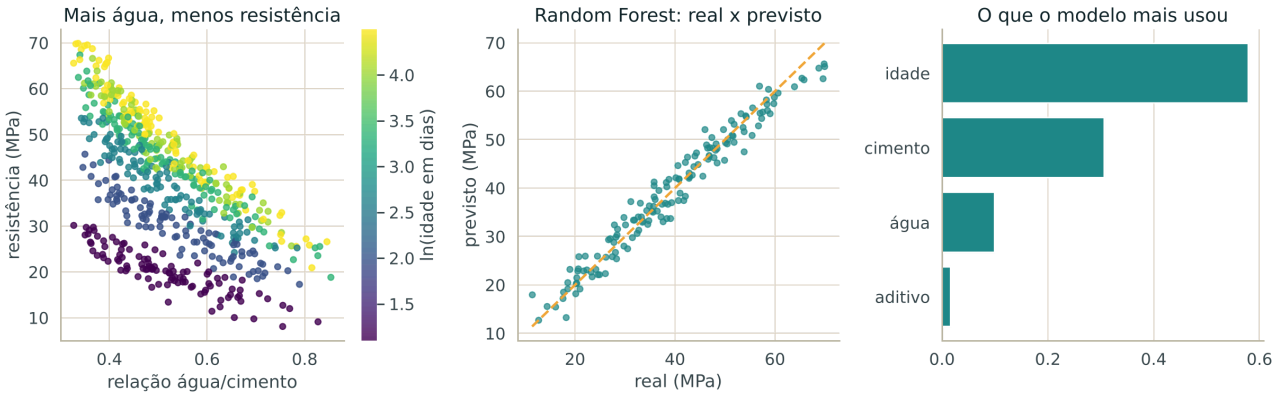


Figura 13. Esquerda: mais água por cimento, menos resistência (a cor é a idade). Centro: previsto x real do Random Forest. Direita: importância das variáveis.

NO COLAB · EXERCÍCIO 1.2 · VISUALIZAR ANTES DE MODELAR

Problema	Antes de modelar, entender o que vamos **prever** (a **resistência do concreto, em MPa**) e as variáveis de **entrada** (cimento, água, aditivo e idade): como se distribuem e como se relacionam.
Dados	A tabela `civil` do passo anterior.
Modelo / técnica	Gráficos: histograma, dispersão e mapa de calor.
Como medimos	—
O que observar	Mais água por cimento, menos resistência. Idade e resistência não formam uma reta (a resistência satura).
Nos slides	47, 48 e 52

```
fig, axes = plt.subplots(1, 3, figsize=(16, 4.4))            # 3 gráficos lado a lado

# histograma: como a resistência se distribui
sns.histplot(civil["resistencia_MPa"], kde=True, color=TEAL, ax=axes[0])
axes[0].set_title("Distribuição da resistência"); axes[0].set_xlabel("MPa")

sc = axes[1].scatter(civil["rel_agua_cimento"], civil["resistencia_MPa"],
                     # dispersão: cada ponto é uma amostra; a cor é a idade
                     c=np.log(civil["idade"]), cmap="viridis", alpha=0.7)
axes[1].set_xlabel("relação água/cimento"); axes[1].set_ylabel("resistência (MPa)")
axes[1].set_title("Mais água, menos resistência")
cb = plt.colorbar(sc, ax=axes[1]); cb.set_label("ln(idade em dias)")

# mapa de calor: correlações
sns.heatmap(civil.corr(), annot=True, fmt=".2f", cmap="coolwarm", center=0, ax=axes[2], cbar=False)
axes[2].set_title("Correlação entre variáveis")
plt.tight_layout(); plt.show()
```

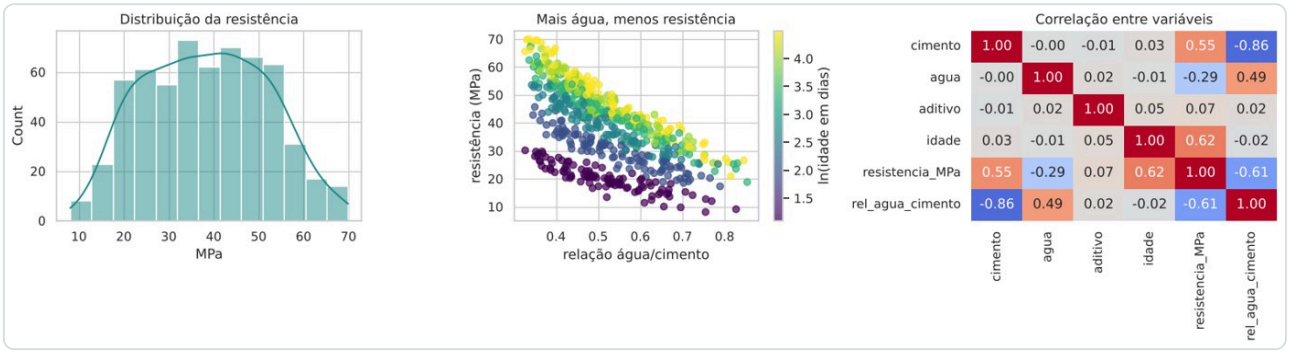


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(600 amostras de concreto simuladas; o **alvo** que queremos prever depois é a **resistência (MPa)**; as entradas são cimento, água, aditivo e idade)

- **Gráfico A, "Distribuição da resistência" (histograma):** horizontal = resistência (MPa), vertical = quantas amostras caem em cada faixa. As resistências vão de cerca de **8 a 70 MPa**, com a maior parte entre **20 e 60 MPa** e média perto de 40 MPa. Não há um valor dominante nem valores absurdos, então os dados parecem razoáveis para modelar.
- **Gráfico B, "Mais água, menos resistência" (dispersão):** horizontal = relação água/cimento, vertical = resistência (MPa), **cor** = logaritmo da idade (roxo = concreto novo, amarelo = concreto velho). A nuvem **desce** para a direita: quanto mais água por cimento, menor a resistência (Lei de Abrams). Para a mesma relação a/c, os pontos **amarelos ficam acima** dos roxos: concreto mais velho é mais resistente. A idade explica a "faixa" de cores.
- **Gráfico C, "Correlação entre variáveis" (mapa de calor):** cada quadrado é a correlação entre duas variáveis (de −1 a +1; vermelho = positiva forte, azul = negativa forte). A **resistência** correlaciona com **idade (0,62)**, **cimento (0,55)**, **relação a/c (−0,61)** e **água (−0,29)**; o aditivo quase não aparece (0,07). Cimento e relação a/c têm **−0,86** entre si: carregam informação parecida.
- **Atenção:** correlação mede se duas variáveis andam juntas em **linha reta**. A idade tem relação curva com a resistência (satura com o tempo), por isso o 0,62 subestima o quanto ela importa.

PERGUNTAS

1. Qual variável mais se relaciona com a resistência? A relação com a água/cimento é uma reta?
2. Por que a idade e a resistência não formam uma reta? (a resistência satura com o tempo)

RESPOSTAS COMENTADAS

1. Pela correlação do mapa de calor, as duas variáveis mais ligadas à resistência são a **idade** (+0,62) e a **relação água/cimento** (−0,61); o cimento tem +0,55. A relação com a água/cimento **não é uma reta**: segue a Lei de Abrams,

uma curva **exponencial** (cai rápido e depois mais devagar), por isso uma correlação "linear" de −0,61 subestima a força da relação.

2. O cimento continua reagindo com a água, mas **cada vez mais devagar**: a resistência sobe muito nos primeiros dias e depois **satura** (hidratação). Por isso o **logaritmo da idade** correlaciona mais (+0,75) do que a idade crua (+0,62), e usamos `log_idade` na seção 1.4.

NO COLAB · EXERCÍCIO 1.3 · REGRESSÃO: LINEAR X RANDOM FOREST

Problema	Prever a resistência (um **número**) a partir de cimento, água, aditivo e idade.
Dados	As 600 amostras: 75% para treino e 25% para teste.
Modelo / técnica	**Regressão linear** (uma soma ponderada das variáveis) x **Random Forest** (300 árvores).
Como medimos	**MAE** (erro médio em MPa) e **R^2** (fração da variação explicada; 1 é perfeito).
O que observar	O Random Forest erra bem menos (MAE ≈ 2,16 MPa, R^2 ≈ 0,96) que a reta (MAE ≈ 5,53 MPa). No gráfico, quanto mais perto da linha tracejada, melhor.
Nos slides	52

```
feats_civil = ["cimento", "agua", "aditivo", "idade"]       # variáveis de ENTRADA (X)
X = civil[feats_civil]                                       # tabela de entrada
y = civil["resistencia_MPa"]                                 # o que queremos PREVER (y)

# Regra de ouro: separar treino e teste ANTES de ajustar qualquer modelo
# 25% fica para teste
X_tr, X_te, y_tr, y_te = train_test_split(X, y, test_size=0.25, random_state=SEED)

modelos_civil = {
    "Regressão linear": LinearRegression(),                              # modelo 1: uma reta
    # modelo 2: 300 árvores
    "Random Forest": RandomForestRegressor(n_estimators=300, random_state=SEED),
}
res = []; prev = {}
for nome, m in modelos_civil.items():                        # repete para cada modelo
    m.fit(X_tr, y_tr)                                        # TREINAR com os dados de treino
    # PREVER a resistência dos dados de teste
    prev[nome] = m.predict(X_te)
    res.append({"Modelo": nome,
                "MAE (MPa)": mean_absolute_error(y_te, prev[nome]),    # erro médio
                # raiz do erro quadrático médio
                "RMSE (MPa)": np.sqrt(np.mean((y_te - prev[nome]) ** 2)),
                "R²": r2_score(y_te, prev[nome])})                     # ajuste (1 = perfeito)
tab_civil = pd.DataFrame(res).set_index("Modelo").round(3)
display(tab_civil)

# O que a regressão linear aprendeu: α (intercepto) e um β (peso) para cada variável
lin_civil = modelos_civil["Regressão linear"]
print("resistência = α + β1·cimento + β2·água + β3·aditivo + β4·idade")
print("α = %.2f MPa" % lin_civil.intercept_)
display(pd.DataFrame({"β": lin_civil.coef_}, index=feats_civil).round(4))
print("Cada β diz quanto a resistência muda (em MPa) quando a variável sobe 1 unidade e as outras ficam
fixas.")

# Gráfico: previsto x real (ponto na linha tracejada = previsão perfeita)
fig, axes = plt.subplots(1, 2, figsize=(11, 4.6), sharex=True, sharey=True)
for ax, (nome, p) in zip(axes, prev.items()):
    ax.scatter(y_te, p, alpha=0.5, color=TEAL)
    lim = [y_te.min(), y_te.max()]
    ax.plot(lim, lim, "--", color=RED, label="previsão perfeita")
    ax.set_title(nome); ax.set_xlabel("real (MPa)"); ax.set_ylabel("previsto (MPa)"); ax.legend()
plt.tight_layout(); plt.show()
```

Saída

```
                  MAE (MPa)  RMSE (MPa)     R²
Modelo
Regressão linear      5.526       6.567  0.767
Random Forest         2.160       2.669  0.962
resistência = α + β1·cimento + β2·água + β3·aditivo + β4·idade
α = 26.90 MPa

              β
cimento  0.1072
agua    -0.2038
aditivo  0.9715
idade    0.2680
Cada β diz quanto a resistência muda (em MPa) quando a variável sobe 1 unidade e as outras ficam
fixas.
```

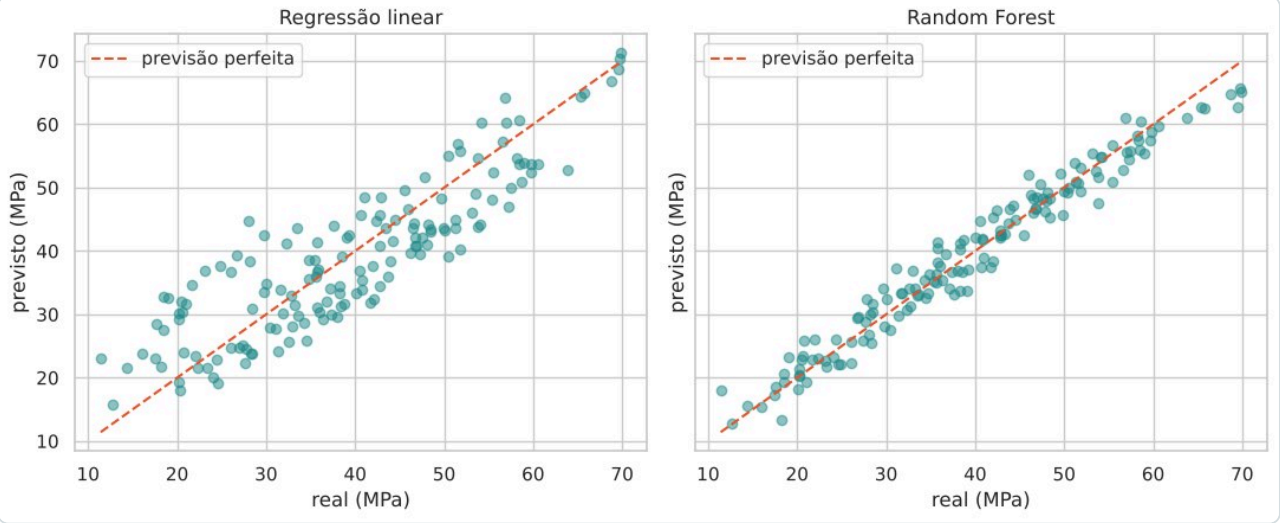


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(os dois painéis mostram as 150 amostras de **teste**, que os modelos não viram)

- **Como ler um gráfico "real x previsto":** horizontal = resistência **real** medida no ensaio (MPa); vertical = resistência **prevista** pelo modelo (MPa). A **linha tracejada** é a previsão perfeita (previsto = real). Quanto mais perto dela, melhor o modelo.
- **Painel "Regressão linear":** os pontos formam uma nuvem **larga** em volta da linha: erro médio (MAE) de **5,53 MPa**, R^2 de **0,767**. Para concreto de 30 MPa, o erro típico é de quase 20%.
- **Painel "Random Forest":** os pontos ficam **colados** na linha: MAE de **2,16 MPa** e R^2 de **0,962**. Ele captura as curvas (efeito da idade e da relação a/c) que a reta não captura.
- **Coeficientes da regressão linear (tabela acima):** o β diz quanto a resistência muda quando a variável sobe 1 unidade e as outras ficam fixas: **cimento +0,107 MPa**, **água −0,204 MPa**, **aditivo +0,97 MPa** e **idade +0,268 MPa** (por unidade de cada variável; a idade em dias). O α (26,90 MPa) é o ponto de partida da conta. Cuidado: o β da idade supõe crescimento **em linha reta** para sempre, o que o concreto não faz.
- **Na engenharia:** prever a resistência a partir do traço e da idade ajuda a decidir, por exemplo, quando desformar, sem esperar o ensaio de laboratório.

PERGUNTAS

1. Pelos β da regressão linear, o que mais pesa na resistência? E por que cuidado ao comparar β?
2. O Random Forest tem R^2 de 0,96 e a reta, 0,77. Isso quer dizer que a reta é inútil?

RESPOSTAS COMENTADAS

1. O **aditivo** tem o maior β (+0,97 MPa por 1 %), a **água** é negativa (−0,20 MPa por litro) e o cimento é positivo (+0,11 MPa por kg/m³). Cuidado: os β dependem da **unidade** de cada variável (litros, kg, % e dias), então não dá para comparar o tamanho deles diretamente. E a relação real é **curva** (Abrams), por isso a reta tem R^2 de só 0,77.

2. Não é inútil: ela entrega α e β **interpretáveis** e já capta a tendência. Mas, com as variáveis cruas, erra em média 5,5 MPa. A seção 1.4 mostra que, com variáveis escolhidas pela física, a mesma reta cai para 3,1 MPa.

Engenharia de atributos: dar ao modelo o que a física ensina

A engenharia sabe que o que importa é a **relação água/cimento** e o **logaritmo da idade**. Criando essas variáveis, o modelo linear melhora de MAE 5,53 MPa para **3,10 MPa** (R^2 de 0,77 para 0,93). O Random Forest descobre relações semelhantes sozinho, ao custo de ser menos interpretável.

NO COLAB · EXERCÍCIO 1.4 · ENGENHARIA DE ATRIBUTOS: DAR AO MODELO O QUE A FÍSICA ENSINA

Problema	Melhorar o modelo **linear** usando o conhecimento de engenharia.
Dados	As mesmas amostras, agora com novas variáveis: **relação água/cimento** e **logaritmo da idade**.
Modelo / técnica	**Regressão linear** com as novas variáveis; importância das variáveis no Random Forest.
Como medimos	MAE e R^2 no teste (comparar com a seção 1.3).
O que observar	A reta cai de MAE 5,53 para cerca de 3,10 MPa só com variáveis melhores: **conhecimento do domínio** vale.
Nos slides	52

```
civil["log_idade"] = np.log(civil["idade"])                    # cria a variável: logaritmo da idade
# novas entradas, escolhidas pela física
feats2 = ["rel_agua_cimento", "log_idade", "aditivo"]
# mesma divisão de antes
X2_tr, X2_te, _, _ = train_test_split(civil[feats2], y, test_size=0.25, random_state=SEED)
lin2 = LinearRegression().fit(X2_tr, y_tr)                     # treina de novo a regressão linear
p2 = lin2.predict(X2_te)                                       # previsões no teste
print("Linear com atributos de engenharia: MAE = %.2f MPa | RMSE = %.2f MPa | R² = %.3f" % (
      mean_absolute_error(y_te, p2), np.sqrt(np.mean((y_te - p2) ** 2)), r2_score(y_te, p2)))
print("α = %.2f MPa" % lin2.intercept_)
# pesos do modelo com variáveis de engenharia
display(pd.DataFrame({"β": lin2.coef_}, index=feats2).round(3))

# Quais variáveis o Random Forest mais usou?
imp = pd.Series(modelos_civil["Random Forest"].feature_importances_, index=feats_civil).sort_values()
imp.plot(kind="barh", color=TEAL, title="O que o Random Forest mais usou")
plt.show()
```

Saída

```
Linear com atributos de engenharia: MAE = 3.10 MPa | RMSE = 3.70 MPa | R² = 0.926
α = 48.82 MPa

                       β
rel_agua_cimento -71.112
log_idade          8.627
aditivo            1.466
```

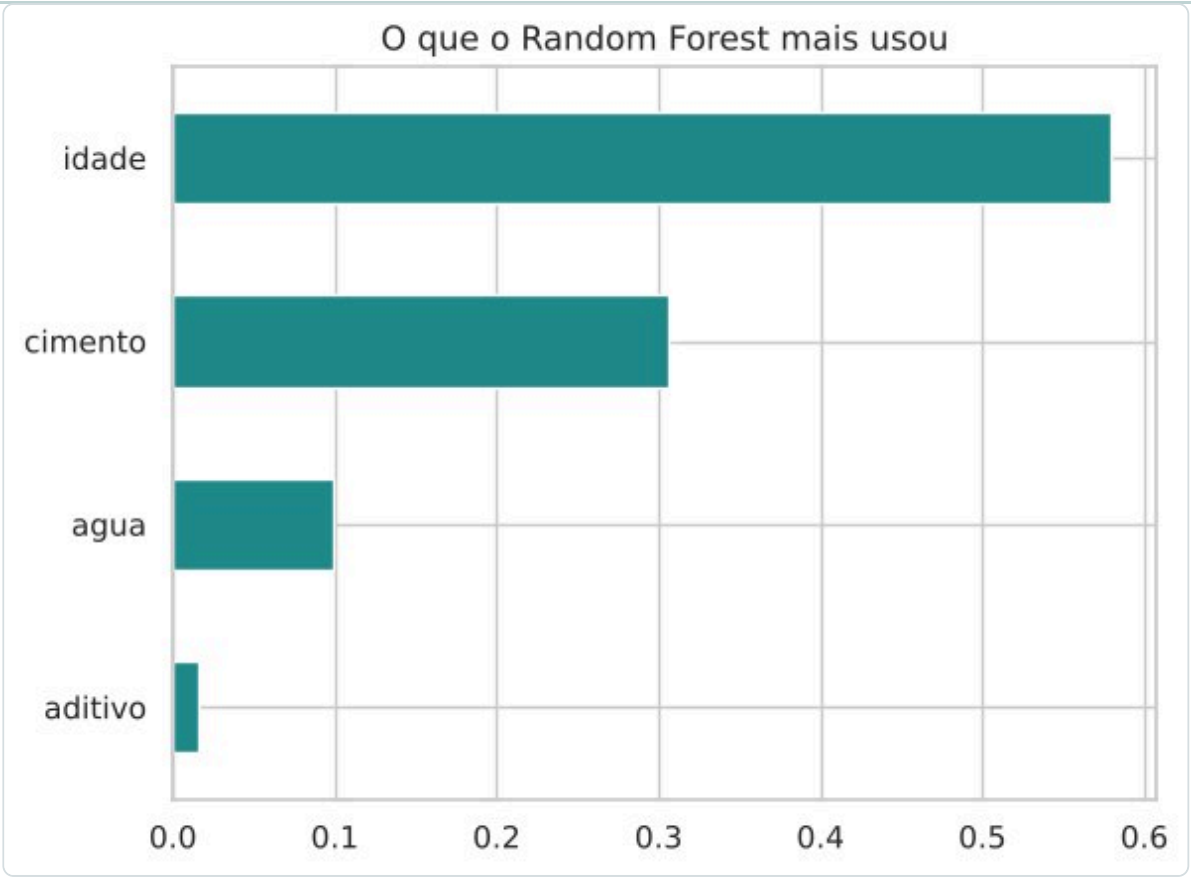


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(e dos números acima)

- **O que mudou nos números:** a regressão linear com os atributos de engenharia (relação **água/cimento** e **logaritmo da idade**) caiu de MAE **5,53 para 3,10 MPa** e subiu de R^2 **0,767 para 0,926**, só por receber variáveis que traduzem a física do problema.
- **O gráfico de barras ("O que o Random Forest mais usou"):** cada barra é a **importância** da variável nas decisões da floresta (as barras somam 1). A **idade** é a mais usada (≈ 0,58), depois o **cimento** (≈ 0,31), a **água** (≈ 0,10) e o **aditivo** (≈ 0,015, quase nada). Isso confirma o mapa de calor: idade e cimento mandam; o aditivo, neste conjunto, pouco contribui.
- **Cuidado:** importância mostra o que o modelo **usou**, não prova causa. Variáveis parecidas (cimento e relação a/c) dividem a importância entre si.

PERGUNTAS

1. O modelo linear melhorou ao receber a variável `rel_agua_cimento` ? O que isso diz sobre **conhecimento do domínio**?
2. O Random Forest descobriu sozinho essa relação? Qual a vantagem e qual o custo (interpretabilidade)?

RESPOSTAS COMENTADAS

1. Sim: o MAE caiu de 5,53 para ≈ 3,10 MPa e o R^2 subiu de 0,77 para 0,93, **sem mudar o algoritmo**, só os dados de entrada. O β de `rel_agua_cimento` é grande e negativo (≈ −71): mais água por cimento, menos resistência. Isso mostra o valor do **conhecimento do domínio**: a física já sabia qual variável importava.

2. Sim, quase: o Random Forest chegou a MAE ≈ 2,16 MPa **sem receber** a relação água/cimento pronta, porque faz muitos cortes e acompanha a curva. A **vantagem** é não precisar conhecer a fórmula. O **custo** é a interpretabilidade (não há um β por variável, só a importância) e a extrapolação ruim para valores fora da faixa vista no treino.

6. Bloco 2 · Engenharia de Produção: qualidade na linha

Onde implementar

Em linhas de injeção, usinagem ou montagem em que CLPs e sistemas de manufatura registram os parâmetros do processo. O modelo sinaliza a peça com **risco de defeito** antes da inspeção final, reduzindo refugo e retrabalho e direcionando a inspeção.

Pergunta	Dados	Técnica	Ganho
A peça sai boa ou defeituosa?	temperatura, pressão, velocidade, umidade, desgaste da ferramenta	Classificação (classes raras)	menos refugo e inspeção focada

Os dados (simulados)

2.500 peças; **11,6% com defeito**. O defeito cresce quando a temperatura ou a pressão saem da faixa ideal **em qualquer sentido** (tanto muito baixa quanto muito alta) e com o desgaste da ferramenta. Essa relação não é linear, e é isso que vai separar os modelos.

Três modelos e a armadilha da acurácia

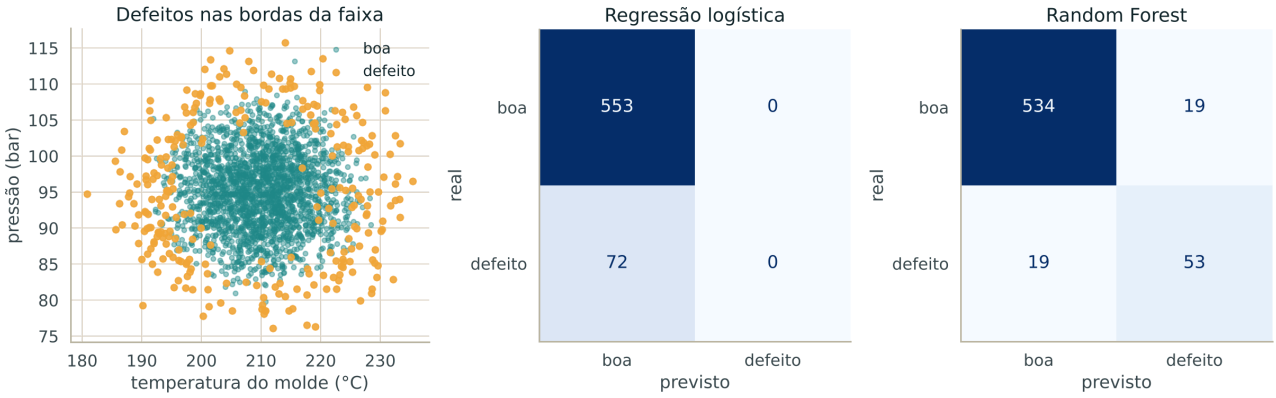


Figura 14. Esquerda: os defeitos ficam nas bordas da faixa ideal. Centro e direita: matrizes de confusão. A regressão logística (fronteira reta) não acha nenhum dos 72 defeitos; o Random Forest acha 53.

NO COLAB · EXERCÍCIO 2.2 · CLASSIFICAÇÃO E A ARMADILHA DA ACURÁCIA

Problema	Treinar três classificadores e ver por que a **acurácia sozinha engana**.
Dados	As 2.500 peças: 75% treino e 25% teste (625 peças, 72 defeituosas), com `stratify` para manter a proporção de defeitos.
Modelo / técnica	**Regressão logística**, **árvore de decisão** (profundidade 4) e **Random Forest** (300 árvores), com `class_weight="balanced"` (dá mais peso à classe rara).
Como medimos	Acurácia, **sensibilidade (recall)**, **precisão** e F1.
O que observar	A logística acerta 88,5% e acha **zero** defeitos (igual a dizer sempre "boa"). O Random Forest acha 53 dos 72.
Nos slides	54

```
# entradas (X)
feats_prod = ["temp_molde_C", "pressao_bar", "velocidade_m_s", "umidade_pct", "desgaste_h"]
# yp: 0 = boa, 1 = defeito
Xp = producao[feats_prod]; yp = producao["defeito"]
# stratify mantém a proporção
Xp_tr, Xp_te, yp_tr, yp_te = train_test_split(Xp, yp, test_size=0.25, stratify=yp, random_state=SEED)

acc_base = 1 - yp_te.mean()                     # acurácia de um "modelo" que SEMPRE diz "peça boa"
print("Acurácia de um 'modelo' que nunca prevê defeito: %.1f%%" % (100 * acc_base))

modelos_prod = {
    # fronteira reta
    "Regressão logística": make_pipeline(StandardScaler(), LogisticRegression(max_iter=1000)),
    "Árvore de decisão": DecisionTreeClassifier(max_depth=4, class_weight="balanced", random_state=SEED),
    "Random Forest": RandomForestClassifier(n_estimators=300, class_weight="balanced",
random_state=SEED),
}
linhas = []
for nome, m in modelos_prod.items():
    m.fit(Xp_tr, yp_tr)                         # treina
    pred = m.predict(Xp_te)                     # prevê "boa" (0) ou "defeito" (1) no teste
    linhas.append({"Modelo": nome,
                   # acertos no total
                   "Acurácia": accuracy_score(yp_te, pred),
                   # dos defeitos reais, quantos achou
                   "Recall (defeitos achados)": recall_score(yp_te, pred),
                   # dos alertas, quantos eram defeito
                   "Precisão (alertas certos)": precision_score(yp_te, pred, zero_division=0),
                   # das peças boas, quantas liberou
                   "Especificidade (boas liberadas)": recall_score(yp_te, pred, pos_label=0),
                   "F1": f1_score(yp_te, pred)})
tab_prod = pd.DataFrame(linhas).set_index("Modelo").round(3)
display(tab_prod)
```

Saída

```
Acurácia de um 'modelo' que nunca prevê defeito: 88.5%

                    Acurácia  Recall (defeitos achados)  \
Modelo
Regressão logística     0.885                      0.000
Árvore de decisão       0.896                      0.708
Random Forest           0.939                      0.736

                    Precisão (alertas certos)  \
Modelo
Regressão logística                      0.000
Árvore de decisão                        0.537
Random Forest                            0.736

                    Especificidade (boas liberadas)     F1
Modelo
Regressão logística                           1.000  0.000
Árvore de decisão                             0.920  0.611
Random Forest                                 0.966  0.736
```

```
# Matriz de confusão de cada modelo (linhas = real, colunas = previsto)
fig, axes = plt.subplots(1, 3, figsize=(15, 4.2))
for ax, (nome, m) in zip(axes, modelos_prod.items()):
    matriz(yp_te, m.predict(Xp_te), ax, [0, 1], ["boa", "defeito"], titulo=nome)
plt.tight_layout(); plt.show()
```

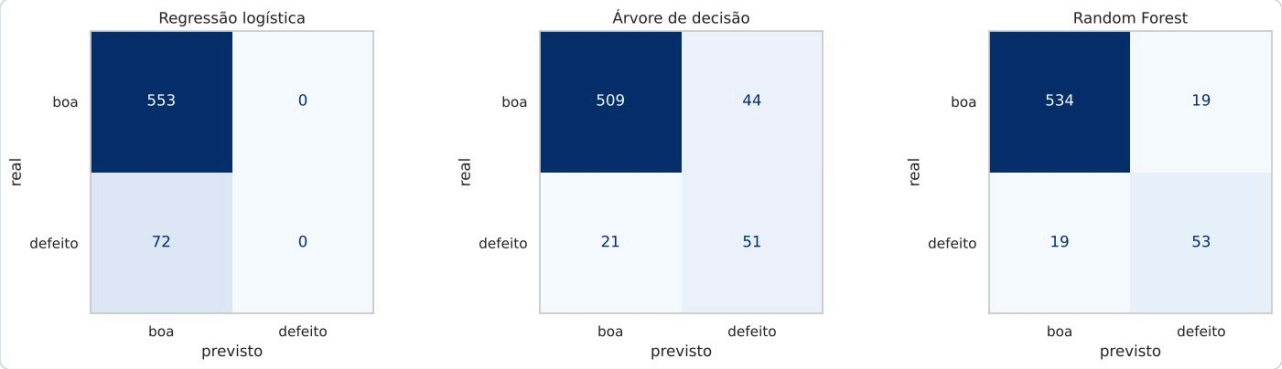


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(matrizes de confusão no teste: 625 peças, 72 defeituosas)

- **Como ler uma matriz: linhas** = o que a peça realmente é; **colunas** = o que o modelo previu. A diagonal (de cima à esquerda para baixo à direita) são os **acertos**; fora da diagonal, os erros. Números maiores têm fundo azul mais escuro.
- **Regressão logística:** acertou as 553 peças boas, mas **0 dos 72 defeitos**: previu "boa" sempre. A acurácia seria 88,5% (553/625) e o modelo seria **inútil**: essa é a armadilha da acurácia.
- **Árvore de decisão:** achou **51 dos 72** defeitos, mas gerou **44 falsos alarmes** (peças boas marcadas como defeito).
- **Random Forest:** achou **53 dos 72** defeitos e teve **19 falsos alarmes**: é o melhor equilíbrio entre os três.
- **Lição:** com classes raras, olhe a matriz e as métricas por classe, não só a acurácia.

PERGUNTAS

1. Por que a **regressão logística** não achou os defeitos? (dica: tanto temperatura *baixa* quanto *alta* causam defeito; uma reta não representa isso)
2. Na linha, o que custa mais: **deixar passar** uma peça defeituosa (falso negativo) ou **refugar** uma peça boa (falso positivo)? Isso muda a métrica e o limiar?

RESPOSTAS COMENTADAS

1. O defeito aparece nos **dois extremos**: temperatura muito baixa **ou** muito alta (e o mesmo para a pressão). A regressão logística só sabe fazer uma fronteira **reta** (quanto mais temperatura, mais risco, sempre no mesmo sentido), o que não separa esse padrão em "U". Como só ~11,6% das peças são defeituosas, o melhor palpite dela é "peça boa" para todas: acurácia 88,5%, **sensibilidade 0** (nenhum defeito achado).

2. Depende do **custo de cada erro**. Em peça de **segurança** (freio), deixar passar um defeito (**falso negativo**) pode causar acidente: priorize **sensibilidade** e use limiar baixo. Em uma peça barata, refugar uma peça boa (**falso positivo**) pode custar mais do que o defeito: priorize **precisão**. A métrica e o limiar devem refletir isso.

NO COLAB · EXERCÍCIO 2.1 · CRIAR E VISUALIZAR OS DADOS

Problema	Dizer se uma peça sai **boa** ou **defeituosa** a partir dos parâmetros do processo.
Dados	2.500 peças simuladas: temperatura do molde, pressão, velocidade, umidade e desgaste da ferramenta. Cerca de 11,6% têm defeito. O defeito aparece quando temperatura ou pressão saem da faixa ideal **em qualquer sentido**.
Modelo / técnica	Ainda não há modelo.
Como medimos	—
O que observar	Poucos defeitos (classes **desbalanceadas**) e defeitos nas **bordas** da faixa ideal, não em uma única direção.
Nos slides	47, 53 e 54

```
rng = np.random.default_rng(SEED)
n = 2500                                        # número de peças
temp_molde = rng.normal(210, 8, n)              # temperatura do molde, °C (média 210, desvio 8)
pressao = rng.normal(95, 6, n)                  # pressão, bar
velocidade = rng.normal(1.2, 0.15, n)           # velocidade de injeção, m/s
umidade = rng.normal(45, 8, n)                  # umidade, %
desgaste = rng.uniform(0, 500, n)               # horas de uso da ferramenta

# O defeito cresce quando temperatura ou pressão saem da faixa ideal (em qualquer sentido) e com o
# desgaste
z = (-9.5 + 0.03 * (temp_molde - 210) ** 2 + 0.04 * (pressao - 95) ** 2 + 0.006 * desgaste
     # "pontuação de risco" de cada peça
     + 0.5 * (velocidade - 1.2) / 0.15 + 0.03 * (umidade - 45))
# sorteia defeito (1) ou peça boa (0) conforme o risco
defeito = np.random.default_rng(1).binomial(1, 1 / (1 + np.exp(-z)))

producao = pd.DataFrame({"temp_molde_C": temp_molde, "pressao_bar": pressao, "velocidade_m_s":
velocidade,
                         "umidade_pct": umidade, "desgaste_h": desgaste, "defeito": defeito})
print("Peças:", len(producao), "| taxa de defeitos: %.1f%%" % (100 * producao["defeito"].mean()))
display(producao.head())
```

Saída

```
Peças: 2500 | taxa de defeitos: 11.6%

   temp_molde_C  pressao_bar  velocidade_m_s  umidade_pct  desgaste_h  defeito
0    212.437737    98.318461        1.161307    52.488905  390.724154        0
1    201.680127    96.493482        1.155077    27.622415  124.668426        0
2    216.003610   101.052010        1.095501    40.561659  410.420688        0
3    217.524518    97.906721        1.264272    44.563081   88.566775        0
4    194.391718   102.306351        1.235197    46.843917  179.736761        1
```

```
fig, axes = plt.subplots(1, 3, figsize=(16, 4.2))
# troca 0/1 por texto, para os gráficos
rot = producao["defeito"].map({0: "boa", 1: "defeito"})
# quantas peças de cada classe
sns.countplot(x=rot, hue=rot, palette=[TEAL, RED], legend=False, ax=axes[0])
axes[0].set_title("Classes desbalanceadas"); axes[0].set_xlabel("")
# boxplot da temperatura
sns.boxplot(data=producao, x=rot, y="temp_molde_C", hue=rot, palette=[TEAL, RED], legend=False,
ax=axes[1])
axes[1].set_title("Temperatura do molde"); axes[1].set_xlabel("")
sns.scatterplot(data=producao, x="temp_molde_C", y="pressao_bar", hue=rot,
                # dispersão temperatura x pressão
                palette={"boa": TEAL, "defeito": RED}, alpha=0.6, ax=axes[2])
axes[2].set_title("Defeitos nas bordas da faixa ideal"); axes[2].legend(title="")
plt.tight_layout(); plt.show()
```

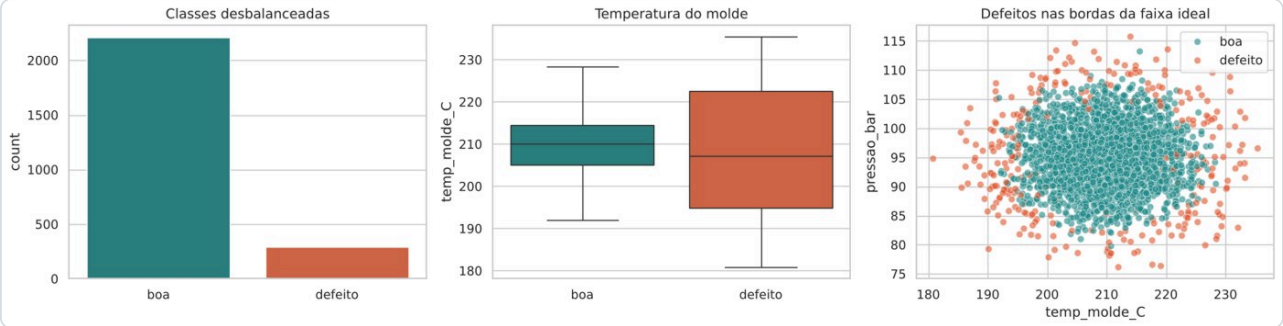


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(2.500 peças simuladas; queremos prever se a peça sai **boa** ou **defeituosa**)

- **Gráfico A, "Classes desbalanceadas":** horizontal = classe, vertical = quantidade de peças. Há cerca de **2.200 peças boas** contra cerca de **290 defeituosas** (≈ 11,6%). Defeitos são raros, e isso afeta como avaliamos o modelo (próximo exercício).
- **Gráfico B, "Temperatura do molde" (boxplot):** cada caixa mostra onde estão 50% das peças (a linha no meio é a mediana). As peças boas ficam numa caixa **estreita** (cerca de 205 a 215 °C). As defeituosas têm uma caixa **larga**, e a mediana é **parecida** com a das boas. Ou seja, o defeito **não** é "temperatura alta": ele aparece quando a temperatura sai da faixa para **cima ou para baixo**.
- **Gráfico C, "Defeitos nas bordas da faixa ideal" (dispersão):** horizontal = temperatura do molde (°C), vertical = pressão (bar). Pontos verde-azulados = peças boas, concentrados no **centro**; pontos **laranja** = defeitos, nas **bordas** (muito quente, muito frio, pressão muito alta ou muito baixa). Nenhuma reta separa essas classes, então modelos lineares vão ter dificuldade.
- **Na engenharia:** o processo tem uma **janela ideal**; sair dela, para qualquer lado, aumenta o defeito.

A regressão logística acerta 88,5% e encontra **zero** defeitos: é o mesmo que o modelo ingênuo. A árvore e a floresta capturam a relação não linear. A árvore pode ser lida como regras, o que ajuda a explicar a decisão a um gestor:

As métricas completas deste modelo (acurácia 93,9%, precisão e sensibilidade de 73,6%, especificidade de 96,6% e AUC de 0,96) e a curva ROC estão na seção 4.2; no notebook, são as seções 2.3 e 2.4.

Validação cruzada e limiar de decisão

Na validação cruzada (5 partes), o recall médio foi de **0,862 ± 0,048** para a árvore e **0,848 ± 0,042** para o Random Forest. O limiar de decisão define o equilíbrio entre achar defeitos e gerar alarmes falsos:

Limiar	Recall	Precisão	Peças sinalizadas
0,2	0,90	0,56	116
0,3	0,88	0,62	102
0,4	0,82	0,71	83
0,5	0,74	0,73	73
0,6	0,60	0,78	55
0,7	0,53	0,81	47

NO COLAB · EXERCÍCIO 2.3 · INTERPRETAR A ÁRVORE, VALIDAR E AJUSTAR O LIMIAR

Problema	Explicar a decisão a um gestor, conferir se o resultado é estável e escolher quando emitir o alerta.
Dados	Os mesmos dados e modelos do passo 2.2.
Modelo / técnica	Árvore lida como regras "se... então..."; **validação cruzada** (5 partes); **limiar de decisão** do Random Forest.
Como medimos	Recall médio ± desvio na validação cruzada; recall e precisão para cada limiar.
O que observar	Limiar baixo acha mais defeitos, mas gera mais alarmes falsos; limiar alto faz o contrário.
Nos slides	54

```
arvore = modelos_prod["Árvore de decisão"]
print(export_text(arvore, feature_names=feats_prod, max_depth=3))    # a árvore escrita como regras

# Validação cruzada: repete treino/teste em 5 divisões diferentes. O resultado é confiável?
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=SEED)
for nome in ["Árvore de decisão", "Random Forest"]:
    # recall em cada uma das 5 divisões
    s = cross_val_score(modelos_prod[nome], Xp, yp, cv=cv, scoring="recall")
    # média ± desvio (desvio grande = instável)
    print("%-18s recall médio = %.3f ± %.3f" % (nome, s.mean(), s.std()))

# Limiar de decisão: o modelo dá uma PROBABILIDADE de defeito; o limiar decide quando alertar
# probabilidade de defeito de cada peça
prob = modelos_prod["Random Forest"].predict_proba(Xp_te)[:, 1]
lin = []
for lim in (0.2, 0.3, 0.4, 0.5, 0.6, 0.7):
    pred = (prob >= lim).astype(int)            # alerta se a probabilidade passar do limiar
    lin.append({"limiar": lim, "recall": recall_score(yp_te, pred),
                "precisão": precision_score(yp_te, pred, zero_division=0), "alarmes": int(pred.sum())})
display(pd.DataFrame(lin).round(3))
```

Saída

```
|--- temp_molde_C <= 198.63
|   |--- temp_molde_C <= 194.63
|   |   |--- velocidade_m_s <= 0.98
|   |   |   |--- class: 0
|   |   |--- velocidade_m_s >  0.98
|   |   |   |--- desgaste_h <= 50.20
|   |   |   |   |--- class: 0
|   |   |   |--- desgaste_h >  50.20
|   |   |   |   |--- class: 1
|   |--- temp_molde_C >  194.63
|   |   |--- pressao_bar <= 87.03
|   |   |   |--- desgaste_h <= 19.61
|   |   |   |   |--- class: 0
|   |   |   |--- desgaste_h >  19.61
|   |   |   |   |--- class: 1
|   |   |--- pressao_bar >  87.03
|   |   |   |--- pressao_bar <= 101.52
|   |   |   |   |--- class: 0
|   |   |   |--- pressao_bar >  101.52
|   |   |   |   |--- class: 1
|--- temp_molde_C >  198.63
|   |--- temp_molde_C <= 221.93
...
```

PERGUNTAS

que limiar você escolheria numa linha de **peças de segurança** (freios)? E numa linha de **embalagens** simples?

RESPOSTAS COMENTADAS

Freios: limiar baixo, em torno de **0,2**: sensibilidade ≈ 0,90 (acha 9 em cada 10 defeitos), ao custo de precisão ≈ 0,56 (116 peças sinalizadas para 72 defeituosas). Inspecionar peças a mais é barato perto de um acidente.

Embalagens: limiar mais alto, em torno de **0,5 a 0,6**: precisão ≈ 0,73 a 0,78 e bem menos alarmes (73 a 55), ao custo de achar menos defeitos (sensibilidade 0,74 a 0,60). Um defeito eventual custa pouco; muitos alarmes falsos atrapalham a produção.

7. Bloco 3 · Engenharia Elétrica: motores, perfis e anomalias

Onde implementar

Em motores, transformadores e painéis com sensores de corrente, vibração e temperatura. Na manutenção preditiva, **falhas são raras e poucos casos têm rótulo**; por isso o aprendizado não supervisionado descobre os regimes de operação e sinaliza o que foge do padrão, antes da falha.

Pergunta	Dados	Técnica	Ganho
Quantos regimes existem? O que é anormal?	rotação, corrente, vibração, temperatura	k-means e Isolation Forest	alerta antes da falha e menos paradas

Os dados (simulados)

1.200 leituras de motores em três regimes de carga (baixa, média e alta), com 12,4% de falhas, mais a série de vibração de um motor ao longo de 300 horas, com desgaste crescente e três picos anômalos injetados.

NO COLAB · EXERCÍCIO 3.1 · CRIAR OS DADOS (SIMULADOS)

Problema	Descobrir **quantos regimes de operação** existem nos motores e **quais leituras são anormais**.
Dados	1.200 leituras de motores em 3 regimes de carga (baixa, média, alta): rotação, corrente, vibração, temperatura e falha (12,4%).
Modelo / técnica	Ainda não há modelo.
Como medimos	—
O que observar	A coluna `regime` existe, mas **não será mostrada aos algoritmos**: serve só para conferirmos depois.
Nos slides	55 e 56

```
rng = np.random.default_rng(SEED)
n = 1200                                                              # número de leituras
# regime de carga de cada leitura (40%, 35%, 25%)
regime = rng.choice(["baixa", "media", "alta"], size=n, p=[0.4, 0.35, 0.25])
# (rotação rpm, corrente A) típicas de cada regime
base = {"baixa": (1200, 8.0), "media": (1800, 12.0), "alta": (2400, 17.0)}
# rotação = valor típico + variação
rpm = np.array([base[r][0] for r in regime]) + rng.normal(0, 60, n)
# corrente = valor típico + variação
corrente = np.array([base[r][1] for r in regime]) + rng.normal(0, 0.8, n)
# desgaste: existe, mas NÃO é medido
desgaste_oculto = rng.gamma(shape=2.0, scale=0.5, size=n)
# vibração (mm/s) sobe com rpm e desgaste
vibracao = 1.0 + 0.0006 * rpm + 1.2 * desgaste_oculto + rng.normal(0, 0.25, n)
# temperatura (°C)
temperatura = 40 + 0.012 * rpm + 6.0 * desgaste_oculto + rng.normal(0, 2.0, n)
z = -18.0 + 2.0 * vibracao + 0.12 * temperatura                        # risco de falha
falha = rng.binomial(1, 1 / (1 + np.exp(-z)))                          # falha (1) ou não (0)

motores = pd.DataFrame({"regime": regime, "rpm": rpm, "corrente_A": corrente,
                        "vibracao_mm_s": vibracao, "temperatura_C": temperatura, "falha": falha})
print(motores.shape, "| falhas: %.1f%%" % (100 * motores["falha"].mean()))
display(motores.head())
```

Saída

```
(1200, 6) | falhas: 12.4%

  regime          rpm  corrente_A  vibracao_mm_s  temperatura_C  falha
0   alta  2340.890518   19.025524       4.673497      80.999072      1
1  media  1748.349499   13.184079       3.909073      69.807805      1
2   alta  2547.445446   17.895518       3.596572      77.994790      0
3  media  1908.104517   11.689770       4.129312      68.764978      0
4  baixa  1175.295035    7.293440       2.911464      60.466394      0
```

Visualizar: quais variáveis andam juntas?

O mapa de calor da correlação mostra que **rotação e corrente** são quase a mesma informação (correlação 0,97): variáveis redundantes. Vibração e temperatura crescem juntas com o desgaste.

NO COLAB · EXERCÍCIO 3.2 · VISUALIZAR: SÉRIE TEMPORAL, RELAÇÕES E CORRELAÇÃO	
Problema	Olhar os dados de sensores antes de agrupar: como a **vibração** muda no tempo, como **vibração e temperatura** se relacionam em cada regime e quais variáveis andam juntas.
Dados	Uma **série temporal** de um motor (vibração em 300 horas, com desgaste crescente e 3 picos injetados) e a tabela `motores`.
Modelo / técnica	Gráficos: série temporal, dispersão por regime e mapa de calor.
Como medimos	—
O que observar	A vibração tem tendência de alta (desgaste) e 3 picos. Rotação e corrente têm correlação 0,97 (informação redundante).
Nos slides	47, 48 e 56

```
# Série temporal de UM motor: vibração ao longo de 300 horas
t = np.arange(300)                                          # horas 0, 1, ..., 299
rng_t = np.random.default_rng(7)
# tendência de desgaste + ruído
serie = pd.DataFrame({"hora": t, "vibracao": 2.0 + 0.004 * t + rng_t.normal(0, 0.12, t.size)})
# coluna que marca onde injetamos picos (só para conferir)
serie["anomalia_real"] = 0
for i in (80, 170, 245):                                    # 3 picos nas horas 80, 170 e 245
    serie.loc[i, "vibracao"] += rng_t.uniform(1.0, 1.6)
    serie.loc[i, "anomalia_real"] = 1

fig, axes = plt.subplots(1, 2, figsize=(15, 4.2), gridspec_kw={"width_ratios": [1.6, 1]})
axes[0].plot(serie["hora"], serie["vibracao"], color=NAVY, lw=1)                # a série
axes[0].set_title("Vibração de um motor ao longo do tempo"); axes[0].set_xlabel("hora");
axes[0].set_ylabel("mm/s")
sns.scatterplot(data=motores, x="vibracao_mm_s", y="temperatura_C", hue="regime",
                # dispersão colorida pelo regime
                hue_order=["baixa", "media", "alta"], palette=[TEAL, ORANGE, RED], alpha=0.6, ax=axes[1])
axes[1].set_title("Vibração x temperatura por regime")
plt.tight_layout(); plt.show()
```

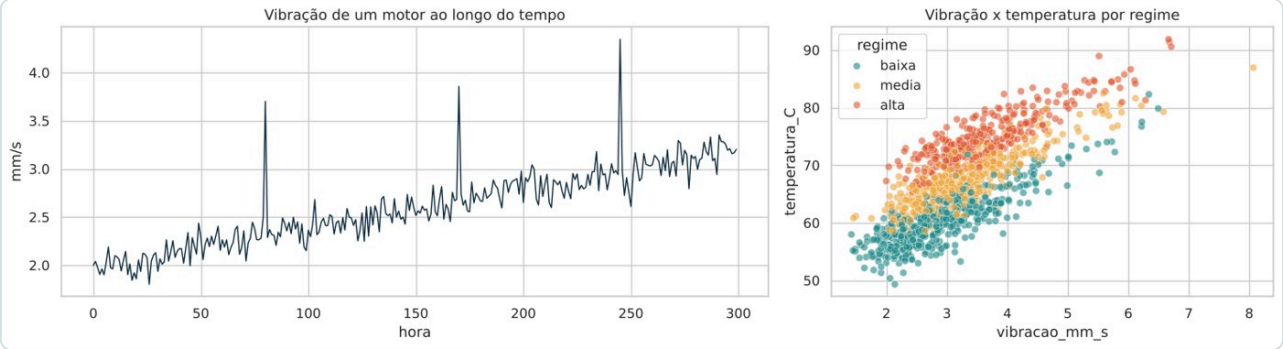


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(dados de motores elétricos simulados)

- **Gráfico da esquerda, "Vibração de um motor ao longo do tempo":** horizontal = hora (0 a 300), vertical = vibração (mm/s). A linha **sobe devagar** (de cerca de 2,0 para 3,2 mm/s): é o desgaste natural. Os **3 picos** perto das horas 80, 170 e 245 são eventos anormais, e são eles que queremos detectar.
- **Gráfico da direita, "Vibração x temperatura por regime":** horizontal = vibração, vertical = temperatura (°C); cor = regime de carga (**baixa**, **média**, **alta**). A nuvem sobe para a direita: mais vibração, mais temperatura. Os regimes aparecem em camadas (alta carga no alto), mas se **sobrepõem** nas bordas, e é isso que o algoritmo vai tentar separar sem ver a coluna "regime".

```
cols_m = ["rpm", "corrente_A", "vibracao_mm_s", "temperatura_C"]      # as 4 medidas do motor
plt.figure(figsize=(5.2, 4.2))
sns.heatmap(motores[cols_m].corr(), annot=True, fmt=".2f", cmap="BuGn", vmin=0, vmax=1, linewidths=.5,
            # correlação entre pares
            xticklabels=["rpm", "corrente", "vibração", "temp."], yticklabels=["rpm", "corrente",
"vibração", "temp."])
plt.title("Correlação entre variáveis do motor"); plt.show()
```

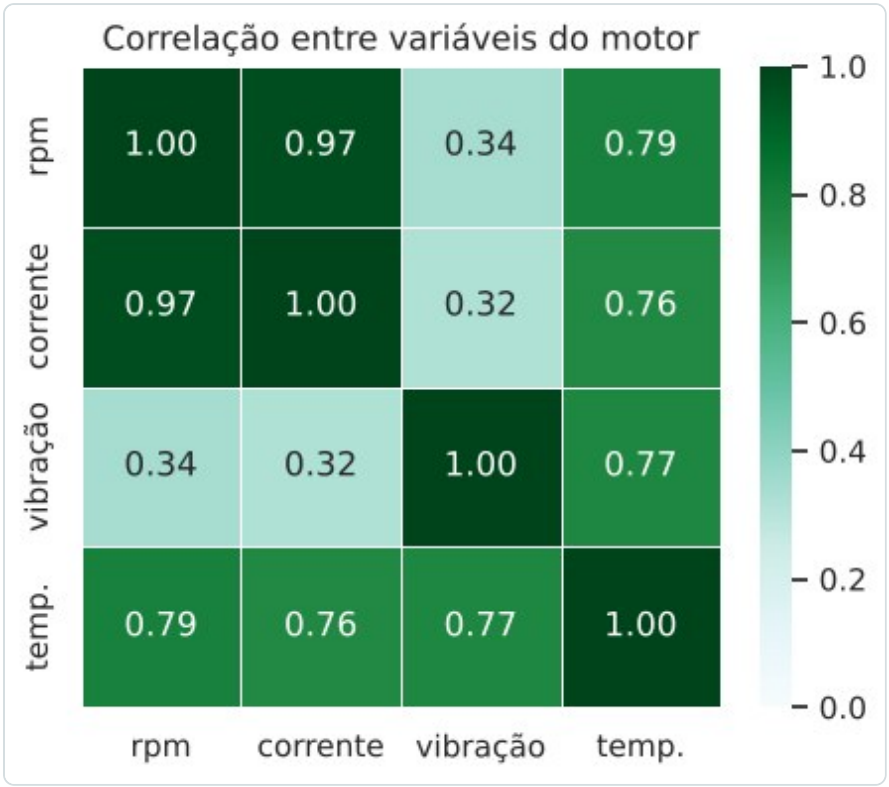


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

("Correlação entre variáveis do motor")

- **Como ler:** cada quadrado é a correlação entre duas variáveis (0 a 1 aqui; verde-escuro = andam juntas). A diagonal é sempre 1,00 (cada variável com ela mesma).
- **rpm e corrente: 0,97.** Quase a **mesma informação**: motor que gira mais puxa mais corrente. Usar as duas é redundante.
- **Temperatura:** correlaciona com rpm (**0,79**), corrente (**0,76**) e vibração (**0,77**): é a variável que "resume" o estado do motor.
- **Vibração e rpm: 0,34.** A vibração depende pouco da rotação e carrega informação **própria**, útil para achar anomalias.

k-means: descobrir regimes sem rótulos

O algoritmo vê apenas as quatro medidas (rotação, corrente, vibração e temperatura), não a coluna `regime`. A inércia (cotovelo) sugere k = 3; a silhueta, curiosamente, é maior com k = 2 (0,476 contra 0,435). **Nenhuma métrica decide sozinha**: aqui o conhecimento do domínio, três regimes de carga, pesa na escolha.

NO COLAB · EXERCÍCIO 3.3 · K-MEANS: DESCOBRIR REGIMES SEM RÓTULOS

Problema	Descobrir **quantos grupos (regimes)** existem, sem usar a coluna `regime`.
Dados	As 4 medidas do motor (rotação, corrente, vibração, temperatura), padronizadas.
Modelo / técnica	**k-means**: escolhe *k* centros, atribui cada ponto ao centro mais próximo e repete.
Como medimos	**Cotovelo** (inércia) e **silhueta** para escolher *k*; **Rand ajustado** para comparar com os regimes reais (1,0 = idênticos).
O que observar	O cotovelo sugere k = 3 (silhueta maior em k = 2: nenhuma métrica decide sozinha). Rand ajustado ≈ 0,79.
Nos slides	45 e 56

```
# padroniza (mesma escala)
Xk = StandardScaler().fit_transform(motores[["rpm", "corrente_A", "vibracao_mm_s", "temperatura_C"]])

# Testar vários valores de k (2 a 8) e medir o cotovelo (inércia) e a silhueta
ks = range(2, 9)
inercia, silh = [], []
for k in ks:
    # treina o k-means com k grupos
    km_k = KMeans(n_clusters=k, n_init=10, random_state=SEED).fit(Xk)
    # quão "apertados" estão os grupos
    inercia.append(km_k.inertia_)
    # quão separados estão os grupos
    silh.append(silhouette_score(Xk, km_k.labels_))

fig, axes = plt.subplots(1, 2, figsize=(11, 3.8))
axes[0].plot(list(ks), inercia, "o-", color=TEAL); axes[0].set_title("Método do cotovelo (inércia)");
axes[0].set_xlabel("k")
axes[1].plot(list(ks), silh, "o-", color=ORANGE); axes[1].set_title("Silhueta (maior é melhor)");
axes[1].set_xlabel("k")
plt.tight_layout(); plt.show()

# Escolhemos k = 3 (cotovelo + conhecimento do domínio: três regimes de carga)
km = KMeans(n_clusters=3, n_init=10, random_state=SEED).fit(Xk)
# grupo encontrado para cada leitura
motores["grupo"] = km.labels_
print("Tabela cruzada: grupo encontrado x regime verdadeiro (que o algoritmo não viu)")
display(pd.crosstab(motores["grupo"], motores["regime"]))
print("Índice de Rand ajustado: %.3f (1,0 = grupos idênticos aos regimes)" %
adjusted_rand_score(motores["regime"], motores["grupo"]))
# quão bem separados e compactos
print("Silhueta com k = 3: %.3f | Inércia: %.0f" % (silhouette_score(Xk, km.labels_), km.inertia_))
print("\nPerfil médio de cada grupo (valores originais) e taxa de falhas:")
display(motores.groupby("grupo").agg(rpm=("rpm", "mean"), corrente_A=("corrente_A", "mean"),
vibracao_mm_s=("vibracao_mm_s", "mean"),
                                     temperatura_C=("temperatura_C", "mean"), taxa_falha=("falha",
"mean"), n=("falha", "size")).round(2))

plt.figure(figsize=(6.5, 4.6))
sns.scatterplot(data=motores, x="rpm", y="corrente_A", hue="grupo", palette="Set2", alpha=0.7)
plt.title("k-means (k = 3) em rotação x corrente"); plt.show()
```

Saída

```
Tabela cruzada: grupo encontrado x regime verdadeiro (que o algoritmo não viu)

regime  alta  baixa  media
grupo
0          0    427     11
1          0     51    375
2        311      0     25
Índice de Rand ajustado: 0.792 (1,0 = grupos idênticos aos regimes)
Silhueta com k = 3: 0.435 | Inércia: 1508

Perfil médio de cada grupo (valores originais) e taxa de falhas:

            rpm  corrente_A  vibracao_mm_s  temperatura_C  taxa_falha    n
grupo
0       1207.92        8.15           2.68          59.13        0.01  438
1       1726.86       11.54           3.35          67.08        0.12  426
2       2353.67       16.61           3.82          75.31        0.28  336
```

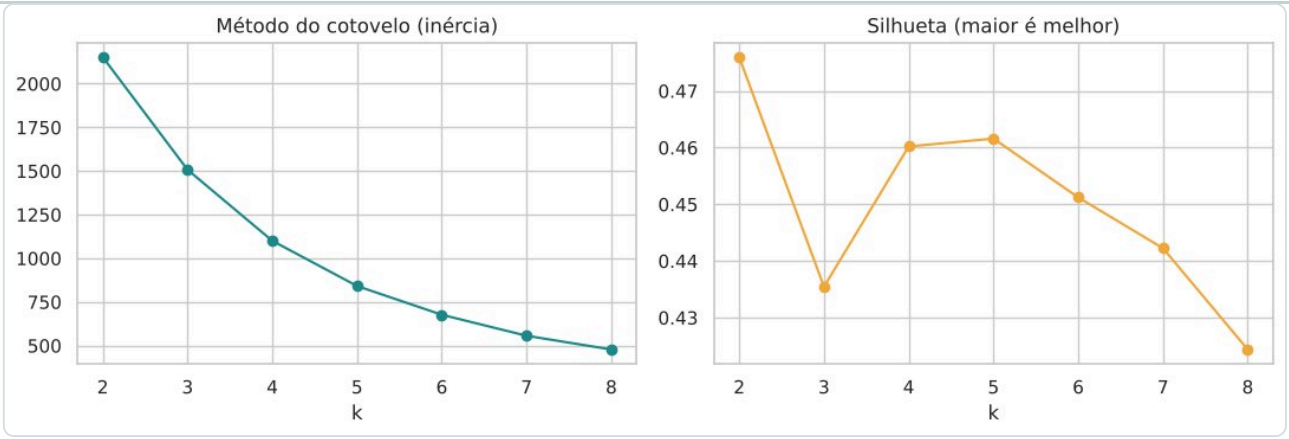


Gráfico gerado pela célula acima no Colab

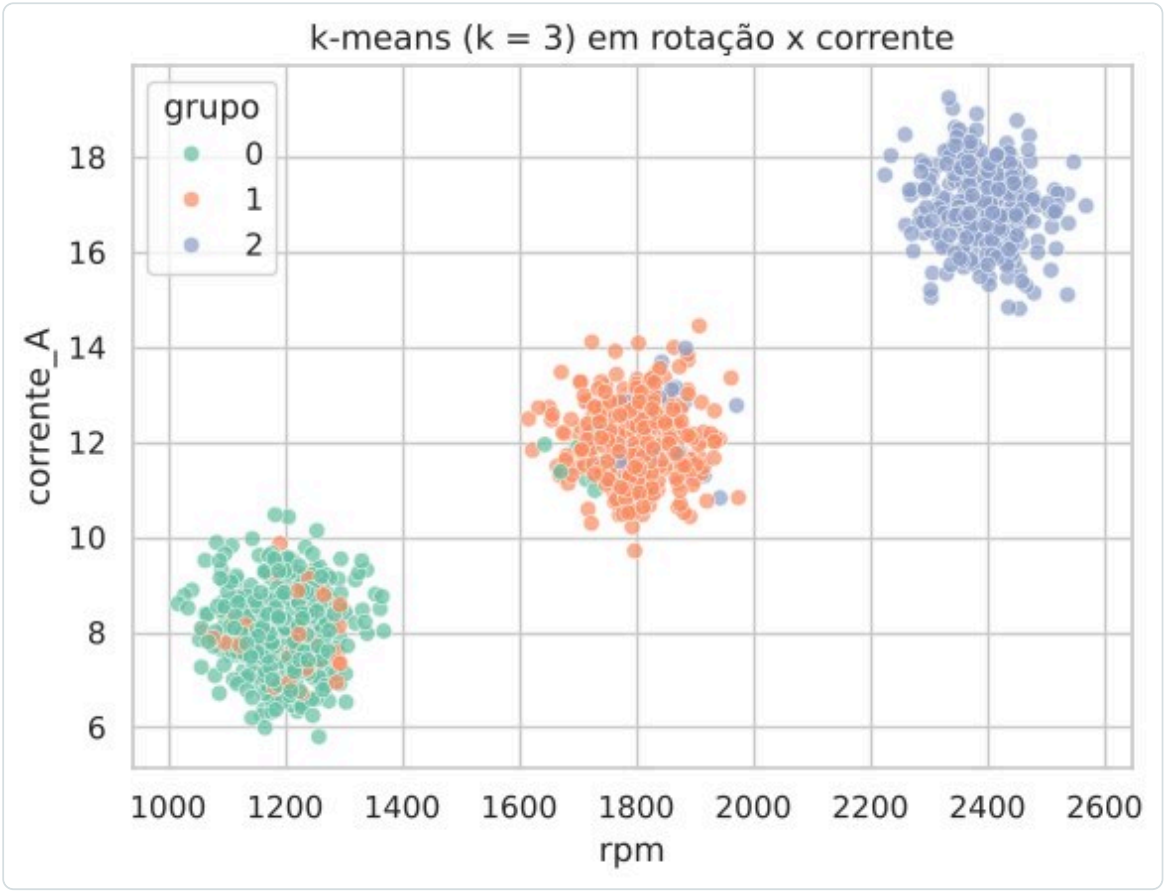


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(k-means sem usar a coluna "regime")

- **Gráfico "Método do cotovelo (inércia)":** horizontal = número de grupos k, vertical = inércia (o quanto os pontos ficam longe do centro do seu grupo; menor é melhor). Ela despenca de k = 2 até 3 ou 4 e depois **cai devagar**: o "cotovelo" sugere 3 ou 4 grupos.
- **Gráfico "Silhueta":** mede quão bem separados estão os grupos (maior é melhor). O maior valor é em k = 2 (0,48), mas k = 3 (0,435) e k = 5 (0,46) são parecidos. **A escolha de k = 3 vem da engenharia**: sabemos que o motor trabalha em 3 cargas (baixa, média, alta).
- **Gráfico "k-means (k = 3) em rotação x corrente":** cada ponto é uma leitura, cor = grupo encontrado. Três nuvens bem separadas: grupo 0 (≈ 1.200 rpm e 8 A), grupo 1 (≈ 1.800 rpm e 12 A) e grupo 2 (≈ 2.400 rpm e 17 A). Os poucos pontos de cor "errada" no meio de outra nuvem são leituras em que o k-means (que usa as 4 variáveis) discordou do regime verdadeiro. O índice de Rand de **0,79** resume essa concordância (1,0 = idêntico).
- **Tabela de perfil:** o grupo de maior carga tem **28%** de falhas, contra **12%** no médio e **1%** no baixo. Os grupos descobertos têm significado na manutenção.

PERGUNTAS

Atenção ao escolher k: a silhueta é maior com k = 2 e o cotovelo sugere 3. **Nenhuma métrica decide sozinha**: aqui o conhecimento do domínio (três regimes de carga) pesa na escolha.

que *perfil de operação* cada grupo representa? Algum grupo concentra mais falhas? (compare `motores.groupby("grupo")["falha"].mean()`)

RESPOSTAS COMENTADAS

Pela tabela de perfil médio (e pelo cruzamento com os regimes): o **grupo 0** é a **baixa carga** (≈ 1.208 rpm, 8,2 A, vibração 2,7 mm/s, 59 °C) com **0,9%** de falhas; o **grupo 1** é a **carga média** (≈ 1.727 rpm, 11,5 A) com **12%**; o **grupo 2** é a **alta carga** (≈ 2.354 rpm, 16,6 A, 75 °C) com **28%**. A falha **concentra-se na alta carga**: é onde a manutenção preditiva rende mais.

Sobre k: a silhueta (0,48 com k = 2, contra 0,44 com k = 3) prefere 2 grupos porque baixa e média carga formam uma "nuvem" contínua. O cotovelo e o conhecimento de domínio (3 regimes de carga) pesaram para escolher k = 3. **Nenhuma métrica decide sozinha.**

Os grupos recuperam bem os regimes (índice de Rand ajustado de 0,79). A taxa de falhas por grupo é de **0,9%** (grupo 0, baixa carga), **12%** (grupo 1) e **28%** (grupo 2, alta carga): o agrupamento revelou onde o risco se concentra.

Agrupamento hierárquico

O agrupamento hierárquico (método de Ward) junta os motores mais parecidos, passo a passo, e mostra o resultado em um **dendrograma**: cortar a árvore em uma altura dá o número de grupos, sem fixar k antes. Na Figura 10 (seção 4.4) aparece o dendrograma de 18 motores sorteados.

NO COLAB · EXERCÍCIO 3.4 · AGRUPAMENTO HIERÁRQUICO: O DENDROGRAMA

Problema	Ver como os motores se parecem, **sem fixar o número de grupos** antes.
Dados	18 motores sorteados entre as 1.200 leituras (para o gráfico ficar legível).
Modelo / técnica	**Agrupamento hierárquico** (método de Ward): junta os mais parecidos, passo a passo.
Como medimos	Altura do corte no **dendrograma**.
O que observar	Cortar a árvore em uma altura define o número de grupos. Motores juntos na base são muito parecidos.
Nos slides	45 e 56

```
idx18 = np.random.default_rng(4).choice(len(Xk), 18, replace=False)      # sorteia 18 motores
# calcula a hierarquia de junções (método de Ward)
L = linkage(Xk[idx18], method="ward")
fig, ax = plt.subplots(figsize=(9, 3.8))
dendrogram(L, ax=ax, color_threshold=0.45 * L[:, 2].max(), above_threshold_color="#9AA7AD",
           # desenha o dendrograma (cores = grupos ao cortar)
           labels=[str(i + 1) for i in range(18)])
ax.set_title("Hierárquico: dendrograma de 18 motores"); ax.set_xlabel("Motor (número)");
ax.set_ylabel("Distância entre grupos"); limpa(ax)
plt.show()

# Métricas: o mesmo corte em 3 grupos, aplicado às 1.200 leituras
from sklearn.cluster import AgglomerativeClustering
# hierárquico (Ward) cortado em 3 grupos
hier = AgglomerativeClustering(n_clusters=3, linkage="ward").fit(Xk)
print("Hierárquico (3 grupos): Rand ajustado = %.3f | silhueta = %.3f" % (
      adjusted_rand_score(motores["regime"], hier.labels_), silhouette_score(Xk, hier.labels_)))
print("k-means      (3 grupos): Rand ajustado = %.3f | silhueta = %.3f" % (
      adjusted_rand_score(motores["regime"], km.labels_), silhouette_score(Xk, km.labels_)))
```

Saída

```
Hierárquico (3 grupos): Rand ajustado = 0.957 | silhueta = 0.434
k-means      (3 grupos): Rand ajustado = 0.792 | silhueta = 0.435
```

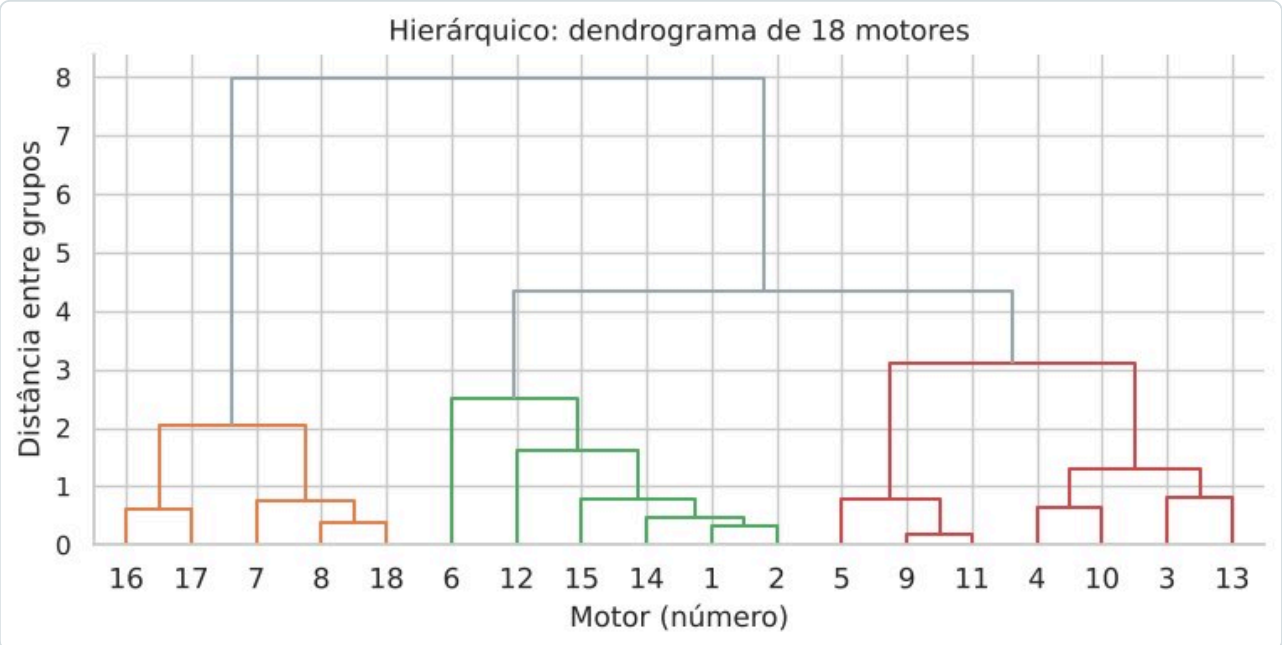


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(dendrograma de 18 motores)

- **Eixos:** horizontal = número de cada motor; vertical = **distância** entre grupos no momento em que eles se juntam. Cada "U" invertido é uma fusão.
- **Como ler:** motores que se juntam **embaixo** (distância pequena, por exemplo 16 e 17) são **muito parecidos**. Quanto mais alto o "U", mais diferentes eram os grupos que se uniram.
- **Onde cortar:** uma linha horizontal entre as alturas 3,2 e 4,4 corta o gráfico em **3 grupos** (laranja, verde e vermelho). O grande salto entre as junções (4 para 8) mostra que os grupos finais são bem distintos.
- **Resultado no exercício:** com 3 grupos, o hierárquico concorda com os regimes verdadeiros (Rand **0,957**), melhor que o k-means (0,792), com silhuetas iguais (0,434 e 0,435).

PERGUNTAS

1. O hierárquico teve Rand ajustado de 0,96 e o k-means de 0,79, com a mesma silhueta. Qual é "o certo"?
2. Como ler o dendrograma?

RESPOSTAS COMENTADAS

1. Nenhum é "o certo". Os dois usam **critérios diferentes** (o k-means minimiza a distância aos centros; o Ward junta os grupos que menos aumentam a variância) e o **Rand ajustado** só mede a concordância com os regimes que **conhecemos**. Como as silhuetas são iguais (0,43), nenhuma métrica interna prefere um deles. Em dados reais não existe o gabarito `regime`: por isso se comparam métodos e se valida com o domínio.

2. Cada **junção** é um par de grupos que se fundem; a **altura** da junção é a distância entre eles. Motores que se juntam **baixo** são muito parecidos. **Cortar** o dendrograma em uma altura define os grupos (as cores). Saltos grandes de altura sugerem um bom ponto de corte.

Isolation Forest: o que foge do padrão?

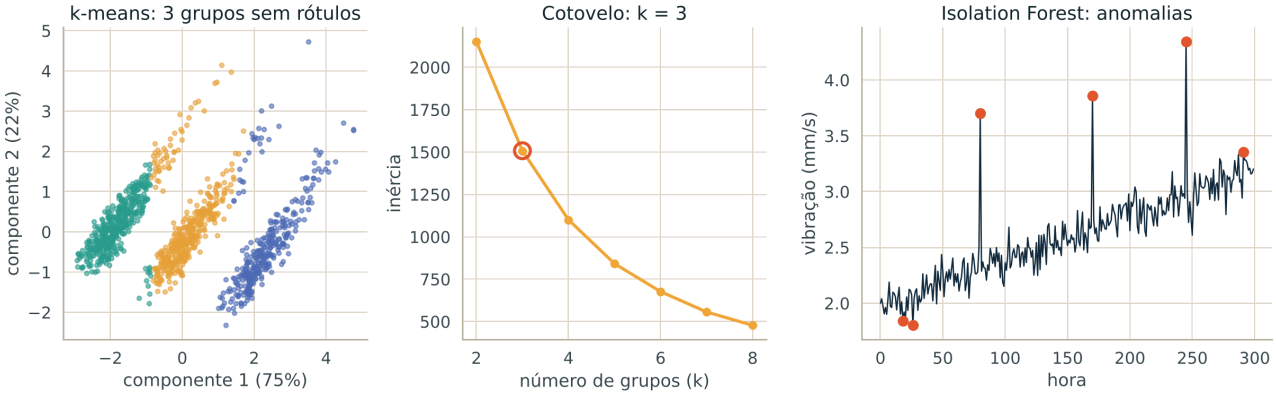


Figura 15. Esquerda: k-means em 3 grupos (visto em 2 componentes do PCA). Centro: cotovelo. Direita: Isolation Forest sinaliza os 3 picos e mais 3 pontos.

NO COLAB · EXERCÍCIO 3.5 · ISOLATION FOREST: O QUE FOGE DO PADRÃO?

Problema	Sinalizar as leituras de vibração **fora do padrão** (anomalias), sem ter exemplos de falha.
Dados	A série de vibração de 300 horas, com 3 picos injetados.
Modelo / técnica	**Isolation Forest**: isola observações raras com cortes aleatórios; as isoladas com poucos cortes são anomalias. `contamination=0.02` = esperamos ~2% de anomalias.
Como medimos	Quantas das 3 anomalias reais foram achadas e quantos alertas no total.
O que observar	Os 3 picos são achados, com alguns alertas a mais: é o equilíbrio entre achar tudo e gerar alarmes falsos. O algoritmo sinaliza; **a pessoa decide**.
Nos slides	45 e 56

```
# modelo: 300 árvores; espera ~2% de anomalias
iso = IsolationForest(n_estimators=300, contamination=0.02, random_state=SEED)
# -1 = anomalia; guardamos 1 para anomalia
serie["anomalia_prevista"] = (iso.fit_predict(serie[["vibracao"]]) == -1).astype(int)

plt.figure(figsize=(12, 3.8))
plt.plot(serie["hora"], serie["vibracao"], color=NAVY, lw=1, label="vibração")
# as horas sinalizadas
ev = serie[serie["anomalia_prevista"] == 1]
plt.scatter(ev["hora"], ev["vibracao"], color=RED, zorder=3, label="anomalia detectada")
plt.legend(); plt.xlabel("hora"); plt.ylabel("vibração (mm/s)")
plt.title("Isolation Forest sinalizando leituras fora do padrão"); plt.show()

# picos reais que foram achados
achou = int(((serie["anomalia_real"] == 1) & (serie["anomalia_prevista"] == 1)).sum())
print("Anomalias reais: %d | detectadas: %d | alertas totais: %d" % (serie["anomalia_real"].sum(), achou,
serie["anomalia_prevista"].sum()))
alertas = int(serie["anomalia_prevista"].sum())
print("Sensibilidade (anomalias reais achadas) = %d/%d = %.2f" % (achou, serie["anomalia_real"].sum(),
achou / serie["anomalia_real"].sum()))
print("Precisão (alertas que eram anomalia real) = %d/%d = %.2f   → os outros %d alertas são falsos
alarmes" % (achou, alertas, achou / alertas, alertas - achou))
```

Saída

```
Anomalias reais: 3 | detectadas: 3 | alertas totais: 6
Sensibilidade (anomalias reais achadas) = 3/3 = 1.00
Precisão (alertas que eram anomalia real) = 3/6 = 0.50   → os outros 3 alertas são falsos alarmes
```

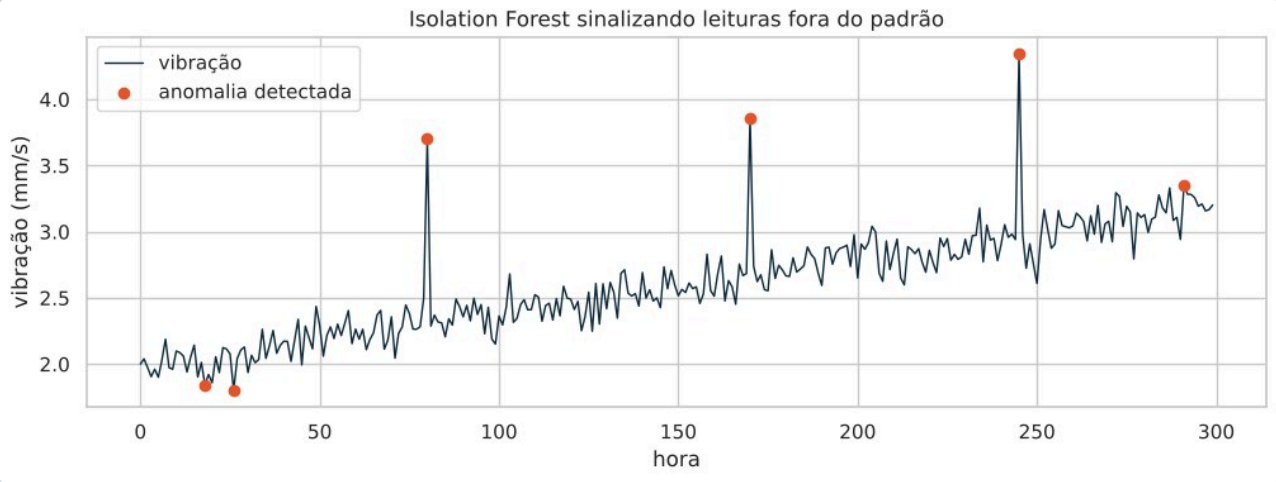


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

("Isolation Forest sinalizando leituras fora do padrão")

- **Eixos:** horizontal = hora (0 a 300), vertical = vibração (mm/s). A linha escura é a série; os **pontos vermelhos** são as leituras que o algoritmo marcou como anomalia.
- **O que foi sinalizado:** os **3 picos reais** (horas ≈ 80, 170 e 245) foram **todos achados** (sensibilidade 3/3). Mas o modelo também marcou outros **3 pontos** (dois valores baixos perto das horas 20 a 25 e um ponto no fim da série), que são **falsos alarmes**. Precisão: 3 de 6 = **0,50**.
- **Por que isso ocorre:** definimos `contamination = 0.02`, ou seja, dissemos que cerca de 2% das leituras são anômalas, então ele sempre marca algumas. Se aumentarmos esse valor, os alertas aumentam e os 3 reais continuam achados.
- **Na engenharia:** sem nenhum exemplo de falha rotulado, o algoritmo já encontra os picos. O ajuste da contaminação é um trade-off entre perder anomalias e gerar alarmes demais.

PERGUNTAS

1. O Isolation Forest achou os 3 picos, mas fez 6 alertas. Isso é bom ou ruim?
2. O que muda se você aumentar a `contamination` de 0,02 para 0,05?

RESPOSTAS COMENTADAS

1. Sensibilidade **1,00** (3 de 3 anomalias reais) e precisão **0,50** (3 de 6 alertas eram reais): os 3 alertas extras são **falsos alarmes** (as leituras mais extremas do ruído e da tendência de desgaste). É bom para manutenção que não pode perder uma falha, mas gera trabalho de checagem. O algoritmo **sinaliza**; a pessoa decide.

2. `contamination` é a fração esperada de anomalias. Aumentar para 0,05 faz o modelo marcar **mais pontos** (15 em 300): a sensibilidade continua 1,00 e a **precisão cai** para 0,20 (3 de 15 alertas, 12 falsos alarmes). Com 0,01 marca só 3 pontos e, neste exemplo, os três são os picos reais (precisão 1,00); mas com dados reais, um valor baixo demais pode **deixar passar** uma anomalia. Teste na célula e compare.

NO COLAB · EXERCÍCIO 3.6 · RESUMO: TRÊS MÉTODOS NÃO SUPERVISIONADOS

Problema	Juntar as três ideias em uma figura.
Dados	Resultados dos passos 3.3, 3.4 e 3.5.
Modelo / técnica	k-means, hierárquico e Isolation Forest.
Como medimos	—
O que observar	Três perguntas, três métodos, **nenhum rótulo**: quantos regimes? como se parecem? o que foge do padrão?
Nos slides	56

```
# PCA só para DESENHAR os 4 sinais em 2 eixos
Zp = PCA(2, random_state=0).fit(Xk)
Q = Zp.transform(Xk); Cc = Zp.transform(km.cluster_centers_)
fig, axes = plt.subplots(1, 3, figsize=(16, 4.2))
ax = axes[0]                                                  # painel 1: k-means
for k_, cor_k in zip(range(3), [TEAL, ORANGE, NAVY]):
    ax.scatter(Q[km.labels_ == k_, 0], Q[km.labels_ == k_, 1], color=cor_k, s=8, alpha=.55)
# X = centro de cada grupo
ax.scatter(Cc[:, 0], Cc[:, 1], marker="X", s=170, color="white", edgecolor="black", zorder=5)
ax.set_title("K-means: 3 regimes (X = centro)"); ax.set_xlabel("Componente 1 (PCA)");
ax.set_ylabel("Componente 2 (PCA)"); limpa(ax)
dendrogram(L, ax=axes[1], color_threshold=0.45 * L[:, 2].max(), above_threshold_color="#9AA7AD",
           labels=[str(i + 1) for i in range(18)])            # painel 2: dendrograma
axes[1].set_title("Hierárquico: dendrograma"); axes[1].set_xlabel("Motor (número)"); limpa(axes[1])
ax = axes[2]                                                  # painel 3: Isolation Forest
ax.plot(serie["hora"], serie["vibracao"], color=TEAL, lw=1)
ax.scatter(ev["hora"], ev["vibracao"], color=RED, s=40, zorder=5, label="fora do padrão")
ax.set_title("Isolation Forest: picos de vibração"); ax.set_xlabel("Horas de operação");
ax.set_ylabel("Vibração (mm/s)"); ax.legend(frameon=False); limpa(ax)
plt.tight_layout(); plt.show()
```

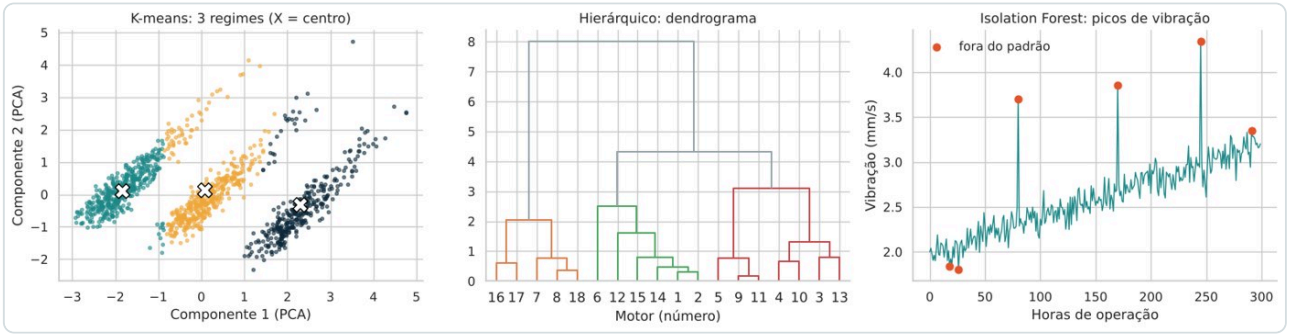


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(resumo dos três métodos não supervisionados)

- **Esquerda, k-means:** as leituras projetadas em dois eixos (componentes 1 e 2) e coloridas por grupo; o "X" marca o centro de um grupo. Mostra **3 regimes** de operação.
- **Centro, dendrograma:** o hierárquico mostra **como** os motores se parecem, sem fixar o número de grupos antes.
- **Direita, Isolation Forest:** a série de vibração com os pontos marcados em vermelho: **o que foge do padrão**.
- **Na engenharia:** use agrupamento para **conhecer** os regimes de operação e detecção de anomalias para **vigiar** o que sai do comum.

Os três picos foram achados e houve três alertas a mais: é o equilíbrio entre achar tudo e gerar alarmes falsos. O algoritmo sinaliza e **a pessoa decide**.

Do alerta à ação (extra)

Um alerta só gera valor quando alguém age. Na palestra, o n8n é citado como o elo entre o modelo e a ação. A atividade que monta o JSON do alerta e o envia a um *webhook* do n8n está no **Bônus B** (capítulo “Bônus B”).

8. Bloco 4 · Engenharia Mecânica: diagnóstico de rolamentos

Onde implementar

Em bombas, ventiladores, redutores e qualquer máquina rotativa. Um acelerômetro mede a vibração e, em vez de trabalhar com o sinal bruto, extraímos poucas **características**: RMS, curtose, fator de crista, energia nas frequências de falha da pista externa (BPFO) e da pista interna (BPFI), e temperatura. O modelo diz se o rolamento está **saudável** ou com falha na **pista externa** ou **interna**.

Pergunta	Dados	Técnica	Ganho
Qual a condição do rolamento?	6 características da vibração	PCA (visualizar) + SVM (classificar)	troca no momento certo, sem parada surpresa

Os dados (simulados)

900 observações, 300 de cada condição. As falhas aumentam o RMS, a curtose e o fator de crista, e elevam a energia na banda característica de cada pista. As duas falhas se parecem mais entre si do que com o rolamento saudável.

NO COLAB · EXERCÍCIO 4.1 · CRIAR OS DADOS (SIMULADOS)

Problema	Dizer a **condição do rolamento**: saudável, falha na pista externa ou falha na pista interna.
Dados	900 observações (300 de cada condição) com 6 características de vibração: RMS, curtose, fator de crista, energia BPFO, energia BPFI e temperatura.
Modelo / técnica	Ainda não há modelo.
Como medimos	—
O que observar	As médias de cada característica por condição: as falhas aumentam RMS, curtose e fator de crista, e a energia na banda da pista com defeito.
Nos slides	57 e 58

```
rng = np.random.default_rng(SEED)
# (média, desvio) de cada característica por condição: rms, curtose, fator de crista, energia BPFO,
# energia BPFI, temperatura
perfil = {
    "saudável":      [(0.65, .15), (3.4, .7), (3.9, .6), (0.04, .025), (0.04, .025), (57, 5)],
    "pista externa": [(0.90, .20), (4.3, .9), (4.8, .8), (0.20, .100), (0.08, .050), (60, 5)],
    "pista interna": [(1.00, .22), (4.6, 1.0), (5.0, .9), (0.10, .060), (0.22, .100), (61, 5)],
}
# nomes das 6 colunas
cols = ["rms_g", "curtose", "fator_crista", "energia_BPFO", "energia_BPFI", "temperatura_C"]
linhas = []
for cond, params in perfil.items():                    # para cada condição do rolamento...
    for _ in range(300):                               # ...sorteia 300 observações
        v = [abs(rng.normal(m, s)) if c.startswith("energia") else rng.normal(m, s)
             for c, (m, s) in zip(cols, params)]       # energia não pode ser negativa (abs)
        linhas.append(v + [cond])
rolamentos = pd.DataFrame(linhas, columns=cols + ["condicao"])
# 5 linhas ao acaso
print(rolamentos.shape); display(rolamentos.sample(5, random_state=SEED).round(2))
# média por condição
display(rolamentos.groupby("condicao")[cols].mean().round(2))
```

Saída

```
(900, 7)

     rms_g  curtose  fator_crista  energia_BPFO  energia_BPFI  temperatura_C  \
70    0.66     2.81          3.54          0.00          0.02          55.21
827   1.06     4.11          4.42          0.11          0.18          55.45
231   0.84     2.64          4.10          0.02          0.02          64.39
588   0.59     4.20          6.05          0.18          0.15          61.76
39    0.54     2.94          2.61          0.04          0.01          54.35

          condicao
70        saudável
827  pista interna
231       saudável
588  pista externa
39        saudável
              rms_g  curtose  fator_crista  energia_BPFO  energia_BPFI  \
condicao
pista externa   0.91     4.27          4.77          0.20          0.09
pista interna   1.00     4.51          4.94          0.11          0.22
saudável        0.63     3.36          3.88          0.04          0.04

              temperatura_C
...
```

PCA: seis variáveis em dois eixos

Com seis variáveis não dá para olhar um gráfico só. O PCA, ajustado apenas com o treino, resume as variáveis em eixos: o primeiro guarda 37,6% da variância e o segundo 15,6% (53% juntos). Já dá para **enxergar** o rolamento saudável separado das duas falhas.

NO COLAB · EXERCÍCIO 4.2 · VISUALIZAR COM PCA: 6 DIMENSÕES EM 2	
Problema	**Enxergar** as 3 condições em um gráfico, mesmo com 6 variáveis.
Dados	As 900 observações (75% treino, 25% teste, com `stratify`).
Modelo / técnica	**PCA**: combina as 6 variáveis em eixos novos (componentes), ordenados pela variância que guardam. Ajustado **só com o treino** (evita vazamento de dados).
Como medimos	Variância explicada por componente.
O que observar	O 1° eixo guarda 37,6% e o 2° 15,6% (53% juntos): já separa o rolamento saudável das falhas.
Nos slides	46, 48 e 58

```
# entradas (6 colunas) e classe
Xm = rolamentos[cols]; ym = rolamentos["condicao"]
Xm_tr, Xm_te, ym_tr, ym_te = train_test_split(Xm, ym, test_size=0.25, stratify=ym, random_state=SEED)

# O PCA é ajustado SÓ com o treino (evita vazamento de dados)
# padroniza e calcula os componentes
pca_mec = make_pipeline(StandardScaler(), PCA(random_state=SEED)).fit(Xm_tr)
# fração da variância de cada componente
var = pca_mec[-1].explained_variance_ratio_
print("Variância explicada por componente:", (100 * var).round(1), "%")

# projeta todas as observações nos 2 primeiros eixos
Z = pca_mec.transform(Xm)[:, :2]
cores = {"saudável": TEAL, "pista externa": ORANGE, "pista interna": RED}
fig, axes = plt.subplots(1, 2, figsize=(13, 4.6))
for cond, cor in cores.items():
    idx = (ym == cond).values
    # cada condição com uma cor
    axes[0].scatter(Z[idx, 0], Z[idx, 1], s=18, alpha=0.6, color=cor, label=cond)
axes[0].set_xlabel("componente 1 (%.0f%%)" % (100 * var[0])); axes[0].set_ylabel("componente 2 (%.0f%%)"
% (100 * var[1]))
axes[0].set_title("6 características resumidas em 2 componentes"); axes[0].legend()
# barras + acumulado
axes[1].bar(range(1, 7), 100 * var, color=TEAL); axes[1].plot(range(1, 7), 100 * np.cumsum(var), "o-",
color=ORANGE)
axes[1].set_xlabel("componente"); axes[1].set_ylabel("variância explicada (%)");
axes[1].set_title("Quanto cada componente guarda")
plt.tight_layout(); plt.show()
```

Saída

```
Variância explicada por componente: [37.6 15.6 14.8 11.9 11.2  8.8] %
```

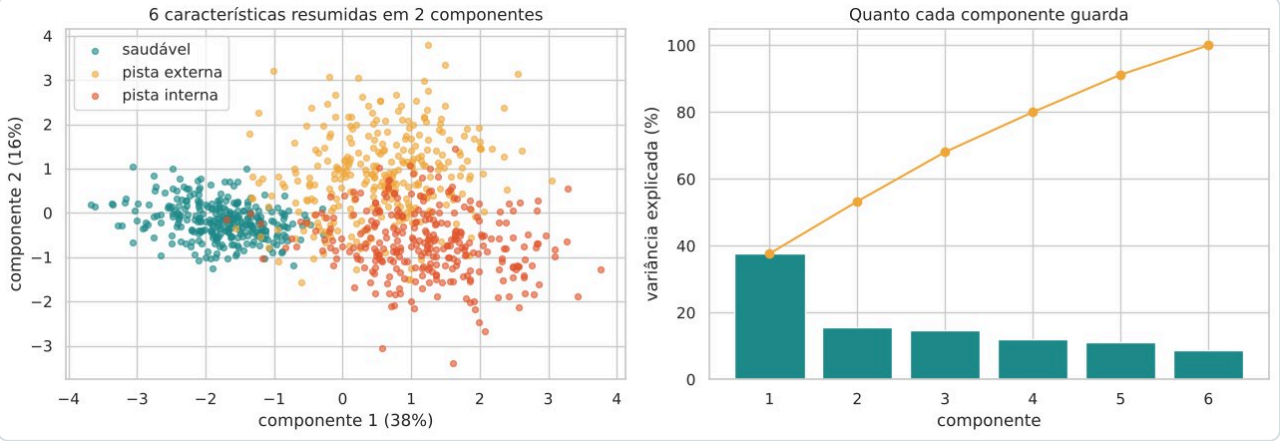


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(900 observações de rolamentos, 6 características de vibração cada)

- **Gráfico da esquerda (projeção PCA):** o PCA combina as 6 variáveis em 2 eixos novos para podermos desenhar. Horizontal = componente 1 (guarda **38%** da informação), vertical = componente 2 (**16%**). Cada ponto é um rolamento: **verde** = saudável, **laranja** = falha na pista externa, **vermelho** = falha na pista interna.
- **O que se vê:** os **saudáveis** ficam bem à esquerda, separados dos defeituosos. As duas falhas ocupam a direita e se **sobrepõem** um pouco, são mais difíceis de distinguir entre si.
- **Gráfico da direita (variância explicada):** cada barra é a informação guardada por um componente (37,6%; 15,6%; 14,8%; 11,9%; 11,2%; 8,8%) e a linha laranja é a soma acumulada. Dois componentes guardam só cerca de **53%**, e três, cerca de **68%**: reduzir para 2 dimensões **perde informação**, e vamos medir quanto no exercício seguinte.

Classificar: SVM com todas as variáveis x após o PCA

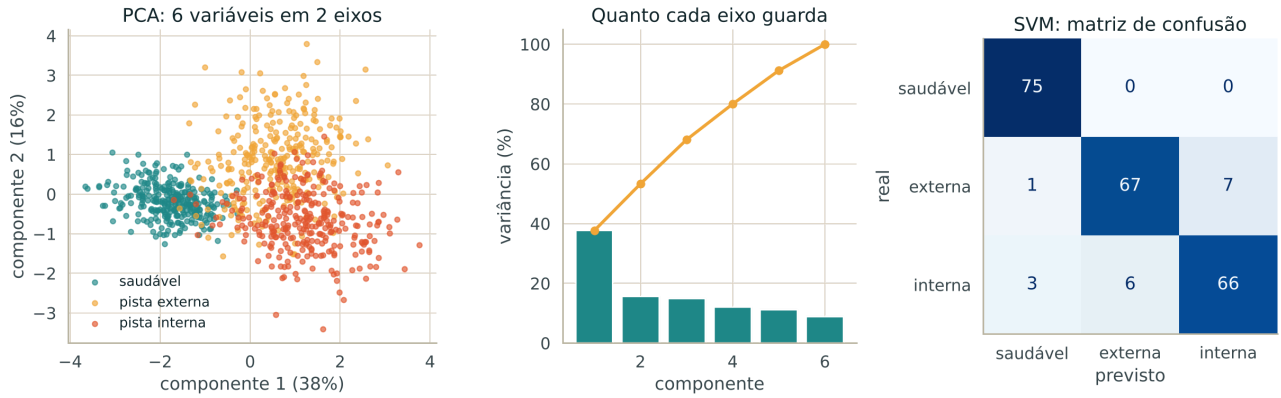


Figura 16. Esquerda: PCA em 2 eixos. Centro: variância por componente. Direita: matriz de confusão do SVM (6 variáveis).

NO COLAB · EXERCÍCIO 4.3 · CLASSIFICAR: SVM COM TODAS AS VARIÁVEIS X SVM DEPOIS DO PCA

Problema	Classificar a condição do rolamento e medir **o que se perde** ao reduzir de 6 para 2 ou 3 componentes.
Dados	As mesmas observações, com a divisão treino/teste do passo anterior.
Modelo / técnica	**SVM** (kernel RBF) com 6 variáveis, após PCA de 2 e de 3 componentes; **Random Forest** para comparar.
Como medimos	Acurácia no teste e **matriz de confusão**.
O que observar	SVM com 6 variáveis: 92,4%. PCA de 2 componentes: 86,7%. De 3: 90,7%. O PCA ajuda a enxergar, mas reduzir dimensões perde informação.
Nos slides	58

```
modelos_mec = {
    # usa as 6 variáveis
    "SVM (6 variáveis)": make_pipeline(StandardScaler(), SVC(kernel="rbf", random_state=SEED)),
    # resume em 2 e classifica
    "SVM após PCA (2 comp.)": make_pipeline(StandardScaler(), PCA(n_components=2), SVC(kernel="rbf",
random_state=SEED)),
    # resume em 3
    "SVM após PCA (3 comp.)": make_pipeline(StandardScaler(), PCA(n_components=3), SVC(kernel="rbf",
random_state=SEED)),
    # para comparar
    "Random Forest": RandomForestClassifier(n_estimators=300, random_state=SEED),
}
res = []
for nome, m in modelos_mec.items():
    m.fit(Xm_tr, ym_tr)                                                    # treina
    # mede no teste
    res.append({"Modelo": nome, "Acurácia no teste": accuracy_score(ym_te, m.predict(Xm_te))})
tab_mec = pd.DataFrame(res).set_index("Modelo").round(3)
display(tab_mec)

ordem = ["saudável", "pista externa", "pista interna"]
fig, ax = plt.subplots(figsize=(5.2, 4.4))
# onde o SVM erra
matriz(ym_te, modelos_mec["SVM (6 variáveis)"].predict(Xm_te), ax, ordem, titulo="SVM com as 6
variáveis")
plt.tight_layout(); plt.show()

# Métricas por classe do SVM (6 variáveis): precisão, sensibilidade e F1 de cada condição
from sklearn.metrics import classification_report
print(classification_report(ym_te, modelos_mec["SVM (6 variáveis)"].predict(Xm_te), digits=3))
```

Saída

```
                       Acurácia no teste
Modelo
SVM (6 variáveis)                  0.924
SVM após PCA (2 comp.)             0.867
SVM após PCA (3 comp.)             0.907
Random Forest                      0.920
               precision    recall  f1-score   support

pista externa      0.918     0.893     0.905        75
pista interna      0.904     0.880     0.892        75
     saudável      0.949     1.000     0.974        75

     accuracy                         0.924       225
    macro avg      0.924     0.924     0.924       225
 weighted avg      0.924     0.924     0.924       225
```

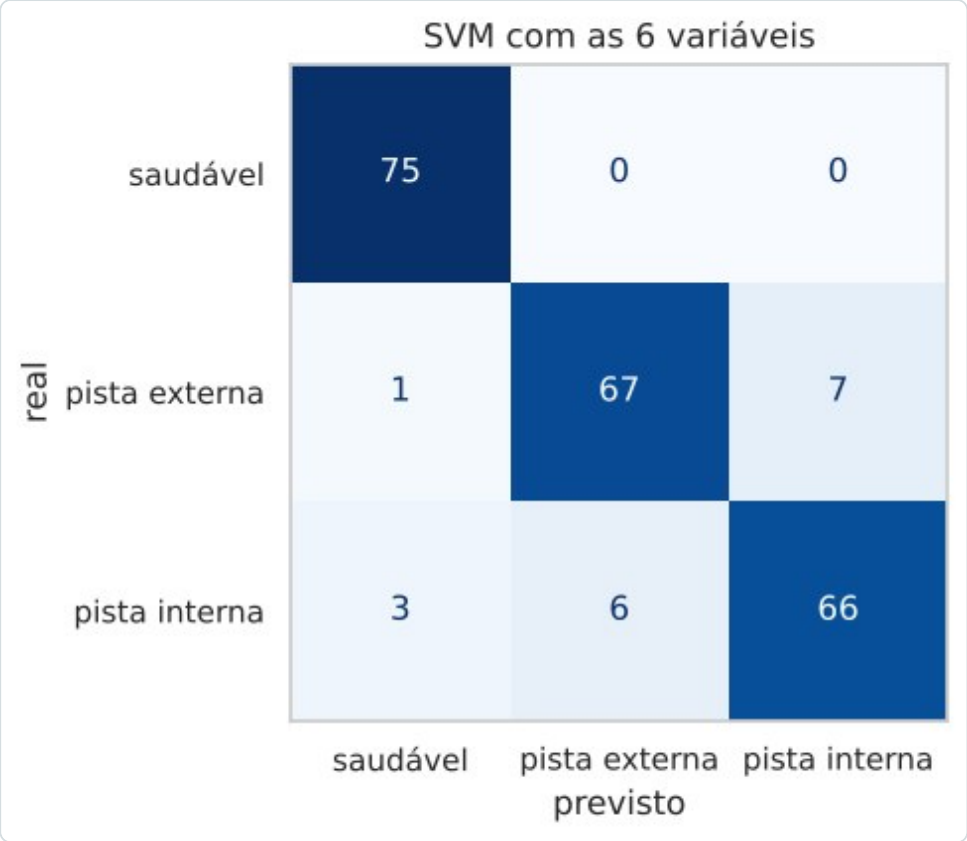


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(matriz de confusão do SVM com as 6 variáveis, 225 rolamentos de teste: 75 de cada condição)

- **Como ler:** linhas = condição real; colunas = condição prevista; a diagonal são os acertos.
- **Saudável:** 75 de 75 certos. Nenhum rolamento saudável foi condenado.
- **Pista externa:** 67 certos, 1 confundido com saudável e **7 confundidos com pista interna**.
- **Pista interna:** 66 certos, 3 confundidos com saudável e **6 com pista externa**.
- **Conclusão:** acurácia de **92,4%** ((75 + 67 + 66)/225). Os erros se concentram entre as **duas falhas** (13 casos) e confirmam o que o PCA mostrou: elas se parecem. Em manutenção, o pior erro é confundir falha com saudável (4 casos).
- **O efeito do PCA (tabela acima):** SVM com as 6 variáveis **92,4%**; após PCA de 3 componentes, **90,7%**; de 2 componentes, **86,7%**; Random Forest, **92,0%**. Reduzir dimensão custa um pouco de acerto, mas facilita visualizar e explicar.

PERGUNTAS

1. O que se perde ao reduzir de 6 para 2 componentes? E ao usar 3?
2. Quais classes o modelo mais confunde? Por que as duas falhas se parecem mais entre si do que com o rolamento saudável?
3. Em manutenção, é pior classificar uma falha como saudável ou um saudável como falha?

RESPOSTAS COMENTADAS

1. Ao resumir em **2 componentes**, a acurácia cai de 92,4% para 86,7% (perda de ~6 pontos); com **3**, para 90,7%. Os componentes 3 a 6 guardam 47% da variância (100 − 37,6 − 15,6) e parte dessa informação ajuda a separar as classes: **reduzir dimensões sempre perde informação**. O PCA é ótimo para **enxergar**, não necessariamente para melhorar o classificador.

2. O relatório por classe mostra: **saudável** tem sensibilidade 1,00 e precisão 0,95; as duas falhas ficam em ≈ 0,88 a 0,89 de sensibilidade. As **duas falhas se confundem entre si** porque ambas elevam RMS, curtose e fator de crista de forma parecida: só diferem em **qual banda de frequência** (BPFO ou BPFI) concentra a energia. Em relação ao saudável, ambas ficam longe.

3. Em geral, **falha classificada como saudável** é mais grave: a máquina continua rodando e pode quebrar sem aviso (parada não planejada). Saudável classificado como falha gera uma **inspeção desnecessária**. Por isso, em manutenção, costuma-se priorizar a **sensibilidade** para falhas (o mesmo raciocínio do limiar na Produção).

Reduzir de 6 para 2 componentes custa quase sete pontos de acurácia (92,4% para 86,7%); com 3 componentes a perda é menor (90,7%). O PCA ajuda a **enxergar**, mas reduzir dimensões sempre perde informação. O SVM confunde sobretudo as duas falhas entre si (7 e 6 erros); só 3 de 75 observações saudáveis foram classificadas como falha e nenhuma falha de pista externa foi dada como saudável.

9. Bloco 5 · Engenharia Química: concentração por espectros

Onde implementar

Em reatores e linhas de processo com sonda de espectroscopia no infravermelho próximo (NIR). A análise de laboratório é lenta; o espectro é imediato. Um modelo converte o **espectro** (aqui, 120 comprimentos de onda) em **concentração**: um **sensor virtual** para controle em tempo real e menos amostras de laboratório. Na quimiometria, a regressão sobre componentes principais (PCR) é uma técnica clássica.

Pergunta	Dados	Técnica	Ganho
Qual a concentração do analito A (%)?	absorbância em 120 comprimentos de onda	PCA + regressão	resposta em segundos e controle do processo

Os dados (simulados)

220 espectros com três substâncias (A, B e C). Os picos de A e B se **sobrepõem**, há **deriva de linha de base** e ruído. As 120 variáveis são muito correlacionadas e há quase tantas variáveis quanto amostras de treino (154): um terreno em que a regressão direta tende a sobreajustar.

NO COLAB · EXERCÍCIO 5.1 · CRIAR E VISUALIZAR OS ESPECTROS (SIMULADOS)

Problema	Estimar a **concentração do analito A (%)** a partir do espectro da amostra.
Dados	220 espectros com 120 comprimentos de onda (1100 a 2300 nm). Três substâncias (A, B, C) com picos sobrepostos, deriva de linha de base e ruído.
Modelo / técnica	Ainda não há modelo.
Como medimos	—
O que observar	Cada curva é uma amostra; a cor mostra a concentração de A. Os picos de A e B se misturam: não dá para ler a concentração "a olho".
Nos slides	59 e 60

```
rng = np.random.default_rng(SEED)
n = 220                                                    # número de amostras
comprimento = np.linspace(1100, 2300, 120)                 # 120 comprimentos de onda, em nm
# forma de um pico (curva em sino)
pico = lambda centro, larg: np.exp(-0.5 * ((comprimento - centro) / larg) ** 2)

A = rng.uniform(0, 10, n)     # concentração do analito de interesse (%)  <- é o que queremos prever
B = rng.uniform(0, 10, n)     # interferente 1
Cc = rng.uniform(0, 10, n)    # interferente 2

espectro = (A[:, None] * 0.10 * pico(1450, 45) + B[:, None] * 0.09 * pico(1530, 55)
            # espectro = soma dos picos de A, B e C (proporcionais às concentrações)
            + Cc[:, None] * 0.08 * pico(1930, 60))
# linha de base que varia
deriva = rng.normal(0.5, 0.15, (n, 1)) + rng.normal(0, 0.00015, (n, 1)) * (comprimento - 1700)
# espectro medido = sinal + deriva + ruído
S = espectro + deriva + rng.normal(0, 0.03, (n, comprimento.size))
print("Espectros:", S.shape, "(amostras x comprimentos de onda)")
```

Saída

```
Espectros: (220, 120) (amostras x comprimentos de onda)
```

```
fig, axes = plt.subplots(1, 2, figsize=(14, 4.4))
cmap = plt.cm.viridis
# desenha 1 a cada 6 espectros, em ordem de concentração
for i in np.argsort(A)[::6]:
    # cor = concentração de A
    axes[0].plot(comprimento, S[i], color=cmap(A[i] / 10), lw=0.9, alpha=0.8)
sm = plt.cm.ScalarMappable(cmap=cmap, norm=plt.Normalize(0, 10)); plt.colorbar(sm,
ax=axes[0]).set_label("concentração de A (%)")
axes[0].set_xlabel("comprimento de onda (nm)"); axes[0].set_ylabel("absorbância");
axes[0].set_title("Espectros: picos sobrepostos e linha de base variável")
# histograma
axes[1].hist(A, bins=20, color=TEAL); axes[1].set_title("Concentrações de A nas amostras");
axes[1].set_xlabel("%")
plt.tight_layout(); plt.show()
```

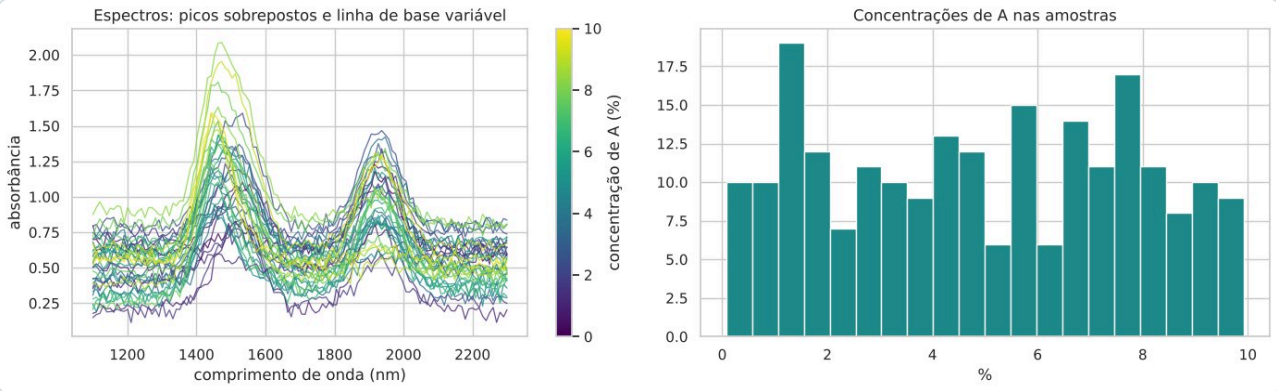


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

(220 espectros simulados; queremos estimar a **concentração da substância A (%)** de cada amostra)

- **Gráfico da esquerda, "Espectros":** horizontal = comprimento de onda (nm), vertical = absorbância (quanta luz a amostra absorve). Cada linha é uma amostra. Há dois **picos** (por volta de 1.450 e 1.930 nm), e a **cor** indica a concentração de A: linhas **amarelas** (A alta) têm picos **mais altos**, e linhas roxas (A baixa) têm picos baixos. A altura da linha de base varia de amostra para amostra (um defeito do instrumento) e os picos de outras substâncias se sobrepõem, então o valor de A **não** se lê direto em um único ponto.
- **Gráfico da direita, "Concentrações de A nas amostras":** horizontal = % de A (0 a 10), vertical = número de amostras. Os valores se espalham de forma razoavelmente uniforme, o que é bom para treinar (cobre toda a faixa).
- **Na engenharia:** é a ideia de **sensor virtual**: em vez de um ensaio de laboratório demorado, o espectro (rápido) é usado para estimar a concentração.

PCA: quantos componentes bastam?

Quatro componentes explicam 95,4% da variância; cinco chegam a 97,7%.

NO COLAB · EXERCÍCIO 5.2 · PCA: QUANTOS COMPONENTES BASTAM?

Problema	Resumir as **120 variáveis** do espectro em poucos componentes, mantendo a informação necessária para prever a **concentração de A (%)**.
Dados	Os 220 espectros: 70% treino e 30% teste.
Modelo / técnica	**PCA** ajustado só no treino.
Como medimos	Variância acumulada (critério usual: 95%).
O que observar	4 componentes explicam 95,4% da variância. Mas veremos que 5 dão o menor erro.
Nos slides	46 e 60

```
# treino (70%) e teste (30%)
S_tr, S_te, A_tr, A_te = train_test_split(S, A, test_size=0.3, random_state=SEED)

# padroniza e calcula o PCA com o treino
pca_q = make_pipeline(StandardScaler(), PCA(random_state=SEED)).fit(S_tr)
# variância de cada componente
var_q = pca_q[-1].explained_variance_ratio_
acum = np.cumsum(var_q)                                                    # variância acumulada
# nº de componentes para chegar a 95%
n95 = int(np.argmax(acum >= 0.95) + 1)
print("%d componentes explicam %.1f%% da variância (de %d variáveis)" % (n95, 100 * acum[n95 - 1],
S.shape[1]))

# espectros projetados nos componentes
T = pca_q.transform(S_tr)
fig, axes = plt.subplots(1, 2, figsize=(13, 4.4))
axes[0].plot(range(1, 13), 100 * acum[:12], "o-", color=TEAL); axes[0].axhline(95, color=RED, ls="--",
label="95%")
axes[0].set_xlabel("nº de componentes"); axes[0].set_ylabel("variância acumulada (%)");
axes[0].set_title("Quantos componentes bastam?"); axes[0].legend()
# cada ponto é um espectro; cor = concentração
sc = axes[1].scatter(T[:, 0], T[:, 1], c=A_tr, cmap="viridis", s=22)
plt.colorbar(sc, ax=axes[1]).set_label("concentração de A (%)")
axes[1].set_xlabel("componente 1"); axes[1].set_ylabel("componente 2"); axes[1].set_title("Cada ponto é
um espectro")
plt.tight_layout(); plt.show()
```

Saída

```
4 componentes explicam 95.4% da variância (de 120 variáveis)
```

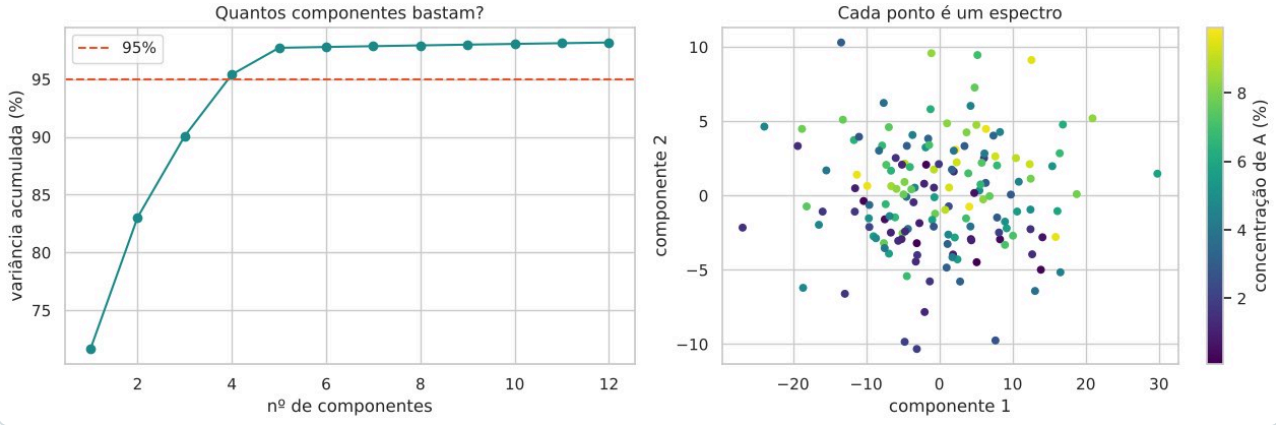


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

- **Gráfico da esquerda, "Quantos componentes bastam?":** horizontal = número de componentes do PCA, vertical = variância acumulada (%). A linha tracejada vermelha marca 95%. Com **1 componente** já temos cerca de 72%; **4 componentes** chegam a **95,4%** (cruzam a linha) e **5** passam de 97%. As 120 variáveis originais cabem em poucos componentes.
- **Gráfico da direita, "Cada ponto é um espectro":** horizontal = componente 1, vertical = componente 2; **cor** = concentração de A. As cores aparecem **misturadas**: com só 2 componentes não dá para ver a concentração. A informação sobre A está em componentes além dos 2 primeiros, e é por isso que precisamos de 4 ou 5 no modelo.

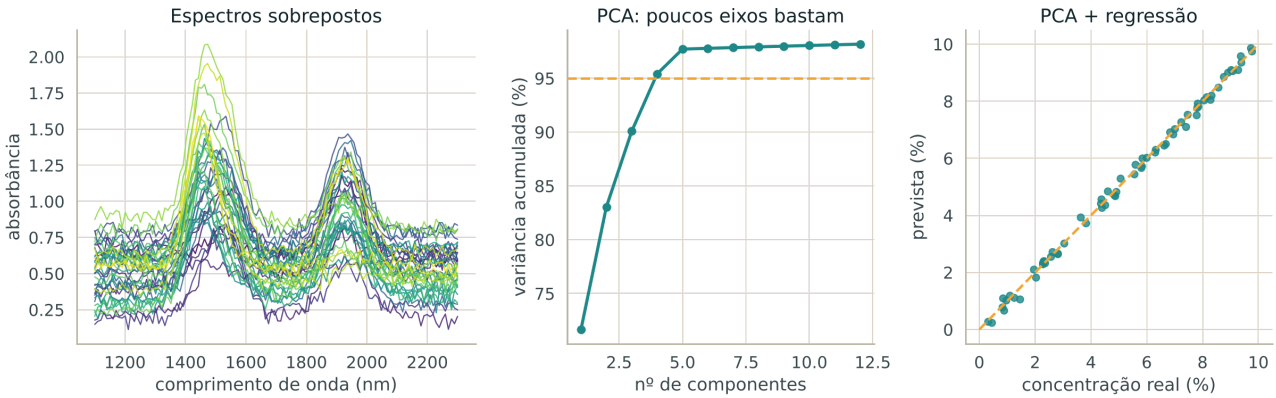


Figura 17. Esquerda: espectros coloridos pela concentração. Centro: variância acumulada do PCA. Direita: previsto x real do PCA com 5 componentes.

NO COLAB · EXERCÍCIO 5.3 · REGRESSÃO: 120 VARIÁVEIS X PCA	
Problema	Prever a concentração de A com o **menor erro**.
Dados	Espectros de treino e teste do passo anterior.
Modelo / técnica	**Regressão linear** nos 120 comprimentos de onda; **regressão após PCA** (PCR) com 4 e 5 componentes; **Random Forest**.
Como medimos	MAE (em % de concentração) e R^2.
O que observar	PCA com **5 componentes** erra menos (MAE ≈ 0,12%, R^2 ≈ 0,997). Com 4 o erro explode (1,78%), embora a regra dos 95% sugerisse 4: **variância explicada não é tudo**.
Nos slides	60

```
modelos_q = {
    # usa todos os comprimentos de onda
    "Linear (120 variáveis)": LinearRegression(),
    # resume em 4 e faz regressão
    "PCA (4 comp.) + linear": make_pipeline(StandardScaler(), PCA(n_components=4), LinearRegression()),
    # resume em 5
    "PCA (5 comp.) + linear": make_pipeline(StandardScaler(), PCA(n_components=5), LinearRegression()),
    "Random Forest": RandomForestRegressor(n_estimators=200, random_state=SEED),
}
res = []; prev_q = {}
for nome, m in modelos_q.items():
    m.fit(S_tr, A_tr); prev_q[nome] = m.predict(S_te)            # treina e prevê a concentração
    res.append({"Modelo": nome, "MAE (%)": mean_absolute_error(A_te, prev_q[nome]),
                "RMSE (%)": np.sqrt(np.mean((A_te - prev_q[nome]) ** 2)), "R²": r2_score(A_te,
prev_q[nome])})
tab_q = pd.DataFrame(res).set_index("Modelo").round(3)
display(tab_q)

melhor = "PCA (5 comp.) + linear"                                 # o melhor modelo
plt.figure(figsize=(5.2, 4.6))
plt.scatter(A_te, prev_q[melhor], color=TEAL, alpha=0.7)          # previsto x real
plt.plot([0, 10], [0, 10], "--", color=RED); plt.xlabel("concentração real (%)"); plt.ylabel("prevista
(%)")
plt.title(melhor); plt.tight_layout(); plt.show()
```

Saída

Modelo	MAE (%)	RMSE (%)	R²
Linear (120 variáveis)	0.268	0.332	0.986
PCA (4 comp.) + linear	1.779	2.184	0.398
PCA (5 comp.) + linear	0.117	0.144	0.997
Random Forest	0.548	0.689	0.940

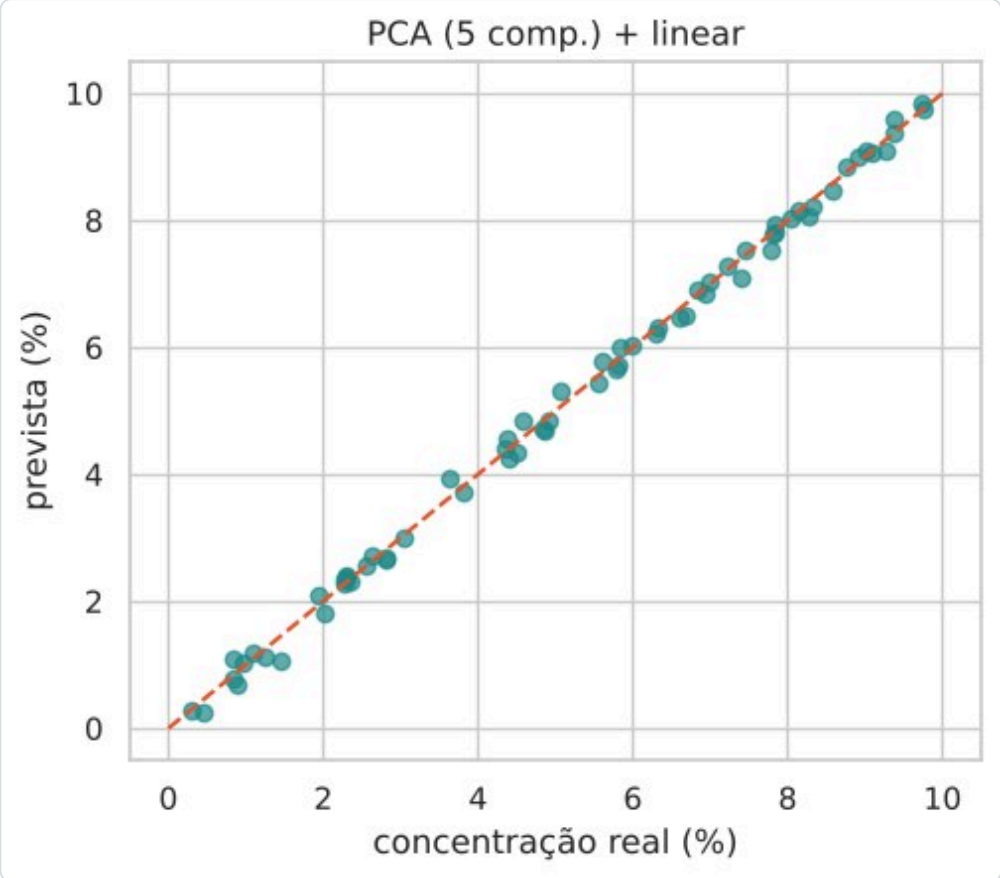


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

- **Gráfico "PCA (5 comp.) + linear":** horizontal = concentração **real** de A (%), vertical = concentração **prevista**. A linha tracejada vermelha é a previsão perfeita. Os pontos ficam **praticamente sobre a linha**: erro médio de apenas **0,117 pontos percentuais** e R^2 de **0,997**.
- **Comparação (tabela acima, no teste): PCA 5 + linear**: MAE 0,117, R^2 0,997 (melhor). **Linear com 120 variáveis**: MAE 0,268, R^2 0,986 (bom, mas usa tudo e é mais sensível ao ruído). **Random Forest**: MAE 0,548, R^2 0,940. **PCA 4 + linear**: MAE **1,779**, R^2 **0,398**, ou seja, com 4 componentes (95,4% da variância) o modelo **piora muito**.
- **Lição:** "explicar 95% da variância" não garante que a informação do **alvo** esteja ali. Teste o número de componentes pela métrica de previsão (MAE e R^2), não só pela variância.

PERGUNTAS

1. O critério dos **95% de variância** sugeriu 4 componentes, mas **5** deram o menor erro. Por que a variância explicada não é tudo? O que são esses 5 eixos fisicamente? (dica: 3 substâncias + linha de base)
2. Qual a vantagem de reduzir antes de regredir quando há mais variáveis do que amostras?
3. Onde estaria a incerteza em um sensor virtual instalado na planta? (calibração, deriva, nova matéria-prima)

RESPOSTAS COMENTADAS

1. Os 4 primeiros componentes já cobrem 95% da variância, mas essa variância é dominada pelos **picos fortes** (A, B e C sobrepostos). O **5º eixo**, com pouca variância, é o que **separa a contribuição de A da de B** (picos que se sobrepõem) e corrige a linha de base: informação decisiva para prever A. Por isso, com 4 componentes o MAE é 1,78% e com 5 cai para 0,12%. Fisicamente, os eixos correspondem a **3 substâncias + a linha de base** (+ ruído). **Variância explicada não é o mesmo que informação útil para o alvo**: valide o número de componentes (por exemplo, por validação cruzada).

2. Com 120 variáveis e só 154 amostras de treino, as variáveis são **muito correlacionadas** e a regressão sofre com colinearidade e tende a **sobreajustar**. O PCA resume em poucas variáveis **independentes**, mais estáveis e com menos ruído. (Aqui a regressão linear nas 120 variáveis ainda foi bem, R^2 0,986, mas o PCR com 5 componentes foi melhor: 0,997.)

3. A incerteza vem de: **calibração** do espectrômetro, **deriva** da linha de base ao longo do tempo, **nova matéria-prima** com picos diferentes, temperatura e entupimento da sonda, e amostras **fora da faixa de concentração** usada no treino. Em campo, mantenha **checagens periódicas com o laboratório** e retreine quando necessário.

O PCA com **5 componentes** tem o menor erro (MAE de 0,12%, R^2 de 0,997), melhor do que a regressão nos 120 comprimentos de onda e do que o Random Forest. Com 4 componentes o erro explode (1,78%), embora a regra dos 95% de variância sugerisse 4. A razão é física: são **três substâncias mais a linha de base** (e ruído); o quinto eixo, de pouca variância, carrega informação relevante. **Variância explicada não é tudo: valide o número de componentes** (por exemplo, com validação cruzada).

10. Quadro-resumo: a técnica certa para cada pergunta

Engenharia	Pergunta	Técnica	Principais métricas	Resultado no curso
Civil	Qual a resistência?	Regressão (linear, Random Forest)	MAE, R^2	RF: MAE 2,16 MPa; R^2 0,96
Produção	A peça terá defeito?	Classificação (árvore, floresta)	sensibilidade, precisão, especificidade, ROC/AUC	RF: sensibilidade 0,74; especificidade 0,97; AUC 0,96
Elétrica	Quais perfis e anomalias?	k-means, hierárquico, Isolation Forest	silhueta, Rand ajustado, alertas	Rand 0,79; 3 de 3 anomalias
Mecânica	Qual a condição do rolamento?	PCA + SVM	acurácia, matriz de confusão	SVM: 92,4%
Química	Qual a concentração?	PCA + regressão	MAE, R^2	PCA(5): MAE 0,12%; R^2 0,997

O fluxo é o mesmo em todas: **dados → separar treino e teste → treinar → medir no teste → decidir com responsabilidade**. O que muda é o dado, a pergunta e o custo dos erros.

Código do quadro-resumo (Colab, seção 6)

```
# Tabela final com o resultado de cada engenharia (os números vêm das células anteriores)
resumo = pd.DataFrame({
    "Engenharia": ["Civil", "Produção", "Elétrica", "Mecânica", "Química"],
    "Resultado no teste": [
        "Random Forest: MAE %.2f MPa, R² %.3f" % (tab_civil.loc["Random Forest", "MAE (MPa)"],
tab_civil.loc["Random Forest", "R²"]),
        "Random Forest: recall %.2f, precisão %.2f" % (tab_prod.loc["Random Forest", "Recall (defeitos
achados)"], tab_prod.loc["Random Forest", "Precisão (alertas certos)"]),
        "k-means: Rand ajustado %.2f; Isolation Forest: %d de %d anomalias" %
(adjusted_rand_score(motores["regime"], motores["grupo"]), achou, serie["anomalia_real"].sum()),
        "SVM: acurácia %.2f" % tab_mec.loc["SVM (6 variáveis)", "Acurácia no teste"],
        "PCA (5 comp.) + linear: MAE %.2f %%, R² %.3f" % (tab_q.loc["PCA (5 comp.) + linear", "MAE (%)"],
tab_q.loc["PCA (5 comp.) + linear", "R²"]),
    ]})
display(resumo)
```

11. Cuidados na prática

O desempenho do modelo não resolve sozinho os problemas de dados, processo e governança. Os seis cuidados da palestra:

Cuidado	Por que importa
Qualidade	Dados ausentes, erros de sensor (descalibrado), rótulos incorretos e formatos incompatíveis contaminam qualquer modelo.
Vazamento	Informações do teste ou do futuro não podem participar do treino. Separe os dados antes de padronizar ou ajustar; use pipelines.
Viés	A população, as máquinas ou as condições reais podem diferir dos dados usados: obras, cargas e condições fora do histórico enganam o modelo.
Validação	Testar em dados independentes e monitorar mudanças ao longo do tempo (deriva): quando o processo, a matéria-prima ou os sensores mudam, o desempenho cai.
Privacidade	Minimizar dados pessoais, proteger acessos e respeitar as regras aplicáveis. Webhooks e chaves de API não devem ficar públicos.
Supervisão	Definir quem interpreta, decide e responde pelos resultados. O modelo apoia, não substitui o profissional.

Outros pontos do curso	Por que importa
Desbalanceamento	Falhas e defeitos são raros. Use métricas adequadas (sensibilidade, precisão, especificidade, ROC) e peso de classes.
Dados simulados	Os dados do curso são didáticos. Antes de usar uma técnica em um projeto real, valide com dados independentes da sua obra, linha ou planta.

12. Guia da prática no Colab

1. Abra o link do notebook **Colab_IA_nas_Engenharias.ipynb** no Google Colab (botão no repositório do curso no GitHub).
2. Clique em **Arquivo › Salvar uma cópia no Drive**, para ter a sua própria versão editável.
3. Execute as células em ordem com **Shift+Enter**. As seções 0.1 a 0.3 (e o capítulo 2) explicam o Colab, o Python básico e carregam as bibliotecas. **No Colab nada precisa ser instalado**; a célula 0.2 é opcional e só serve para quem roda fora do Colab.
4. Leia a ficha de cada exercício e os comentários do código (explicam o que cada linha faz) e responda às perguntas do bloco, em voz alta ou em grupo.
5. Altere **um valor por vez** e compare os resultados.

No celular o Colab abre em versão simplificada; ative "Site para computador" no navegador. Para a aula, o ideal é um notebook ou computador.

Mapa do notebook

Seção do Colab	Conteúdo	Apostila
0. Preparação	Como o Colab funciona, Python em 5 minutos, instalação opcional e bibliotecas	cap. 2 e 12
Exemplos 1 a 5 (Parte A)	Fronteira supervisionada, árvore e Random Forest, regressão, SVM e overfitting	3.5 e 4
Bloco 1 · Exercícios 1.1 a 1.4 (Civil, 14 min)	Dados, visualização, regressão linear x Random Forest, engenharia de atributos	cap. 5
Bloco 2 · Exercícios 2.1 a 2.5 (Produção, 14 min)	Dados, três modelos, validação cruzada e limiar, métricas e curva ROC	cap. 6 e 4.2
Bloco 3 · Exercícios 3.1 a 3.6 (Elétrica, 14 min)	Dados, visualização, k-means, dendrograma, Isolation Forest e resumo	cap. 7 e 4.4
Bloco 4 · Exercícios 4.1 a 4.3 (Mecânica, 14 min)	Características de vibração, PCA e SVM	cap. 8 e 4.5
Bloco 5 · Exercícios 5.1 a 5.3 (Química, 14 min)	Espectros, PCA e regressão	cap. 9
6. Fechamento (10 min)	Quadro-resumo e desafio final	cap. 10 e 11
Bônus A (extra)	Imagens de folhas sintéticas, atributos de cor e LBP, Random Forest e Teachable Machine	cap. 13
Bônus B (extra)	Alerta do Isolation Forest enviado ao n8n	cap. 14
Bônus C (extra)	Rede neural pequena (primeiro passo do Deep Learning) para a resistência do concreto	cap. 18

Em cada capítulo desta apostila, a faixa laranja **NO COLAB** indica a seção do notebook que você está vendo (problema, dados, modelo, como medimos e o que observar), seguida do código comentado e da saída que o notebook produz.

Desafios finais (escolha um)

1. **Civil:** use só ensaios de 3 e 7 dias. Dá para prever a resistência aos 28 dias?
2. **Produção:** varie o limiar do Random Forest e escolha o ideal para peças de segurança.
3. **Elétrica:** mude `contamination` do Isolation Forest (0,01; 0,02; 0,05) e discuta falsos alarmes.
4. **Mecânica:** acrescente ruído às características e veja quando o SVM deixa de separar as classes.
5. **Química:** aumente o ruído do espectro e ache o número de componentes do PCA com menor erro, usando validação cruzada.
6. **Seus dados:** troque os dados simulados por um CSV do seu laboratório e repita o fluxo (visualização, modelo, métrica). Entregável: uma pergunta clara, X, y (se houver), a métrica e o principal risco.

13. Bônus A · Imagens: folhas e Teachable Machine

Atividade extra, fora do tempo da aula. A palestra começa com imagens de folhas; aqui está a versão prática, com código e sem código.

Da imagem aos números

Uma foto é uma tabela de números (pixels). Para classificar imagens com o ML clássico, extraímos poucos **atributos**: de **cor** (média e desvio dos canais R, G e B) e de **textura** (o histograma do *Local Binary Pattern*, LBP, que compara cada pixel com seus vizinhos). Depois o fluxo é o de sempre: separar treino e teste, treinar um Random Forest e medir no teste.

Esse é o caminho do mestrado contado na palestra: com 120 folhas de citros em seis classes (greening, CVC, rubelose e deficiências de manganês, magnésio e zinco), o descritor LBP chegou a 99,94% de sensibilidade para o greening, enquanto a inspeção visual detecta, em média, 47,61% das plantas com sintomas.

O exemplo do notebook (folhas sintéticas)

Para rodar sem baixar fotos, o notebook **gera folhas sintéticas**: a sadia é verde com nervura central; a com sintoma tem **manchas amareladas irregulares** de intensidade variável. Há variação de iluminação e algumas folhas sadias têm amarelado leve, para o problema não ser trivial.

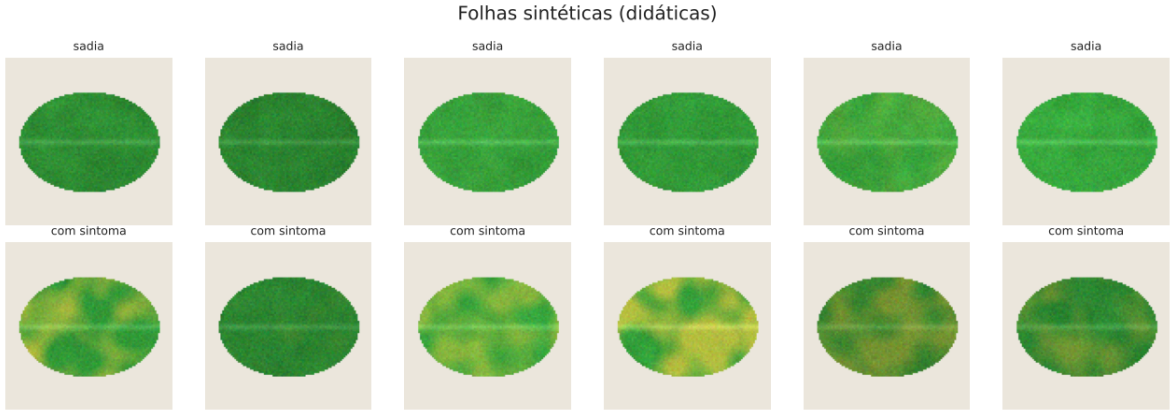


Figura 18. Folhas sintéticas (didáticas): sadias na linha de cima, com sintoma na de baixo. Note que o sintoma pode ser leve, e que algumas folhas sadias são mais amareladas que outras.

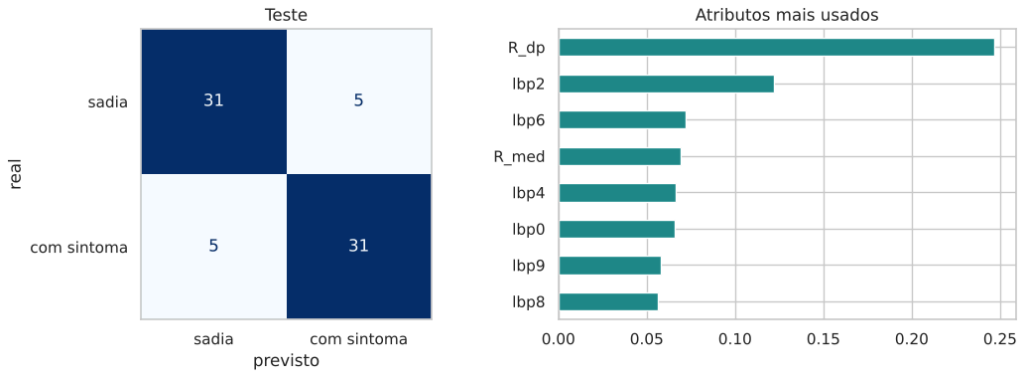


Figura 19. Esquerda: matriz de confusão no teste. Direita: atributos mais usados pelo Random Forest.

NO COLAB · BÔNUS A · FOLHAS SINTÉTICAS E ATRIBUTOS DE IMAGEM	
Problema	Classificar uma folha como **sadia** ou **com sintoma** (amarelado irregular, parecido com o *greening*).
Dados	240 folhas **sintéticas** geradas no código (120 sadias e 120 com sintoma), com variação de iluminação e sintomas de intensidade variável. Com fotos reais, o passo a passo é o mesmo, mas o desafio é maior.
Modelo / técnica	Extraímos **16 atributos** por imagem (média e desvio de R, G, B e o histograma de textura **LBP**) e classificamos com **Random Forest**.
Como medimos	Acurácia, sensibilidade (sintoma achado) e especificidade no teste.
O que observar	O modelo acerta cerca de 86%: o problema não é trivial, e os atributos de cor e textura mais usados aparecem no gráfico da direita.
Nos slides	27 a 32 (exemplo das folhas e Teachable Machine)

```
from skimage.feature import local_binary_pattern      # LBP: descritor de textura
from scipy.ndimage import gaussian_filter             # suavização, para criar manchas "naturais"

def folha(doente, rng, tam=96):
    """Gera uma folha sintética (imagem tam x tam). doente=True cria manchas amareladas."""
    # coordenadas dos pixels
    yy, xx = np.mgrid[0:tam, 0:tam]
    # elipse = contorno da folha
    forma = ((xx - tam / 2) / (tam * 0.42)) ** 2 + ((yy - tam / 2) / (tam * 0.30)) ** 2 < 1
    # variação suave de tom
    ruido = gaussian_filter(rng.normal(0, 1, (tam, tam)), 4)
    ruido = (ruido - ruido.min()) / (ruido.max() - ruido.min())
    # cor verde (R, G, B)
    verde = np.stack([0.18 + 0.05 * ruido, 0.55 + 0.1 * ruido, 0.20 + 0.05 * ruido], axis=-1)
    # sadia: amarelado leve e raro; com sintoma: de leve a forte
    forca = rng.uniform(0.2, 1.0) if doente else (rng.uniform(0.0, 0.45) if rng.random() < 0.5 else 0.0)
    mancha = forca * np.clip(gaussian_filter(rng.normal(0, 1, (tam, tam)), 5) * 6 + rng.uniform(-0.2,
0.8), 0, 1)[..., None]
    # mistura verde e amarelo onde há mancha
    verde = verde * (1 - mancha) + np.array([0.80, 0.75, 0.25]) * mancha
    # nervura central
    nervura = np.exp(-((yy - tam / 2) ** 2) / 3.0)[..., None] * 0.10
    # variação de iluminação
    luz = rng.uniform(0.8, 1.2)
    # imagem final com ruído
    img = np.clip((verde + nervura) * luz + rng.normal(0, 0.03, (tam, tam, 3)), 0, 1)
    img[~forma] = [0.93, 0.92, 0.88]                                          # fundo claro
    return img, forma

rng = np.random.default_rng(5)
imgs, formas, rotulos_img = [], [], []
for i in range(240):                              # 240 folhas: alterna sadia (0) e com sintoma (1)
    d = i % 2
    im, fm = folha(d, rng); imgs.append(im); formas.append(fm); rotulos_img.append(d)
rotulos_img = np.array(rotulos_img)

fig, axes = plt.subplots(2, 6, figsize=(13, 4.6))
# mostra 6 sadias (linha de cima) e 6 com sintoma (embaixo)
for j in range(6):
    axes[0, j].imshow(imgs[2 * j]); axes[0, j].set_title("sadia", fontsize=9)
    axes[1, j].imshow(imgs[2 * j + 1]); axes[1, j].set_title("com sintoma", fontsize=9)
for ax in axes.ravel(): ax.axis("off")
plt.suptitle("Folhas sintéticas (didáticas)"); plt.tight_layout(); plt.show()
```



Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

- **O que é:** 12 folhas **sintéticas** (desenhadas pelo código). A fileira de cima é de folhas **sadias**: verdes e uniformes. A de baixo é de folhas **com sintoma**: manchas amareladas irregulares, parecidas com o *greening*.
- **Atenção:** algumas folhas com sintoma estão quase verdes (sintoma fraco), e o modelo vai ter dificuldade com elas. A iluminação também varia de folha para folha, como numa foto real.

```
def atributos(im, fm):
    """Resume uma imagem em 16 números: cor (6) e textura LBP (10)."""
    # só os pixels da folha (sem o fundo)
    pixels = im[fm]
    # média e desvio de R, G e B
    cor = list(pixels.mean(axis=0)) + list(pixels.std(axis=0))
    cinza = im.mean(axis=2)                                          # versão em tons de cinza
    # textura local
    lbp = local_binary_pattern((cinza * 255).astype(np.uint8), P=8, R=1, method="uniform")
    # histograma normalizado do LBP
    hist = np.bincount(lbp[fm].astype(int), minlength=10)[:10] / fm.sum()
    return cor + list(hist)

nomes = ["R_med", "G_med", "B_med", "R_dp", "G_dp", "B_dp"] + ["lbp%d" % k for k in range(10)]
# tabela: 1 linha por imagem
Xim = pd.DataFrame([atributos(im, fm) for im, fm in zip(imgs, formas)], columns=nomes)
print(Xim.shape, "(imagens x atributos)")
Xi_tr, Xi_te, yi_tr, yi_te = train_test_split(Xim, rotulos_img, test_size=0.3, stratify=rotulos_img,
random_state=SEED)

# treina o classificador
rf_im = RandomForestClassifier(n_estimators=200, random_state=SEED).fit(Xi_tr, yi_tr)
# prevê no teste
pred_im = rf_im.predict(Xi_te)
print("Acurácia: %.2f | sensibilidade (sintoma achado): %.2f | especificidade: %.2f" % (
      accuracy_score(yi_te, pred_im), recall_score(yi_te, pred_im), recall_score(yi_te, pred_im,
pos_label=0)))
print("Precisão (alertas certos): %.2f | F1: %.2f" % (precision_score(yi_te, pred_im), f1_score(yi_te,
pred_im)))
fig, axes = plt.subplots(1, 2, figsize=(11, 4))
# matriz de confusão
matriz(yi_te, pred_im, axes[0], [0, 1], ["sadia", "com sintoma"], titulo="Teste")
pd.Series(rf_im.feature_importances_, index=nomes).sort_values().tail(8).plot(kind="barh", color=TEAL,
ax=axes[1], title="Atributos mais usados")
plt.tight_layout(); plt.show()
```

Saída

```
(240, 16) (imagens x atributos)
Acurácia: 0.86 | sensibilidade (sintoma achado): 0.86 | especificidade: 0.86
Precisão (alertas certos): 0.86 | F1: 0.86
```

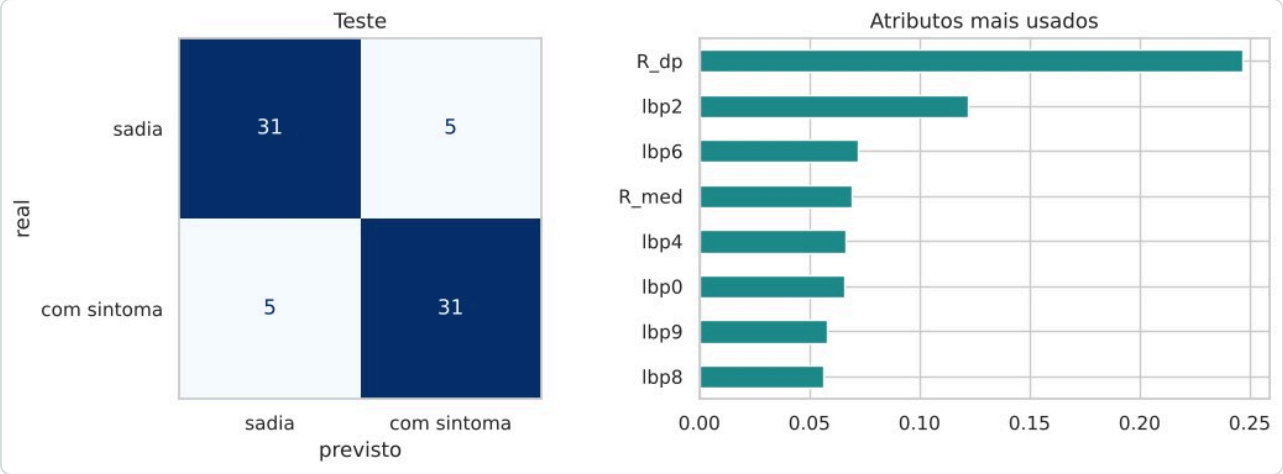


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

- **Matriz "Teste":** linhas = realidade, colunas = previsão. De 36 folhas sadias, **31** foram certas e **5** receberam o alarme sem precisar; de 36 com sintoma, **31** foram achadas e **5** passaram despercebidas. Acurácia, sensibilidade e especificidade de **0,86**.
- **Gráfico "Atributos mais usados":** cada barra é a importância do atributo na decisão. O mais usado é **R_dp** (desvio-padrão do canal vermelho): mede o quanto a cor **varia** dentro da folha, ou seja, a irregularidade das manchas. Os atributos **lbp** descrevem a **textura** (padrões locais da imagem). Resumo: o modelo separa as folhas pela **variação de cor e pela textura**.

Cuidados com imagens

Folhas sintéticas são fáceis. Com fotos reais pesam a luz, o fundo, a câmera e a variedade da planta: valide em fotos de outro dia, outra fazenda e outro celular. Sintomas parecidos (deficiências nutricionais, outras doenças) confundem; o modelo é uma **triagem**, e a confirmação é feita por análise de laboratório. Para fotos reais, a abordagem moderna usa redes neurais convolucionais, que aprendem os atributos sozinhas.

Sem programar: Teachable Machine

1. Abra https://teachablemachine.withgoogle.com/ e escolha **Projeto de imagem**.
2. Crie duas classes, por exemplo “folha sadia” e “folha com sintoma”, e envie ou grave de 30 a 50 fotos de cada.
3. Clique em **Treinar modelo** e teste com uma foto nova pela câmera ou por arquivo.
4. Discuta: o que acontece com uma folha de outra planta, com outra luz ou com um fundo diferente?

É o mesmo fluxo de exemplos, padrões e previsão, sem uma linha de código. A previsão é uma pista para investigar e não substitui a confirmação especializada.

14. Bônus B · Do modelo à ação: n8n e outras ferramentas

Atividade extra, fora do tempo da aula. Na palestra o n8n aparece só como menção no bloco de Elétrica.

Um modelo só gera valor quando **alguém age** sobre a previsão. O **n8n** é uma plataforma de automação de fluxos (código aberto, visual, com *nodes*) que pode receber o resultado do modelo e disparar ações: e-mail, Telegram, planilha, abertura de chamado.

Sensor	Modelo	Webhook	n8n	Ação
leitura	previsão	HTTP POST com JSON	regras	alerta ou chamado

Montando o fluxo

1. Crie um fluxo (workflow) e adicione o nó **Webhook** com método POST.
2. Adicione um nó **IF** com a condição `nivel` igual a `ALTO`.
3. No ramo verdadeiro, adicione um nó de notificação (Telegram, Gmail ou Slack) e um nó **Google Sheets** (Append Row) para registrar a leitura.
4. No Webhook, use *Listen for test event* e cole a URL na variável `N8N_WEBHOOK_URL` do notebook (seção “Bônus B” do notebook).

```
{
  "timestamp": "2026-10-28T20:29:31",
  "motor_id": "M-017",
  "hora_operacao": 18,
  "vibracao_mm_s": 1.84,
  "nivel": "ALTO"
}
```

> **Atenção**
>
> O Colab só alcança um n8n com **URL pública** (n8n Cloud ou um túnel como o ngrok). Teste antes da aula e tenha capturas de tela como plano B. Nunca publique chaves de API nem URLs privadas no notebook.

NO COLAB · BÔNUS B · ALERTA DO ISOLATION FOREST PARA O N8N	
Problema	Transformar a previsão em **ação**: quando o modelo sinaliza uma anomalia, avisar alguém.
Dados	A primeira anomalia detectada na seção 3.5 (variável `ev`).
Modelo / técnica	Nenhum modelo novo: montamos um **JSON** e o enviamos por **HTTP POST** a um *webhook* do **n8n** (automação visual).
Como medimos	O n8n responde com o código 200 quando recebe.
O que observar	Em branco, o código só **mostra** o JSON que seria enviado. Para enviar de verdade, cole a URL do webhook (precisa ser **pública**: n8n Cloud ou ngrok).
Nos slides	extra: não está nos slides

```
# json: montar a mensagem; datetime: data e hora do alerta
import json, datetime
try:
    import requests                          # requests: envia a mensagem pela internet (HTTP)
except ImportError:
    requests = None

# cole aqui a URL do webhook do n8n, ex.: "https://SEU-N8N/webhook-test/alerta-motor" (nunca
# publique chaves!)
N8N_WEBHOOK_URL = ""

def enviar_alerta(hora, vibracao, motor_id="M-017"):
    """Monta o JSON do alerta e, se houver URL, envia ao n8n."""
    payload = {"timestamp": datetime.datetime.now().isoformat(timespec="seconds"),   # quando
               # qual motor e hora
               "motor_id": motor_id, "hora_operacao": int(hora),
               # leitura e nível do alerta
               "vibracao_mm_s": round(float(vibracao), 2), "nivel": "ALTO"}
    # mostra o JSON
    print(json.dumps(payload, indent=2, ensure_ascii=False))
    # só envia se houver URL
    if N8N_WEBHOOK_URL and requests is not None:
        try:
            r = requests.post(N8N_WEBHOOK_URL, json=payload, timeout=10); print("n8n respondeu:",
r.status_code)
        except Exception as e:
            print("Não foi possível chamar o n8n:", e)

# primeira anomalia detectada (seção 3.5)
primeira = ev.iloc[0]
enviar_alerta(primeira["hora"], primeira["vibracao"])
```

Saída

```
{
  "timestamp": "2026-10-29T12:59:48",
  "motor_id": "M-017",
  "hora_operacao": 18,
  "vibracao_mm_s": 1.84,
  "nivel": "ALTO"
}
```

Outras ferramentas do ecossistema

Ferramenta	Para que serve	Quando usar
MLflow	Registrar experimentos e versionar modelos	Comparar muitas tentativas de treino
Streamlit / Gradio	Interface web em poucas linhas de Python	Mostrar o modelo a quem não programa
FastAPI	Expor o modelo como uma API	Integrar com n8n ou outros sistemas
Node-RED	Automação industrial e IoT	Fluxos junto a CLPs e sensores
Grafana / Power BI	Painéis de monitoramento	Acompanhar indicadores em tempo real

15. Glossário

Termo	Significado
Feature (variável explicativa)	Variável de entrada do modelo.
Target (alvo)	Variável que queremos prever.
Treino e teste	Partes dos dados usadas, respectivamente, para ajustar e para avaliar o modelo.
Overfitting / underfitting	Ajuste excessivo ao treino (ruim em dados novos) / modelo simples demais.
Validação cruzada	Repetição do treino e do teste em partes diferentes dos dados.
MAE, RMSE, R^2	Métricas de erro e de ajuste em regressão.
Matriz de confusão	Tabela que cruza classes previstas e reais.
Precisão e recall (sensibilidade)	Proporção de alertas corretos e proporção de casos reais detectados.
Especificidade	Proporção de casos normais corretamente liberados (VN ÷ (VN + FP)).
Curva ROC e AUC	Sensibilidade contra falsos positivos para todos os limiares; AUC é a área sob a curva (0,5 acaso, 1,0 perfeito).
Vetores de suporte	Pontos mais próximos da fronteira do SVM, que a definem.
Dendrograma	Árvore do agrupamento hierárquico; cortá-la define os grupos.
LBP	Local Binary Pattern: descritor de textura que compara cada pixel com seus vizinhos.
Teachable Machine	Ferramenta do Google para treinar modelos de imagem, som ou pose no navegador, sem programar.
Limiar de decisão	Valor de probabilidade a partir do qual o alerta é emitido.
Classes desbalanceadas	Quando uma classe (como defeito ou falha) é muito mais rara que a outra.
Agrupamento (k-means)	Agrupa observações semelhantes, sem rótulos.
Silhueta e cotovelo	Critérios para escolher o número de grupos.
Anomalia (outlier)	Observação que foge do padrão da maioria.
PCA	Projeta os dados em poucos eixos preservando a variação.
Árvore de decisão	Decide por uma sequência de perguntas sobre as variáveis.
Random Forest	Conjunto de muitas árvores que decidem por votação.
SVM / kernel	Separa as classes com a fronteira de maior margem / função que permite fronteiras curvas.
α e β (coeficientes)	Na reta $y = \alpha + \beta \cdot x$, α é o intercepto e β a inclinação: quanto y muda quando x sobe uma unidade.
RMSE	Raiz do erro quadrático médio: como o MAE, mas pune mais os erros grandes.
Pipeline	Sequência de etapas (por exemplo, padronizar e treinar) tratadas como um único modelo.
Sensor virtual	Modelo que estima uma grandeza difícil de medir a partir de outras fáceis de medir.
Webhook	Endereço que recebe dados enviados por outro sistema via HTTP.

16. Perguntas de revisão

1. Qual a diferença entre regressão e classificação? Dê um exemplo de cada em engenharia.
2. Por que separamos os dados em treino e teste antes de ajustar o modelo?
3. Um modelo acerta 88% das peças em um conjunto com 12% de defeitos. Isso é bom?
4. Qual métrica você priorizaria em uma peça de segurança? E em um produto de baixo custo?
5. O que acontece com os erros de treino e de teste conforme a complexidade do modelo aumenta?
6. Para que serve a validação cruzada e o que o desvio padrão dela indica?
7. Qual a diferença entre agrupamento e classificação?
8. Por que a silhueta sugeriu k = 2 nos motores se há três regimes de carga?
9. Por que o SVM exige variáveis padronizadas e a árvore de decisão não?
10. Quando o PCA é útil? Por que ajustá-lo só com os dados de treino?
11. Por que, na Química, 5 componentes foram melhores que 4, se 4 já explicavam 95% da variância?
12. Em um modelo de defeitos, qual a diferença entre sensibilidade e especificidade? O que a curva ROC mostra?
13. Por que uma Random Forest costuma errar menos do que uma única árvore?
14. O que o SVM chama de margem e de vetores de suporte?
15. No Teachable Machine, o que acontece se a foto nova tiver luz ou fundo muito diferentes das de treino?
16. Como ligar um modelo a um alerta por e-mail usando o n8n? (Bônus B)

Respostas comentadas

1. Regressão prevê um número (resistência do concreto em MPa); classificação prevê uma categoria (peça boa ou defeituosa).
2. Para medir o desempenho em dados que o modelo nunca viu. Avaliar no mesmo conjunto do treino superestima a qualidade e esconde o overfitting.
3. Não necessariamente: dizer “sempre boa” já acerta 88%. É preciso olhar recall, precisão e a matriz de confusão.
4. Em peça de segurança, o recall (não deixar defeito passar). Em baixo custo, pode valer a precisão, para evitar refugar peças boas. A escolha depende do custo de cada erro.
5. O erro de treino cai sempre; o de teste cai e depois sobe (overfitting). O ponto ideal é o mínimo do erro de teste.
6. Avalia o modelo em várias divisões dos dados. Um desvio grande indica resultado instável, dependente do corte.
7. A classificação usa rótulos conhecidos e prevê categorias; o agrupamento não tem rótulos e descobre grupos nos próprios dados.
8. Nenhuma métrica decide sozinha. A silhueta favorece grupos bem separados; o conhecimento do domínio (três regimes) e o cotovelo apontam para 3.
9. O SVM usa distâncias, que são dominadas pelas variáveis de maior escala; a árvore só compara cada variável a um limite.
10. Para visualizar, comprimir variáveis correlacionadas e reduzir ruído. Ajustá-lo com todos os dados deixaria informação do teste vazar para o treino.

11. Eram três substâncias mais a linha de base; o quinto eixo, de pouca variância, carrega informação relevante. Variância explicada não é tudo: valide o número de componentes.
12. Sensibilidade é a fração dos defeitos reais que o modelo acha (evita falsos negativos); especificidade é a fração das peças boas liberadas corretamente (evita falsos positivos). A curva ROC mostra as duas para todos os limiares; a AUC resume a qualidade (0,5 é o acaso).
13. Cada árvore é treinada em uma amostra diferente e erra de um jeito; a votação de muitas árvores dá uma fronteira mais estável e reduz o overfitting.
14. A margem é a distância entre a fronteira e os pontos mais próximos de cada classe; esses pontos mais próximos são os vetores de suporte, que definem a fronteira.
15. O desempenho tende a cair, porque o modelo aprendeu padrões das fotos de treino. É preciso treinar e validar com a variedade de condições reais.
16. O notebook envia um JSON por HTTP POST a um webhook; no n8n, um nó IF testa o nível de risco e um nó de e-mail ou Telegram envia a mensagem.

17. Referências e materiais

- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12.
- Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*. O'Reilly.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1).
- Cortes, C.; Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3).
- Liu, F. T.; Ting, K. M.; Zhou, Z.-H. (2008). Isolation Forest. *IEEE ICDM*.
- Jolliffe, I. T.; Cadima, J. (2016). Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374.
- Abrams, D. A. (1918). *Design of concrete mixtures*. Structural Materials Research Laboratory, Bulletin 1.
- Smith, W. A.; Randall, R. B. (2015). Rolling element bearing diagnostics using the Case Western Reserve University data: a benchmark study. *Mechanical Systems and Signal Processing*, 64–65.
- Ojala, T.; Pietikäinen, M.; Mäenpää, T. (2002). Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE TPAMI*, 24(7).
- Ribeiro, P. P. E. (2014). Aplicação de técnicas de processamento de imagens para diferenciação do greening de outras pragas. Dissertação, EESC-USP.

Documentação e links

- Google Colab: https://colab.research.google.com/
- scikit-learn: https://scikit-learn.org/stable/
- Aprendizado supervisionado: https://scikit-learn.org/stable/supervised_learning.html
- Agrupamento: https://scikit-learn.org/stable/modules/clustering.html
- PCA: https://scikit-learn.org/stable/modules/decomposition.html#pca
- Teachable Machine: https://teachablemachine.withgoogle.com/
- n8n: https://docs.n8n.io/
- Notebook e slides do curso: repositório no GitHub (link informado pela ministrante)

Confira os links e as referências antes de divulgar este material.

Sobre a ministrante

Dra. Patricia Pedroso Estevam Ribeiro. Engenheira Eletricista (UNIFEB), mestre em Engenharia Elétrica (USP São Carlos), MBA em Data Science e Analytics (USP/ESALQ) e doutora em Oncologia Molecular (Hospital de Amor). Contato: patriciapedrosoestevam@gmail.com.

18. Bônus C · Redes neurais e Deep Learning (extra)

Este capítulo é um extra opcional: não faz parte da apresentação. Ele corresponde ao **Bônus C** do notebook.

Termo	O que é	Exemplo em engenharia	Onde aparece no curso
Inteligência Artificial	Campo amplo: sistemas que simulam capacidades humanas, como decidir e aprender.	Sistema de manutenção que decide quando parar uma máquina.	O curso inteiro
Machine Learning	Modelos que aprendem com exemplos, a partir de variáveis escolhidas por nós (colunas de uma tabela).	Prever a resistência do concreto; classificar peça boa ou defeituosa; agrupar regimes de motores.	Exemplos 1 a 5 e Blocos 1 a 5
Deep Learning	Redes neurais com muitas camadas, que aprendem as características direto dos dados brutos.	Inspeção visual de defeitos em imagens de peças; reconhecer folhas doentes em fotos; detectar falhas no som ou no sinal bruto de vibração.	Teachable Machine (Bônus A) e rede neural pequena (Bônus C)

Como funciona uma rede neural

Um **neurônio artificial** recebe várias entradas, multiplica cada uma por um **peso**, soma tudo e aplica uma função que decide o quanto ele "acende". Uma **rede** organiza muitos neurônios em camadas: a **camada de entrada** recebe os dados (por exemplo, cimento, água, aditivo e idade), as **camadas escondidas** combinam as informações, e a **camada de saída** entrega a resposta (por exemplo, a resistência prevista). No treino, o algoritmo compara a previsão com a resposta certa e **ajusta os pesos** aos poucos para errar menos. Quando há muitas camadas escondidas, falamos em **Deep Learning**; para imagens, usam-se redes especiais chamadas **convolucionais (CNN)**.

	ML clássico (neste curso)	Deep Learning
Dados de entrada	Tabelas, com variáveis que escolhemos (rpm, temperatura, relação a/c)	Dados brutos: imagens, áudio, sinais, texto
Quantos exemplos	Centenas a milhares	Milhares a milhões (ou uma rede já treinada e ajustada com poucos exemplos)
Explicar a decisão	Mais fácil (coeficientes, regras da árvore)	Mais difícil ("caixa-preta")
Custo de computação	Baixo: roda no computador comum	Alto: costuma precisar de GPU
Exemplo no curso	Random Forest para a resistência do concreto	Teachable Machine para classificar imagens; rede neural no Bônus C

Onde está o Deep Learning neste curso? (1) No **Teachable Machine** (Bônus A): ele treina no navegador uma **rede neural profunda já treinada com milhões de imagens** (aprendizado por transferência) para reconhecer as suas classes, sem você escrever código. (2) No **Bônus C**: uma rede neural pequena, com duas camadas escondidas, prevê a resistência do concreto e é comparada com a regressão linear e o Random Forest.

NO COLAB · BÔNUS C · REDE NEURAL PEQUENA PARA PREVER A RESISTÊNCIA DO CONCRETO	
Problema	Prever a **resistência do concreto (MPa)** com uma **rede neural** e comparar com a regressão linear e o Random Forest do exercício 1.3.
Dados	As mesmas 600 amostras do Bloco 1 (cimento, água, aditivo e idade), com a mesma divisão treino/teste.
Modelo / técnica	**Rede neural (MLP)** com 2 camadas escondidas (32 e 16 neurônios). Cada neurônio soma as entradas com pesos e aplica uma função; as camadas empilhadas aprendem relações curvas. **Deep Learning** é esta ideia com **muitas camadas**.
Como medimos	MAE, RMSE e R^2 no teste, e o gráfico real x previsto.
O que observar	A rede neural teve o menor erro nestes dados (MAE 1,87 MPa contra 2,16 do Random Forest), mas a diferença é pequena e ela é mais difícil de explicar. O Deep Learning brilha mesmo em **imagens, áudio e texto** com muitos exemplos.
Nos slides	extra: não está nos slides

```
# rede neural do scikit-learn (Perceptron de Múltiplas Camadas)
from sklearn.neural_network import MLPRegressor
from sklearn.metrics import mean_squared_error          # erro quadrático médio (para o RMSE)

# --- 1) Refazer a mesma divisão treino/teste do exercício 1.3 e treinar a rede ---
X_tr, X_te, y_tr, y_te = train_test_split(civil[feats_civil], civil["resistencia_MPa"], test_size=0.25,
random_state=SEED)
# redes neurais precisam das variáveis padronizadas
rede = make_pipeline(StandardScaler(),
                     # 2 camadas escondidas: 32 e 16 neurônios
                     MLPRegressor(hidden_layer_sizes=(32, 16),
                                  max_iter=3000, random_state=SEED))
rede.fit(X_tr, y_tr)                                    # TREINAR: ajusta os pesos para errar menos
prev_rede = rede.predict(X_te)                          # previsões nos dados de teste

# --- 2) Quantos pesos a rede aprendeu? ---
mlp = rede[-1]                                          # o passo final do pipeline: a rede neural
n_pesos = sum(w.size for w in mlp.coefs_) + sum(b.size for b in mlp.intercepts_)   # pesos + vieses
print("Arquitetura: 4 entradas -> 32 neurônios -> 16 neurônios -> 1 saída (resistência)")
print("Pesos aprendidos: %d (a regressão linear aprendeu só 5: α e quatro β)" % n_pesos)

# --- 3) Métricas no teste, lado a lado com os modelos do exercício 1.3 ---
mae_r = mean_absolute_error(y_te, prev_rede); rmse_r = np.sqrt(mean_squared_error(y_te, prev_rede)); r2_r
= r2_score(y_te, prev_rede)
# tabela do exercício 1.3 (linear e Random Forest)
tab = tab_civil[["MAE (MPa)", "RMSE (MPa)", "R²"]].copy()
tab.loc["Rede neural (MLP)"] = [round(mae_r, 3), round(rmse_r, 3), round(r2_r, 3)]
display(tab)

# --- 4) Gráfico: real x previsto ---
fig, ax = plt.subplots(figsize=(5.2, 4.6))
# cada ponto é uma amostra de teste
ax.scatter(y_te, prev_rede, alpha=0.5, color=TEAL)
lim = [y_te.min(), y_te.max()]
# linha ideal: previsto = real
ax.plot(lim, lim, "--", color=RED, label="previsão perfeita")
ax.set_xlabel("real (MPa)"); ax.set_ylabel("previsto (MPa)"); ax.set_title("Rede neural (MLP)");
ax.legend(frameon=False); limpa(ax)
plt.tight_layout(); plt.show()
```

Saída

```
Arquitetura: 4 entradas -> 32 neurônios -> 16 neurônios -> 1 saída (resistência)
Pesos aprendidos: 705 (a regressão linear aprendeu só 5: α e quatro β)

                  MAE (MPa)  RMSE (MPa)     R²
Modelo
Regressão linear      5.526       6.567  0.767
Random Forest         2.160       2.669  0.962
Rede neural (MLP)     1.869       2.265  0.972
```

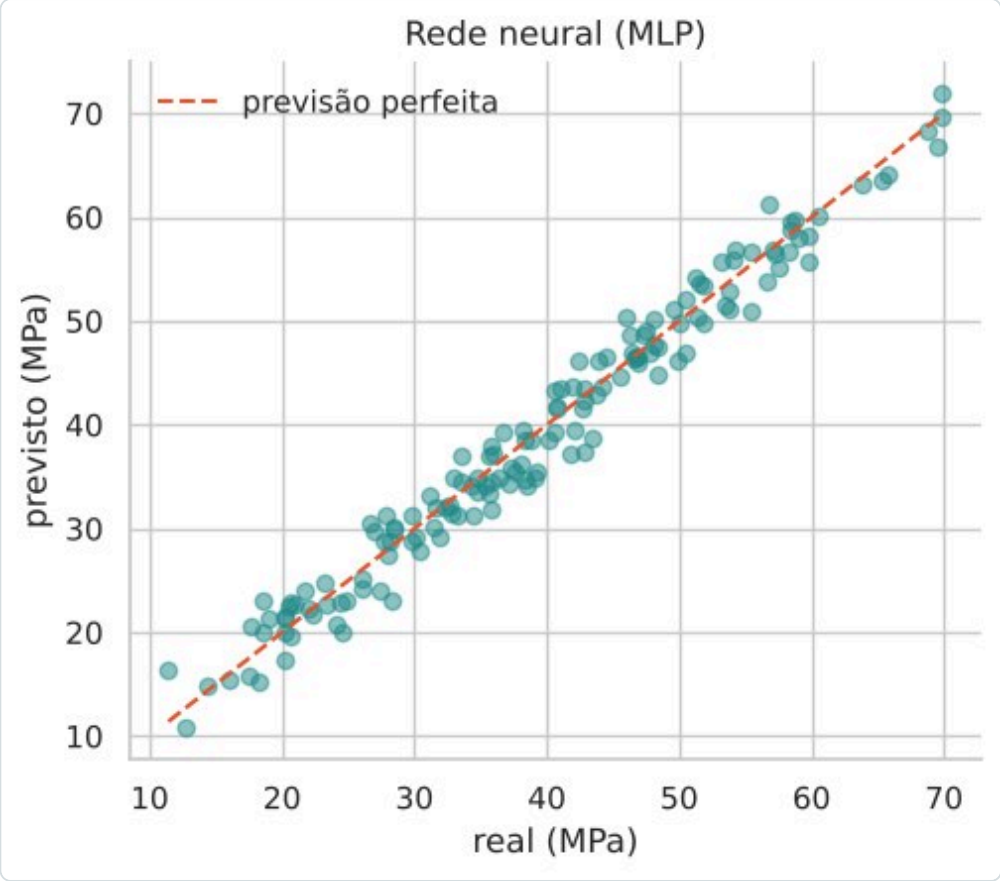


Gráfico gerado pela célula acima no Colab

LEITURA DOS GRÁFICOS

- **O que a rede aprendeu:** 4 entradas (cimento, água, aditivo, idade), duas camadas escondidas (32 e 16 neurônios) e 1 saída (a resistência em MPa). No total são **705 pesos** ajustados no treino, contra apenas 5 números da regressão linear.
- **Tabela (teste):** a regressão linear erra **5,53 MPa** (R^2 0,767), o Random Forest **2,16 MPa** (R^2 0,962) e a rede neural **1,87 MPa** (R^2 0,972). A rede neural teve o menor erro, mas a diferença para o Random Forest é pequena.
- **Gráfico "real x previsto":** horizontal = resistência real (MPa), vertical = prevista pela rede. A linha tracejada é a previsão perfeita; os pontos ficam **colados nela**, ou seja, a rede capturou as curvas (idade que satura, efeito da água).
- **Onde está o Deep Learning:** uma rede neural com **muitas** camadas (dezenas ou centenas) é o que se chama de *Deep Learning*. Ela compensa quando há muitos dados brutos, como **imagens** (defeitos em peças, folhas), **sinais** e **texto**. O Teachable Machine do Bônus A usa uma rede profunda já treinada.

PERGUNTAS

1. Qual a diferença entre uma rede neural e a regressão linear do exercício 1.3?
2. A rede neural foi melhor que o Random Forest? O que isso diz sobre quando usar Deep Learning?

RESPOSTAS COMENTADAS

1. A regressão linear aprende **5 números** (α e quatro β) e só desenha uma **reta** (ou plano). A rede neural aprende **centenas de pesos** em camadas empilhadas, e por isso consegue desenhar **curvas** e combinar variáveis (por exemplo, o efeito da idade que satura com o tempo).

2. Aqui a rede foi um pouco melhor (MAE **1,87 MPa** contra **2,16 MPa** do Random Forest, e R^2 0,972 contra 0,962), mas a diferença é pequena. Em **dados em tabela e poucos exemplos** (600 amostras), o Random Forest costuma chegar perto com muito menos ajuste e é mais simples de explicar. O **Deep Learning** compensa quando há **muitos dados** e

informação "bruta" difícil de resumir em colunas: **imagens** (defeitos em peças, folhas), **sinais** (áudio, vibração bruta) e **texto**. O Teachable Machine do Bônus A usa uma rede profunda já treinada com milhões de imagens.