Inteligência Artificial aplicado na Engenharia

Dra. Patricia Pedroso Estevam Ribeiro

· Engenharia Elétrica · Ciências de Dados · Bioinformática (Oncologia Molecular)

MINHA HISTÓRIA

Do curso técnico para a engenharia até a bioinformática em oncologia

1999-2001	**CETEC** Ensino médio com curso técnico em Processamento de Dados
2002–2006	**UNIFEB** Engenharia Elétrica com ênfase em Computação
2006	**SÃO CARLOS** Primeiro emprego, na Enalta
2009	**EMBRAPA INSTRUMENTAÇÃO** Estágio na Embrapa de São Carlos
2010–2014	**USP SÃO CARLOS** Engenharia Elétrica, processamento de imagens. Estágio no laboratório do Dr. Lúcio André. Mestrado em 2014
Depois do mestrado	**LICEUTEC** Docência em Eletrotécnica, Eletrônica e Automação Industrial
2020 - 2026	**HOSPITAL DE AMOR** Doutorado em Oncologia Molecular e bolsa DTI-A
2023–2024	**USP/ESALQ** MBA em Data Science e Analytics
2025 - Hoje	**USP/ESALQ** MBA em Gestão de Negócios Digitais e IA (em andamento)

MINHA HISTÓRIA · PRIMEIRO EMPREGO, ENALTA (2006–2007)

Meu primeiro projeto: controlar a irrigação com um microcontrolador PIC

Problema: controlar a lâmina de vinhaça aplicada na plantação.

Sistema: aspersor alimentado por uma motobomba, em um equipamento de rolo de irrigação.

Meu trabalho: desenvolver o controlador com microcontrolador PIC, na Enalta, em São Carlos.





MINHA HISTÓRIA · MESTRADO, USP SÃO CARLOS E EMBRAPA INSTRUMENTAÇÃO

Visão computacional para identificar o greening nos citros

Problema: a inspeção visual detecta em média 47,61% das plantas com sintomas, e o PCR é caro e lento.

Dados: 120 folhas em seis classes: greening, CVC, rubelose e deficiências de manganês, magnésio e zinco.

Métodos de visão computacional clássica. : análise de de textura (LBP, LFP e Haralick) em imagens de folhas.





99,94%

de sensibilidade do LBP para o greening. Nas seis classes, o LBP variou de 97,02% a 99,94%.

Os descritores de Haralick ficaram bem abaixo, entre 38% e 46%.

Fonte: dissertação (EESC-USP, 2014) e Ribeiro, Paiva e Jorge, X WVC (2014)

No doutorado: Reconhecimento de padrão de biomarcadores de instabilidade genômica em trabalhadores rurais

A mesma base de engenharia (dados, estatística e programação) aplicada a dados epidemiológicos e moleculares.

DADOS

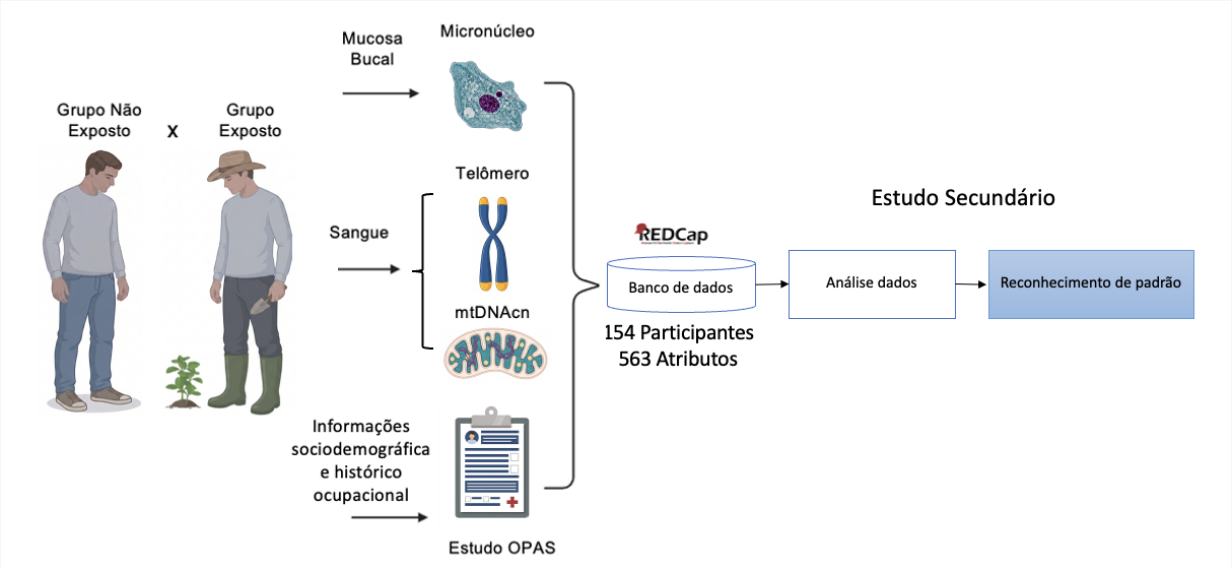
Dados dos grupos expostos e não expostos

MÉTODOS

Estatística, técnica de visualização e projeção de dados seleção de variáveis, aprendizado supervisionado, aprendizado não supervisionado.

USO POTENCIAL

Identificar perfis de risco e apoiar a vigilância em saúde de trabalhadores expostos a agrotóxicos.



77,78%
Acurácia média com Support Vector Machine (SVM)

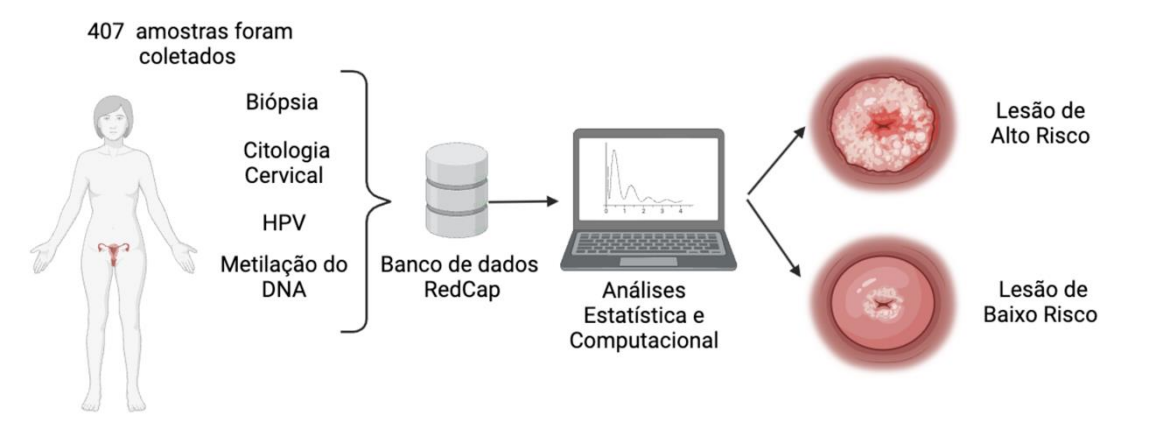
0,80
AUC SVM

0,85
Sensibilidade média

MBA EM DATA SCIENCE E ANALYTICS

Metilação do DNA e aprendizado de máquina no câncer cervical

12
genes metilados analisados por PCR



84,15%
acurácia média do Random Forest no teste

0,91
AUC no conjunto de teste

RF, SVM e LDA comparados: lesão de baixo risco (<NIC2) contra alto risco (NIC2+)

A PCA destacou **EPB41L3, JAM3 e hsa-miR-124** como marcadores de NIC2+

PROJETO 1 · LAMINAS DE H&E DE MELANOMA

TILs e resposta à imunoterapia anti-PD-1

TILs são os linfócitos infiltrantes de tumor, observados nas lâminas de histopatologia.

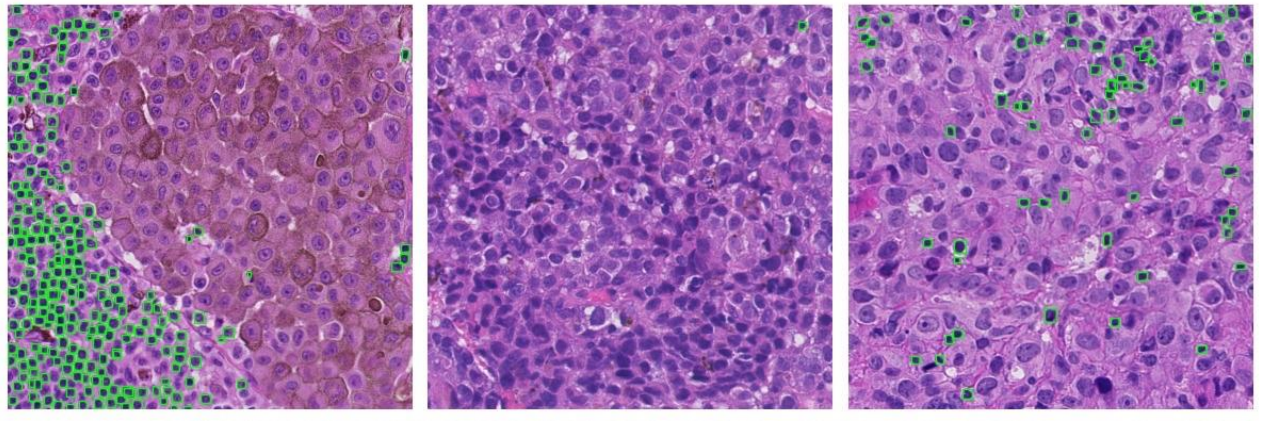
Lâmina histopatológica → **Classificação dos TILs** → **Resposta ao anti-PD-1**

Brisk

Linfócitos infiltram o tumor de forma difusa.

Non-brisk

Infiltração focal ou esparsa.



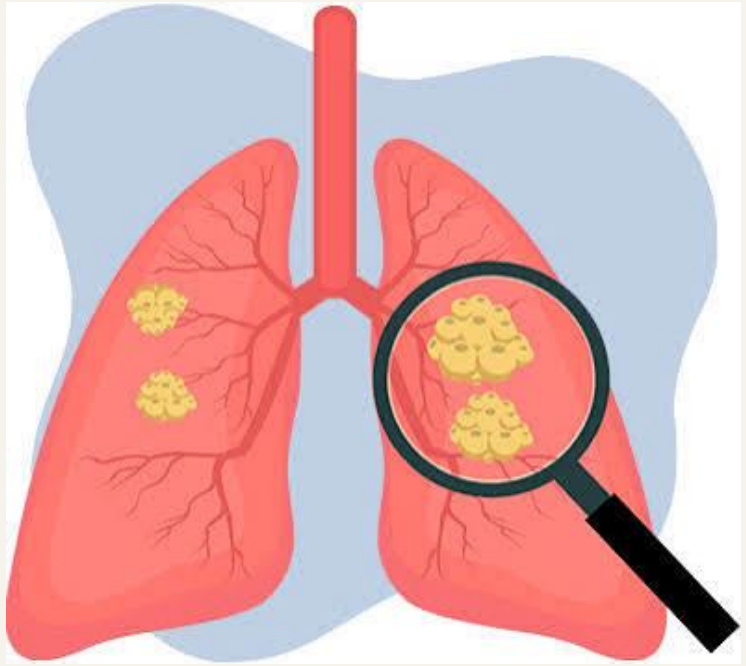
Deep Learning (CNN)
Vision Transformers (ViT)

PROJETO BOLSA DTI – A · CÂNCER DE PULMÃO (NSCLC)

Validação externa de uma assinatura gênica para imunoterapia (Anti-PDL1) para câncer de pulmão

ASSINATURA NANOSTRING FIXA

- ZNF100
- PRR5
- GLS2
- MAPT



COMO VALIDAMOS

Dois conjuntos públicos do GEO: GSE166449 e GSE207422.

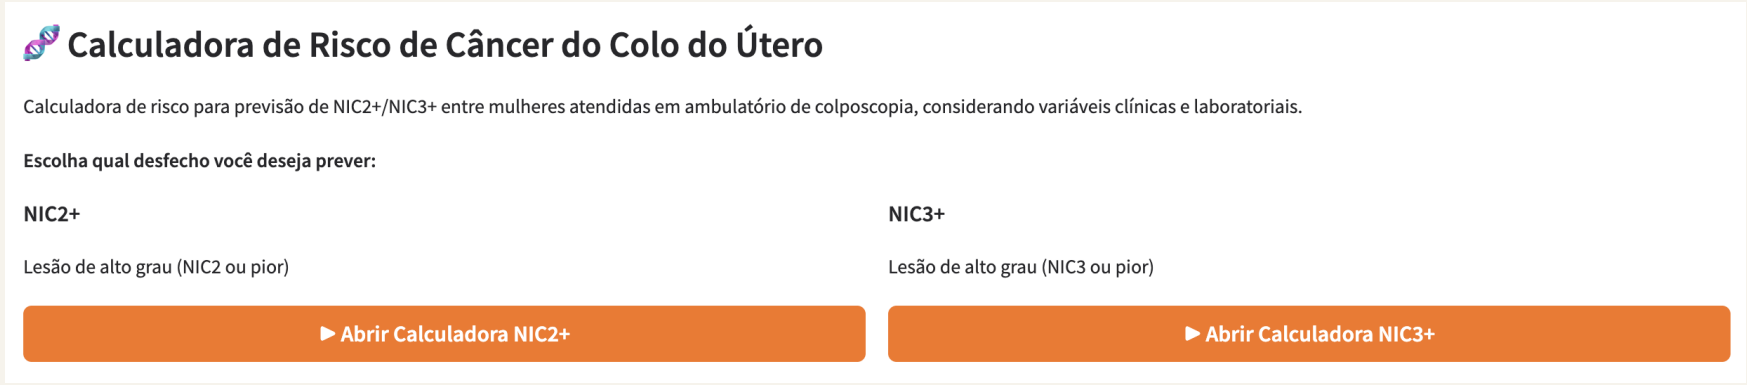
PROJETO BOLSA DTI – A · CÂNCER DO COLO DO ÚTERO

Calculadora de risco de neoplasia intraepitelial cervical (NIC)

1.689

casos na coorte

genótipos de HPV (16, 18, 31, 45, 51, 33/58, 56/59/66, 35/39/68)



Aplicativo em fase de teste pelos médicos ginecológicos

MBA USP ESALQ – Gestão de Negócios com IA

Viabilidade de IA no rastreamento do câncer do colo do útero

MINHA HISTÓRIA

O que a engenharia elétrica me ensinou?

Raciocinar

Transformar problemas complexos em soluções estruturadas.

Enxergar o todo

Compreender o sistema antes de tentar resolver suas partes.

Investigar

Questionar, formular hipóteses e buscar respostas baseadas em evidências.

Conectar saberes

Unir matemática, programação e ciência para resolver novos desafios.

Automatizar

Transformar processos manuais em soluções eficientes e reproduzíveis.

Inovar

Usar a base da engenharia para responder perguntas novas na saúde.

MERCADO HOJE

O mercado está mudando. E nós também precisamos aprender.

Não é preciso saber tudo: é preciso aprender, experimentar e avaliar.

39%

das habilidades profissionais devem mudar até 2030

1 APRENDER

Atualizar conhecimentos ao longo da carreira.

2 USAR IA

Aplicar ferramentas para explorar dados e automatizar tarefas.

3 AVALIAR

Conferir resultados e assumir a decisão com responsabilidade.

O diferencial não é só conhecer a tecnologia: é saber **quando, como e por que usá-la.**

Fonte: World Economic Forum, Future of Jobs Report 2025 (projeção global).

Toda engenharia gera dados; a IA ajuda a decidir

O dado muda, o método é o mesmo.

Engenharia Civil

Exemplo: prever a resistência do concreto

Traço e idade do concreto viram uma previsão de resistência (regressão).

Engenharia de Produção

Exemplo: achar defeitos na linha

Parâmetros do processo viram um alerta de peça com risco de defeito (classificação).

Engenharia Elétrica

Exemplo: anomalias em motores

Corrente e vibração revelam regimes de operação e falhas (agrupamento e detecção de anomalias).

Engenharia Mecânica

Exemplo: diagnosticar rolamentos

A vibração vira diagnóstico da falha (PCA e SVM).

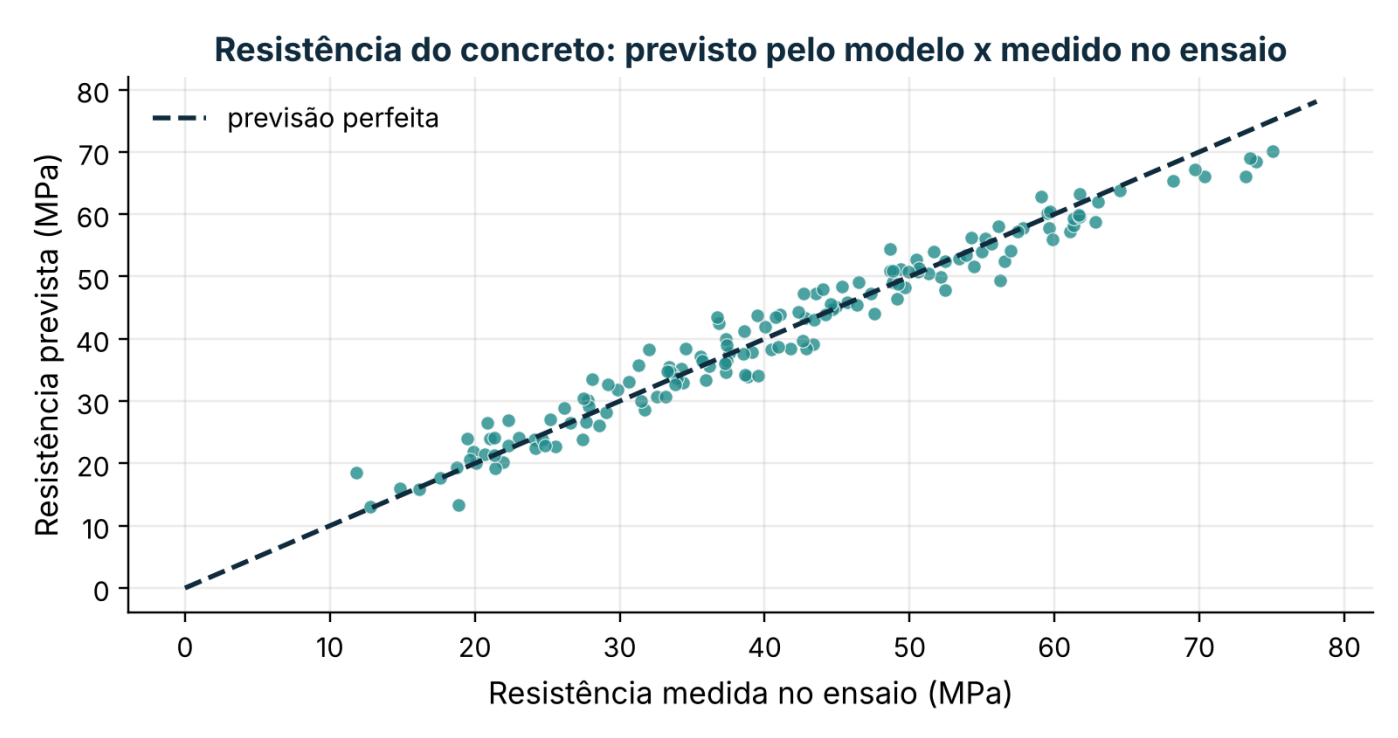
Engenharia Química

Exemplo: sensor virtual de espectros de infravermelho (NIR)

A luz absorvida pela amostra vira concentração em segundos (PCA e regressão).

Engenharia Civil: prever a resistência do concreto

O ensaio aos 28 dias demora; o modelo antecipa a resposta.



Dados simulados, para fins didáticos.

DADOS

Cimento, água, aditivo e idade do concreto.

IA

Regressão (linear e Random Forest).

DECISÃO

Ajustar o traço e decidir a desforma mais cedo, com menos ensaios.

Bloco 1 do curso · Regressão e visualização

Toda engenharia gera dados; a IA ajuda a decidir

O dado muda, o método é o mesmo.

Engenharia Civil

Exemplo: prever a resistência do concreto

Traço e idade do concreto viram uma previsão de resistência (regressão).

Engenharia de Produção

Exemplo: achar defeitos na linha

Parâmetros do processo viram um alerta de peça com risco de defeito (classificação).

Engenharia Elétrica

Exemplo: anomalias em motores

Corrente e vibração revelam regimes de operação e falhas (agrupamento e detecção de anomalias).

Engenharia Mecânica

Exemplo: diagnosticar rolamentos

A vibração vira diagnóstico da falha (PCA e SVM).

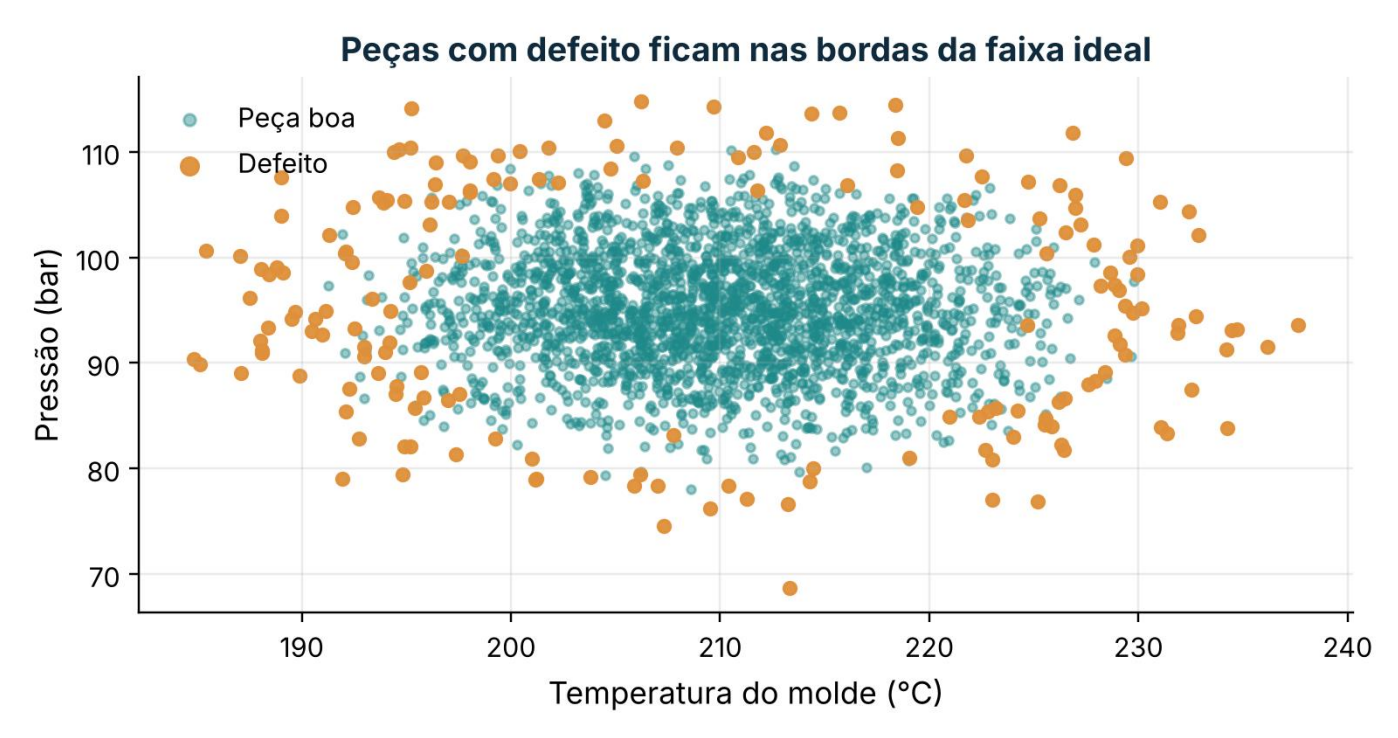
Engenharia Química

Exemplo: sensor virtual de espectros de infravermelho (NIR)

A luz absorvida pela amostra vira concentração em segundos (PCA e regressão).

Engenharia de Produção: achar defeitos na linha

Os parâmetros do processo avisam quais peças têm risco de defeito.



Dados simulados, para fins didáticos.

DADOS

Temperatura, pressão, velocidade, umidade e desgaste da ferramenta.

IA

Classificação com classes raras (regressão logística, árvore e Random Forest).

DECISÃO

Menos refugo e retrabalho; inspeção focada nas peças de risco.

Bloco 2 do curso · Classificação e métricas

Toda engenharia gera dados; a IA ajuda a decidir

O dado muda, o método é o mesmo.

Engenharia Civil

Exemplo: prever a resistência do concreto

Traço e idade do concreto viram uma previsão de resistência (regressão).

Engenharia de Produção

Exemplo: achar defeitos na linha

Parâmetros do processo viram um alerta de peça com risco de defeito (classificação).

Engenharia Elétrica

Exemplo: anomalias em motores

Corrente e vibração revelam regimes de operação e falhas (agrupamento e detecção de anomalias).

Engenharia Mecânica

Exemplo: diagnosticar rolamentos

A vibração vira diagnóstico da falha (PCA e SVM).

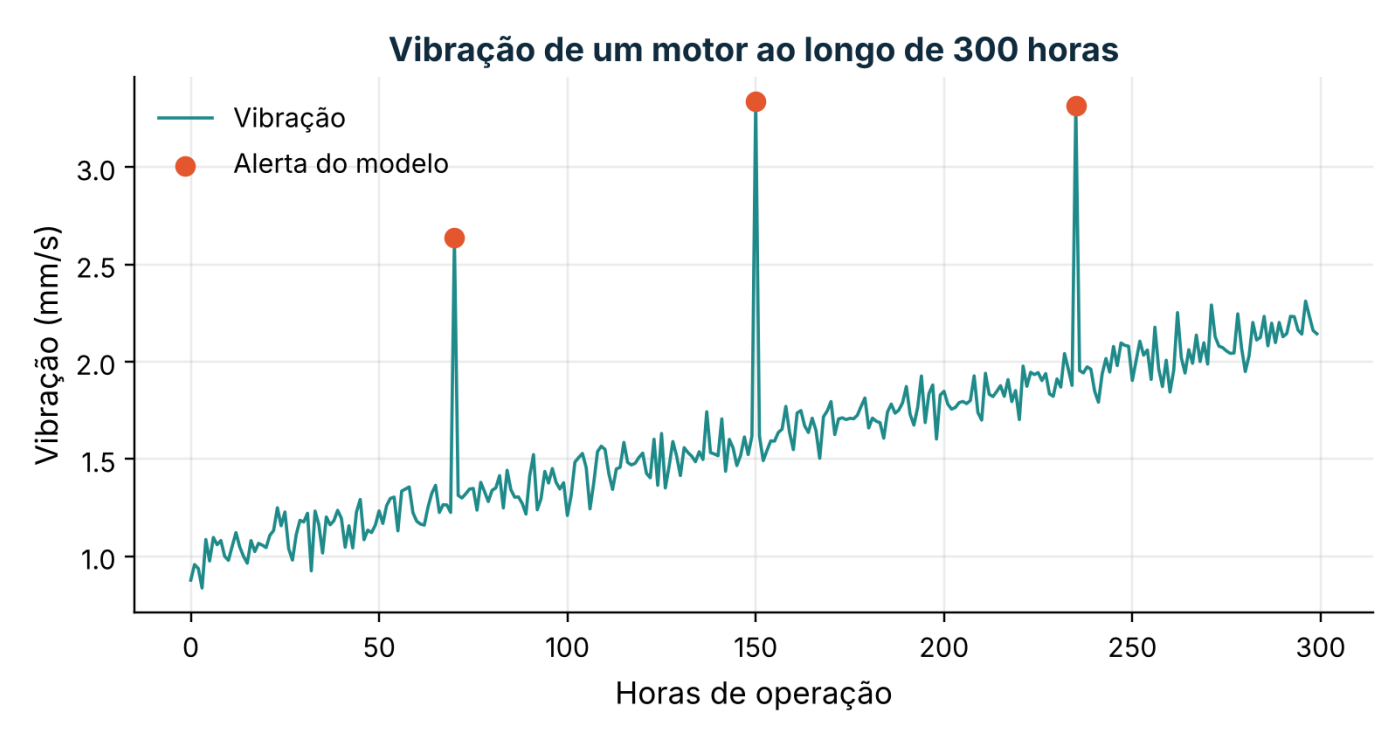
Engenharia Química

Exemplo: sensor virtual de espectros de infravermelho (NIR)

A luz absorvida pela amostra vira concentração em segundos (PCA e regressão).

Engenharia Elétrica: detectar anomalias em motores

Sem rótulos, o modelo descobre regimes e sinaliza o que foge do padrão.



Dados simulados, para fins didáticos.

DADOS

Corrente, rotação, vibração e temperatura.

IA

Agrupamento (k-means e hierárquico) e Isolation Forest.

DECISÃO

Alerta antes da falha e menos paradas não planejadas.

Bloco 3 do curso · Aprendizado não supervisionado

Toda engenharia gera dados; a IA ajuda a decidir

O dado muda, o método é o mesmo.

Engenharia Civil

Exemplo: prever a resistência do concreto

Traço e idade do concreto viram uma previsão de resistência (regressão).

Engenharia de Produção

Exemplo: achar defeitos na linha

Parâmetros do processo viram um alerta de peça com risco de defeito (classificação).

Engenharia Elétrica

Exemplo: anomalias em motores

Corrente e vibração revelam regimes de operação e falhas (agrupamento e detecção de anomalias).

Engenharia Mecânica

Exemplo: diagnosticar rolamentos

A vibração vira diagnóstico da falha (PCA e SVM).

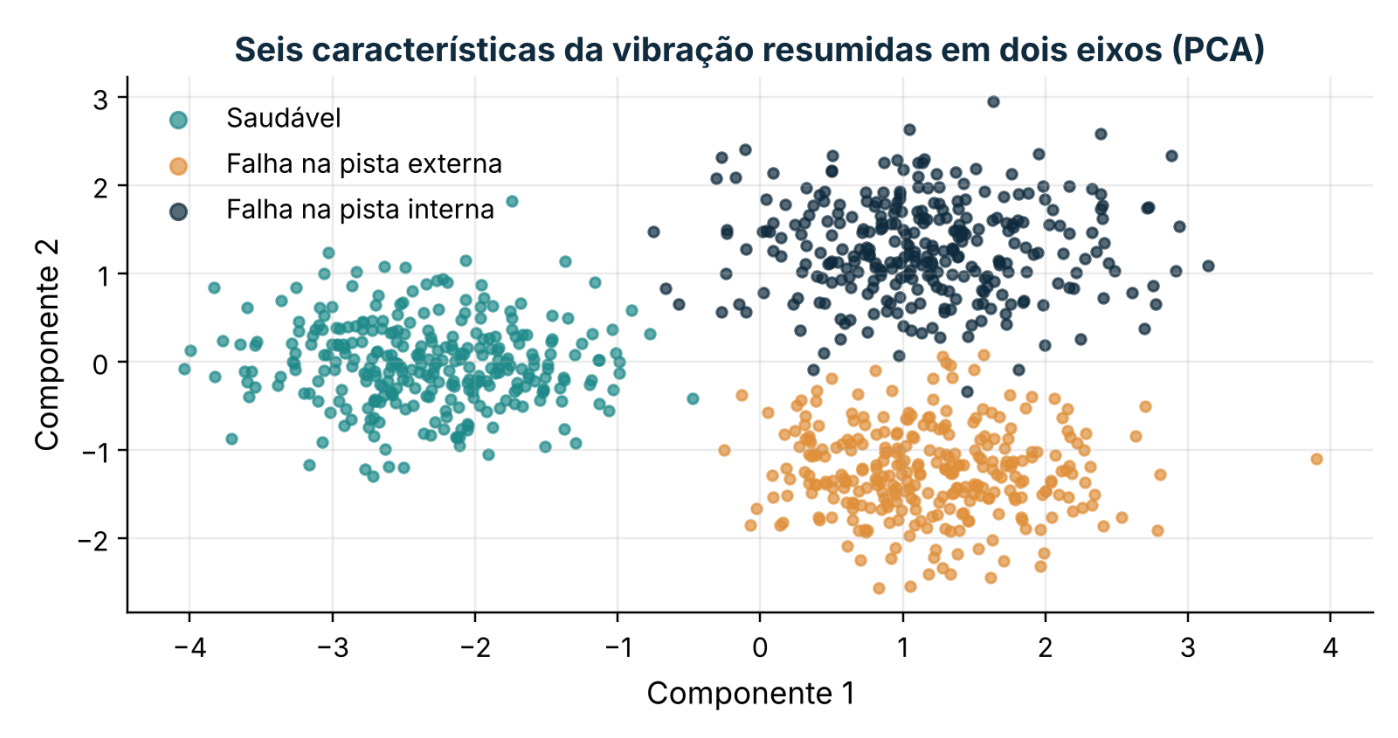
Engenharia Química

Exemplo: sensor virtual de espectros de infravermelho (NIR)

A luz absorvida pela amostra vira concentração em segundos (PCA e regressão).

Engenharia Mecânica: diagnosticar rolamentos

A vibração revela se o rolamento está saudável ou com falha, e onde.



Dados simulados, para fins didáticos.

DADOS

RMS, curtose, fator de crista, energia em BPFO e BPFI, temperatura.

IA

PCA (visualizar) e SVM (classificar).

DECISÃO

Trocar o rolamento no momento certo, sem parada surpresa.

Bloco 4 do curso · PCA e SVM

Toda engenharia gera dados; a IA ajuda a decidir

O dado muda, o método é o mesmo.

Engenharia Civil

Exemplo: prever a resistência do concreto

Traço e idade do concreto viram uma previsão de resistência (regressão).

Engenharia de Produção

Exemplo: achar defeitos na linha

Parâmetros do processo viram um alerta de peça com risco de defeito (classificação).

Engenharia Elétrica

Exemplo: anomalias em motores

Corrente e vibração revelam regimes de operação e falhas (agrupamento e detecção de anomalias).

Engenharia Mecânica

Exemplo: diagnosticar rolamentos

A vibração vira diagnóstico da falha (PCA e SVM).

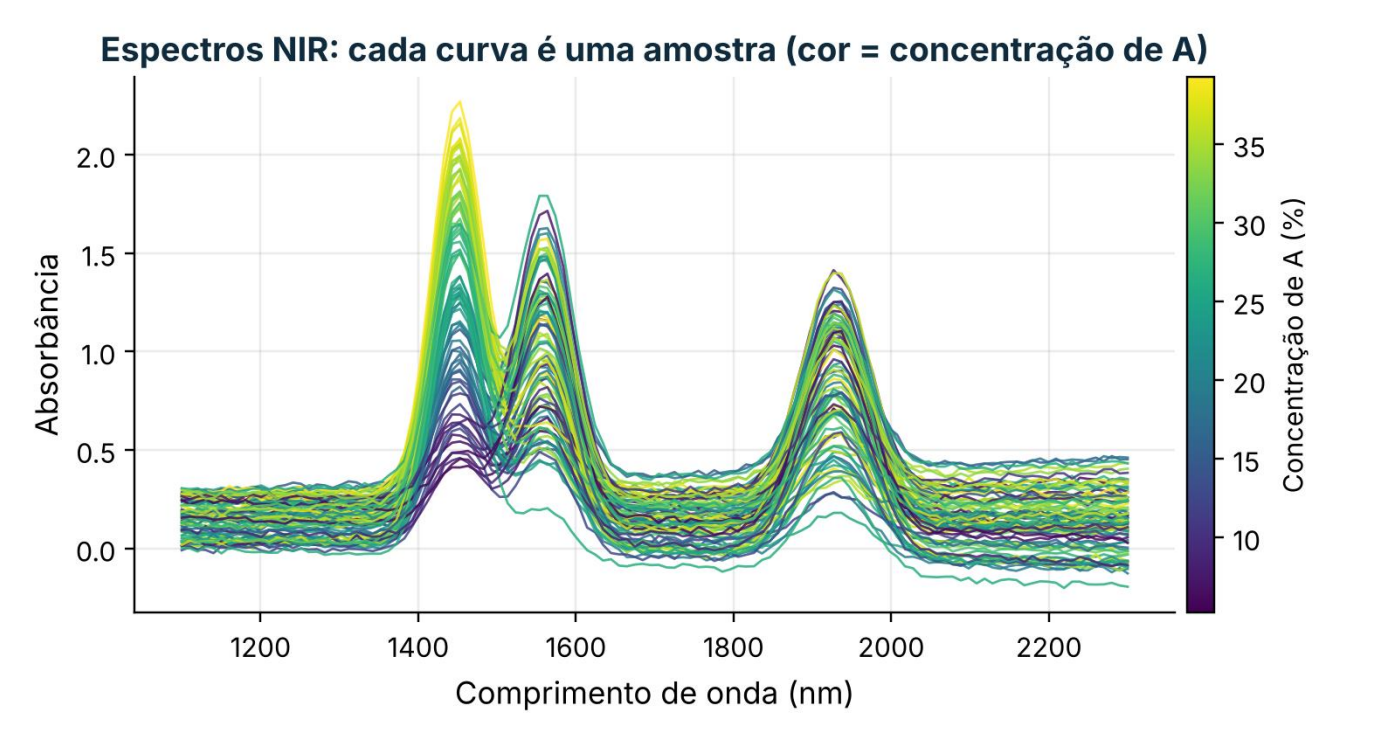
Engenharia Química

Exemplo: sensor virtual de espectros de infravermelho (NIR)

A luz absorvida pela amostra vira concentração em segundos (PCA e regressão).

Engenharia Química: sensor virtual com espectros NIR

Sensor virtual com espectros NIR: A luz absorvida pela amostra vira concentração em segundos.



NIR: Espectroscopia de infravermelho próximo
Dados simulados, para fins didáticos.

DADOS

Absorbância em 120 comprimentos de onda (infravermelho próximo).

IA

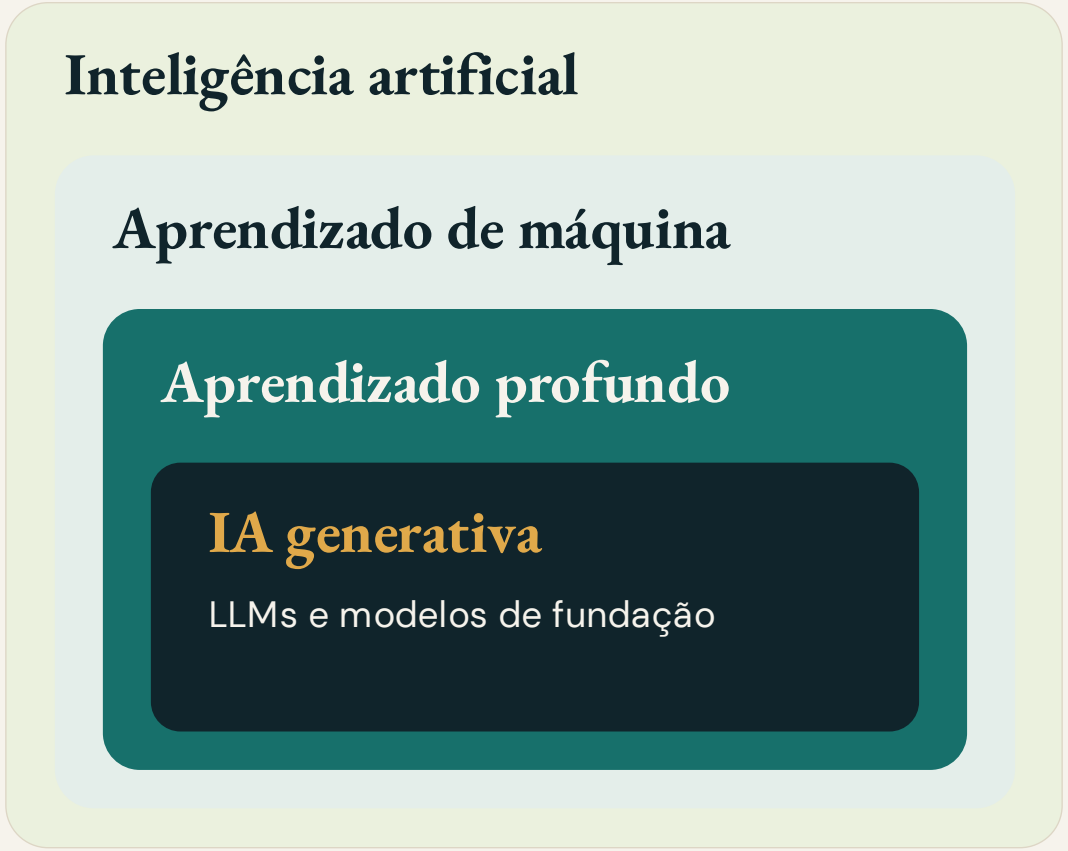
PCA e regressão.

DECISÃO

Resposta imediata e controle do processo em tempo real.

Bloco 5 do curso · PCA e regressão

Inteligência artificial



Inteligência artificial

É um campo da ciência da computação que permite que máquinas e sistemas simulem a capacidade humana de raciocinar, aprender, tomar decisões e resolver problemas.

Aprendizado de máquina

É um subcampo da Inteligência Artificial (IA) que permite aos computadores aprenderem e melhorarem a partir de dados de forma autônoma, Aprende com exemplos.

Aprendizado profundo

Subárea de AM com redes neurais de muitas camadas, que aprendem direto de imagens, sinais e texto.

IA generativa

Cria texto, imagem e código a partir do que aprendeu.

Antes de escolher o algoritmo: qual é a pergunta?

A tarefa define o tipo de modelo e a forma de avaliar seu resultado.

APRENDIZADO SUPERVISIONADO (rótulo)

REGRESSÃO

Prever um número.

EX.: estimar temperatura de motor, tempo de manutenção ou demanda energética.

CLASSIFICAÇÃO

Prever uma categoria.

EX.: normal/falha, aprovado/reprovado ou classe de risco.

NÃO SUPERVISIONADO (sem rótulo)

AGRUPAMENTO

Encontrar observações semelhantes sem rótulos fornecidos.

EX.: descobrir perfis de operação.

PERGUNTA
O que quero prever ou descobrir?

DADOS X
Variáveis de entrada

ALVO y
Variável de saída (AM supervisionado)

MÉTRICA
Acurácia, precisão, curva ROC, sensibilidade, especificidade

TÉCNICAS

As técnicas de IA e onde as encontramos

Técnica	O que faz	No dia a dia	Nas engenharias
Aprendizado de máquina supervisionado	Aprende com exemplos que já têm a resposta e prevê casos novos.	Filtro de spam, análise de crédito	Resistência do concreto; defeito em peças da linha
Aprendizado de máquina não supervisionado	Encontra grupos e padrões nos dados, sem resposta pronta.	Recomendações de compra, grupos de clientes	Perfis de operação de motores; anomalias em sensores
Redes neurais (aprendizado profundo)	Camadas de neurônios artificiais que aprendem padrões complexos.	Reconhecimento de voz, tradução automática	Inspeção visual de peças; trincas em estruturas
Visão computacional	Extrai informação de imagens e vídeos.	Desbloqueio do celular, leitura de placas	Inspeção de frutas; carros autônomos; defeitos de solda
IA generativa (LLMs)	Cria texto, imagem e código a partir do que aprendeu.	Assistentes de texto, geradores de imagem	Documentação técnica, código e relatórios

IA aprende padrões a partir de exemplos

Pense nela como uma ferramenta: recebe exemplos, encontra padrões e produz uma resposta.

1 EXEMPLOS

Dados de entrada

2 PADRÕES

O algoritmo ajusta o modelo

3 PREVISÃO

Classifica ou estima um caso novo

4 REVISÃO

Uma pessoa verifica e decide

Importante: IA não é mágica nem infalível. A qualidade dos dados e a validação fazem diferença.

Vamos ver isso em um exemplo, a seguir.

Na prática, todo projeto segue quatro passos

Agora, como organizar isso em um projeto de verdade.

1 DADOS
Carregar e limpar

2 DIVISÃO
Separar treino e teste

3 MODELO
Treinar o algoritmo: aqui a IA aprende os padrões

4 AVALIAÇÃO
Medir no conjunto de teste

Regra de ouro: nunca avalie o modelo com os mesmos dados usados para treinar.

Faremos esses quatro passos em Python, até o gráfico de resultados.

1. Aprendizado de Máquina Supervisonado
Primeiro, mostramos exemplos (treinamento)

Dados rotulados ajudam o modelo a aprender a diferença entre classes.

1 EXEMPLOS — 2 PADRÕES — 3 PREVISÃO

O computador recebe muitos exemplos rotulados



Folha A

Folha B

Cada imagem vem acompanhada de um exemplo conhecido

“Este exemplo tem sinais de greening”
“Este outro pertence a outra classe”

É como estudar várias questões com o gabarito antes de fazer uma prova.

2. Depois, o modelo aprende padrões

Em imagens, esses padrões podem envolver textura, cor e forma.

1 EXEMPLOS — 2 PADRÕES — 3 PREVISÃO

O algoritmo procura padrões



Pode aprender diferenças como:

- textura
- distribuição de cores
- formato e manchas

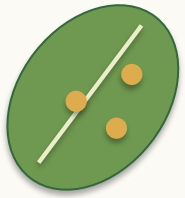
O modelo não “entende” a folha como uma pessoa: aprende relações estatísticas nos dados.

3. Por fim, analisamos uma nova imagem (teste)

O modelo produz uma estimativa que precisa ser conferida.

1 EXEMPLOS — 2 PADRÕES — 3 PREVISÃO

Nova folha



Modelo de IA

Compara padrões com o que aprendeu

Resultado

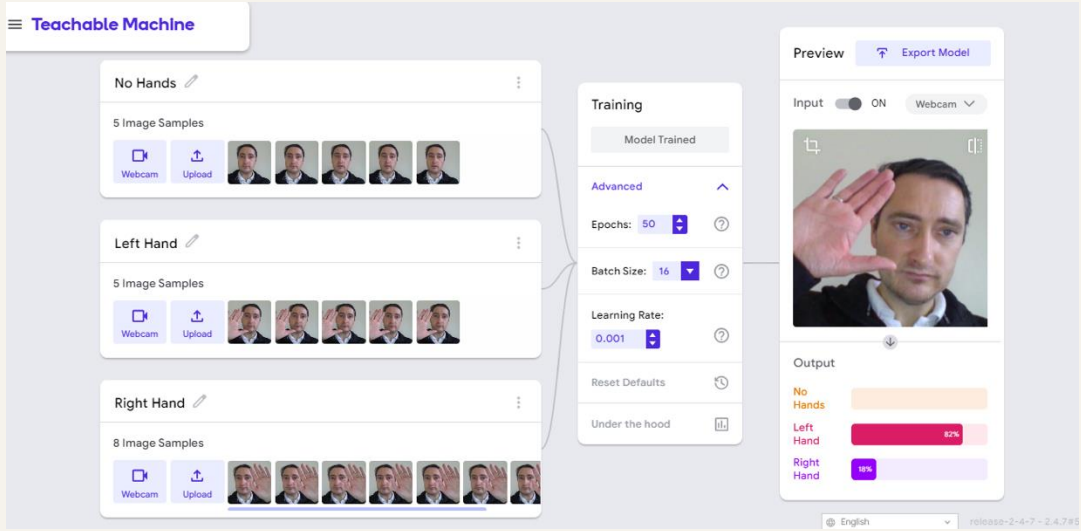
“Padrão compatível com greening”

A previsão é uma pista para investigar — não substitui a confirmação especializada.

Demonstração prática de Machine Learning

Teachable Machine

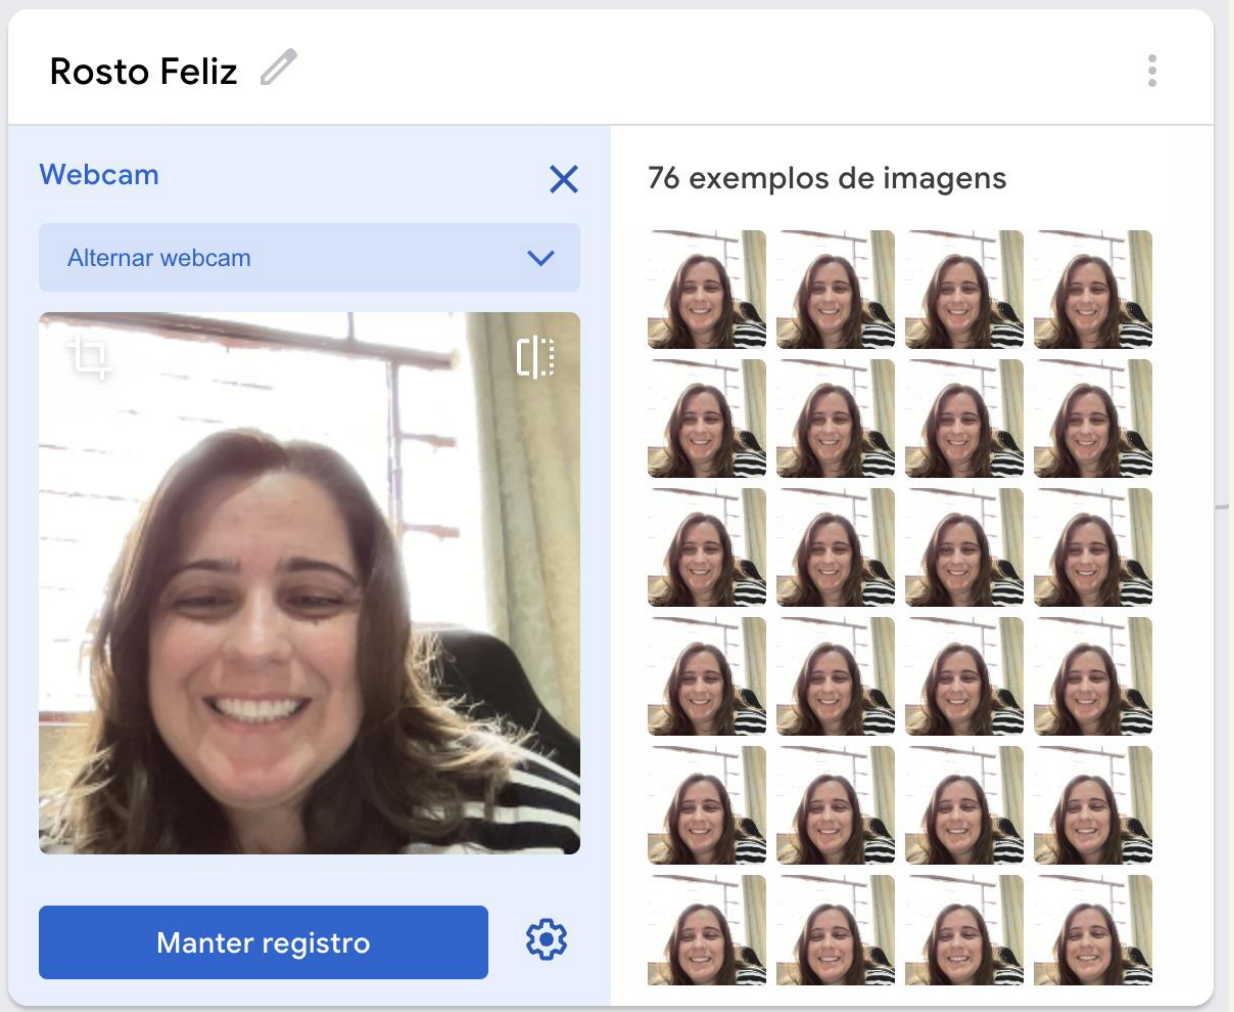
É uma ferramenta educacional de aprendizado de máquina do Google que permite criar e testar modelos diretamente no navegador, sem exigir experiência prévia em programação. Ela transforma conceitos abstratos de *machine learning* em um processo visual e experimental, trabalhando principalmente com **imagens, sons e poses corporais**.

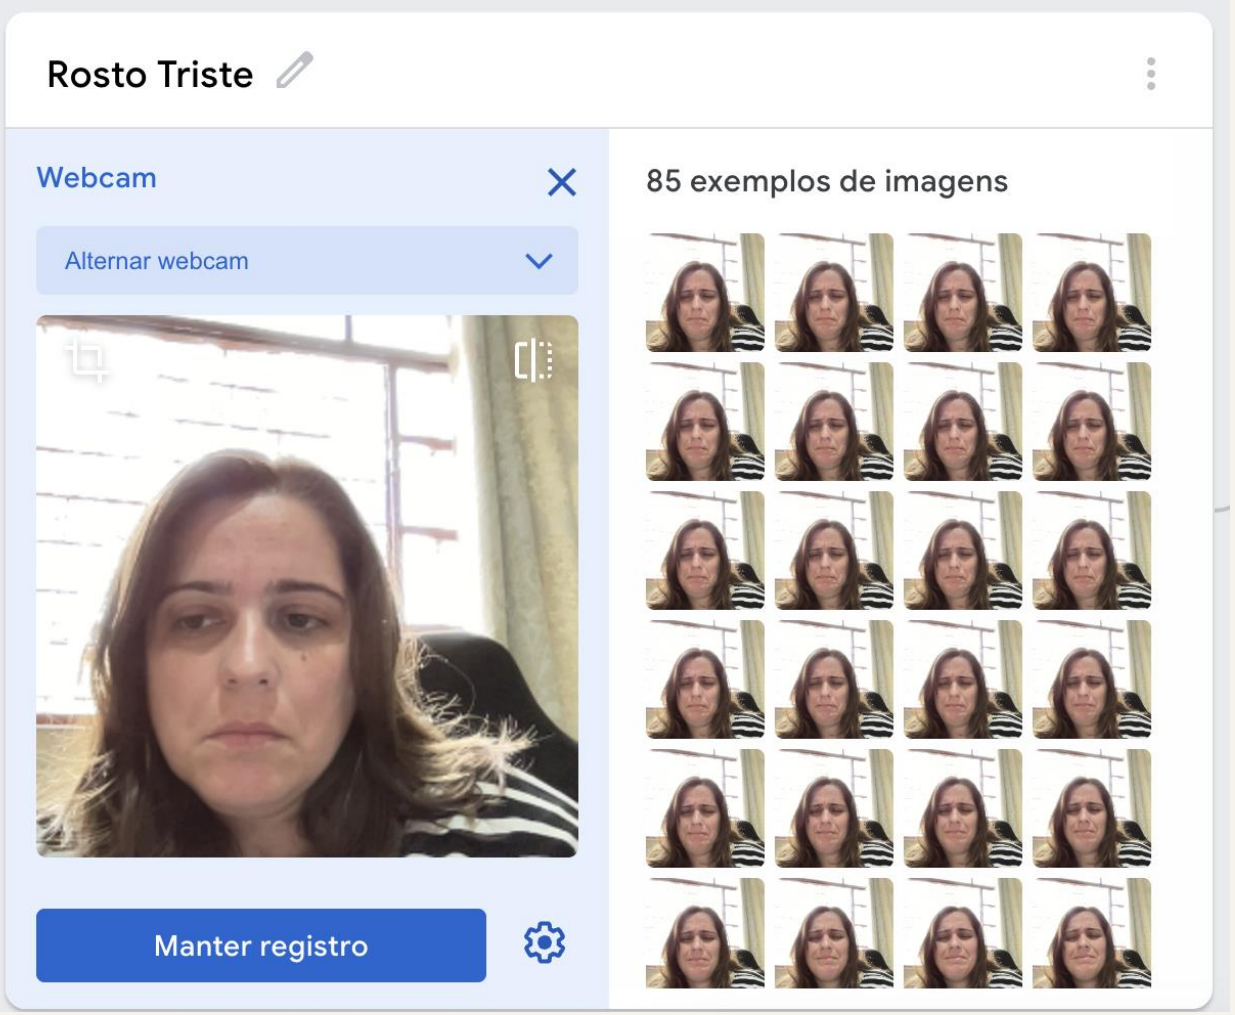


https://teachablemachine.withgoogle.com/

Demonstração prática de Machine Learning

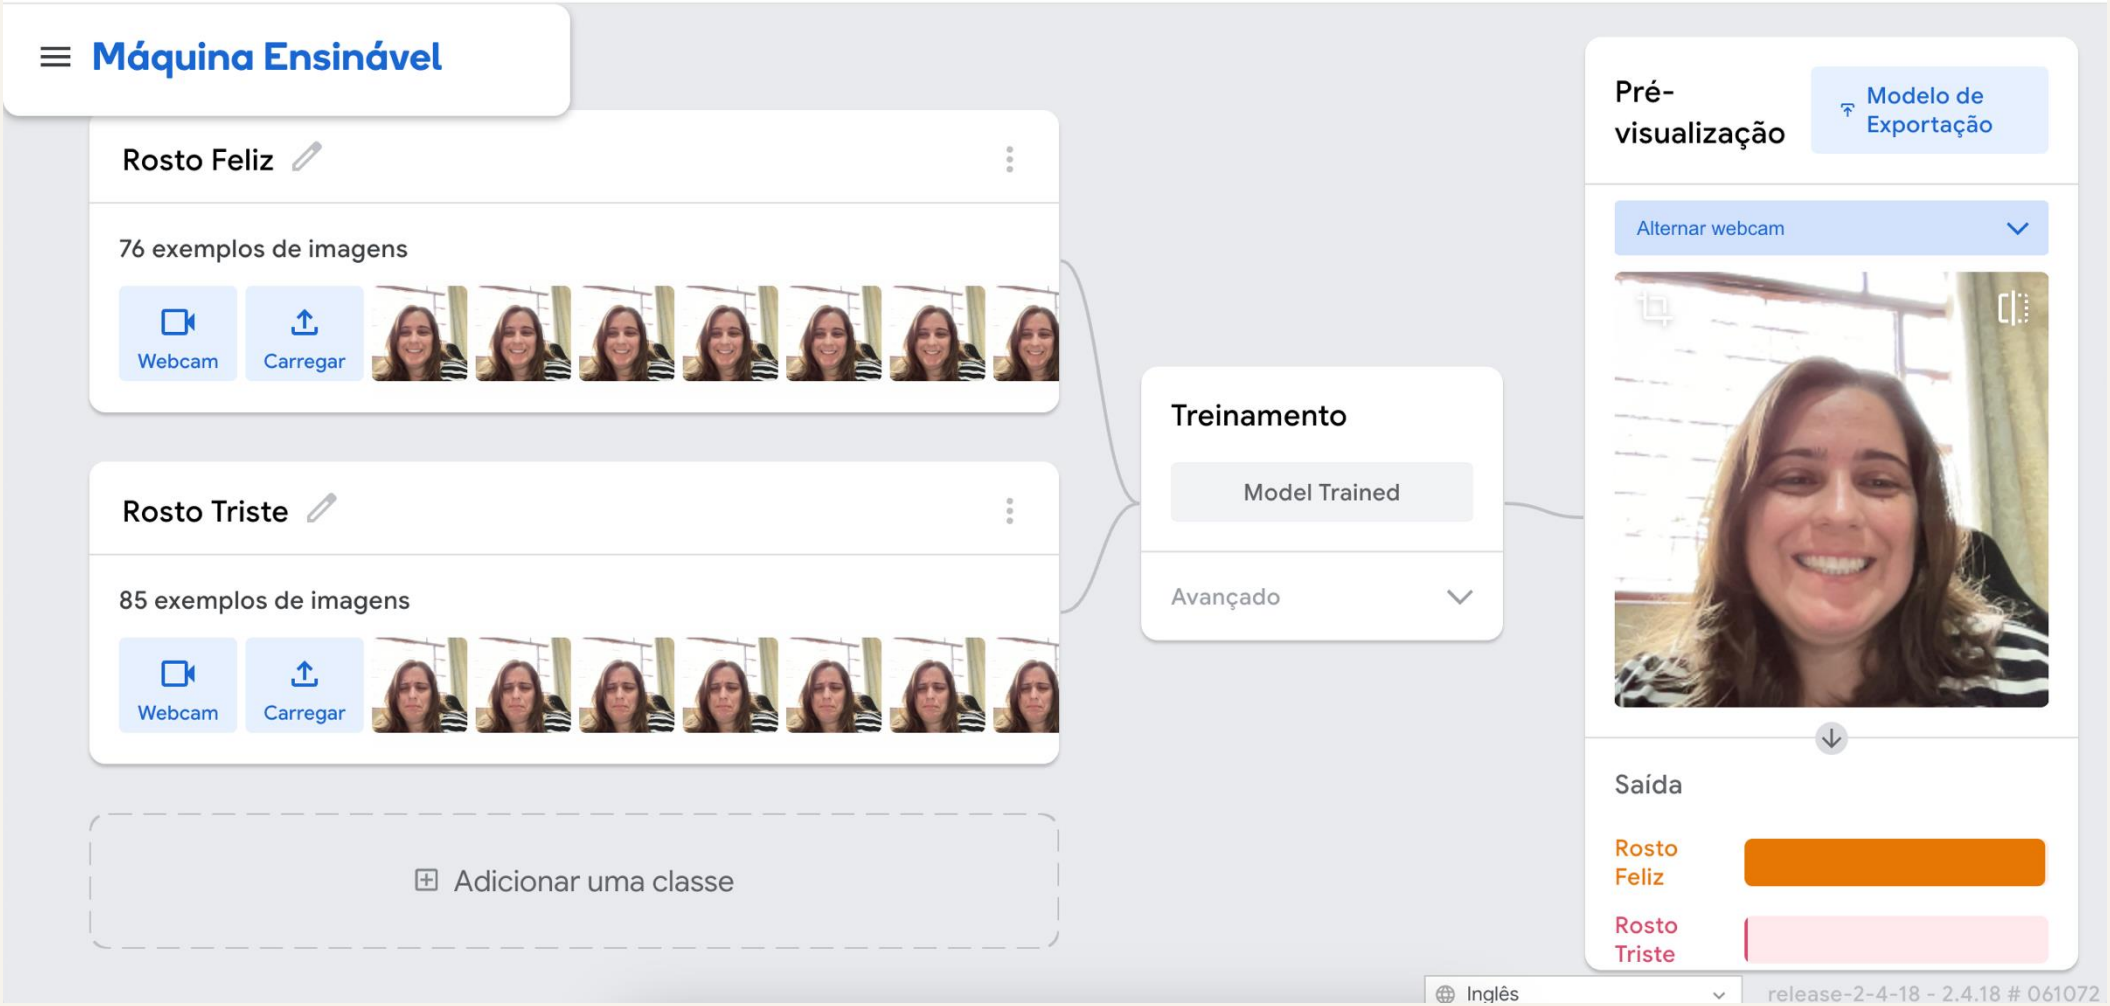
Teachable Machine





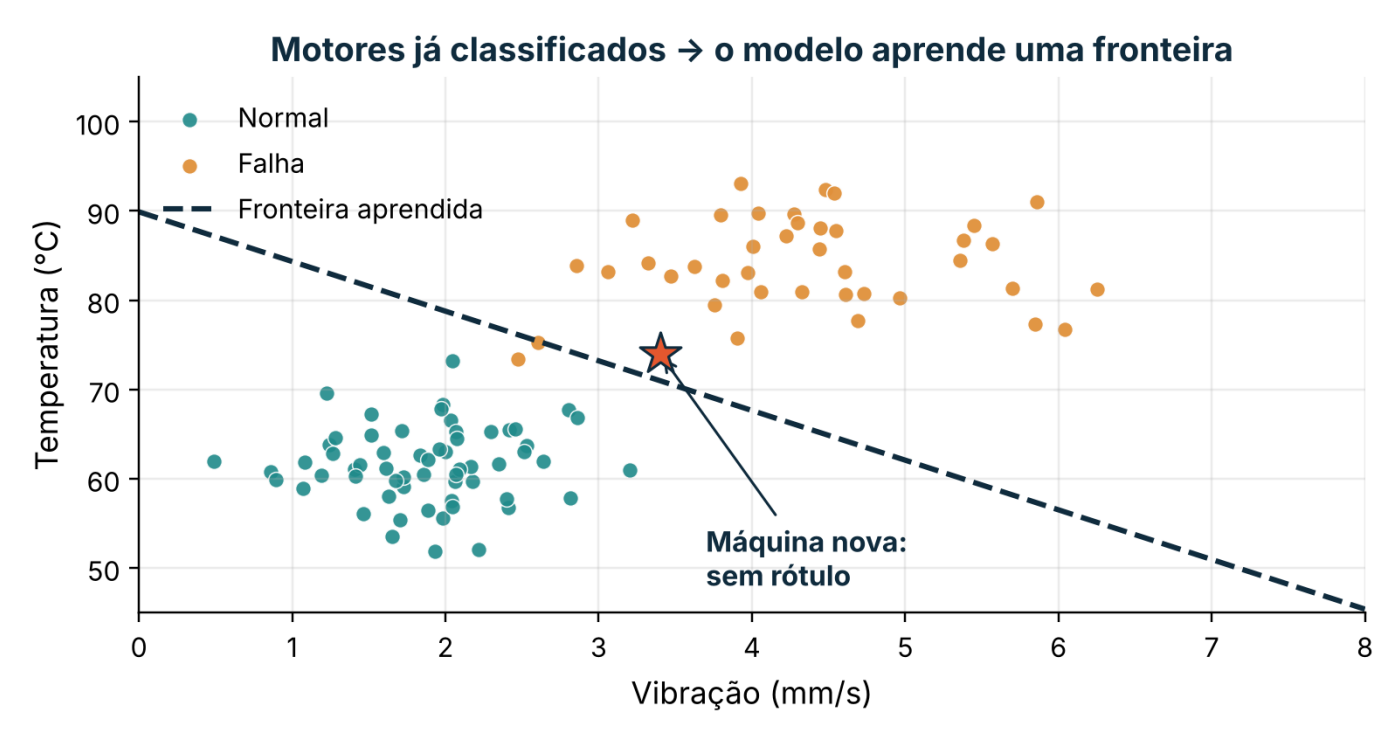
Demonstração prática de Machine Learning

Teachable Machine



Supervisionado: aprender com exemplos rotulados

O treinamento inclui entradas X e uma resposta conhecida y.



1 · EXEMPLOS

Motores já classificados como normal ou falha, com temperatura e vibração medidas.

2 · APRENDIZADO

O modelo encontra a fronteira que relaciona X (temperatura, vibração) com y (normal ou falha).

3 · PREVISÃO

Para uma máquina nova, estima a classe; depois avaliamos os erros.

A qualidade do modelo depende da qualidade dos rótulos.

Supervisionado: aprender com exemplos rotulados

Exemplo: prever se uma máquina precisa de inspeção a partir de temperatura, vibração e horas de uso.

Árvore de Decisão

Divide dados com perguntas do tipo “se... então...”. Fácil de explicar.

Random Forest

Combina várias árvores e agrega suas previsões; pode capturar relações não lineares.

Regressão Logística

Estima a probabilidade de uma classe; baseline útil e interpretável.

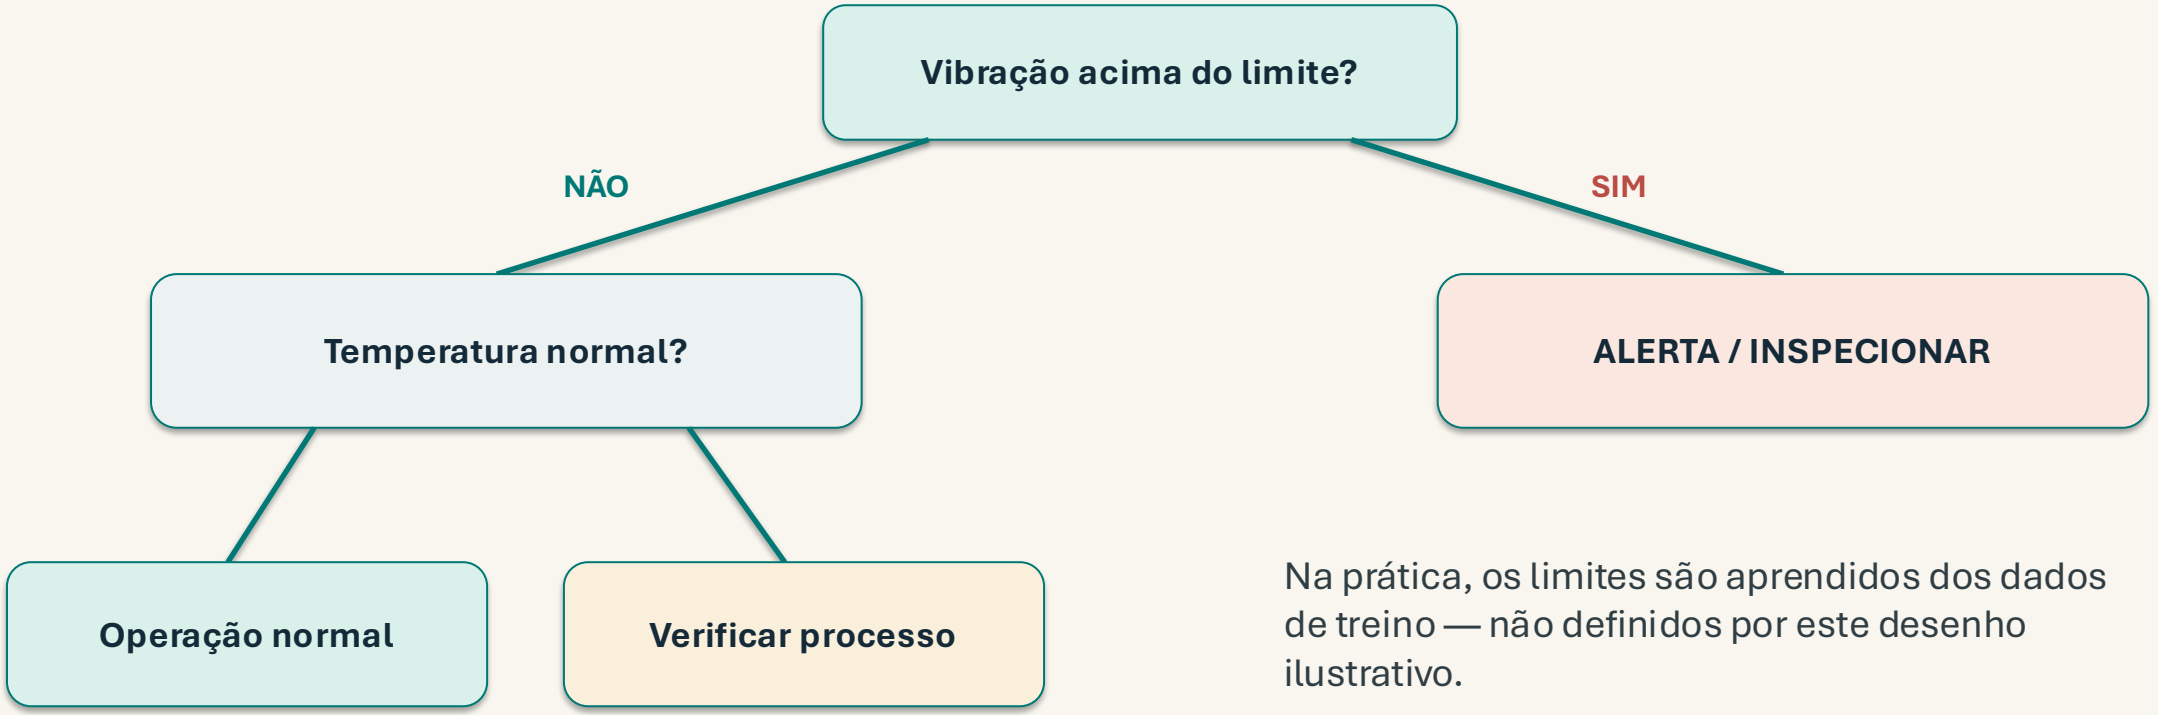
SVM

Busca uma fronteira de separação; a padronização costuma ser importante.

Não existe um algoritmo melhor para todos os problemas: compare-os com os mesmos dados de teste.

Árvore de Decisão: perguntas que levam a uma saída

Uma árvore transforma padrões em regras que podem ser inspecionadas.



Na prática, os limites são aprendidos dos dados de treino — não definidos por este desenho ilustrativo.

Supervisionado: aprender com exemplos rotulados

Exemplo: prever se uma máquina precisa de inspeção a partir de temperatura, vibração e horas de uso.

Árvore de Decisão

Divide dados com perguntas do tipo “se... então...”. Fácil de explicar.

Random Forest

Combina várias árvores e agrega suas previsões; pode capturar relações não lineares.

Regressão Logística

Estima a probabilidade de uma classe; baseline útil e interpretável.

SVM

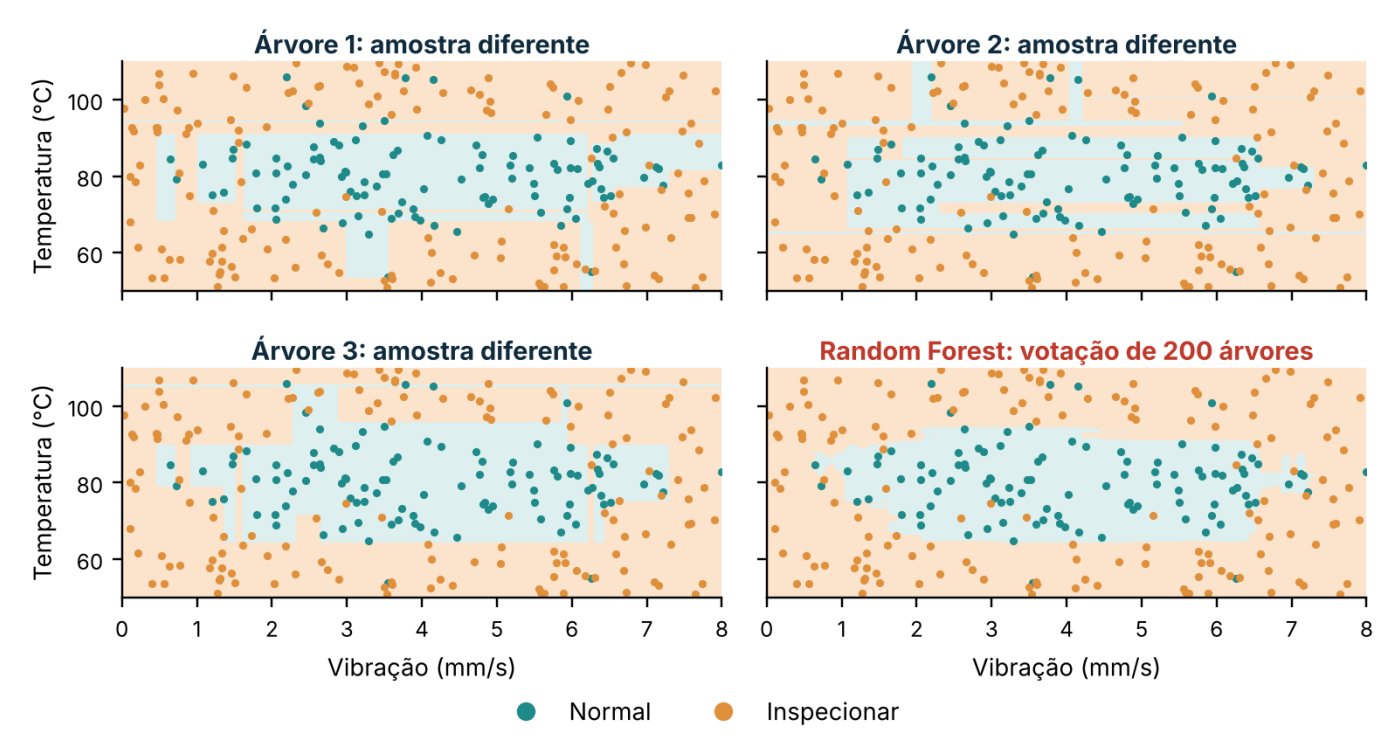
Busca uma fronteira de separação; a padronização costuma ser importante.

Não existe um algoritmo melhor para todos os problemas: compare-os com os mesmos dados de teste.

EXEMPLO 2 · ÁRVORE E RANDOM FOREST · COLAB: PARTE A

Random Forest: várias árvores votam juntas

Exemplo: prever se uma máquina precisa de inspeção a partir de temperatura, vibração e horas de uso.



Dados simulados, com duas entradas (vibração e temperatura) para facilitar a visualização.

ENTRADAS (X)

Temperatura, vibração e horas de uso.

MODELO

Cada árvore treina com uma amostra diferente dos dados. A previsão final é a votação de todas.

SAÍDA (y)

Classe prevista (normal ou inspecionar); a proporção de votos indica a confiança.

Uma árvore sozinha decora o ruído; a floresta faz a média dos erros e generaliza melhor.

Neste exemplo, no teste: acurácia de uma árvore sozinha ≈ 82% · Random Forest = 86%.

Supervisionado: aprender com exemplos rotulados

Exemplo: prever se uma máquina precisa de inspeção a partir de temperatura, vibração e horas de uso.

Árvore de Decisão

Divide dados com perguntas do tipo “se... então...”. Fácil de explicar.

Random Forest

Combina várias árvores e agrega suas previsões; pode capturar relações não lineares.

Regressão Logística

Estima a probabilidade de uma classe; baseline útil e interpretável.

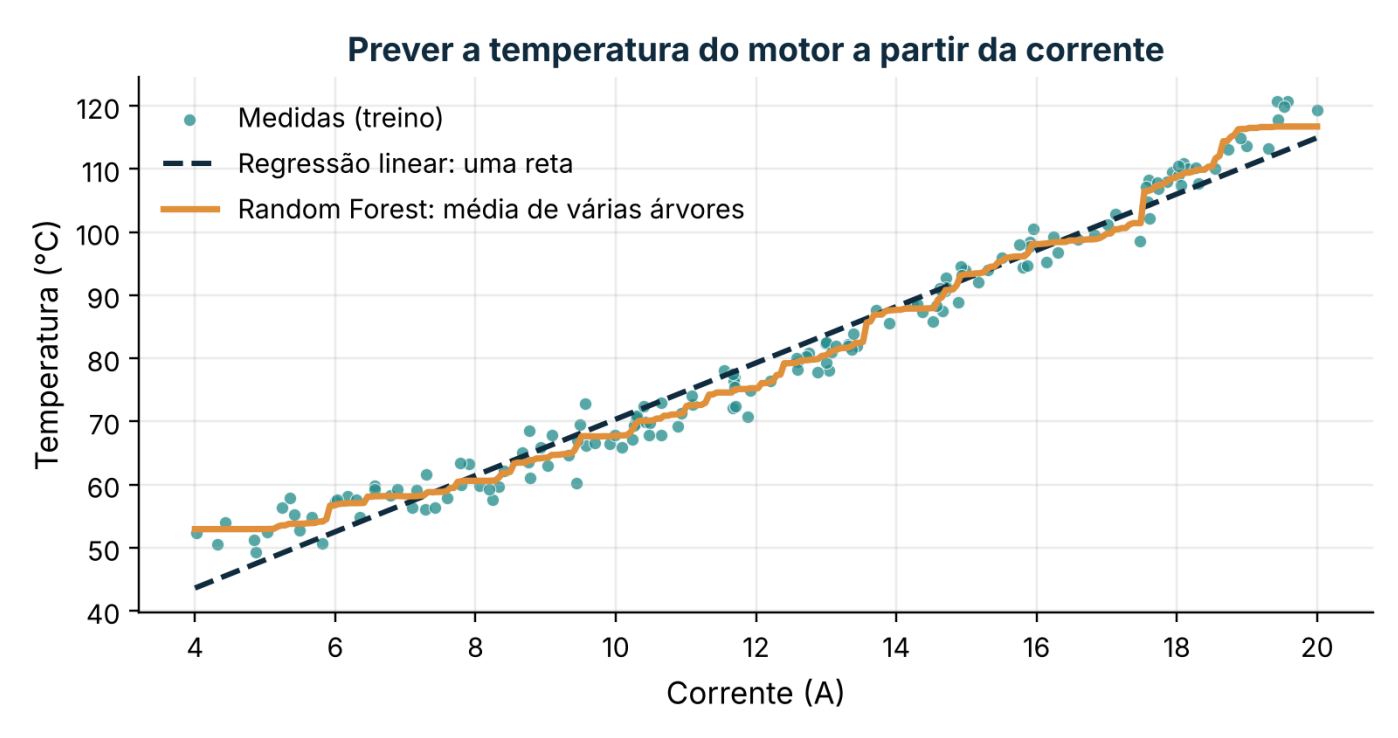
SVM

Busca uma fronteira de separação; a padronização costuma ser importante.

Não existe um algoritmo melhor para todos os problemas: compare-os com os mesmos dados de teste.

Regressão: prever um valor numérico

Exemplo: estimar a temperatura de um motor a partir da corrente elétrica.



Dados simulados, com uma única entrada (corrente) para facilitar a visualização.

ENTRADAS (X)

Corrente elétrica (A).

MODELO

Aprende a relação entre a corrente e a temperatura. A reta é simples; o Random Forest segue curvas.

SAÍDA (y)

Temperatura prevista em °C, comparada com a medida real.

Métricas: MAE (erro médio absoluto), RMSE (penaliza erros grandes) e R^2 (variação explicada).

Neste exemplo, no teste: MAE da reta = 3,0 °C · MAE do Random Forest = 2,3 °C.

Supervisionado: aprender com exemplos rotulados

Exemplo: prever se uma máquina precisa de inspeção a partir de temperatura, vibração e horas de uso.

Árvore de Decisão

Divide dados com perguntas do tipo “se... então...”. Fácil de explicar.

Random Forest

Combina várias árvores e agrega suas previsões; pode capturar relações não lineares.

Regressão Logística

Estima a probabilidade de uma classe; baseline útil e interpretável.

SVM

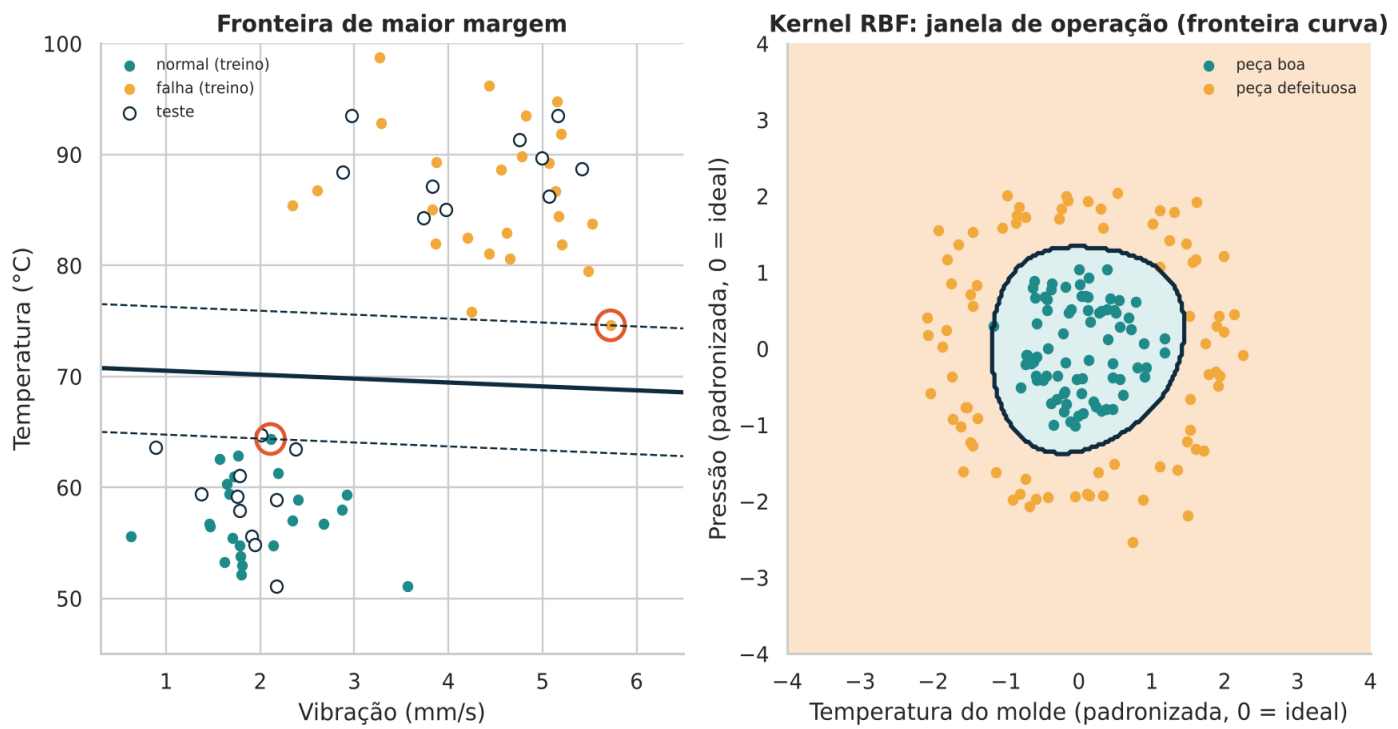
Busca uma fronteira de separação; a padronização costuma ser importante.

Não existe um algoritmo melhor para todos os problemas: compare-os com os mesmos dados de teste.

EXEMPLO 4 · SVM · COLAB: PARTE A

SVM: a fronteira com a maior margem

Exemplo: separar motores normais de motores com falha, e peças boas de peças defeituosas.



Dados simulados, para fins didáticos.

MARGEM

Folga entre a fronteira e os pontos mais próximos de cada classe. Quanto maior, mais segura a separação.

VETORES DE SUPORTE

Os pontos circulados (2 de 49 no exemplo dos motores). Só eles definem a linha; o resto não muda o resultado.

KERNEL

Peça boa no centro e defeituosa em volta: nenhuma reta separa (acerta 56%). O kernel RBF faz a fronteira curva (100%).

Padronize as variáveis antes: o SVM usa distâncias, e variáveis de escala maior dominariam.

Como ler: à esquerda, cada ponto é um motor (horizontal = vibração, vertical = temperatura; verde = normal, laranja = falha; círculos vermelhos = vetores de suporte). À direita, cada ponto é uma peça (temperatura do molde e pressão padronizadas, 0 = ideal; verde = boa, laranja = defeituosa).

Como saber se a classificação funciona?

Acurácia não basta, principalmente quando as classes são desbalanceadas.

	prevista: boa	prevista: defeito
real: boa	**534** Verdadeiro negativo (VN) peça boa, prevista boa	**19** Falso positivo (FP) peça boa, alarme falso
real: defeito	**19** Falso negativo (FN) defeito que passou	**53** Verdadeiro positivo (VP) defeito detectado

Random Forest no bloco de Produção: 625 peças de teste, 72 defeituosas.

ACURÁCIA · 94% (VP + VN) ÷ total

Acertos em geral. Engana quando uma classe é rara: dizer 'sempre boa' já daria 88%.

PRECISÃO · 74% VP ÷ (VP + FP)

Dos alertas emitidos, quantos eram casos reais. Alta precisão = menos falsos alarmes.

SENSIBILIDADE (RECALL) · 74% VP ÷ (VP + FN)

Dos casos reais, quantos foram detectados. Baixo recall = falsos negativos, casos que passam.

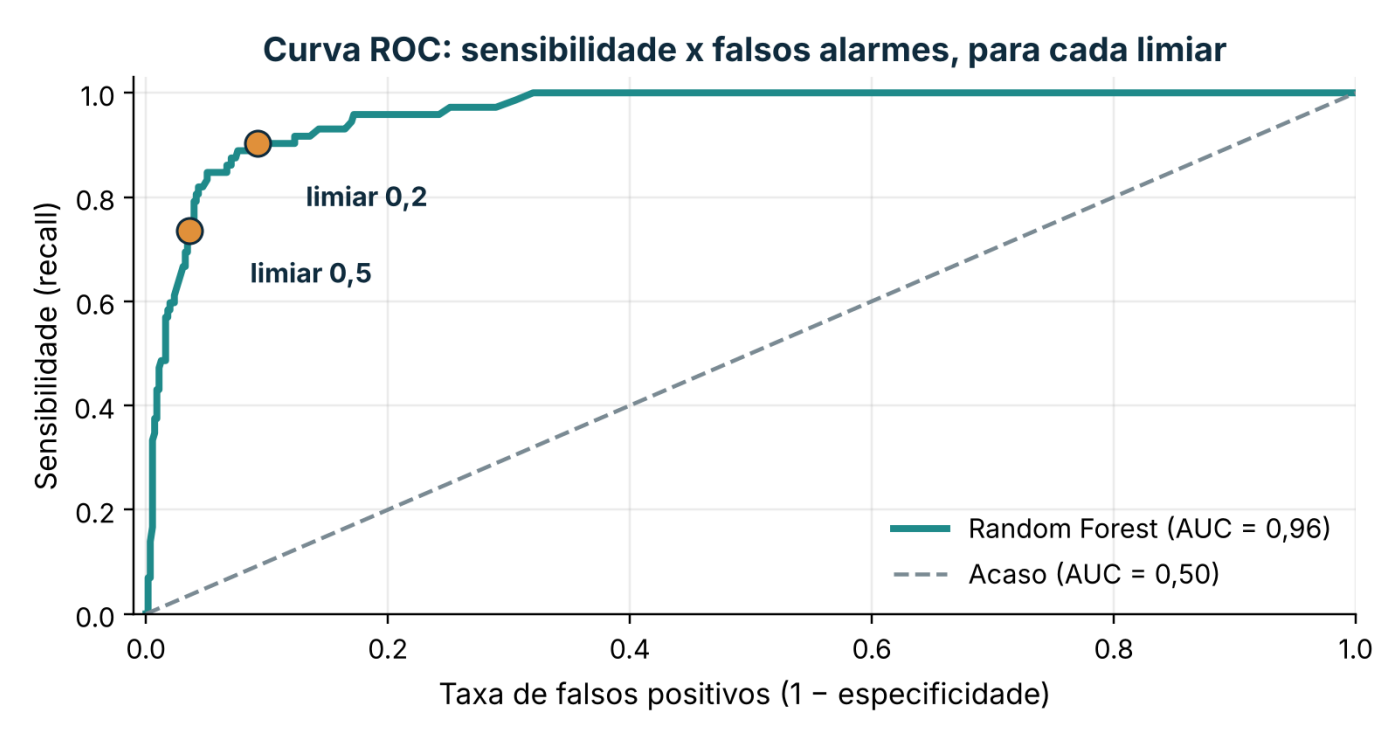
ESPECIFICIDADE · 97% VN ÷ (VN + FP)

Dos casos normais, quantos foram liberados corretamente. Baixa = falsos positivos.

Em segurança e qualidade, o custo dos erros deve orientar a métrica e o limiar de decisão.

Curva ROC: o efeito do limiar de decisão

Cada ponto da curva é um limiar: mais sensibilidade custa mais falsos alarmes.



Mesmo modelo e dados do slide anterior.

COMO LER

Eixo y: sensibilidade. Eixo x: falsos positivos (1 − especificidade). Quanto mais perto do canto superior esquerdo, melhor.

AUC

Área sob a curva: 0,5 é o acaso e 1,0 é perfeito. Aqui, 0,96.

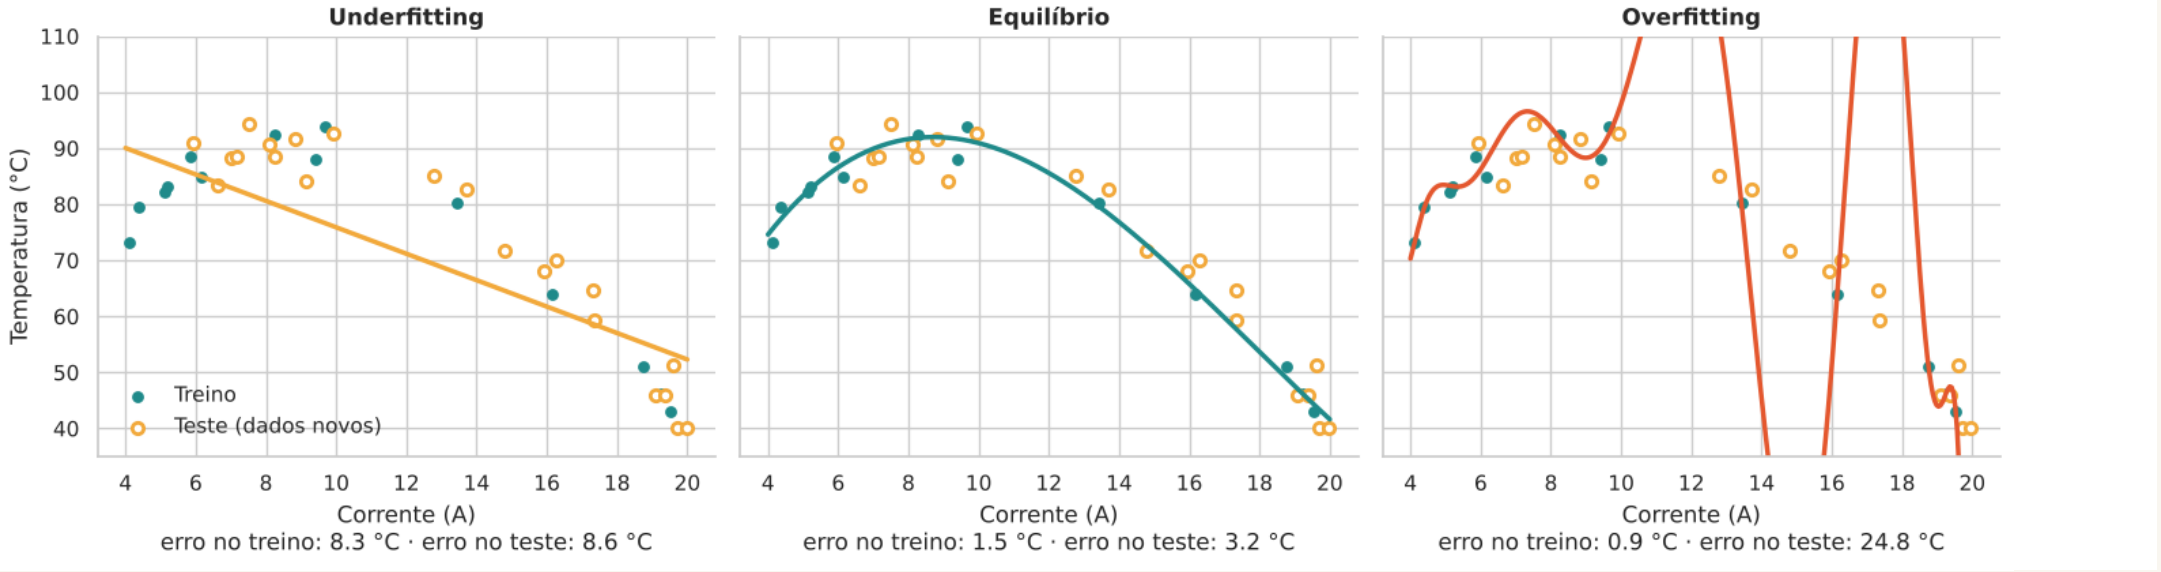
LIMIAR

Com 0,2 o modelo acha 90% dos defeitos, com 9% de falsos alarmes. Com 0,5: 74% e 3,4%.

Em peça de segurança, escolha um limiar que priorize a sensibilidade.

Overfitting: decorar não é aprender

Exemplo: prever a temperatura do motor a partir da corrente, com poucas medidas (14 de treino e 22 de teste).



Underfitting

Reta simples demais para a curva corrente × temperatura: erra 8,3 °C no treino e 8,6 °C no teste.

Equilíbrio

Grau 3 acompanha a curva real: erra 1,5 °C no treino e 3,2 °C no teste.

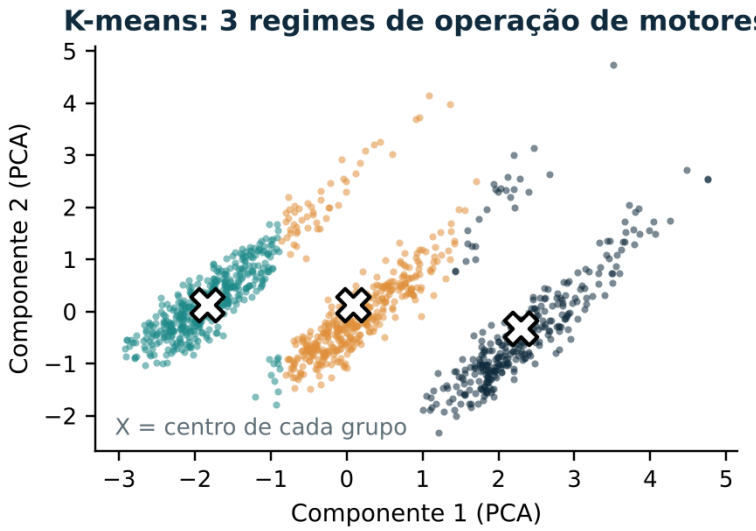
Overfitting

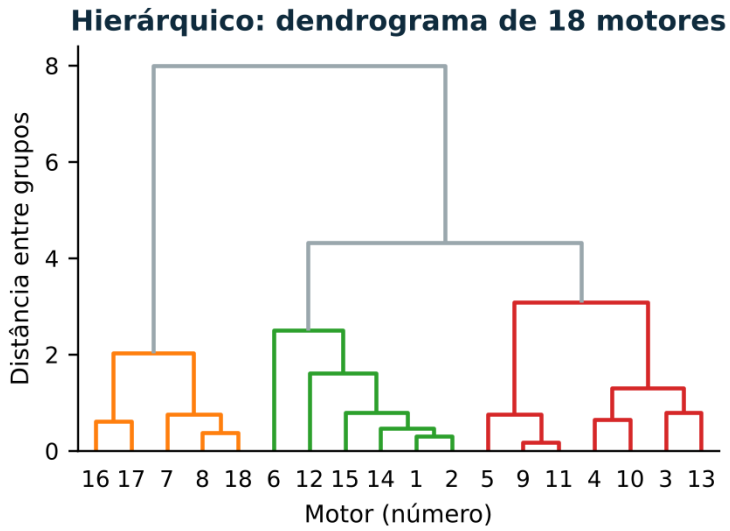
Grau 13 decora o ruído: erra 0,9 °C no treino, mas 24,8 °C no teste, com valores absurdos.

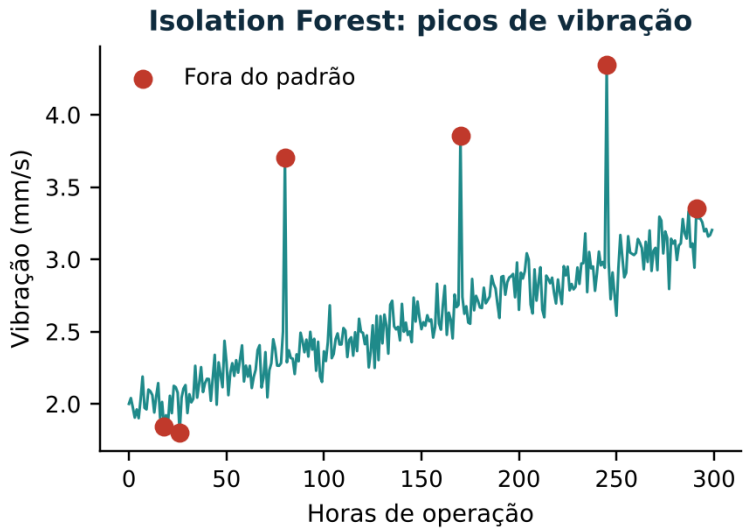
SEPARAR treino/teste | **TREINAR** apenas treino | **VALIDAR** ajustar | **TESTAR** dados novos

Não supervisionado: descobrir padrões sem rótulos

Não informamos ao algoritmo a classe correta; ele procura estrutura nos dados.







K-MEANS

Forma K grupos com base na distância entre observações. Ex.: regimes de carga de motores.

CLUSTERING HIERÁRQUICO

Organiza semelhanças em uma hierarquia de grupos. Ex.: quais motores são mais parecidos.

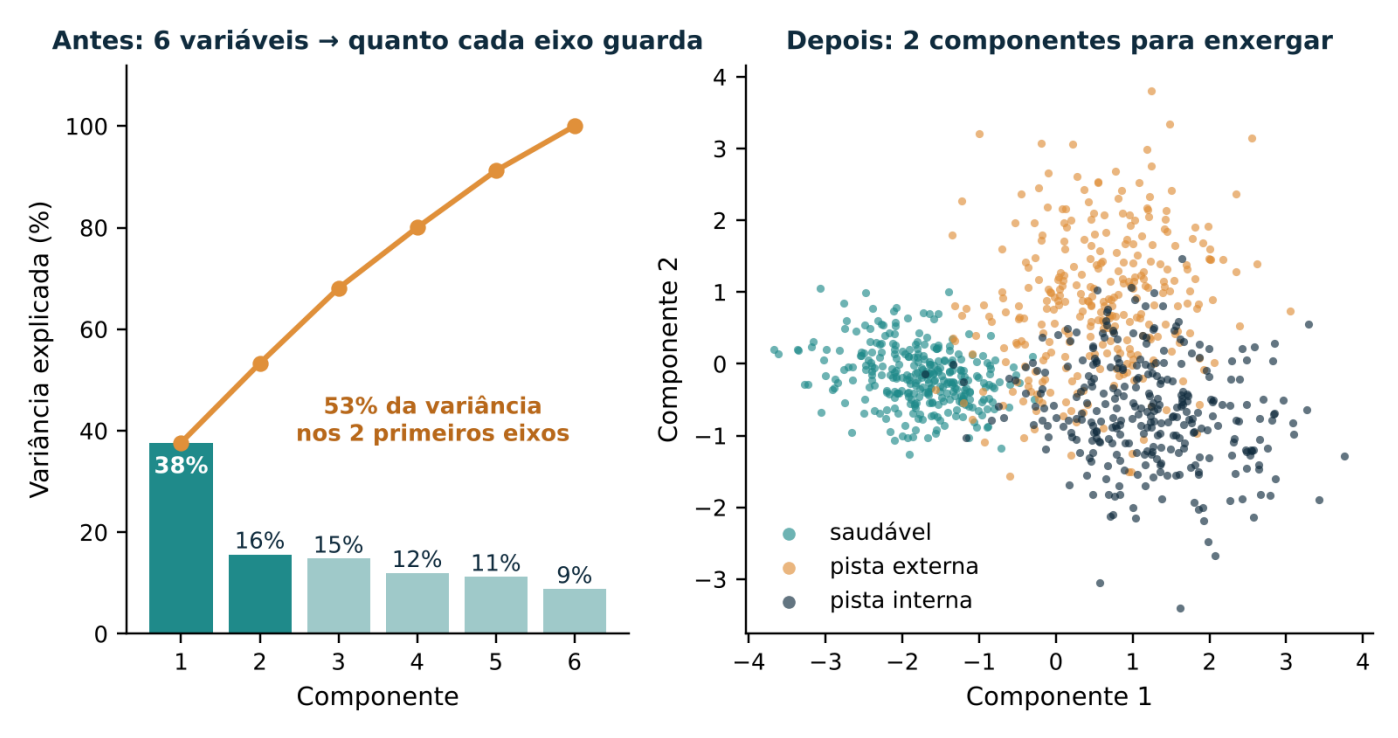
ISOLATION FOREST

Ajuda a encontrar observações raras ou atípicas. Ex.: picos de vibração fora do padrão.

Os grupos precisam ser interpretados; cluster não é automaticamente diagnóstico nem causa.

PCA: resumir muitas variáveis em poucas dimensões

PCA cria componentes que preservam o máximo possível da variância dos dados.



Rolamentos (dados simulados do notebook): 6 características de vibração.

ANTES

Dezenas ou centenas de variáveis: sensores, espectros ou medidas de ensaio. Aqui, 6.

TRANSFORMAÇÃO

Combina variáveis em eixos novos, ordenados pela variância explicada.

DEPOIS

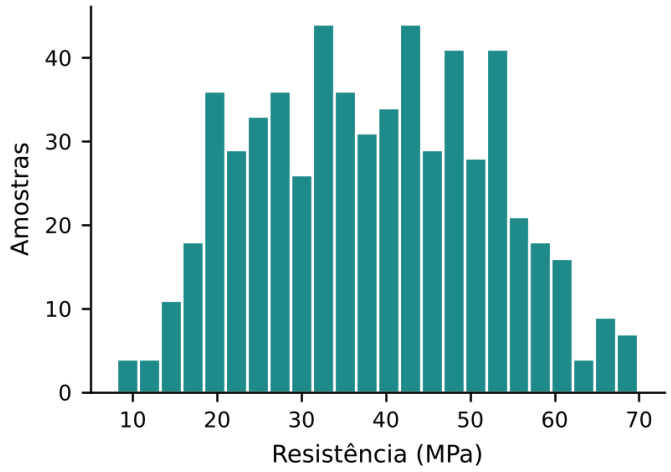
Visualizar em 2D, explorar estrutura ou reduzir dimensões antes de outro modelo.

PCA não é, por si só, um classificador nem um algoritmo de agrupamento. Ajuste-o apenas no treino.

Visualizar antes de modelar

Parte 1: como os dados se distribuem e como os grupos se comparam.

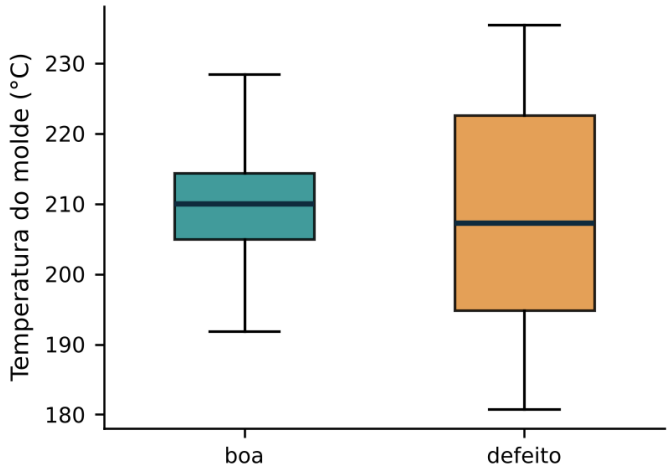
Histograma



Distribuição da resistência do concreto.

O que vemos: resistências de 8 a 70 MPa, espalhadas: a idade do concreto explica parte disso.

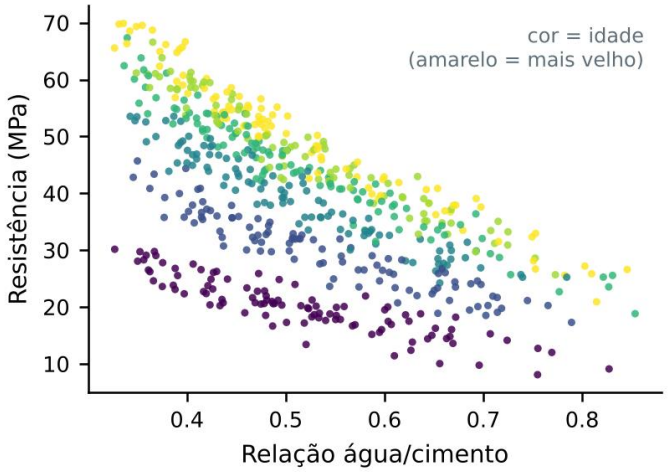
Boxplot



Compara grupos: temperatura do molde de peças boas e defeituosas.

O que vemos: mediana parecida, mas os defeitos variam mais: aparecem nos dois extremos.

Dispersão



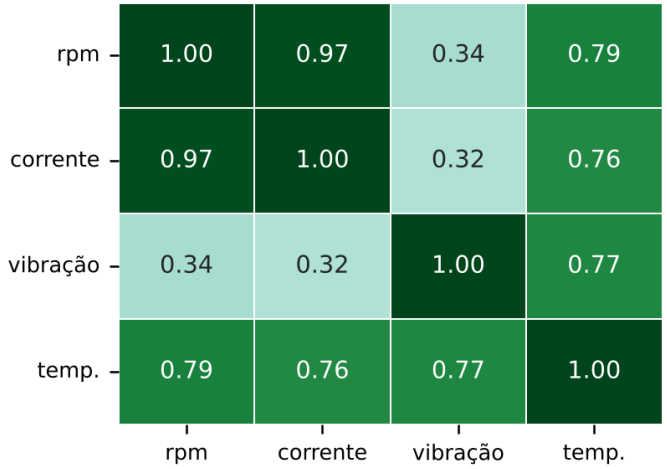
Duas variáveis juntas: relação água/cimento x resistência.

O que vemos: mais água por cimento, menos resistência; a cor mostra o efeito da idade.

Visualizar antes de modelar

Parte 2: relações entre variáveis, evolução no tempo e redução de dimensões.

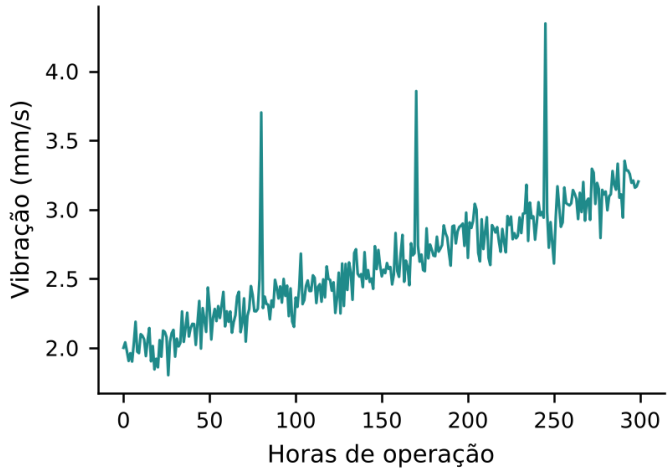
Mapa de calor



Quais variáveis andam juntas: correlação entre elas.

O que vemos: rpm e corrente quase iguais (0,97): variáveis redundantes.

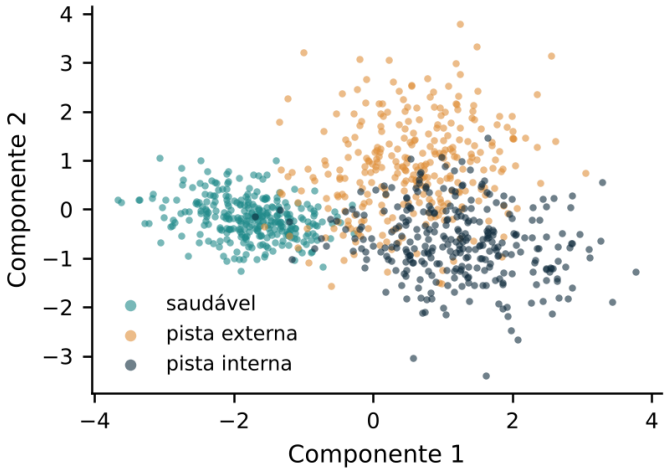
Série temporal



Vibração de um motor ao longo das horas.

O que vemos: tendência de alta (desgaste) e 3 picos fora do padrão.

PCA

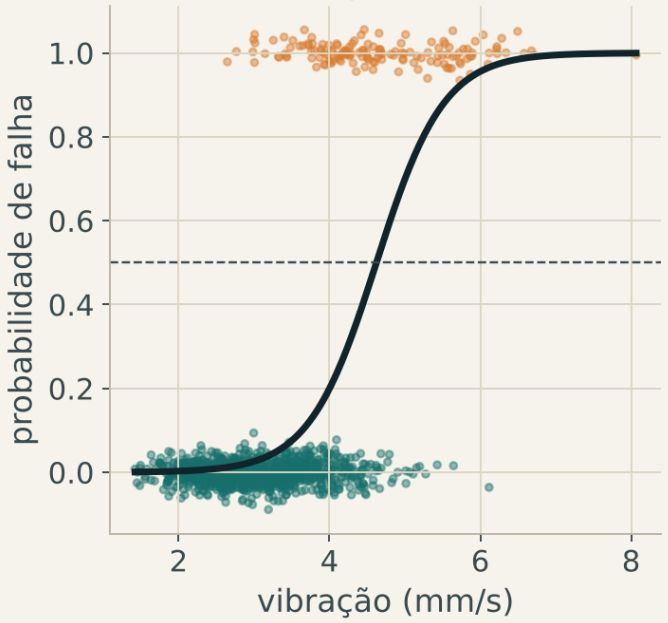


Resume 6 características de vibração em 2 dimensões para enxergar.

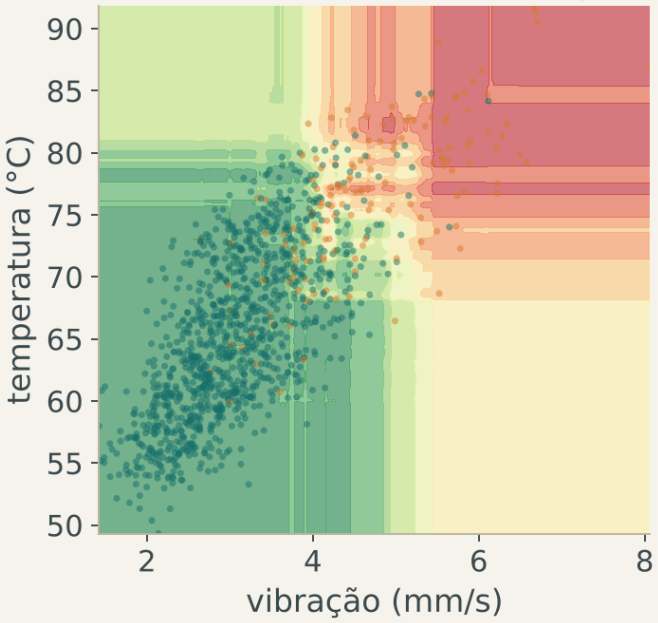
O que vemos: o rolamento saudável se separa das falhas; 2 eixos guardam 53% da variância.

Três algoritmos em uma imagem

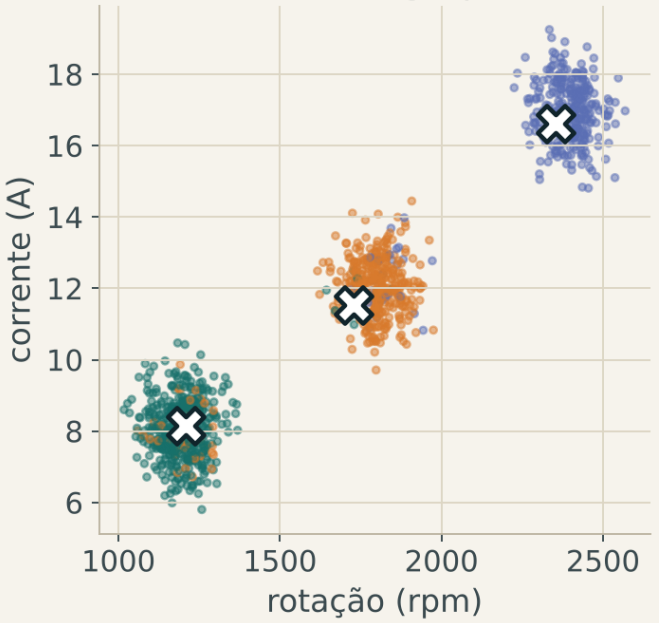
Regressão logística:
curva de probabilidade



Random Forest:
muitas árvores recortam regiões



k-means:
centros e grupos



Mesmos motores, três ideias: a regressão logística estima probabilidades, a floresta recorta regiões e o agrupamento encontra centros.

PRÁTICA

Parte prática · Google Colab

Abra o notebook, salve uma cópia no Drive e execute as células em ordem.

COMO COMEÇAR

1. Abra o notebook .ipynb no Google Colab.
2. Clique em “Salvar uma cópia no Drive”.
3. Execute cada célula com Shift + Enter.
4. Leia as saídas e responda às perguntas.
5. Altere uma variável por vez e compare.

O QUE VAMOS FAZER

- Civil: regressão e visualização.
- Produção: classificação com classes raras.
- Elétrica: k-means e Isolation Forest.
- Mecânica: PCA e SVM.
- Química: PCA e regressão.

Notebook: Colab_IA_nas_Engenharias.ipynb (no repositório do curso). Dados simulados: não é preciso baixar nada.

Civil: prever a resistência do concreto

Usina de concreto e canteiro de obras: decidir mais cedo e ensaiar menos.

Problema

O ensaio aos 28 dias demora quase um mês; o traço só é validado depois.

Dados

Traço (cimento, água, aditivo), idade e resistência de ensaios anteriores.

Técnica

Regressão: linear e Random Forest, com visualização da relação água/cimento.

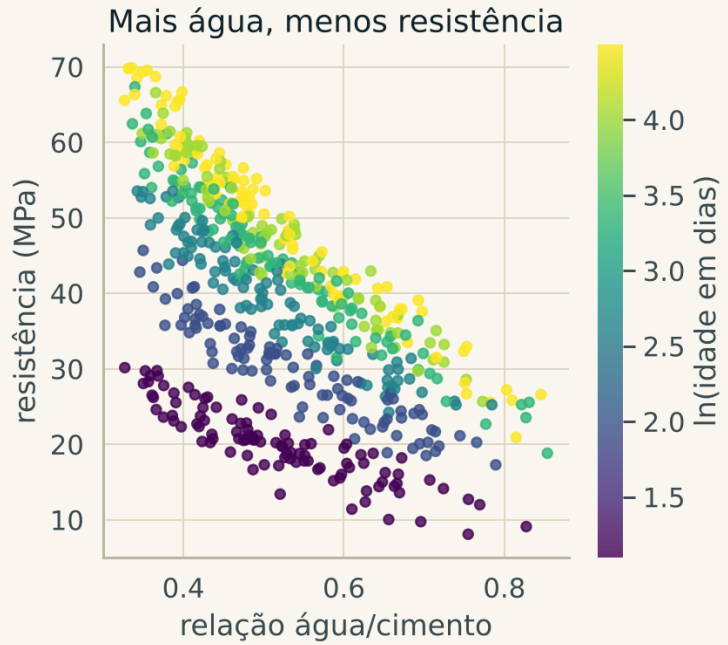
Ganho

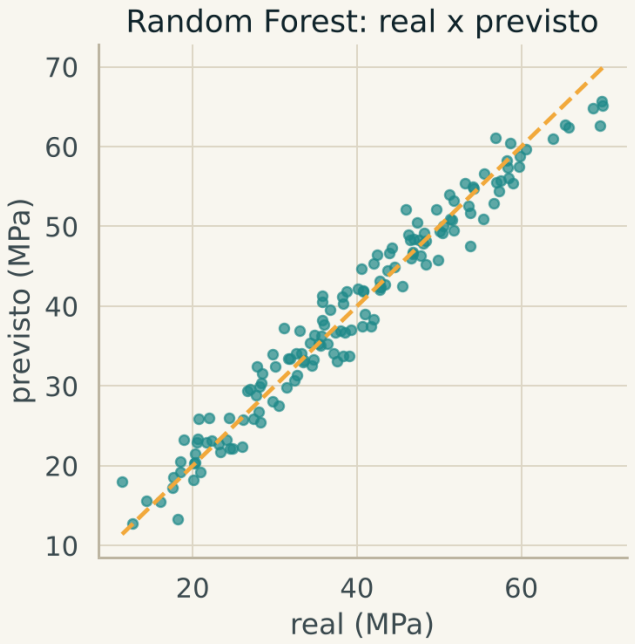
Ajustar o traço antes, decidir a desforma e reduzir ensaios e desperdício.

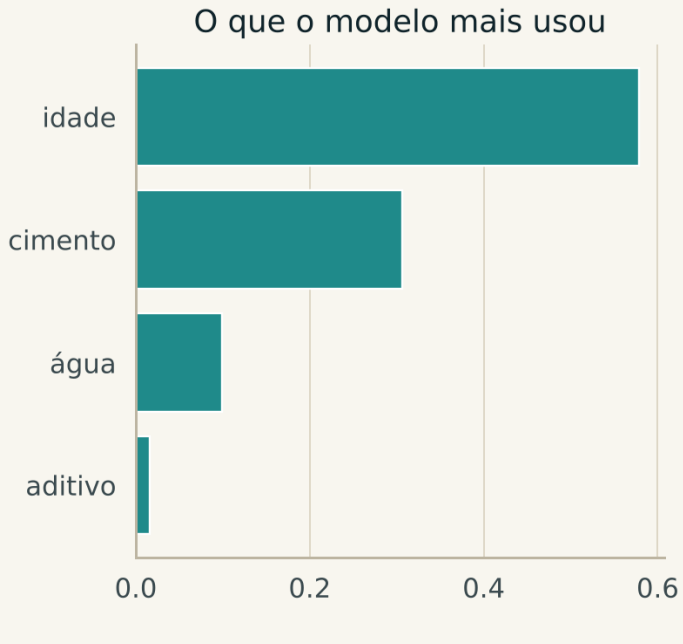
Prática no Colab: Bloco 1 · Exercícios 1.1 a 1.4. Dados simulados a partir da Lei de Abrams.

Regressão: resistência do concreto

Pergunta: qual a resistência (MPa) a partir do traço e da idade?







No teste: Random Forest com MAE de 2,16 MPa e R^2 de 0,96. A regressão linear erra 5,53 MPa e, com a relação água/cimento, cai para 3,10 MPa.

Dados simulados, para fins didáticos. Colab: Bloco 1 · Exercícios 1.1 a 1.4.

Como ler: (A) cada ponto é uma amostra de concreto: mais água por cimento, menos resistência, e a cor mostra a idade. (B) real × previsto no teste: quanto mais perto da diagonal, melhor. (C) a idade e o cimento são as variáveis mais usadas pelo modelo.

Produção: qualidade da peça na linha

Injeção, usinagem e montagem: achar o defeito antes da inspeção final.

Problema

Defeitos são raros (cerca de 12%); inspecionar tudo é caro e lento.

Dados

Temperatura, pressão, velocidade, umidade e desgaste da ferramenta.

Técnica

Classificação: regressão logística, árvore e Random Forest; recall e precisão.

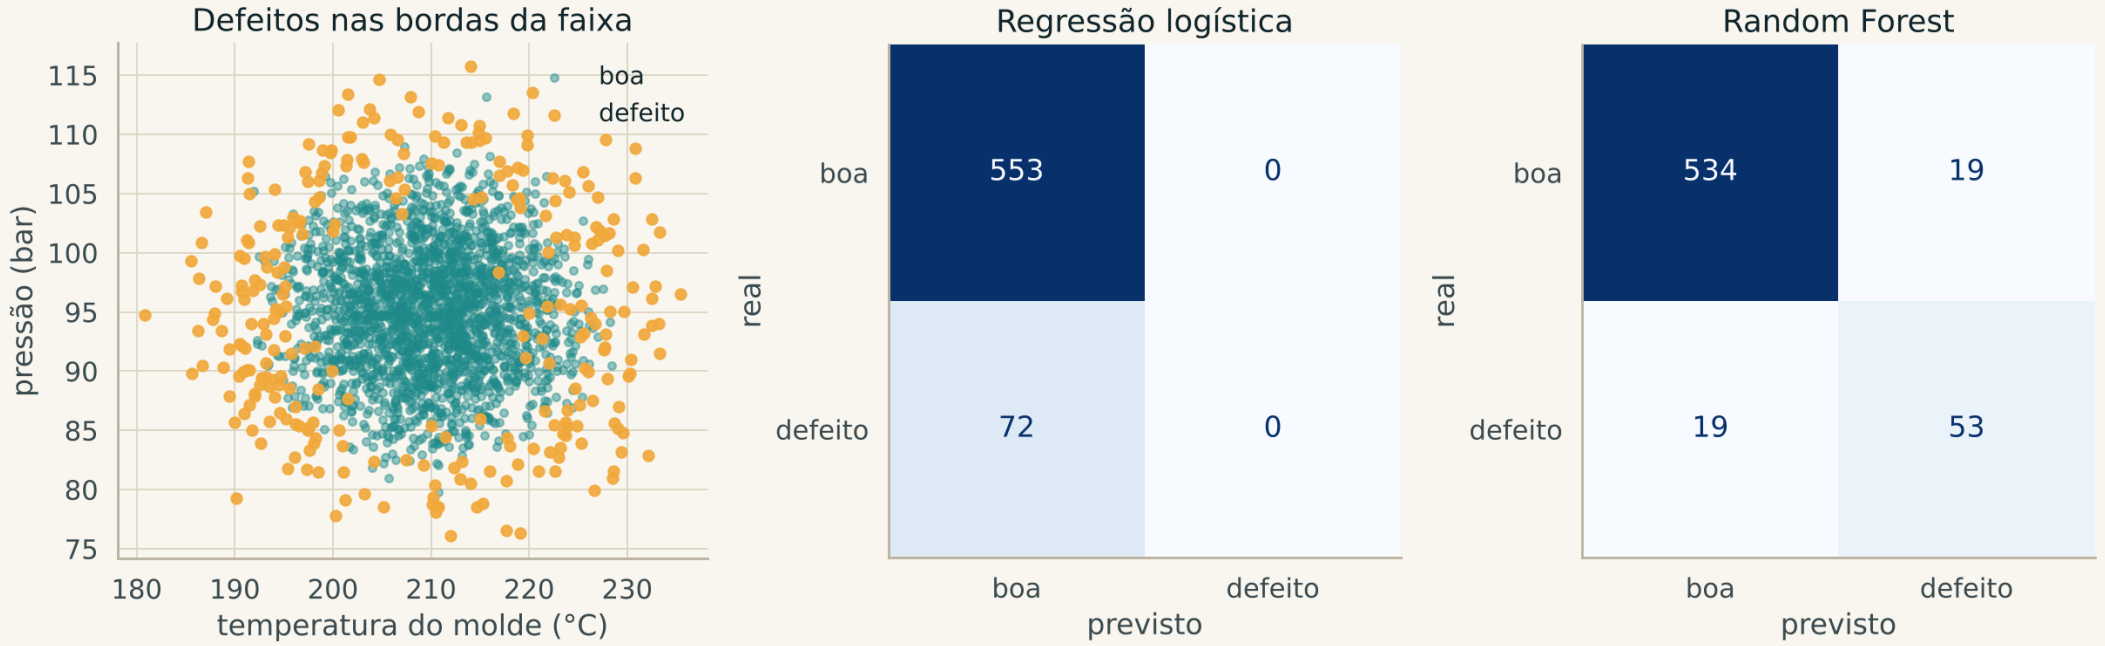
Ganho

Menos refugo e retrabalho; inspeção direcionada às peças de risco.

Cuidado: dizer 'sempre boa' acerta 88%. Por isso olhamos recall e precisão.

Classificação: peça boa ou defeituosa

Pergunta: a peça terá defeito, dados os parâmetros do processo?



Defeitos raros (11,6%): dizer 'sempre boa' acerta 88,5% e não acha nenhum defeito; o Random Forest acha 74% dos defeitos, com 74% de precisão.

Dados simulados, para fins didáticos. Colab: Bloco 2 · Exercícios 2.1 a 2.5.

Como ler: (A) cada ponto é uma peça (temperatura do molde × pressão): os defeitos (laranja) ficam nas bordas da faixa ideal. (B e C) matrizes de confusão no teste: linhas = real, colunas = previsto; a regressão logística acha 0 dos 72 defeitos, o Random Forest acha 53.

Elétrica: perfis e anomalias em motores

Motores, transformadores e painéis com sensores de corrente, vibração e temperatura.

Problema

Quase não há falhas rotuladas; como saber o que é normal e o que é anormal?

Dados

Rotação, corrente, vibração e temperatura lidas continuamente.

Técnica

Não supervisionado: k-means (perfis de operação) e Isolation Forest (anomalias).

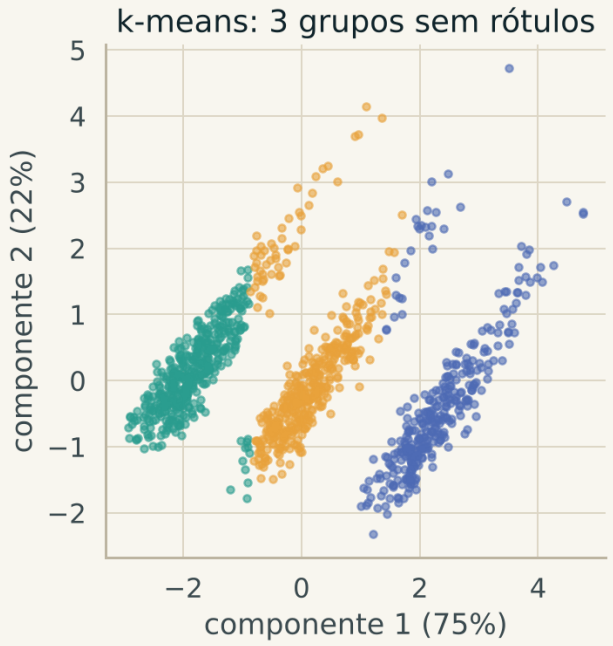
Ganho

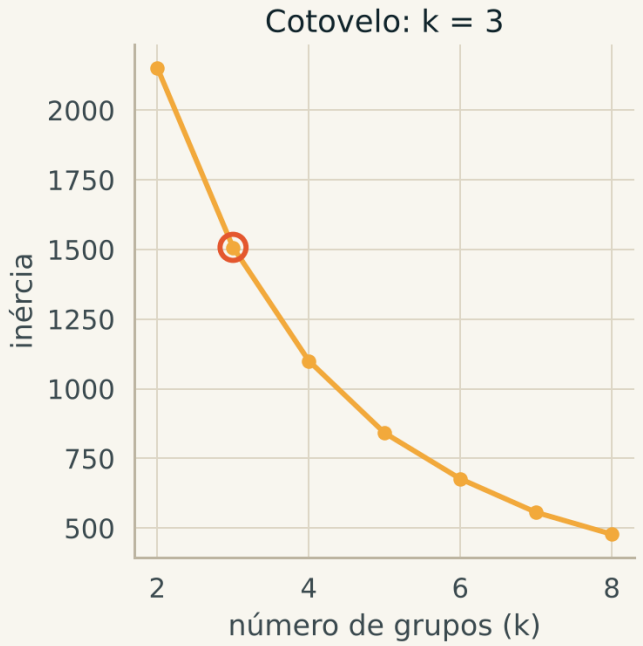
Alerta antes da falha, menos paradas e manutenção planejada (com n8n).

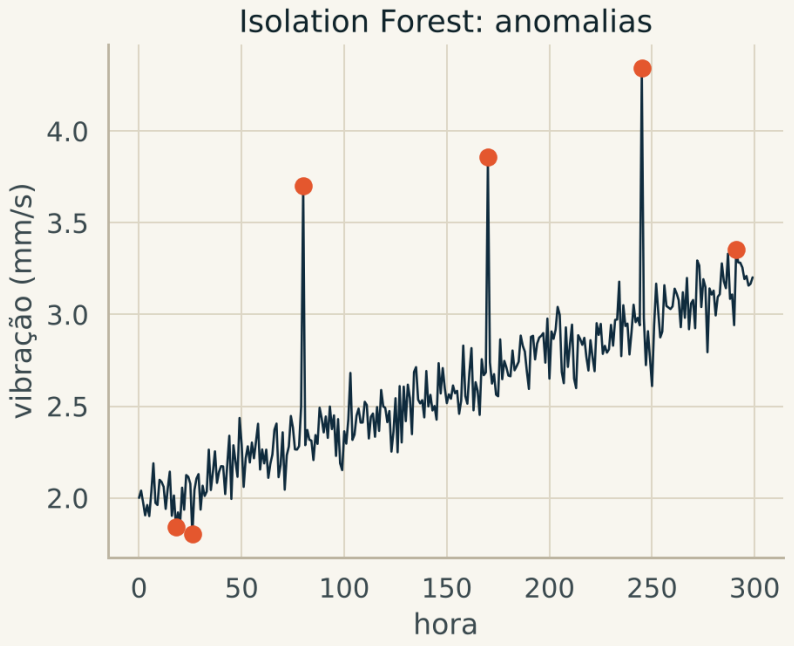
Sem rótulos, o algoritmo sinaliza e a pessoa decide.

Não supervisionado: regimes e anomalias

Pergunta: quantos regimes de operação existem e o que foge do padrão?







Sem nenhum rótulo: o k-means recuperou os 3 regimes de carga (Rand ajustado 0,79) e o Isolation Forest achou 3 de 3 anomalias, com 6 alertas no total.

Dados simulados, para fins didáticos. Cores = grupos encontrados. Colab: Bloco 3 · Exercícios 3.1 a 3.6.

Como ler: (A) leituras do motor em 2 eixos, coloridas pelo grupo do k-means (3 regimes). (B) cotovelo: a inércia cai devagar depois de k = 3. (C) vibração no tempo: pontos vermelhos são leituras fora do padrão (os 3 picos reais e 3 falsos alarmes).

Mecânica: diagnóstico de rolamentos

Bombas, ventiladores e redutores: o acelerômetro diz muito sobre a saúde da máquina.

Problema

Saber se o rolamento está saudável ou com falha, e em qual pista.

Dados

RMS, curtose, fator de crista, energias nas frequências de falha e temperatura.

Técnica

PCA para visualizar 6 variáveis em 2 eixos e SVM para classificar.

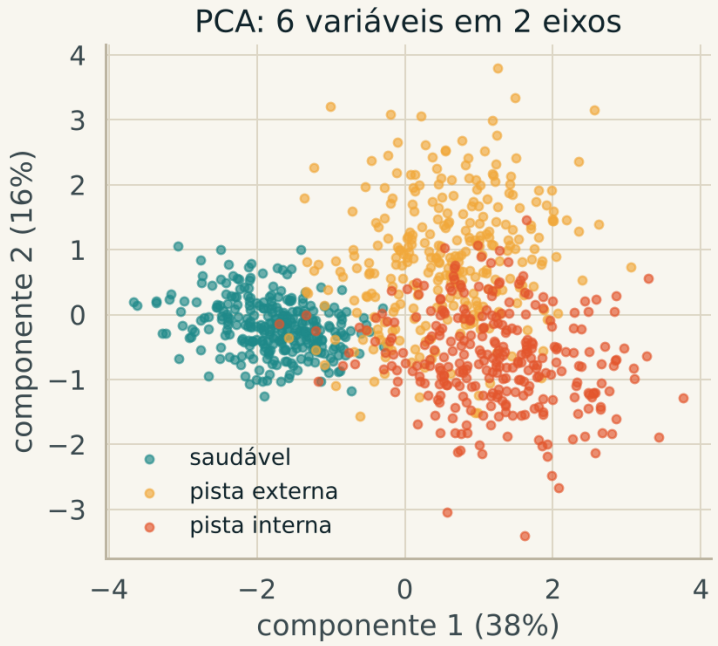
Ganho

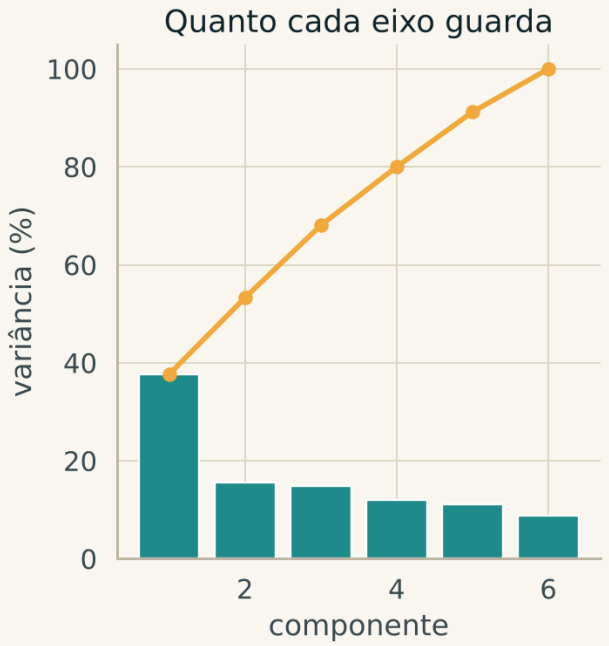
Trocar no momento certo, sem parada surpresa e sem troca antecipada.

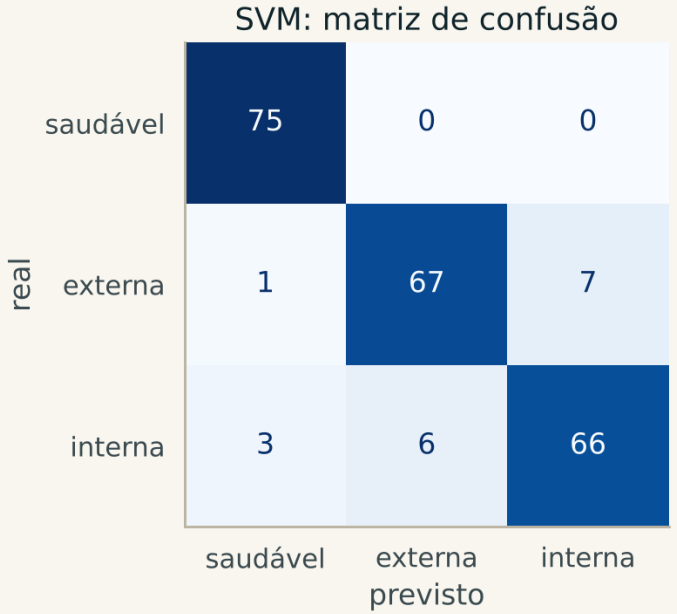
O PCA ajuda a enxergar; o classificador decide. Ajuste o PCA só com o treino.

PCA e SVM: condição do rolamento

Pergunta: qual a condição do rolamento, dadas 6 características da vibração?







6 variáveis, 3 condições: o SVM acerta 92,4% no teste. Reduzir para 2 componentes do PCA cai para 86,7%; com 3 componentes, 90,7%.

Dados simulados, para fins didáticos. Colab: Bloco 4 · Exercícios 4.1 a 4.3.

Como ler: (A) cada ponto é um rolamento em 2 eixos: o saudável (verde) se separa das falhas, que se sobrepõem um pouco. (B) barras = informação de cada componente, linha = acumulado (2 componentes guardam cerca de 53%). (C) matriz do SVM no teste: diagonal = acertos; os erros ficam entre pista externa e interna.

Química: sensor virtual com espectros

Reatores e linhas de processo com espectroscopia NIR: medir sem esperar o laboratório.

Problema

A análise de laboratório é lenta e os picos das substâncias se sobrepõem.

Dados

Espectros com 120 comprimentos de onda e a concentração medida no laboratório.

Técnica

PCA para resumir 120 variáveis e regressão sobre os componentes.

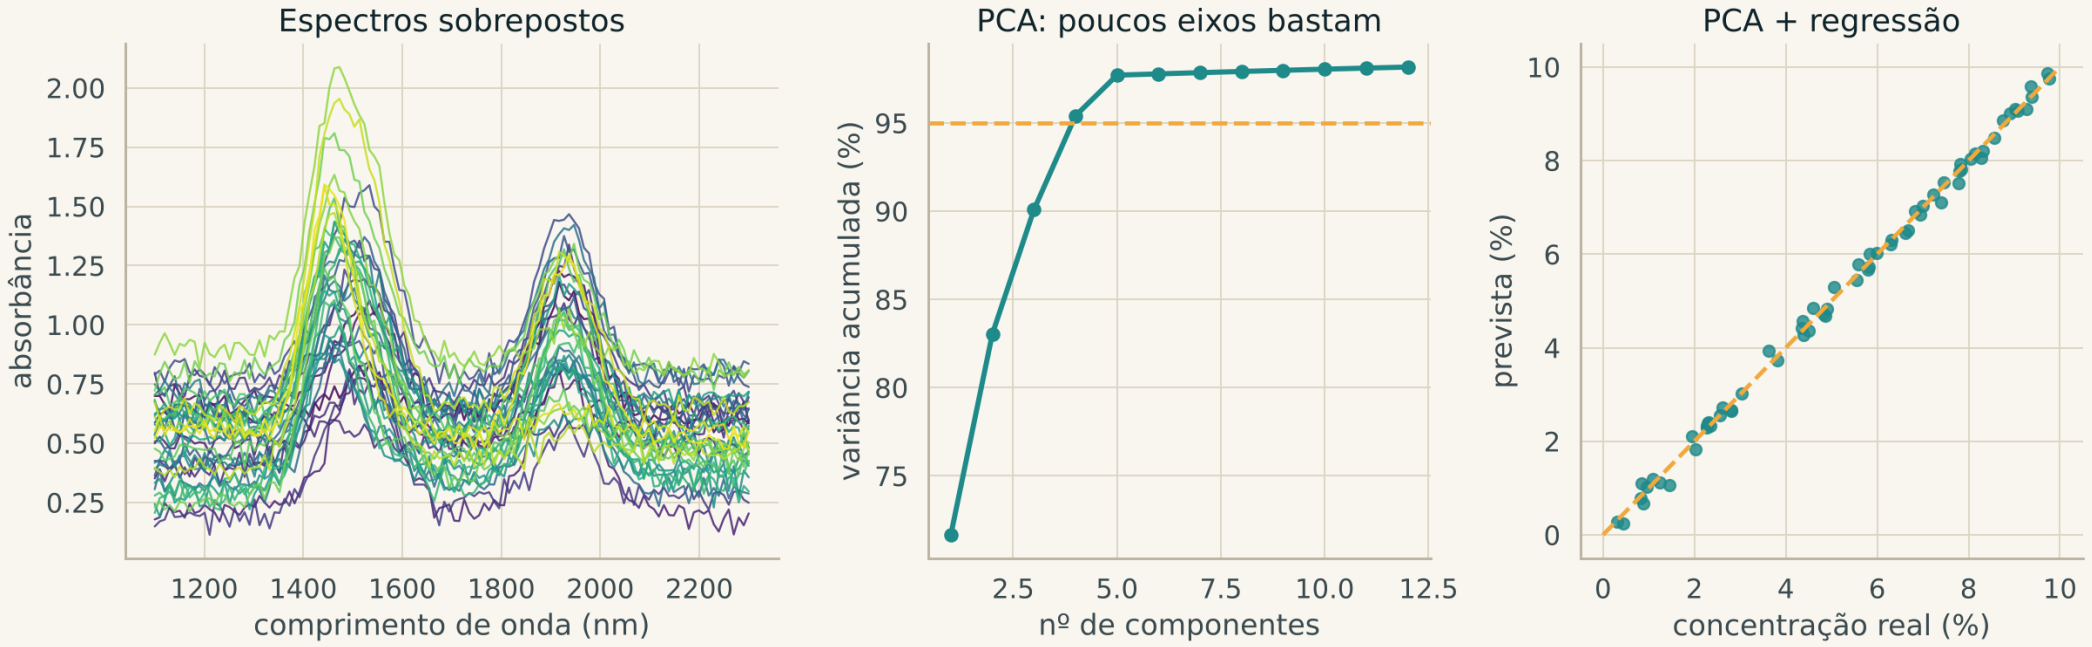
Ganho

Concentração em segundos, controle em tempo real e menos amostras de laboratório.

Mais variáveis do que amostras: reduzir antes de regredir evita o sobreajuste.

PCA + regressão: concentração por espectro

Pergunta: qual a concentração do analito A (%), dado o espectro?



120 comprimentos de onda: PCA com 5 componentes dá MAE de 0,12% e R^2 de 0,997. Com 4 componentes o erro sobe para 1,78%; o Random Forest erra 0,55%.

Dados simulados, para fins didáticos. Colab: Bloco 5 · Exercícios 5.1 a 5.3.

Como ler: (A) cada linha é o espectro de uma amostra; a cor é a concentração de A e picos mais altos indicam mais A. (B) variância acumulada: 4 componentes passam de 95% e 5 chegam a 97,8%. (C) concentração real × prevista com 5 componentes: pontos sobre a diagonal = previsão quase perfeita.

RESPONSABILIDADE

Cuidados antes de levar a IA para o mundo real

O desempenho do modelo não resolve sozinho os problemas de dados, processo e governança.

Qualidade

Dados ausentes, erros de sensor, rótulos incorretos e formatos incompatíveis.

Vazamento

Informações do teste ou do futuro não podem participar do treino.

Viés

A população, as máquinas ou as condições reais podem diferir dos dados usados.

Validação

Testar em dados independentes e monitorar mudanças ao longo do tempo.

Privacidade

Minimizar dados pessoais, proteger acessos e respeitar regras aplicáveis.

Supervisão

Definir quem interpreta, decide e responde pelos resultados.

DESAFIOS · NA MINHA PRÁTICA

O que aprendi ao implementar

Dados mandam no cronograma

Arquivos grandes, nomes conflitantes e formatos diferentes tomam tempo de qualquer modelo.

Validar antes de prometer

Coortes externas mostram o que o modelo aprendeu de verdade.

Pipeline reproduzível

Scripts em sequência e documentação permitem que outra pessoa repita o resultado.

Privacidade desde o início

De-identificar na entrada é mais barato e mais seguro do que corrigir depois.

CONCLUSÃO

Fechamento: o algoritmo é só uma parte da solução

O valor vem de combinar conhecimento do domínio, dados de qualidade, avaliação e implementação.

PROBLEMA	DADOS	MODELO	VALIDAÇÃO	IMPACTO
relevante	confiáveis	adequado	independente	medido

“A engenharia me ensinou a resolver problemas. A inteligência artificial ampliou as possibilidades. E a oncologia me mostrou como essas ferramentas podem contribuir para a vida das pessoas.”

Perguntas e discussão

CONCLUSÃO

A IA amplia o conhecimento humano.

Em qualquer engenharia, três coisas sustentam um projeto de IA:

1

Dados bem preparados

Sem bons dados, nenhum modelo se sustenta.

2

Validação rigorosa

Testar e confirmar em dados externos antes de confiar.

3

Pessoas no centro

A decisão final é de quem conhece o problema: engenheiro, técnico e usuário.

A IA não substitui o profissional.
Ela amplia quem sabe aplicá-la com método e responsabilidade.

PRÓXIMOS PASSOS

Como continuar depois do curso

Quatro hábitos para quem quer entrar na pesquisa com IA.

1 APRENDER

Python e scikit-learn

2 PRATICAR

Dados públicos e projetos pequenos

3 CONECTAR

Colegas de outras áreas

4 PESQUISAR

Iniciação científica e pós-graduação

Engenharia é bem mais que engenharia: é método para resolver problemas que importam.

Dados abertos para praticar: Kaggle, UCI Machine Learning Repository e dados abertos da sua área.

Referências e recursos para continuar

Consulte documentação oficial e use os notebooks como ponto de partida.

- Google Colab — https://colab.research.google.com/
- scikit-learn — https://scikit-learn.org/stable/
- Supervised learning — https://scikit-learn.org/stable/supervised_learning.html
- Clustering — https://scikit-learn.org/stable/modules/clustering.html
- PCA — https://scikit-learn.org/stable/modules/decomposition.html#pca
- Notebook e slides do curso — repositório no GitHub (link da ministrante)

Antes de divulgar, revise links, biografia, tempo disponível e permissões de uso dos materiais.

Perguntas e conversa



Baixar os arquivos

Currículo Lattes

LinkedIn

E-mail: patriciapedrosoestevam@gmail.com

ANEXO

Referências

Ribeiro P. P. E. Aplicação de técnicas de processamento de imagens para diferenciação do greening de outras pragas. Dissertação, EESC-USP (2014).

Ribeiro P. P. E.; Paiva M. S. V.; Jorge L. A. C. Application of texture analysis for differentiation of the greening from others pests. X WVC (2014).

Ribeiro P. P. E.; Jorge L. A. C.; Paiva M. S. V. Diferenciação do greening de outras doenças foliares em citros. Avanços em Visão Computacional, cap. 8 (2012).

Silva D. C. P.; Ribeiro P. P. E. et al. Extração de características para geração de um classificador para detecção precoce do HLB em citros. VI WVC.

Ribeiro P. P. E.; Righetto A. J. Análise computacional de genes metilados para classificar risco em pacientes com câncer cervical e HPV. TCC, MBA USP/ESALQ (2024).

Da Q. et al. Computational pathology in the era of emerging foundation and agentic AI. arXiv:2603.05884 (2026).

World Economic Forum. Future of Jobs Report 2025 (2025).

PwC. Barômetro de Empregos de IA 2026, edição Brasil, via Movimento Econômico (30/09/2026).

Afya. ASCO 2026: aplicações clínicas da IA na oncologia (31/05/2026).

Ismail L. et al. Digital twin-driven predictive maintenance in industrial engineering. arXiv:2509.24443 (2025).

IEEE Computer Society. IoT, edge, and digital twins: the new playbook for maintenance (2026).

KaaloT. Top 5 industrial automation trends for 2026 (12/05/2026).

IBA. AI and digital health in Brazil: balancing innovation and regulation (2025).

CI-IA Saúde (UFMG). Boletim de março de 2026: Resolução CFM nº 2.454/2026 e PreemieTest.

Futuro da Saúde; Estratégia Med; Congresso em Foco: regulação e políticas de IA em saúde no Brasil (2025–2026).

ANEXO

Referências (continuação)

Stack Overflow. 2025 Developer Survey: AI (2025).

Siemens. Siemens lança no Brasil o Eigen Engineering Agent (30/09/2026).

Tesla. Documentação oficial sobre câmeras e assistência à condução (Tesla Vision / FSD Supervised).

Karpathy A. (Tesla). Keynote do workshop de veículos autônomos, CVPR 2021, via InsideEVs (2021).

TechCrunch. Tesla is no longer using radar sensors in Model 3 and Model Y built in North America (25/05/2021).

Jumper J. et al. Protein structure prediction with AlphaFold. Nature 596:583–589 (2021).
Perez M. V. et al. Smartwatch to identify atrial fibrillation. N Engl J Med 381:1909–1917 (2019).

TOMRA Food. LUCAi: classificação de frutas com inteligência artificial (aplicação comercial).

Mercado Livre. Página oficial de tecnologia, logística e armazenagem.

Canaltech. Mercado Livre introduz nova geração de robôs para reforçar operação logística (24/09/2025).

Istoé Dinheiro. Mercado Livre usa robôs de separação (25/09/2025).

Abràmoff M. D. et al. Autonomous AI for diabetic retinopathy (IDx-DR). npj Digit Med 1:39 (2018).
McKinney S. M. et al. AI system for breast cancer screening. Nature 577:89–94 (2020).